

INFO-F205 — Calcul Formel et Numérique

Syllabus d'exercices

Exercices initiaux de Maarten Jansen et Gianluca Bontempi
Corrections initiales par Keno Merckx et Arnaud Pollaris
Adaptation des énoncés et corrections et mise en page par Robin Petit

Année académique 2024-2025
Version du 9 février 2026

Table des matières

1	Introduction à Matlab/Octave	2
2	Représentation à virgule fixe et virgule flottante	10
2.1	Virgule fixe	11
2.2	Virgule flottante	11
3	Conditionnement et arithmétique tronquée	15
3.1	Conditionnement	18
3.2	Erreur d'annulation	20
3.3	Erreur de génération	20
4	Manipulation de nombres à virgule flottante en Matlab	22
5	Introduction à la résolution de systèmes linéaires	26
6	Résolution de systèmes linéaires par factorisation	34
7	Équations différentielles ordinaires	43
8	Interpolation	49
8.1	Interpolation de Lagrange	52
8.2	Interpolation de Newton	54
9	Interpolation (partie 2)	57
10	Résolution d'équations non-linéaires	65
11	Résolution d'équations non-linéaires par itération de point fixe	70

Séance 1 — Introduction à Matlab/Octave

Rappel théorique

Pour MATLAB (dont le nom vient de *MATrix LABoratory*), l'élément central pour les opérations est la matrice (ce qui comporte les vecteurs comme cas particuliers). La déclaration d'un vecteur se fait via les crochets :

```
x = [x1, x2, ...]
```

Les virgules pour séparer les éléments sont facultatives. L'instruction suivante est donc équivalente à la précédente :

```
x = [x1 x2 ...]
```

Une matrice se déclare comme une suite de vecteurs séparés par un point virgule. La matrice identité 2×2 peut donc se définir comme ceci :

```
I2 = [1 0; 0 1]
```

La notation `beg:end` (ou de manière plus générale `beg:step:end`) génère un vecteur contenant toutes les valeurs de la forme `beg + t*step` pour `t` entre 0 et $\lfloor (\text{end}-\text{beg})/\text{step} \rfloor$.

MATLAB propose toute une série de fonctions préexistantes (e.g. `sin`, `cos`, `exp`, `log`, `abs`, ...) qui peuvent être appelées tant sur des nombres que sur des matrices (et donc des vecteurs) en quel cas l'opération est effectuée individuellement sur chaque entrée de la matrice. Notez que `log(M)` ne calcule pas le log matriciel, il faut utiliser la fonction `logm` pour cela.

Il existe également des fonctions servant à générer des matrices dont `eye` qui génère la matrice identité (ou tout du moins une sous-matrice d'une matrice identité), `zeros` et `ones` qui génèrent respectivement une matrice ne contenant que des 0 ou que des 1, etc. Si un unique paramètre est donné à ces fonctions, alors elles renverront une matrice carrée dont la dimension correspond à ce paramètre. Si par contre plusieurs paramètres entiers sont donnés, alors la *matrice* (ou plus généralement le tableau de matrices) renvoyée aura les dimensions demandées.

Les dimensions d'une matrice peuvent être récupérées via la fonction `size` qui renvoie un vecteur dont les composantes correspondent aux dimensions. La fonction `length` quant à elle renvoie la plus grande des dimensions. La transposée d'une matrice (ou d'un vecteur) se fait via l'apostrophe.

```
>> A = zeros(2, 3)
A =
    0    0    0
    0    0    0
>> size(A)
ans =
     2     3
>> length(A)
```

```
ans = 3
>> A'
ans =
    0    0
    0    0
    0    0
```

Puisque MATLAB est prévu pour manipuler des matrices (et des vecteurs), les opérations usuelles sont celles définies sur les matrices. En particulier, si A et B sont deux matrices carrées, l'instruction $C = A*B$ va prendre le *produit matriciel* entre A et B et si c'est le produit de Hadamard qui est voulu (donc le *produit composante par composante*), il faut utiliser l'instruction $C = A .* B$. Nous pouvons mettre cela en lumière en ayant A la matrice identité $n \times n$ et B la matrice $n \times n$ ne contenant que des 1. La première est l'identité pour le produit matriciel alors que la seconde est l'identité pour le produit de Hadamard. Dès lors $A*B$ devrait donner B alors que $A .* B$ devrait donner A .

```
>> A = eye(2);
>> B = ones(2);
>> isequal(A * B, B)
ans = 1
>> isequal(A .* B, A)
ans = 1
```

De manière plus générale, précéder les opérateurs d'un point permet d'en utiliser la version *component-wise*. Remarquez qu'ici un point-virgule a été placé après les définitions de A et B . Cela permet de ne pas afficher le résultat de l'instruction. De plus, la fonction `isequal` est utilisée ici pour déterminer l'égalité entre plusieurs matrices (ou vecteurs). Cette fonction peut être appelée avec plus de deux paramètres et renvoie 1 si et seulement si toutes les matrices reçues ont les mêmes dimensions et les mêmes entrées aux mêmes indices.

Indicer une matrice (ou un vecteur) se fait avec des parenthèses (contrairement à la plupart des autres langages qui utilisent des crochets), et attention la première position correspond à l'indice 1 (et non 0)! Si $x = [1 \ 2 \ 3]$, alors $x(1)$ est 1 et $x(3)$ est 3. MATLAB permet un indigage un peu plus *fancy* : il est possible d'indicer une matrice avec un tableau afin de choisir les lignes (ou colonnes) à extraire. En particulier, puisque la notation `beg:end` (qui correspond à `beg:1:end`) crée un vecteur contenant toutes les valeurs entières entre `beg` et `end` avec un pas de 1, la notation $x(a:b)$ permet donc d'extraire un sous-vecteur de x en ne prenant que les indices entre a et b . Notons que le mot-clef `end` de MATLAB peut également servir lors de l'indigage : $x(2:end-1)$ permet par exemple de prendre tous les éléments du vecteur x sauf le premier et le dernier.

Exercice 1.1. Démarrez MATLAB (ou OCTAVE). Dans la fenêtre de commande, tapez $x = -1:0.1:1$ et ensuite, exécutez chacune des commandes suivantes :

```
sqrt(x)
sin(x)
x.^3
```

```
plot(x, cos(x .^ 2))
plot(x, sin(x .^ 3))
```

Exécutez les commandes suivantes et expliquez les résultats :

```
x = [2 3 4 5]
y = -1:1:2
x .^ y
x .* y
x ./ y
```

Résolution. Vous pouvez observer ici que `.^` sert bien à mettre chaque élément du vecteur individuellement au cube et que si vous tentez `x ^ 3`, vous aurez une erreur de la part de MATLAB. Le reste des instructions est assez clair : `sqrt(x)` prend la racine carrée de chaque élément, `sin(x)` prend le sinus, etc.

Pour le second point, notez que `y = [-1 0 1 2]` et donc en particulier `y(2) == 0`. Dès lors le deuxième élément de `x ./ y` vaut ici `Inf`.

Exercice 1.2. Initialisez la matrice `A = [1 5 8; 84 81 7; 12 34 71]` et examinez le contenu de :

- `A(1,1)`;
- `A(2,1)`;
- `A(1,2)`;
- `A(3,3)`;
- `A(1:2,:)`;
- `A(:,1)`;
- `A(3,:)`;
- `A(:,2:3)`;
- `A(1:end,:)`.

Que produisent les commandes suivantes :

```
x = 1:1:10
z = rand(10)
y = [z; x]
c = rand(4)
e = [c eye(size(c)); eye(size(c)) ones(size(c))];
d = sqrt(c)
t1 = d*d
t2 = d .* d
```

Résolution. `A(i,j)` donne l'élément à la *i*ème ligne et la *j*ème colonne. Dès lors `A(1,1)` est l'élément dans le coin supérieur gauche, etc. `A(1:2,:)` prend uniquement les lignes dans 1:2 (à savoir les lignes 1 et 2) et toutes les colonnes. `A(1:end,:)` prend tous les éléments de `A`.

Pour la seconde partie, notez que la fonction `rand` renvoie une matrice de nombres pris uniformément dans l'intervalle ouvert $(0, 1)$ dont les dimensions correspondent aux paramètres d'appel. Dès lors `z` est une matrice 10×10 . `y` est quant à lui une matrice de 11 lignes et 10 colonnes puisque `x` est une matrice de dimension 1×10 qui est ajoutée *en-dessous* de `z` pour former `y` (notez bien le point-virgule dans la définition).

`c` est une matrice 4×4 d'éléments pris uniformément dans l'intervalle ouvert $(0, 1)$, donc `size(c)` renvoie un vecteur ligne (donc une matrice 1×2) dont les deux composantes

valent 4. e est donc une matrice définie par bloc et ressemblant à ceci :

$$\begin{bmatrix} c_{11} & c_{12} & c_{13} & c_{14} & 1 & 0 & 0 & 0 \\ c_{21} & c_{22} & c_{23} & c_{24} & 0 & 1 & 0 & 0 \\ c_{31} & c_{32} & c_{33} & c_{34} & 0 & 0 & 1 & 0 \\ c_{41} & c_{42} & c_{43} & c_{44} & 0 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 1 & 1 & 1 & 1 \\ 0 & 1 & 0 & 0 & 1 & 1 & 1 & 1 \\ 0 & 0 & 1 & 0 & 1 & 1 & 1 & 1 \\ 0 & 0 & 0 & 1 & 1 & 1 & 1 & 1 \end{bmatrix}$$

Exercice 1.3. Initialisez une matrice A de dimension 4×4 . Étant donné que la fonction `sum` donne la somme des éléments d'un vecteur donné en paramètre, utilisez la fonction `sum` pour trouver la somme des éléments de la première ligne et de la deuxième colonne. Attention à ne compter qu'une seule fois chaque élément !

Résolution. Voici deux solutions possibles :

```
sum(A(:,1)) + sum(A(1,:)) - A(1,1)
sum(A(2:end,1)) + sum(1,:)
```

Exercice 1.4. Soient les trois matrices suivantes :

$$A = \begin{bmatrix} 2 & -3 \\ 4 & 1 \end{bmatrix} \quad B = \begin{bmatrix} 44 & 101 \\ -18 & -41 \end{bmatrix} \quad C = \begin{bmatrix} 1 & 2 \\ -2 & -5 \end{bmatrix}$$

À l'aide de MATLAB, calculez $C^{-1}AC$. Que pouvez-vous en déduire ?

Résolution. Pour déterminer l'inverse d'une matrice, il faut utiliser la fonction `inv` :

```
>> A = [2 -3; 4 1];
>> B = [44 101; -18 -41];
>> C = [1 2; -2 -5];
>> D = inv(C) * A * C
D =
    44    101
   -18   -41
>> isequal(B, D)
ans = 1
```

Donc $B = C^{-1}AC$.

Exercice 1.5. Écrivez un script qui prend en paramètre deux matrices carrées A et B et qui les additionne, les soustrait et les multiplie. Commentez votre script et utilisez la fonction `disp` pour l'affichage.

Résolution.

```
1 function ex5(A, B)
2     disp('Somme :');
```

```

3  C = A+B;
4  disp(C);
5  disp('Différence :');
6  A-B
7  disp('Produit :');
8  A*B
9  end

```

Exercice 1.6. Écrivez un script qui dessine les deux fonctions $f_1(x) = x^2 \cos x$ et $f_2(x) = x^2 \sin x$ sur la même figure. Prenez $x = -2:0.1:2$.

Résolution. Par défaut, chaque nouvel appel à la fonction `plot` efface la figure actuelle et recommence à partir de rien. Pour conserver ce qui a été dessiné sur la figure jusqu'à présent, il faut utiliser l'instruction `hold` :

```

1  x = -2:0.1:2;
2  y1 = x.^2.*cos(x);
3  y2 = x.^2.*sin(x);
4  plot(x, y1);
5  hold;
6  plot(x, y2);

```

Exercice 1.7. L'équation itérative suivante permet de résoudre l'équation $x^2 - x - 1 = 0$:

$$x_{t+1} = 1 + \frac{1}{x_t}$$

pour $t \geq 0$, où $x_0 = 2$. Écrivez un script MATLAB qui implémente ceci à précision ε choisie. Testez votre programme pour $\varepsilon = 5 \times 10^{-4}$.

Résolution.

```

1  function phi = ex7(precision)
2  xprev = 0;
3  xcurr = 2;
4  while abs(xcurr - xprev) >= precision
5      xprev = xcurr;
6      xcurr = 1 + 1./xcurr;
7  end
8  phi = xcurr
9  disp(phi*phi - phi - 1); % devrait être proche de 0
10 end

```

Exercice 1.8. Étant donné A , une matrice de dimension 4×5 , écrivez un script pour trouver la somme de chacune des colonnes en utilisant (i) une boucle `for` et (ii) la fonction `sum`.

Résolution.

```

1 function [colsum1, colsum2] = ex8(A)
2     [rows, cols] = size(A);
3     colsum1 = [];
4     for colidx=1:cols
5         tmp = 0;
6         for rowidx=1:rows
7             tmp = tmp+A(rowidx,colidx);
8         end
9         colsum1 = [colsum1 tmp];
10    end
11    colsum2 = sum(A, 1); % sum(A, 2) for sum of rows

```

Exercice 1.9. Soit x un vecteur de n éléments. Écrivez un script MATLAB pour déterminer le produit

$$P_k = \prod_{i \neq k} x_i = x_1 x_2 \dots x_{k-1} x_{k+1} \dots x_{n-1} x_n.$$

Testez votre script avec des valeurs extrêmes de x et de n .

Résolution.

```

1 function product = ex9(x, k)
2     [rows, cols] = size(x);
3     if(rows > 1)
4         disp('x is not a vector');
5     elseif(k < 1 || k > cols)
6         disp('Incorrect value of k');
7     else
8         product = 1.;
9         for i=1:cols
10            if(i != k)
11                product = product * x(1,i);
12            end
13        end
14    end

```

Notons que nous pouvons également utiliser la fonction `prod` de MATLAB qui, de manière similaire à `sum`, retourne le produit du vecteur passé en paramètre afin d'avoir le produit de toutes les entrées. Or nous savons que $x_k P_k = \prod_{i=1}^n x_i$, donc nous pouvons simplement diviser par x_k . Il faut tout de même que $x_k \neq 0$ pour cela :

```

1 function product = ex9v2(x, k)
2     if(x(1,k) != 0)
3         product = prod(x) / x(1,k);
4     else
5         product = ex9(x, k);
6     end

```

Exercice 1.10. Écrivez un script qui génère une matrice dont les éléments le long de la diagonale valent d et les coefficients directement au-dessus et en-dessous de cette diagonale valent c . Le reste des entrées doit être égal à 0.

Résolution. Utilisons la fonction `diag` qui fonctionne de la manière suivante :

- `diag(A)` pour une matrice A renvoie un vecteur (colonne) contenant tous les éléments de la diagonale;
- `diag(v)` pour un vecteur v renvoie une matrice ayant le vecteur v pour diagonale et des 0 partout ailleurs (en particulier `diag(diag(v))` est égal à v);
- `diag(v, k)` pour un vecteur v et un entier k renvoie une matrice ayant v pour k ème diagonale (à savoir les entrées (i, j) pour lesquelles $j-i$ vaut k) et avec des 0 partout ailleurs.

```

1 function A = ex10(n, a, b)
2     subdiag = ones(n-1, 1);
3     upper_diag = diag(subdiag, 1);
4     lower_diag = diag(subdiag, -1);
5     around_diags = lower_diag + upper_diag;
6     main_diag = diag(ones(n, 1));
7     A = a * main_diag + b * around_diags;

```

Une version plus explicite peut s'écrire comme ceci :

```

1 function A = ex10_explicit(n, a, b)
2     A = zeros(n);
3     for i=1:n
4         for j=1:n
5             if(i == j)
6                 A(i,j) = a;
7             elseif(abs(i-j) == 1)
8                 A(i,j) = b;
9             end
10        end
11    end

```

Exercice 1.11. Écrivez une fonction MATLAB pour résoudre l'équation suivante :

$$ax^2 + bx + c = 0.$$

La fonction doit prendre en entrée les paramètres a , b et c et renvoyer les valeurs des deux racines

Résolution.

```
1 function [x1, x2] = ex11(a, b, c)
2   if(a == 0)
3     disp('a cannot be 0');
4   else
5     D = b*b - 4*a*c;
6     x1 = (-b + sqrt(D)) / (2*a);
7     x2 = (-b - sqrt(D)) / (2*a);
8   end
```

Exercice 1.12. En sachant que la série suivante :

$$\sum_{k \geq 0} A^k = I + A + A^2 + A^3 + \dots$$

converge vers $(I - A)^{-1}$ si les valeurs propres de la matrice A sont bornées par 1 en valeur absolue. La matrice suivante (de dimension $n \times n$) satisfait cette condition si $a + 2b < 1$:

$$\begin{bmatrix} a & b & 0 & \dots & 0 & 0 & 0 \\ b & a & b & \dots & 0 & 0 & 0 \\ 0 & b & a & \dots & 0 & 0 & 0 \\ \vdots & & & \ddots & & & \vdots \\ 0 & 0 & 0 & \dots & a & b & 0 \\ 0 & 0 & 0 & \dots & b & a & b \\ 0 & 0 & 0 & \dots & 0 & b & a \end{bmatrix}$$

Expérimentez avec cette matrice pour différentes valeurs de a , b et n pour illustrer que cette série converge sous la condition annoncée.

Résolution.

```
1 function inverse = ex12(n, a, b)
2   A = ex10(n, a, b);
3   Apow = A;
4   inverse = eye(n);
5   for k=1:100
6     inverse = inverse + Apow;
7     new_Apow = Apow*A;
8     disp('||A^k - A^(k-1)||_inf:');
9     disp(max(abs(new_Apow-Apow)(:)));
10    Apow = new_Apow;
11  end
12  disp('||(sol * (I-A)) - I||_inf:');
13  disp(max(abs(inverse * (eye(n)-A) - eye(n))(:)));
```

Séance 2 — Représentation à virgule fixe et virgule flottante

Rappel théorique

Dans ce qui suit, nous devons toujours travailler dans une base b fixée (typiquement $b = 2$ dans un ordinateur ou $b = 10$ lorsque nous raisonnons sur papier).

La représentation à *virgule fixe* consiste à se fixer une base $b \geq 2$, un signe $s \in \{0, 1\}$ (où $s = 0$ désigne qu'un nombre est positif et $s = 1$ désigne qu'un nombre est négatif) et $n + m + 1$ chiffres (en base b toujours) dont les $n + 1$ premiers sont utilisés pour représenter la partie entière d'un nombre et les m suivants sont utilisés pour représenter la partie décimale, i.e. :

$$x = ([x_n, x_{n-1}, \dots, x_1, x_0, x_{-1}, \dots, x_{-m}], b, s),$$

où les x_k sont entre 0 et $b - 1$ (donc des chiffres en base b). Cette représentation représente le nombre :

$$x = (-1)^s \sum_{k=-m}^n x_k \cdot b^k.$$

Attention, nous identifions ici la représentation et la valeur du nombre représenté.

Travailler en virgule fixe correspond en réalité à travailler uniquement sur des entiers sur $m + 1 + n$ chiffres, mais de les interpréter $\times b^{-m}$.

Cependant, en fonction du contexte, on pourrait vouloir avoir plus de précision pour la partie entière ou plus de précision pour la partie décimale, ce qui n'est pas possible.

La *virgule flottante* cherche à contourner ce problème en travaillant sur une *mantisse* de taille t fixée, mais également avec un exposant e (généralisant la notation scientifique). Le nombre à virgule flottante suivant

$$x = ([x_1, \dots, x_t], e, b, s)$$

est donc à interpréter comme le nombre réel suivant

$$x = (-1)^s m b^{e-t} = (-1)^s \sum_{k=1}^t x_k b^{e-k}.$$

Attention, nous imposons à nouveau ici $s \in \{0, 1\}$, $b \geq 2$, $e \in \mathbb{Z}$ (en effet cet exposant peut très bien être négatif), mais également $1 \leq x_1 \leq b - 1$ et $0 \leq x_k \leq b - 1$ pour $k \geq 2$. En particulier x_1 ne peut pas être nul (ce qui garantit l'unicité de la représentation d'un nombre sous cette forme).

À base b fixée, pour t, L, U des entiers tels que $L \leq U$, nous définissons l'ensemble $\mathbb{F}(b, t, L, U)$ comme l'ensemble contenant tous les réels $x \in \mathbb{R}$ qui admettent une représentation à virgule flottante avec (i) une mantisse de taille t ; (ii) la base b ; et (iii) $L \leq e \leq U$.

Notons qu'il est possible de montrer que $|\mathbb{F}(b, t, L, U)| = 2(U - L + 1)(b - 1)b^{t-1}$. En effet, dans la représentation $([x_1, \dots, x_t], e, b, s)$ peut prendre :

- 2 valeurs pour s (à savoir 0, 1) ;

- $U - L + 1$ valeurs pour e (à savoir $L, L + 1, \dots, U - 1, U$);
- $b - 1$ valeurs pour x_1 (à savoir $1, 2, \dots, b - 1$);
- et b valeurs pour chacun des x_k pour $2 \leq k \leq t$ (à savoir $0, 1, \dots, b - 1$).

Le produit de ces différentes entrées vaut bien $2(U - L + 1)(b - 1)b^{t-1}$.

Notons tout de même que le fait d'imposer $x_1 \neq 0$ nous empêche de représenter 0 en virgule flottante. Nous appelons ces représentations sous *forme normalisée*. Évidemment, en pratique, la possibilité de tout de même mettre x_1 à 0 permet de représenter des *valeurs spéciales*, e.g. la valeur 0, mais également $\pm\infty$, ou encore NaN.

2.1 Virgule fixe

■ **Exercice 2.1.** Si $b = 10, n = 3, m = 6$ et $s = 0$, à quel nombre correspond $[0012200000]$?

Résolution. Puisque $n = 3$, nous savons que les 4 premiers chiffres représentent la partie entière, et les 6 derniers représentent la partie fractionnaire. De plus $s = 0$, donc le nombre considéré est positif. Dès lors il correspond à $0012.200000 = 12.2$, ou encore :

$$1 \times 10^1 + 2 \times 10^0 + 2 \times 10^{-1} = 10 + 2 + 0.2 = 12.2$$

■ **Exercice 2.2.** Même question si $b = 3$?

Résolution. Si $b = 3$, alors ce nombre correspond à :

$$1 \times 3^1 + 2 \times 3^0 + 2 \times 3^{-1} = 3 + 2 + \frac{2}{3} = 5 + \frac{2}{3} = \frac{17}{3}.$$

■ **Exercice 2.3.** Si $b = 3, n = 3, m = 6$ et $s = 0$, à quel nombre correspond $[3012200000]$?

Résolution. Puisque nous travaillons en base $b = 3$, tous les chiffres doivent être entre 0 et $b - 1 = 3 - 1 = 2$. Or le premier chiffre donné est 3, la représentation n'est donc pas valide.

2.2 Virgule flottante

■ **Exercice 2.4.** A quels nombres correspondent :

- $([34], e = 2, b = 10, s = 0)$;
- $([34], e = 1, b = 16, s = 1)$;
- $([10001], e = 6, b = 2, s = 0)$?

Résolution.

$$(-1)^0 \times (3 \times 10^1 + 4 \times 10^0) \times 10^{2-2} = 30 + 4 = 34.$$

$$(-1)^1 \times (3 \times 16^1 + 4 \times 16^0) \times 16^{1-2} = -(48 + 4) \times 16^{-1} = -\frac{52}{16} = -\frac{13}{4}.$$

$$(-1)^0 \times (2^4 + 2^0) \times 2^{6-5} = 17 \times 2^1 = 34.$$

Exercice 2.5. Représentez le nombre 234.5 en virgule flottante avec $b = 2$ et les autres paramètres suffisamment grands.

Résolution. Notons que $234.5 = 234 + \frac{1}{2}$. Dès lors tant la partie entière que la partie fractionnaire sont aisément représentables en binaire. En effet, la partie entière 234 peut s'écrire 11101010. Dès lors $(234.5)_{10} = (11101010.1)_2$, et donc en virgule flottante :

- la mantisse est donnée par [111010101];
- donc $t = 9$;
- le signe est $s = 0$ puisque $234.5 > 0$;
- la base est $b = 2$;
- et l'exposant e peut être trouvé via la formule :

$$e = 9 + \log_2 \frac{234.5}{(-1)^0 \times 469} = 9 + \log_2 \frac{1}{2} = 9 - 1 = 8.$$

Afin de trouver e , notez que nous partons de l'expression (où m est à interpréter comme un nombre entier) :

$$x = (-1)^s m b^{e-t}.$$

Dès lors :

$$b^{e-t} = \frac{x}{(-1)^s m},$$

et finalement :

$$e - t = \log_b \frac{x}{(-1)^s m}.$$

Il ne reste plus qu'à ajouter t des deux côtés pour obtenir la forme générale :

$$e = t + \log_b \frac{x}{(-1)^s m} = t + \log_b \frac{|x|}{m}.$$

Remarque. Notons également que l'exposant e peut, en un sens, être vu comme le nombre de chiffres (de la mantisse) à lire avant de placer la séparation décimale. En effet, si $e = t$, alors c'est que la mantisse donne en réalité un nombre entier. Ici, nous voulons que, parmi les 9 bits, il n'y en ait qu'un seul dans la partie décimale, donc $e = 9 - 1 = 8$.

Exercice 2.6. Combien de nombres peut-on représenter en virgule flottante en base $b = 4$, et avec les paramètres $L = -2$, $U = 2$, et $t = 2$?

Résolution. Utilisons la formule donnée ci-dessus :

$$|\mathbb{F}(4, 2, -2, 2)| = 2(2 - (-2) + 1) \cdot 3 \cdot 4^1 = 2 \times 5 \times 3 \times 4 = 120.$$

Il y a donc 120 nombres représentable sous forme normalisée avec 2 chiffres significatifs, en base 4, et avec un exposant entre -2 et 2 . Il est bien sûr possible d'ajouter à cela des valeurs spéciales, mais nous n'en parlons pas ici.

Exercice 2.7. Considérons le système linéaire suivant :

$$\begin{cases} 0.461x_1 + 0.311x_2 &= 0.150 \\ 0.209x_1 + 0.141x_2 &= 0.068 \end{cases}$$

Il admet pour solution $(x_1, x_2) = (1, -1)$. Montrez que la résolution de ce système en

■ utilisant une représentation en virgule flottante ($b = 10, t = 3$) manque de précision.

Résolution. Nous allons résoudre ce système par méthode de substitution : d'abord isolons x_1 dans la première équation, et puis substituons ce que nous obtenons dans la seconde. Ainsi nous n'aurons plus que x_2 comme inconnue dans cette seconde équation, et ainsi nous pourrions la résoudre pour x_2 . Il ne restera plus qu'à substituer la valeur trouvée pour x_2 dans la première équation pour retrouver x_1 .

Commençons par réécrire tous les nombres en notation scientifique à 3 chiffres significatifs :

$$\begin{cases} 4.61 \times 10^{-1}x_1 + 3.11 \times 10^{-1}x_2 = 1.50 \times 10^{-1} \\ 2.09 \times 10^{-1}x_1 + 1.41 \times 10^{-1}x_2 = 6.80 \times 10^{-2} \end{cases}$$

Isolons ainsi x_1 dans la première équation en arrondissant systématiquement à 3 chiffres :

$$x_1 = \frac{1.50 \times 10^{-1}}{4.61 \times 10^{-1}} - \frac{3.11 \times 10^{-1}}{4.61 \times 10^{-1}}x_2 \stackrel{t=3}{=} 3.26 \times 10^{-1} - 6.75 \times 10^{-1}x_2.$$

Dès lors :

$$\begin{aligned} 2.09 \times 10^{-1} (3.26 \times 10^{-1} - 6.75 \times 10^{-1}x_2) + 1.41 \times 10^{-1}x_2 &= 6.80 \times 10^{-2} \\ 2.09 \cdot 3.26 \times 10^{-2} - 2.09 \cdot 6.75 \times 10^{-2}x_2 + 1.41 \times 10^{-1}x_2 &= 6.80 \times 10^{-2} \\ 6.81 \times 10^{-2} - 1.41 \times 10^{-1}x_2 + 1.41 \times 10^{-1}x_2 &= 6.80 \times 10^{-2} \\ 6.81 \times 10^{-2} &= 6.80 \times 10^{-2}, \end{aligned}$$

il y a donc un problème.

Nous pouvons alors plutôt isoler x_2 dans la première équation et la substituer dans la seconde :

$$x_2 = \frac{1.50 \times 10^{-1}}{3.11 \times 10^{-1}} - \frac{4.61 \times 10^{-1}}{3.11 \times 10^{-1}}x_1 \stackrel{t=3}{=} 4.82 \times 10^{-1} - 1.48 \times 10^0x_1.$$

Dès lors :

$$\begin{aligned} 2.09 \times 10^{-1}x_1 + 1.41 \times 10^{-1} (4.82 \times 10^{-1} - 1.48 \times 10^0x_1) &= 6.80 \times 10^{-2} \\ 2.09 \times 10^{-1}x_1 + 6.80 \times 10^{-2} - 2.09 \times 10^{-1}x_1 &= 6.80 \times 10^{-2} \\ 6.80 \times 10^{-2} &= 6.80 \times 10^{-2}, \end{aligned}$$

et à nouveau : oups. Il n'est pas possible de trouver x_2 .

Remarque : en résolvant le système donné ici, nous tombons systématiquement sur un problème. En effet, après une première substitution, il n'est pas possible d'aller plus loin, tout se comporte comme si la matrice n'était pas inversible. De fait, si nous regardons le déterminant de cette matrice :

$$\det \begin{bmatrix} 0.461 & 0.311 \\ 0.209 & 0.141 \end{bmatrix} = \left(\frac{1}{10^3} \right)^2 \det \begin{bmatrix} 461 & 311 \\ 209 & 141 \end{bmatrix} = 10^{-6} (461 \cdot 141 - 311 \cdot 209) = 2 \times 10^{-6},$$

ce qui est très mauvais signe, et de fait : le problème de résolution du système est très mal conditionné. En effet nous pouvons calculer $\kappa(A) \approx 181\,200$ (c.f. la [section 3](#) et la [section 6](#)).

Exercice 2.8. Considérez l'équation $\alpha x + \beta = 0$ pour $\alpha = 0.111$ et $\beta = -2$. $z = 18$ en est une solution approchée. Utilisez l'arithmétique décimale (donc en base $b = 10$) tronquée à 3 chiffres (donc $t = 3$) pour calculer le reste $r = -\beta - \alpha \cdot z$. Comparez avec le résultat en arithmétique exacte.

Résolution. En effet puisque $0.111 \approx \frac{1}{9}$, il n'est pas compliqué de se convaincre que 18 est une approximation de solution.

Le résidu est donné par :

$$-\beta - \alpha z = 2 - 0.111 \cdot 18 = 2 - \frac{111 \times 18}{1000} = 2 - \frac{999}{500} = \frac{1}{500} = 2 \times 10^{-3}.$$

Cependant en arithmétique tronquée à trois chiffres :

$$\alpha z = 1.11 \times 10^{-1} \times 1.8 \times 10^1 = 1.11 \cdot 1.8 \times 10^0 = 1.998 =_{t=3} 1.99 \times 10^0.$$

Dès lors :

$$-\beta - \alpha z =_{t=3} 2.00 \times 10^0 - 1.99 \times 10^0 = 0.01 = 1 \times 10^{-2}.$$

Il y a donc un facteur 5 entre le résidu approximé et le résidu réel.

Séance 3 — Conditionnement et arithmétique tronquée

Rappel théorique

Conditionnement

Nous considérons un *problème* au sens mathématique, c'est-à-dire une expression sous la forme

$$F(x, d) = 0$$

pour $F : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$ une fonction et $d \in \mathbb{R}^m$ le vecteur représentant les *données*. Résoudre ce problème correspond à trouver une valeur $x \in \mathbb{R}^n$ satisfaisant cette équation.

Si nous pouvons réécrire cette expression sous la forme

$$x = F(d),$$

nous disons que le problème est en *forme explicite*, et sinon il est en *forme implicite*. Nous considérons généralement des problèmes en forme explicite.

Nous notons δd une *perturbation* des données d , et nous notons δx la *perturbation* associée de la solution. Plus précisément, si $\hat{d} = d + \delta d$ est la donnée sur laquelle nous travaillons, alors nous définissons

$$\delta x = F(\hat{d}) - x = F(\hat{d}) - F(d) = F(d + \delta d) - F(d).$$

Nous écrivons également cela

$$x + \delta x = F(d + \delta d).$$

Si $\|x\| \neq 0$ et $\|d\| \neq 0$, nous définissons le *conditionnement relatif* du problème F en la donnée d par :

$$\begin{aligned} \kappa_{\text{rel}}(d) &:= \lim_{D \rightarrow 0} \sup_{\delta d \in B(0, D)} \frac{\|\delta x\| / \|x\|}{\|\delta d\| / \|d\|} \\ &= \frac{\|d\|}{\|x\|} \lim_{D \rightarrow 0} \sup_{\delta d \in B(0, D)} \frac{\|\delta x\|}{\|\delta d\|}. \end{aligned}$$

En particulier si $F \in \mathcal{C}^1(\mathbb{R}, \mathbb{R})$, alors :

$$\kappa_{\text{rel}}(d) = \frac{|d|}{|x|} \lim_{\delta d \rightarrow 0} \left| \frac{F(d + \delta d) - F(d)}{\delta d} \right| = \left| \frac{d \cdot F'(d)}{F(d)} \right|.$$

S'il n'est pas possible de regarder le conditionnement relatif, nous pouvons également regarder le *conditionnement absolu* :

$$\kappa_{\text{abs}}(d) := \lim_{D \rightarrow 0} \sup_{\delta d \in B(0, D)} \frac{\|\delta x\|}{\|\delta d\|}.$$

Notez bien que la raison pour laquelle nous passons par $\lim_{D \rightarrow 0} \sup_{\delta d \in B(0,D)}(\dots)$ dans ces définitions est pour ne pas s'encombrer du cas où $\lim_{\delta d \rightarrow 0}(\dots)$ n'existe pas. En effet pour une suite $(D_n)_n$ décroissante, $n \mapsto \sup_{\delta d \in B(0,D_n)} \varphi(\delta d)$ est également une suite décroissante, et donc cette suite converge (potentiellement vers $+\infty$ si toutes les valeurs sont infinies).

Erreurs

À partir d'ici, fixons un certain $x \in \mathbb{R}$, et considérons $\hat{x} \approx x$ une approximation de x . Nous appelons

- *erreur absolue* la quantité $\delta = |\hat{x} - x|$;
- *écart relatif* la quantité $\rho = \frac{\hat{x} - x}{x}$;
- *erreur relative* la quantité $\varepsilon = |\rho| = \frac{|\hat{x} - x|}{|x|} = \frac{\delta}{|x|}$.

Dans le cas où nous parlons d'erreurs ou d'écarts sur plusieurs quantités différentes, nous ajoutons le nom de la variable considérée en indice, e.g. δ_x ou encore ρ_d .

Notons que $\rho_x = \frac{\hat{x} - x}{x}$, et donc $x\rho_x = \hat{x} - x$, ou encore $\hat{x} = x\rho_x + x = x(1 + \rho_x)$.

Si $x \in \mathbb{R} \setminus \mathbb{F}(b, t, L, U)$, nous ne pouvons représenter qu'une valeur approchée de x . Nous considérons ici les cas suivants :

- un *arrondi* : $\hat{x} = \text{fl}(x)$;
- une *valeur tronquée* : $\hat{x} = \text{tr}(x)$.

Dans le cas d'un arrondi, nous prenons la valeur $\hat{x} \in \mathbb{F}(b, t, L, U)$ qui minimise la distance $|\hat{x} - x|$, alors que dans le cas d'une troncature, nous prenons le plus grand nombre $\hat{x}$ tel que $\hat{x} \leq x$.

Si x et x' sont deux valeurs consécutives de $\mathbb{F}(b, t, L, U)$ (dans le sens où $x < x'$ et il n'existe aucun $\xi \in \mathbb{F}(b, t, L, U)$ tel que $x < \xi < x'$), alors nous pouvons montrer les inégalités suivantes :

$$\frac{1}{b}\varepsilon \leq \frac{|x - x'|}{|x|} \leq \varepsilon,$$

où la quantité $\varepsilon := b^{1-t}$ est appelée *epsilon machine*. De plus, dans le cas d'un arrondi, nous pouvons observer que :

$$\left| \frac{\text{fl}(x) - x}{x} \right| \leq u,$$

où la quantité $u := \frac{1}{2}\varepsilon$ est appelée *précision machine* (ou parfois *unit roundoff* d'où la lettre u).

Erreur de propagation Si nous travaillons sur la valeur $\hat{d} = \text{fl}(d)$ (au lieu de d) et que nous résolvons le problème $F(d)$ associé, nous obtenons une solution $x + \delta x$. L'*erreur de propagation* est l'erreur obtenue sur x , exprimé sur base de l'erreur sur d :

$$\begin{aligned} F(\hat{d}) &= F(d + \delta d) = F(d(1 + \rho_d)) = F(d + d \cdot \rho_d) \\ &\approx F(d) + d\rho_d F'(d) = F(d) + F(d) \frac{d\rho_d F'(d)}{F(d)} = F(d) \left(1 + \frac{d\rho_d F'(d)}{F(d)} \right) \\ &= x(1 + \rho_d \kappa(d)) \end{aligned}$$

où le symbole $\approx$ cache en réalité l'application d'une expansion de Taylor d'ordre 1.

Finalement, la solution *obtenue* est :

$$\hat{x} = \text{fl}(F(\hat{d})) = \text{fl}(x(1 + \rho_d \kappa(d))) = x(1 + \rho_d \kappa)(1 + \rho_{F(d)}).$$

Les erreurs d'*annulation* et d'*absorption* sont deux exemples importants d'erreurs de génération. Une erreur d'annulation arrive lorsque deux nombres proches sont soustraits. Dans ce cas, la valeur résultante est certes petite en valeur absolue, mais peut être potentiellement très grande par rapport à la *vraie* valeur de cette différence, surtout dans le cas où les opérandes sont déjà des valeurs arrondies. Une erreur d'absorption arrive lorsque qu'un nombre très grand est ajouté à un nombre très petit. Dans ce cas, par manque de chiffres significatifs, une grande partie des chiffres composant la *petite* valeur n'apparaîtront pas dans la valeur résultante.

Erreur de génération L'erreur de génération apparaît lorsque le problème $x = F(d)$ est résolu par un algorithme itératif :

$$\begin{aligned} x_1 &= F_1(d) \\ x_2 &= F_2(x_1) \\ &\vdots \\ x &= x_n = F_n(x_{n-1}) \end{aligned}$$

Ici, des erreurs sont produites à chaque étape, et nous pouvons les calculer comme ceci :

$$\hat{x}_1 = x_1(1 + \kappa_1 \rho_d)(1 + \rho_{x_1}) = x_1(1 + \kappa_1 \rho_d \rho_{x_1} + \kappa_1 \rho_d + \rho_{x_1}) \approx x_1(1 + \underbrace{\kappa_1 \rho_d + \rho_{x_1}}_{=:\rho_{x_1}^C}),$$

où nous prenons l'approximation $\rho_a \times \rho_b \approx 0$ (l'ordre de grandeur des erreurs relatives est suffisamment grand pour être pris en compte, mais suffisamment petit pour que le produit de deux telles erreurs puisse être approximé à 0) et où $\rho_{x_1}^C$ est l'écart relatif cumulé (total) sur x_1 . Dès lors :

$$\begin{aligned} \hat{x}_2 &\approx x_2(1 + \kappa_2 \rho_{x_1}^C)(1 + \rho_{x_2}) \\ &\vdots \\ \hat{x} &\approx x \left[1 + \underbrace{\underbrace{\rho_n}_{\text{arrondi}} + \underbrace{\sum_{k=1}^{n-1} \left(\prod_{m=k+1}^n \kappa_m \right) \rho_k + \rho_d \prod_{m=1}^n \kappa_m}_{\text{génération}}}_{=:\rho_{x_n}^C} \right]. \end{aligned}$$

Nous observons que le conditionnement des différents sous-problèmes finissent multipliés, et donc si ces sous-problèmes sont mal conditionnés, $|\hat{x} - x|$ peut se retrouver arbitrairement grand.

Remarque. Pour une preuve de cette assertion, nous pouvons procéder par récurrence sur n . Nous voulons montrer que :

$$\frac{\hat{x}_j}{x_j} - 1 \approx \rho_{x_j}^C = \rho_j + \sum_{k=1}^{j-1} \left(\prod_{m=k+1}^j \kappa_m \right) \rho_k + \rho_d \prod_{m=1}^j \kappa_m.$$

Comme vu ci-dessus, $\hat{x}_1 \approx x_1 (1 + \rho_1 + \kappa_1 \rho_d) = x_1 (1 + \rho_{x_1}^C)$.

$$\begin{aligned}
\hat{x}_j &= x_j \left(1 + \kappa_j \left(\frac{\hat{x}_{j-1}}{x_{j-1}} - 1 \right) \right) (1 + \rho_j) \\
&= x_j \left(1 + \kappa_j \rho_{x_{j-1}}^C \right) (1 + \rho_j) \\
&\approx x_j \left[1 + \rho_j + \kappa_j \left(\rho_{j-1} + \sum_{k=1}^{j-2} \left(\prod_{m=k+1}^{j-1} \kappa_m \right) \rho_k + \rho_d \prod_{m=1}^{j-1} \kappa_m \right) \right] \\
&= x_j \left[1 + \rho_j + \left(\prod_{m=j}^j \kappa_m \right) \rho_{j-1} + \sum_{k=1}^{j-1} \left(\prod_{m=k+1}^{j-1} \kappa_m \right) \kappa_j \rho_k + \rho_d \prod_{m=1}^j \kappa_j \right] \\
&= x_j \left[1 + \rho_j + \sum_{k=1}^{j-1} \left(\prod_{m=k+1}^j \kappa_m \right) \rho_k + \rho_d \prod_{m=1}^j \kappa_m \right] \\
&= x_1 \left(1 + \rho_{x_j}^C \right).
\end{aligned}$$

Notations Pour une opérations $\star : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$, nous considérons l'opération associée $\oplus : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{F}$ définie comme suit :

$$x \oplus y := \text{fl}(\text{fl}(x) \star \text{fl}(y)).$$

En particulier $\oplus$ désigne l'addition arrondie et $\odot$ désigne la multiplication arrondie. Maintenant par induction :

3.1 Conditionnement

Exercice 3.1. Que peut-on dire du conditionnement de la fonction $F(d) = d - 1$ autour de 1 ?

Résolution. Nous ne pouvons pas calculer le conditionnement relatif en $d = 1$ puisque dans ce cas $x = F(d) = 0$. Cependant, pour δd tel que $0 < |\delta d|$, nous pouvons observer que :

$$\kappa_{\text{rel}}(1 + \delta d) = \left| \frac{(1 + \delta d) \cdot 1}{(1 + \delta d) - 1} \right| = \left| \frac{1 + \delta d}{\delta d} \right| \xrightarrow{\delta d \rightarrow 0} +\infty.$$

En particulier pour $|\delta d| \ll 1$, le problème est très mal conditionné en $1 + \delta d$, i.e. le problème est très mal conditionné autour de $d = 1$. Cependant, c'était attendu puisque $F(1) = 0$. Dès lors, il faudrait plutôt regarder le conditionnement absolu en 1, qui est ici :

$$\kappa_{\text{abs}}(1) = |F'(1)| = 1.$$

Le problème est donc lié au fait qu'on approche une situation où la solution est $x = 0$, et non au fait que le problème en lui-même est mal conditionné.

Exercice 3.2. Calculez le conditionnement $\kappa(d)$ des expressions $F(x, d)$ suivantes :

- $x - a^d = 0$ ($a > 0$) ;
- $d - x + 1 = 0$.

Résolution. Rappelons-nous que $\frac{d}{dx}a^x = \ln(a)a^x$. En effet puisque $a^x = \exp(\ln(a)x)$, nous savons :

$$\frac{d}{dx}a^x = \frac{d}{dx}\exp(\ln(a)x) = \ln(a)\exp(\ln(a)x) = \ln(a)a^x.$$

Dès lors dans le premier cas, $x = F(d) = a^d$ et donc :

$$\kappa(d) = \left| \frac{d \ln(a)a^d}{a^d} \right| = |\ln(a)d|.$$

Le conditionnement est donc linéaire en d , i.e. pour de petites valeurs de d , le problème est bien conditionné, mais pour de grandes valeurs de d , le problème est mal conditionné. Intuitivement cela a un sens puisque les exponentielles sont des fonctions de très grande croissance. Dès lors, $a^{d+\delta d}$ peut être arbitrairement loin de a^d , même si δd est très petit, du moment que d soit suffisamment grand. De plus, au plus la base de l'expression est grande, au plus $\ln(a)$ sera grand également. Cependant, cette base apparaît dans un log, donc ce n'est pas elle qui va dominer le comportement. Attention cependant au cas d'une base $0 < a \ll 1$ en quel cas, a^d est très vite très proche de 0, même pour d relativement petit. Dès lors, $|x| \approx 0$, et donc le conditionnement relatif est rapidement très grand. Cela peut se voir avec le coefficient $|\ln(a)|$ qui devient arbitrairement grand à mesure que a s'approche de 0 (par la droite). De plus, dans le cas où $a = 1 - \varepsilon$ pour un certain $\varepsilon > 0$, le conditionnement absolu est donné par :

$$\kappa_{\text{abs}}(d) = |\ln(1 - \varepsilon)| (1 - \varepsilon)^d.$$

Donc pour d petit, le problème est fondamentalement mal conditionné.

Dans le second cas, $x = F(d) = d + 1$, et similairement à l'exercice précédent, on obtient (pour $d \neq -1$) :

$$\kappa(d) = \left| \frac{d}{d+1} \right| \xrightarrow{d \rightarrow -1} +\infty.$$

Contrairement au premier exemple, ce problème-ci est bien conditionné pour de grandes valeurs de d (en valeur absolue), mais est très mal conditionné pour d proche de -1 .

Exercice 3.3. Montrez que l'évaluation de $F(d) = \cos d$ est bien conditionnée près de $d = 0$.

Résolution. Le conditionnement relatif en 0 ne peut être pris, il faut donc à nouveau regarder le conditionnement *autour* de 0 :

$$\kappa(\delta d) = \left| \frac{\delta d \sin \delta d}{\cos \delta d} \right| \xrightarrow{\delta d \rightarrow 0} 0,$$

i.e. pour d se rapprochant de 0, le conditionnement du problème se rapproche également de 0, i.e. le problème est bien conditionné autour de 0.

Exercice 3.4. Que peut-on dire du conditionnement de $F(d) = (d - 1)^2$ autour de $d = 1$?

Résolution. À nouveau, le problème ici est que $F(1) = 0$. Dès lors :

$$\kappa(1 + \delta d) = \left| \frac{(1 + \delta d)2(1 + \delta d - 1)}{(1 + \delta d - 1)^2} \right| = \left| \frac{2(1 + \delta d)\delta d}{\delta d^2} \right| \xrightarrow{\delta d \rightarrow 0} +\infty.$$

Cependant, le conditionnement absolu est donné par :

$$\kappa_{\text{abs}}(1 + \delta d) = |F'(1 + \delta)| = 2(1 + \delta) - 2 = 2\delta d \xrightarrow{\delta d \rightarrow 0} 0.$$

3.2 Erreur d'annulation

Exercice 3.5. Vérifiez que pour $d_1 = 0.1656$, $d_2 = 7.4409$ et $d_3 = 2.9168$ dans un système à virgule flottante où $b = 10$ et $t = 2$:

$$d_1 \oplus (d_2 \oplus d_3) \neq (d_1 \oplus d_2) \oplus d_3,$$

i.e. $\oplus$ n'est pas associatif.

Trouvez un exemple de valeurs distinctes x, y, z satisfaisant :

$$x \oplus (y \oplus z) = (x \oplus y) \oplus z.$$

Résolution. Commençons par arrondir les différentes valeurs : $\text{fl}(d_1) = 0.17 = 1.7 \times 10^{-1}$; $\text{fl}(d_2) = 7.4$; et $\text{fl}(d_3) = 2.9$. Dès lors :

$$d_1 \oplus (d_2 \oplus d_3) = \text{fl}(0.17 + \text{fl}(7.4 + 2.9)) = \text{fl}(0.17 + \text{fl}(10.3)) = \text{fl}(0.17 + 10) = \text{fl}(10.17) = 10.$$

Maintenant :

$$(d_1 \oplus d_2) \oplus d_3 = \text{fl}(\text{fl}(0.17 + 7.4) + 2.9) = \text{fl}(7.6 + 2.9) = \text{fl}(10.5) = 11.$$

Exercice 3.6. Pour un système en virgule flottante où $b = 10$ et $t = 4$ montrez que l'évaluation de la fonction $F(d) = d - 1$ est sujette à une importante erreur d'annulation dans le cas où $d = 1.00098$.

Résolution. Les erreurs d'annulation sont une affaire d'erreur relative après une différence. Ici : $\text{fl}(d) = 1.001$, et donc :

$$\varepsilon_d = \left| \frac{\text{fl}(d) - d}{d} \right| = \frac{1.001 - 1.00098}{1.00098} = \frac{0.00002}{1.00098} < 2 \times 10^{-5}.$$

Cependant, pour $x = F(d)$ et $\hat{x} = \text{fl}(F(\text{fl}(d)))$:

$$\varepsilon_x = \left| \frac{(1.001 - 1) - (1.00098 - 1)}{1.00098 - 1} \right| = \frac{0.00002}{0.00098} = \frac{2}{98} > 2 \times 10^{-2}.$$

Donc même si ε_d est faible et donc *a priori* négligeable, ε_x ne l'est pas du tout : le rapport entre l'erreur relative en sortie et l'erreur relative en entrée est $\frac{\varepsilon_x}{\varepsilon_d} > 10^3$.

3.3 Erreur de génération

Exercice 3.7. Pour $\alpha = 0.8717$ et $\beta = 0.8719$, calculez le point milieu de l'intervalle $(\alpha + \beta)/2$. Utilisez d'abord l'arithmétique décimale *tronquée* à 4 chiffres, et ensuite l'arithmétique décimale *arrondie* à 4 chiffres. Enfin, proposez une autre séquence d'évaluation qui génère moins d'erreur.

Résolution. Puisque $\alpha < \beta$, nous savons que $\alpha < \frac{\alpha+\beta}{2} < \beta$. De plus, $\frac{\alpha+\beta}{2} = 0.8718$.

En arithmétique tronquée :

$$(\alpha \oplus \beta) \odot 2 = \text{tr}(\text{tr}(1.7436)/2) = \text{tr}(1.743/2) = \text{tr}(0.8715) = 0.8715 < \alpha.$$

En arithmétique arrondie :

$$(\alpha \oplus \beta) \odot 2 = \text{fl}(\text{fl}(1.7436)/2) = \text{fl}(1.744/2) = \text{fl}(0.8720) = 0.8720 > \beta.$$

Notons que $\frac{\alpha+\beta}{2} = \alpha + \frac{\beta-\alpha}{2}$. Dans ce cas, regardons :

$$\alpha \oplus ((\beta \ominus \alpha) \odot 2) = \alpha \oplus \text{fl}(2 \times 10^{-4} / 2) = \text{fl}(\alpha + 10^{-4}) = 0.8718,$$

ce qui est la bonne réponse.

Exercice 3.8. Dans un système en virgule flottante où $b = 10$ et $t = 3$, comparez les deux algorithmes suivants d'évaluation de la fonction $F(d) = d^2 - 1$:

- algorithme 1 : $y_1 = d \cdot d$; $x_1 = y_1 - 1$;
- algorithme 2 : $y_2 = d - 1$; $x_2 = y_2 \cdot (y_2 + 2)$.

Résolution. Les deux algorithmes sont équivalents et calculent bien $d^2 - 1$. En effet : $x_1 = y_1 - 1 = d \cdot d - 1 = d^2 - 1$, et $x_2 = y_2(y_2 + 2) = (d - 1)(d - 1 + 2) = (d - 1)(d + 1) = d^2 - 1$.

Intuitivement, le deuxième algorithme devrait être plus stable puisque l'opération avec le conditionnement le plus mauvais (ici la soustraction) a été faite en premier.

Pour l'illustrer, choisissons une valeur de d proche de 1 telle que d soit représentable exactement en virgule flottante $b = 10$ et $t = 3$, et telle que $F(d)$ le soit également. Pour cela, prenons $d = 1.02$ (qui donne $F(d) = 4.04 \times 10^{-2}$).

Pour le premier algorithme, nous avons :

$$\hat{x}_1 = \text{fl}(\text{fl}(1.02^2) - 1) = \text{fl}(\text{fl}(1.0404) - 1) = \text{fl}(1.04 - 1) = 0.04 = 4 \times 10^{-2}.$$

Pour le deuxième algorithme nous avons :

$$\hat{x}_2 = \text{fl}(\text{fl}(0.02) \cdot \text{fl}(2.02)) = \text{fl}(2 \times 10^{-2} \times 2.02) = 4.04 \times 10^{-2}.$$

Nous pouvons observer que $\hat{x}_2$ est ici une solution exacte, alors que $\hat{x}_1$ n'en est pas une. De plus, son erreur relative est donnée par :

$$\varepsilon_{x_1} = \left| \frac{4.04 \times 10^{-2} - 4 \times 10^{-2}}{4 \times 10^{-2}} \right| = 10^{-2}.$$

Séance 4 — Manipulation de nombres à virgule flottante en Matlab

Dans cette séance, nous ferons l'hypothèse simplificatrice que l'arithmétique employée par MATLAB (ou OCTAVE) est exacte.

Exercice 4.1. Écrivez une fonction qui, étant donné un nombre x et son approximation $\hat{x}$, calcule (i) l'erreur absolue et (ii) l'erreur relative.

Résolution.

```
1 function [delta, epsilon] = errors(x, x_hat)
2     delta = abs(x_hat - x);
3     epsilon = delta ./ abs(x);
4 end
```

Exercice 4.2. Dessinez le graphique de de l'erreur relative obtenue pour le problème $F(d) = (d - 1)^2$ avec une perturbation fixe des données de 10^{-2} . Prenez les données dans l'intervalle $[-1, 3]$. Dessinez ensuite sur la même figure le graphique du conditionnement relatif du problème.

Résolution.

```
1 function ex4_2()
2     d = -1:.001:3;
3     d_pert = d + 1e-2;
4     Fd = (d - 1) .^ 2;
5     Fd_pert = (d_pert - 1) .^ 2;
6     [delta, epsilon] = errors(Fd, Fd_pert);
7     plot(d, epsilon, 'LineWidth', 4);
8     hold on;
9     % F(d) = (d-1)^2
10    % F'(d) = 2(d-1)
11    % \kappa_r(d) = F'(d) * d / F(d) = 2d / (d-1)
12    kappa = abs(2 * d ./ (d-1));
13    plot(d, kappa, 'LineWidth', 3);
14 end
```

Exercice 4.3. Écrivez une fonction `increment(m, b)` qui prend en paramètre une mantisse m sous forme d'un vecteur de taille t et une base b , et qui renvoie la mantisse associée à $m+1$ (toujours en base b).

Ensuite, écrivez une fonction `floset(b, t, L, U)` qui prend en paramètre une base b , une taille de mantisse t , et les bornes sur un exposant L et U . Cette fonction doit renvoyer une paire $[F, \text{card}]$ où F est un vecteur trié qui contient toutes les valeurs de $\mathbb{F}(b, t, L, U)$ et où card est la taille de F .

Représentez ensuite ce vecteur sur une figure (c.f. la Figure 2.1 du syllabus).

Résolution.

```

1 function mantissa = increment(m, b)
2     mantissa = m; % copy
3     mantissa(1) = mantissa(1) + 1;
4     t = length(m);
5     for i = 1:t-1
6         if(mantissa(i) == b)
7             mantissa(i) = 0;
8             mantissa(i+1) = mantissa(i+1) + 1;
9         else
10            break;
11        end
12    end
13    mantissa(t) = mod(mantissa(t), b);
14 end

```

```

1 function [F, card] = floset(b, t, L, U)
2     idx = 1;
3     b_pow = zeros(t, 1);
4     b_pow(1) = 1;
5     for i = 2:t
6         b_pow(i) = b_pow(i-1) * b;
7     end
8     mantissa = zeros(1, t);
9     for i=1:b^(t-1)*(b-1)
10        mantissa(end) = 1; % chiffre de poids fort non nul
11        mantissa_value = mantissa * b_pow;
12        for e = L:U
13            F(idx) = (b^(e-t)) * mantissa_value;
14            idx = idx + 1;
15        end
16        mantissa = increment(mantissa, b);
17    end
18    F = [-F F]; % On n'oublie pas les négatifs
19    F = sort(F); % trier le vecteur F
20    card = length(F); % Tout simplement

```

Exercice 4.4. Utilisez le code de l'exercice précédent et représentez sur une figure les distances relatives entre les éléments consécutifs de $\mathbb{F}(b, t, L, U)$ (c.f. la Figure 2.2 du syllabus).

Résolution.

```

1 function flodist(b, t, L, U)
2     [F, card] = floset(b, t, L, U);
3     F = F(F > 0);
4     relativedist = diff(F) ./ F(1:end-1);
5     plot(F(1:end-1), relativedist, '*-')
6 end

```

Exercice 4.5. Écrivez une fonction $\text{fl}(x, b, t, L, U)$ qui prend en paramètre une valeur $x \in \mathbb{R}$, une base b , une taille de mantisse t et des bornes L et U sur un exposant ; et qui renvoie la valeur $\hat{x} = \text{fl}(x) \in \mathbb{F}(b, t, L, U)$, i.e. la valeur approchée la plus proche de x dans cette représentation.

Résolution. Voici une solution naïve :

```

1 function y = fl(x, b, t, L, U)
2   if x > b^U * (1-b^(-t))
3     error('Overflow');
4   elseif x < b^(L-1)
5     error('Underflow');
6   end
7   F = floset(b, t, L, U);
8   y_up = F(F>=x)(1);
9   y_down = F(F<=x)(end);
10  if y_up-x < x-y_down
11    y = y_up;
12  else
13    y = y_down;
14  end

```

Cette approche a tout de même un problème : elle demande de déterminer l'intégralité de $\mathbb{F}(b, t, L, U)$, même pour déterminer un unique float. Nous pouvons plutôt chercher à construire s , m et e individuellement.

Pour cela, supposons d'abord que $x \in \mathbb{F}(b, t, L, U)$. Dans ce cas, nous avons $x = (-1)^s \cdot m \cdot b^{t-e}$, or nous savons également que $b^{t-1} \leq m \leq b^t - 1$. Le signe s peut être trouvé facilement : il suffit de vérifier si $x < 0$. Pour l'exposant e , en utilisant les inégalités ci-dessus et le fait que $|x| b^{e-t} = m$, nous déduisons :

$$b^{e-1} \leq |x| \leq b^e(1 - b^{-t}).$$

En particulier, en prenant le log en base b de chaque élément de ces inégalités (souvenez-vous que log est une fonction croissante, donc les inégalités sont préservées) :

$$e - 1 \leq \log_b |x| \quad \text{et} \quad e \geq \log_b \frac{|x|}{1 - b^{-t}}.$$

En arrondissant de part et d'autre, nous obtenons :

$$\left\lceil \log_b \frac{|x|}{1 - b^{-t}} \right\rceil = e = \lfloor \log_b |x| \rfloor + 1.$$

Nous avons alors $m = |x| \cdot b^{t-e}$, que nous pouvons reconstruire aisément.

Finalement, dans le cas où $x \notin \mathbb{F}(b, t, L, U)$, la quantité $|x| \cdot b^{e-t}$ n'est pas un nombre entier, et il faudra l'arrondir avant de reconstruire la mantisse.

Voici une implémentation :

```

1 function [s, m, e] = fl_better(x, b, t, L, U)
2     if x > b^U * (1-b^(-t))
3         error('Overflow');
4     elseif x < b^(L-1)
5         error('Underflow');
6     elseif x == 0
7         error('0 is not representable');
8     end
9     s = (x < 0); % 1 ou 0
10    x = abs(x); % on passe en valeur absolue
11    e = 1 + floor(log(x) / log(b)); % on trouve e
12    x = x * b^(t-e); % On détermine le nombre encodé par la mantisse
13    x = round(x); % Dans le cas où x n'est pas représentable
14    for i = 1:t
15        m(t-i+1) = floor(mod(x, b));
16        x = x / b;
17    end
18 end

```

Séance 5 — Introduction à la résolution de systèmes linéaires

Rappel théorique

Un système linéaire est un ensemble de m équations linéaires à n inconnues :

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n = b_m \end{cases}$$

Nous pouvons le réécrire sous forme matricielle :

$$Ax = b,$$

où $A \in \mathbb{R}^{m \times n}$ est la matrice de coefficients, $x \in \mathbb{R}^n$ est le vecteur d'inconnues et $b \in \mathbb{R}^m$ est le vecteur de solutions.

Théorème 1. Si A est une matrice carrée, alors les conditions suivantes sont équivalentes :

1. A est inversible (ou encore $\det A \neq 0$) ;
2. $Ax = 0$ admet uniquement $x = 0$ pour solution ;
3. $Ax = b$ admet une unique solution pour tout b ;
4. $\text{rank } A = m = n$.

Méthode de Cramer

Nous introduisons la notation suivante pour tout $1 \leq j \leq n$:

$$B_j := \begin{bmatrix} a_{1,1} & \dots & a_{1,j-1} & b_1 & a_{1,j+1} & \dots & a_{1,n} \\ \vdots & & & \vdots & & & \\ a_{n,1} & \dots & a_{n,j-1} & b_n & a_{n,j+1} & \dots & a_{n,n} \end{bmatrix}$$

La matrice B_j est donc la matrice obtenue en remplaçant la j ème colonne de A par le vecteur b .

Théorème 2 (Cramer). Le vecteur x donné par $x_j = \frac{\det B_j}{\det A}$ est une solution à l'équation $Ax = b$.

Méthode de Gauss

Une matrice A est dite *triangulaire supérieure* si $a_{i,j} = 0$ pour tous $i > j$ et est dite *triangulaire inférieure* si $a_{i,j} = 0$ pour tous $j > i$. A est dite *triangulaire* si elle est soit triangulaire supérieure soit triangulaire inférieure.

Observons que si la matrice A est triangulaire, le système $Ax = b$ est facile à résoudre. En effet, si A est triangulaire supérieure, nous utilisons la substitution rétrograde :

$$x_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j=i+1}^n a_{i,j}x_j \right).$$

En déterminant les entrées de x dans l'ordre décroissante (de x_n jusque x_1), nous pouvons trouver la solution en temps quadratique. De manière symétrique, si A est triangulaire inférieure, nous utilisons la substitution progressive :

$$x_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j=1}^{i-1} a_{i,j} x_j \right).$$

En déterminant les entrées de x dans l'ordre croissant (de x_1 à x_n), à nouveau, nous pouvons trouver la solution en temps quadratique.

L'objectif de la méthode de Gauss est de transformer le système $Ax = b$ en un système équivalent $A'x = b'$ où la matrice A' est triangulaire. Ici, deux systèmes $A^{(1)}x = b^{(1)}$ et $A^{(2)}x = b^{(2)}$ (ou de manière équivalente deux paires $(A^{(1)}, b^{(1)})$ et $(A^{(2)}, b^{(2)})$) sont dits *équivalents* lorsqu'ils admettent les mêmes solutions.

À l'étape $j \in \{1, \dots, n\}$, on veut s'assurer que la matrice A soit triangulaire (supérieure) jusqu'à la colonne j , i.e. que pour $j' \leq j$ et $i > j'$, l'entrée $A_{i,j'}^{(j)}$ soit nulle. En procédant de la sorte, à la fin (donc après la n ème étape), nous aurons bien une matrice triangulaire supérieure.

Pour ce faire, nous notons $m_{i,j}$ le coefficient utilisé à la ligne i , lors de l'étape j , et nous définissons la matrice $A^{(j)}$ comme ceci (où $A^{(0)} := A$) :

$$a_{i,k}^{(j)} = \begin{cases} a_{i,k}^{(j-1)} - m_{i,j} a_{j,k}^{(j-1)} & \text{si } i > j \\ a_{i,k}^{(j-1)} & \text{si } i \leq j \end{cases}$$

De manière équivalente, nous définissons $A^{(j)}$ comme étant $A^{(j-1)}$ à laquelle la j ème ligne est retirée $m_{i,j}$ fois à la ligne i . Bien entendu la même opération doit être appliquée sur b et donc (pour $b^{(0)} := b$) :

$$b_i^{(j)} = \begin{cases} b_i^{(j-1)} - m_{i,j} b_j^{(j-1)} & \text{si } i > j \\ b_i^{(j-1)} & \text{si } i \leq j \end{cases}$$

Nous voulons nous assurer que $a_{i,k}^{(j)} = 0$ pour tous i, j, k tels que $i > k$ et $k \leq j$. Pour cela, nous prenons $m_{i,j} = \frac{a_{i,j}^{(j-1)}}{a_{j,j}^{(j-1)}}$. Nous pouvons aisément vérifier que c'est suffisant par induction. En effet pour $j = 0$, le résultat est trivialement vrai. Pour $j \geq 1$, soit nous regardons le cas $k = j$ où donc pour $i > k$:

$$a_{i,k}^{(j)} = a_{i,j}^{(j)} = a_{i,j}^{(j-1)} - m_{i,j} a_{j,j}^{(j-1)} = 0,$$

par définition de $m_{i,j}$, soit nous regardons le cas $k < j$ et donc par hypothèse d'induction, pour $i > k$:

$$a_{i,k}^{(j)} = \begin{cases} a_{i,k}^{(j-1)} = 0 & \text{si } i \leq j \\ a_{i,k}^{(j-1)} - m_{i,j} a_{j,k}^{(j-1)} = 0 - m_{i,j} \cdot 0 = 0 & \text{si } i > j \end{cases}$$

Attention tout de même, ici à chaque étape, nous devons diviser par $a_{j,j}^{(j-1)}$, mais donc si cette valeur est nulle, le problème est mal défini. Il nous faut alors utiliser la notion de *pivot*, i.e. nous devons interchanger les lignes j et j' où $j' > j$ est l'indice maximisant la

quantité $|a_{j',j}^{(j-1)}|$. Cette méthode de pivot s'appelle *pivot partiel*. Il existe également une notion de *pivot total* dans lequel on échange à la fois deux lignes et deux colonnes afin de placer l'entrée $a_{i',j'}^{(j-1)}$ maximale en valeur absolue à la place de $a_{j,j}^{(j-1)}$. Dans ce cas-ci, attention tout de même à bien conserver les permutations de colonnes qui ont été faites afin de pouvoir retrouver la bonne valeur de x (puisque un échange de colonnes correspond à intervertir deux entrées de x).

Exercice 5.1. Résolvez le système suivant avec la méthode de Cramer :

$$\begin{bmatrix} 4 & 8 & 12 \\ 3 & 8 & 13 \\ 2 & 9 & 18 \end{bmatrix} x = \begin{bmatrix} 4 \\ 5 \\ 11 \end{bmatrix}.$$

Résolution. Observons que les matrices B_j sont données par :

$$B_1 = \begin{bmatrix} 4 & 8 & 12 \\ 5 & 8 & 13 \\ 11 & 9 & 18 \end{bmatrix} \quad B_2 = \begin{bmatrix} 4 & 4 & 12 \\ 3 & 5 & 13 \\ 2 & 11 & 18 \end{bmatrix} \quad B_3 = \begin{bmatrix} 4 & 8 & 4 \\ 3 & 8 & 5 \\ 2 & 9 & 11 \end{bmatrix}$$

Les déterminants sont donc donnés par :

$$\begin{aligned} \det B_1 &= 4 \det \begin{bmatrix} 8 & 13 \\ 9 & 18 \end{bmatrix} - 5 \det \begin{bmatrix} 8 & 12 \\ 9 & 18 \end{bmatrix} + 11 \det \begin{bmatrix} 8 & 12 \\ 8 & 13 \end{bmatrix} \\ &= 4(144 - 117) - 5(144 - 108) + 11(104 - 96) = 108 - 180 + 88 = 16, \\ \det B_2 &= 4 \det \begin{bmatrix} 5 & 13 \\ 11 & 18 \end{bmatrix} - 3 \det \begin{bmatrix} 4 & 12 \\ 11 & 18 \end{bmatrix} + 2 \det \begin{bmatrix} 4 & 12 \\ 5 & 13 \end{bmatrix} \\ &= 4(90 - 143) - 3(72 - 132) + 2(52 - 60) = -212 + 180 - 16 = -48, \\ \det B_3 &= 4 \det \begin{bmatrix} 8 & 5 \\ 9 & 11 \end{bmatrix} - 3 \det \begin{bmatrix} 8 & 4 \\ 9 & 11 \end{bmatrix} + 2 \det \begin{bmatrix} 8 & 4 \\ 8 & 5 \end{bmatrix} \\ &= 4(88 - 45) - 3(88 - 36) + 2(40 - 32) = 172 - 156 + 16 = 32. \end{aligned}$$

Finalement, puisque :

$$\det A = 4 \det \begin{bmatrix} 8 & 13 \\ 9 & 18 \end{bmatrix} - 8 \det \begin{bmatrix} 3 & 13 \\ 2 & 18 \end{bmatrix} + 12 \det \begin{bmatrix} 3 & 8 \\ 2 & 9 \end{bmatrix} = 108 - 224 + 132 = 16,$$

nous déduisons que $x = \frac{1}{16}[16, -48, 32]^\top = [1, -3, 2]^\top$ est la solution au problème. De fait :

$$\begin{bmatrix} 4 & 8 & 12 \\ 3 & 8 & 13 \\ 2 & 9 & 18 \end{bmatrix} \begin{bmatrix} 1 \\ -3 \\ 2 \end{bmatrix} = \begin{bmatrix} 4 - 24 + 24 \\ 3 - 24 + 26 \\ 2 - 27 + 36 \end{bmatrix} = \begin{bmatrix} 4 \\ 5 \\ 11 \end{bmatrix}.$$

■ **Exercice 5.2.** Résolvez ce même système par la méthode de Gauss.

Résolution. Puisque $m_{i,j} = \frac{a_{i,j}^{(j-1)}}{a_{j,j}^{(j-1)}}$ (et $A^{(0)} = A$), nous savons que $m_{2,1} = \frac{3}{4}$ et $m_{3,1} = \frac{1}{2}$.

La matrice $A^{(1)}$ est donc donnée par :

$$A^{(1)} = \begin{bmatrix} 4 & 8 & 12 \\ 3 - \frac{3}{4}4 & 8 - \frac{3}{4}8 & 13 - \frac{3}{4}12 \\ 2 - \frac{1}{2}4 & 9 - \frac{1}{2}8 & 18 - \frac{1}{2}12 \end{bmatrix} = \begin{bmatrix} 4 & 8 & 12 \\ 0 & 2 & 4 \\ 0 & 5 & 12 \end{bmatrix}.$$

Le vecteur $b^{(1)}$ est également donné par $[4, 5 - \frac{3}{4}4, 11 - \frac{1}{2}4]^\top = [4, 2, 9]^\top$. Finalement, $m_{3,2} = \frac{5}{2}$ et donc $A^{(2)}$ est donnée par :

$$A^{(2)} = \begin{bmatrix} 4 & 8 & 12 \\ 0 & 2 & 4 \\ 0 & 5 - \frac{5}{2}2 & 12 - \frac{5}{2}4 \end{bmatrix} = \begin{bmatrix} 4 & 8 & 12 \\ 0 & 2 & 4 \\ 0 & 0 & 2 \end{bmatrix}.$$

Le vecteur $b^{(2)}$ est quant à lui donné par $b^{(2)} = [4, 2, 9 - \frac{5}{2}2]^\top = [4, 2, 4]^\top$.

Par substitution rétrograde, nous déterminons donc :

$$\begin{aligned} x_3 &= \frac{1}{2}4 = 2 \\ x_2 &= \frac{1}{2}(2 - 4x_3) = 1 - 4 = -3 \\ x_1 &= \frac{1}{4}(4 - 8x_2 - 12x_3) = 1 - 2(-3) - 3 \cdot 2 = 1. \end{aligned}$$

Exercice 5.3. Résolvez le système suivant avec la méthode de Gauss en arithmétique flottante pour $b = 10$ et $t = 3$:

$$\begin{bmatrix} 10^{-4} & 1 \\ 1 & 1 \end{bmatrix} x = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Faites pareil en échangeant les deux lignes.

Résolution. $m_{2,1} = 10^4$, donc :

$$\text{fl}(A^{(1)}) = \begin{bmatrix} \text{fl}(10^{-4}) & \text{fl}(1) \\ \text{fl}(1 - 10^4 10^{-4}) & \text{fl}(1 - 10^4) \end{bmatrix} = \begin{bmatrix} 10^{-4} & 1 \\ 0 & -10^4 \end{bmatrix},$$

et $\text{fl}(b^{(1)}) = [\text{fl}(1), \text{fl}(2 - 10^4)]^\top = [1, -10^4]^\top$. Dès lors, par substitution rétrograde :

$$\begin{aligned} x_2 &= \text{fl}\left(\frac{-10^4}{-10^4}\right) = 1 \\ x_1 &= \text{fl}(10^4(1 - 1)) = 0. \end{aligned}$$

Cependant cette "solution" est loin d'en être une :

$$Ax = \begin{bmatrix} 10^{-4} \times 0 + 1 \times 1 \\ 1 \times 0 + 1 \times 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \end{bmatrix} \neq b.$$

Si nous procédons dans l'autre sens, nous voulons résoudre le système :

$$\begin{bmatrix} 1 & 1 \\ 10^{-4} & 1 \end{bmatrix} \begin{bmatrix} x_2 \\ x_1 \end{bmatrix} = \begin{bmatrix} 2 \\ 1 \end{bmatrix}.$$

$m_{2,1}$ vaut donc 10^{-4} , et donc :

$$A^{(1)} = \begin{bmatrix} 1 & 1 \\ 10^{-4} - 10^{-4} \cdot 1 & \text{fl}(1 - 10^{-4} \cdot 1) \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix},$$

et $b^{(1)} = [2, \text{fl}(1 - 10^{-4} \cdot 1)]^\top = [2, 1]^\top$. Dès lors, par substitution rétrograde :

$$\begin{aligned}x_1 &= 1 \\x_2 &= 2 - 1 \cdot 1 = 1.\end{aligned}$$

Cette solution est déjà beaucoup plus proche de la *vraie* solution :

$$Ax = \begin{bmatrix} 10^{-4} + 1 \\ 1 + 1 \end{bmatrix} = \begin{bmatrix} 1.0001 \\ 2 \end{bmatrix} \approx b.$$

De plus, si nous regardons la solution de ce système, nous obtenons :

$$x^* = \frac{1}{9\,999} \begin{bmatrix} 10\,000 \\ 9\,998 \end{bmatrix}$$

et $\text{fl}(x^*) = [1, 1]^\top$.

Exercice 5.4. Résolvez les systèmes suivantes avec la méthode de Gauss et pivot partiel :

1.

$$\begin{bmatrix} -1 & 2 & 1 \\ 1 & 4 & -3 \\ -2 & 0 & 1 \end{bmatrix} x = \begin{bmatrix} 5 \\ -8 \\ 5 \end{bmatrix}$$

2.

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & 1 \\ 3 & 6 & -2 \end{bmatrix} x = \begin{bmatrix} 2 \\ 7 \\ 7 \end{bmatrix}$$

3.

$$\begin{bmatrix} 1 & -1 & 1 \\ 2 & 1 & -1 \\ 1 & 2 & -2 \end{bmatrix} x = \begin{bmatrix} 0 \\ -3 \\ -2 \end{bmatrix}$$

4.

$$\begin{bmatrix} 2 & -3 & 2 & 5 \\ 1 & -1 & 1 & 2 \\ 3 & 2 & 2 & 1 \\ 1 & 1 & -3 & -1 \end{bmatrix} x = \begin{bmatrix} 3 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

Résolution. Pour le premier système, commençons à pivoter les lignes 1 et 3 car la ligne 3 maximise (en valeur absolue) l'entrée de la première colonne, ce qui donne :

$$\begin{bmatrix} -2 & 0 & 1 \\ 1 & 4 & -3 \\ -1 & 2 & 1 \end{bmatrix} x = \begin{bmatrix} 5 \\ -8 \\ 5 \end{bmatrix}.$$

Les coefficients sont $m_{21} = \frac{-1}{2}$ et $m_{31} = \frac{1}{2}$. Après la première étape, nous obtenons :

$$\begin{bmatrix} -2 & 0 & 1 \\ 0 & 4 & -5/2 \\ 0 & 2 & 1/2 \end{bmatrix} x = \begin{bmatrix} 5 \\ 11/2 \\ 5/2 \end{bmatrix}.$$

Pour la deuxième étape, le coefficient nécessaire est $m_{32} = \frac{1}{2}$, et donc :

$$\begin{bmatrix} -2 & 0 & 1 \\ 0 & 4 & -5/2 \\ 0 & 0 & 7/4 \end{bmatrix} x = \begin{bmatrix} 5 \\ -11/2 \\ 21/4 \end{bmatrix}.$$

Par substitution rétrograde, nous trouvons :

$$\begin{aligned} x_3 &= \frac{4}{7} \cdot \frac{21}{4} = 3 \\ x_2 &= \frac{1}{4} \cdot \left(\frac{-11}{2} + \frac{5}{2} \cdot 3 \right) = \frac{1}{4} \cdot \frac{4}{2} = \frac{1}{2} \\ x_1 &= \frac{-1}{2} \cdot (5 - 3) = -1. \end{aligned}$$

La solution est donc $x^* = [-1, \frac{1}{2}, 3]^\top$.

Le second système a un problème : il y a de la redondance entre les équations. On peut voir qu'en prenant 3 fois la dernière égalité et en retirant 7 fois la première égalité, on obtient la deuxième :

$$3(3x_1 + 6x_2 - 2x_3) - 7(x_1 + 2x_2 - x_3) = 3 \times 7 - 7 \times 2$$

donne bien :

$$2x_1 + 4x_2 + x_3 = 7,$$

qui est la deuxième équation. De manière équivalente, on aurait pu remarquer que la deuxième colonne de A est un multiple de la première. Le système est donc sous-déterminé et admet tout vecteur de la forme $x = [3 - 2\beta, \beta, 1]^\top$ comme solution.

En appliquant la méthode de Gauss avec pivot ici, nous commencerions par échanger la première et la dernière ligne de la matrice A (pareil dans b) pour obtenir le système équivalent suivant :

$$\begin{bmatrix} 3 & 6 & -2 \\ 2 & 4 & 1 \\ 1 & 2 & -1 \end{bmatrix} x = \begin{bmatrix} 7 \\ 7 \\ 2 \end{bmatrix}.$$

Le coefficients sont alors $m_{21} = \frac{2}{3}$ et $m_{31} = \frac{1}{3}$, ce qui donne :

$$\begin{bmatrix} 3 & 6 & -2 \\ 0 & 0 & 7/3 \\ 0 & 0 & -1/3 \end{bmatrix} x = \begin{bmatrix} 7 \\ 7/3 \\ -1/3 \end{bmatrix}.$$

On voit bien que la 2e colonne de la matrice, en-dessous de la diagonale, est entièrement nulle, ce qui veut dire que le système est sous-déterminé. Il est également possible d'évaluer le déterminant de A qui est nul, mais nous ne pouvons pas exclure la possibilité que le système est insoluble avec cette information seule.

Concernant le troisième système, il faut commencer par intervertir les deux premières lignes :

$$\begin{bmatrix} 2 & 1 & -1 \\ 1 & -1 & 1 \\ 1 & 2 & -2 \end{bmatrix} x = \begin{bmatrix} -3 \\ 0 \\ 2 \end{bmatrix}.$$

Les coefficients sont alors $m_{21} = \frac{1}{2} = m_{31}$ et donc le système devient :

$$\begin{bmatrix} 2 & 1 & -1 \\ 0 & -3/2 & 3/2 \\ 0 & 3/2 & -3/2 \end{bmatrix} x = \begin{bmatrix} -3 \\ 3/2 \\ -1/2 \end{bmatrix}.$$

Il n'y a pas besoin de pivoter à ce stade-là car les seules entrées d'intérêt valent $3/2$ en valeur absolue. Le dernier coefficient est $m_{32} = -1$, et le système devient alors :

$$\begin{bmatrix} 2 & 1 & -1 \\ 0 & -3/2 & 3/2 \\ 0 & 0 & 0 \end{bmatrix} x = \begin{bmatrix} -3 \\ 3/2 \\ 1 \end{bmatrix}.$$

Puisque tous les coefficients de la dernière ligne sont à 0, mais que l'entrée associée dans b est non-nulle, nous savons que le système n'admet pas de solution.

Finalement, pour le dernier système, la première étape est d'échanger la première et la troisième ligne (pour le pivot) :

$$\begin{bmatrix} 3 & 2 & 2 & 1 \\ 1 & -1 & 1 & 2 \\ 2 & -3 & 2 & 5 \\ 1 & 1 & -3 & -1 \end{bmatrix} x = \begin{bmatrix} 0 \\ 1 \\ 3 \\ 0 \end{bmatrix}.$$

Les coefficients sont $m_{21} = \frac{1}{3}$, $m_{31} = \frac{2}{3}$ et $m_{41} = \frac{1}{3}$, et le système devient :

$$\begin{bmatrix} 3 & 2 & 2 & 1 \\ 0 & -5/3 & 1/3 & 5/3 \\ 0 & -13/3 & 2/3 & 13/3 \\ 0 & 1/3 & -11/3 & -4/3 \end{bmatrix} x = \begin{bmatrix} 0 \\ 1 \\ 3 \\ 0 \end{bmatrix}.$$

Il faut ensuite échanger les lignes 2 et 3 afin d'avoir $-13/3$ sur la diagonale :

$$\begin{bmatrix} 3 & 2 & 2 & 1 \\ 0 & -13/3 & 2/3 & 13/3 \\ 0 & -5/3 & 1/3 & 5/3 \\ 0 & 1/3 & -11/3 & -4/3 \end{bmatrix} x = \begin{bmatrix} 0 \\ 3 \\ 1 \\ 0 \end{bmatrix}.$$

Les coefficients sont $m_{32} = \frac{5}{13}$ et $m_{42} = \frac{-1}{13}$, le système devient donc :

$$\begin{bmatrix} 3 & 2 & 2 & 1 \\ 0 & -13/3 & 2/3 & 13/3 \\ 0 & 0 & 1/13 & 0 \\ 0 & 0 & -47/13 & -1 \end{bmatrix} x = \begin{bmatrix} 0 \\ 3 \\ -2/13 \\ 3/13 \end{bmatrix}.$$

Pour finir, il faut encore faire pivoter les deux dernières lignes :

$$\begin{bmatrix} 3 & 2 & 2 & 1 \\ 0 & -13/3 & 2/3 & 13/3 \\ 0 & 0 & -47/13 & -1 \\ 0 & 0 & 1/13 & 0 \end{bmatrix} x = \begin{bmatrix} 0 \\ 3 \\ 3/13 \\ -2/13 \end{bmatrix}$$

et trouver le dernier coefficient $m_{43} = \frac{-1}{47}$ pour obtenir le système :

$$\begin{bmatrix} 3 & 2 & 2 & 1 \\ 0 & -13/3 & 2/3 & 13/3 \\ 0 & 0 & -47/13 & -1 \\ 0 & 0 & 0 & -1/47 \end{bmatrix} x = \begin{bmatrix} 0 \\ 3 \\ 3/13 \\ -7/47 \end{bmatrix}.$$

Il reste à résoudre le système par substitution rétrograde :

$$x_4 = 7$$

$$x_3 = \frac{-13}{47} \left(\frac{3}{13} + 7 \right) = -2$$

$$x_2 = \frac{-3}{13} \left(3 + \frac{4}{3} - \frac{91}{3} \right) = 6$$

$$x_1 = \frac{1}{3} (-12 + 4 - 7) = -5$$

Séance 6 — Résolution de systèmes linéaires par factorisation

Rappel théorique

Factorisation LU

Observons que $\det(AB) = \det A \det B$ pour toutes matrices carrées A et B . Dès lors, si $\det A$ et $\det B$ sont *faciles* à calculer, le déterminant de AB devient également simple à déterminer. Dans l'autre sens, si en partant d'une matrice A , on peut la factoriser en le produit $A = LU$, telles que $\det L$ et $\det U$ sont faciles à calculer, alors $\det A$ devient également facile à calculer. En particulier, si L et U sont triangulaires, le déterminant de A est également facile à calculer puisque le déterminant d'une matrice triangulaire est simplement le produit des éléments sur sa diagonale.

Une autre justification pour l'intérêt de la factorisation LU est de réaliser que lors de l'élimination de Gauss faite au TP précédent, seule la matrice A nous intéresse, le vecteur b est modifié également, mais ses valeurs ne sont utilisées que lors de la résolution. Dès lors, s'il y a plusieurs systèmes linéaires à résoudre à la suite les uns des autres, mais partageant la même matrice de coefficients, il est plus intéressant de faire cette factorisation une seule fois, et de résoudre les systèmes ensuite.

En effet, l'algorithme de Gauss fournit une matrice triangulaire supérieure U et un vecteur b' tels que (U, b') et (A, b) sont équivalents. Il est possible de voir que toutes les étapes exécutées pendant cette élimination sont en réalité des opérations linéaires dont la matrice associée est triangulaire inférieure atomique. L'inverse de cette matrice est elle-même triangulaire inférieure et ses entrées ne sont autres que les coefficients $m_{i,j}$. Dès lors, si nous appelons cette matrice L , nous avons le système $LUx = b$, qui peut être résolu en résolvant d'abord le système $Ly = b$ et puis le système $Ux = y$.

De manière générale, une factorisation LU d'une matrice A consiste en le fait de déterminer deux matrices L et U (respectivement triangulaire inférieure et triangulaire supérieure) telles que $A = LU$, i.e. :

$$\begin{bmatrix} \ell_{11} & 0 & \dots & 0 \\ \ell_{21} & \ell_{22} & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \ell_{n1} & \ell_{n2} & \dots & \ell_{nn} \end{bmatrix} \begin{bmatrix} u_{11} & u_{12} & \dots & u_{1n} \\ 0 & u_{22} & \dots & u_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & u_{nn} \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}$$

Les matrices L et U ont chacune $\binom{n+1}{2} = \frac{n(n+1)}{2}$ variables libres, et A a n^2 entrées. Intuitivement pour trouver une solution unique à ces n^2 équations à $2\binom{n+1}{2} = n(n+1) = n^2 + n$ inconnues, il faut en fixer n .

L'approche de Doolittle est de fixer les entrées diagonales de L à 1 (i.e. $\ell_{ii} = 1$ pour $1 \leq i \leq n$), et l'approche de Crout est de procéder de la même manière mais sur U (i.e. $u_{ii} = 1$ pour $1 \leq i \leq n$).

L'algorithme de Doolittle utilise donc l'équation suivante :

$$a_{i,j} = (A)_{i,j} = (LU)_{i,j} = \sum_{k=1}^n \ell_{i,k} u_{k,j} = \sum_{k=1}^{\min\{i,j\}} \ell_{i,k} u_{k,j},$$

où la dernière égalité vient du fait que $\ell_{i,k} = 0$ si $k > i$ et $u_{k,j} = 0$ si $k > j$. Il faut utiliser ces égalités dans le bon ordre afin de trouver les coefficients :

- Pour $k \in \{1, \dots, n\}$:
- Calculer la ligne k de U via l'équation :

$$u_{k,j} = a_{k,j} - \sum_{t=1}^{k-1} \ell_{k,t} u_{t,j}$$

- Calculer la colonne k de L via l'équation :

$$\ell_{i,k} = \frac{1}{u_{k,k}} \left[a_{i,k} - \sum_{t=1}^{k-1} \ell_{i,t} u_{t,k} \right]$$

Factorisation de Cholesky

Une matrice $A \in \mathbb{R}^{n \times n}$ est dite *définie positive* (resp. *semi définie positive*) si pour tout vecteur $v \in \mathbb{R}^n$, l'inégalité suivante est vérifiée : $v^\top A v > 0$ (resp. $v^\top A v \geq 0$).

Théorème 3. Une matrice $A \in \mathbb{R}^{n \times n}$ est symétrique et définie positive (resp. semidéfinie positive) si et seulement si elle admet une décomposition $H^\top H$, où H est une matrice triangulaire supérieure dont tous les éléments diagonaux sont strictement positifs (resp. positifs).

À nouveau, cette décomposition permet de résoudre les systèmes linéaires $Ax = b$ en utilisant le fait que $A = H^\top H$. Il faut donc d'abord résoudre $H^\top y = b$ et ensuite $Hx = y$.

La décomposition peut se faire de la manière suivante :

- Pour $i \in \{1, \dots, n\}$:
- Calculer $h_{i,i}$ via l'équation :

$$h_{i,i} = \sqrt{a_{i,i} - \sum_{k=1}^{i-1} h_{k,i}^2}$$

- calculer le reste de la i ème ligne via l'équation (pour $j > i$) :

$$h_{i,j} = \frac{1}{h_{i,i}} \left[a_{i,j} - \sum_{k=1}^{i-1} h_{k,i} h_{k,j} \right].$$

Algorithmes de Jacobi et de Gauss-Seidel

Les algorithmes itératifs ont pour objectif de partir d'une solution initiale $x^{(0)}$ et de la raffiner itérativement. L'objectif est bien sûr d'arriver à une solution au problème posé. Les méthodes linéaires se basent sur $x^{(0)}$ et calculent itérativement les vecteurs $x^{(k+1)}$ satisfaisant une relation sous la forme :

$$Px^{(k+1)} = Nx^{(k)} + b,$$

où $P, N \in \mathbb{R}^{n \times n}$ sont des matrices de coefficients qui dépendent de A .

La méthode de Jacobi consiste à résoudre :

$$Dx^{(k+1)} = (D - A)x^{(k)} + b,$$

pour $D = \text{diag}(A)$, ce qui peut se faire itérativement par la formule (pour $i \in \{1, \dots, n\}$) :

$$x_i^{(k+1)} = \frac{1}{a_{i,i}} \left[b_i - \sum_{j \neq i} a_{i,j} x_j^{(k)} \right].$$

La méthode de Gauss-Seidel part de la même idée mais utilise les *meilleures* estimations $x_j^{(k+1)}$ à la place de $x_j^{(k)}$ si celles-ci ont déjà été calculées :

$$x_i^{(k+1)} = \frac{1}{a_{i,i}} \left[b_i - \sum_{j=1}^{i-1} a_{i,j} x_j^{(k+1)} - \sum_{j=i+1}^n a_{i,j} x_j^{(k)} \right].$$

Ceci correspond bien au formalisme présenté ci-dessus puisque :

$$(D - E)x^{(k+1)} = Fx^{(k)} + b,$$

où E est la négation de la matrice strictement triangulaire inférieure de A alors que F est la négation de la matrice strictement triangulaire supérieure de A (qui satisfont donc l'égalité $D - A = E + F$).

Conditionnement

Le p -conditionnement d'une matrice A est donné par le produit :

$$\kappa_p(A) := \|A\|_p \cdot \|A^{-1}\|_p,$$

où :

$$\|A\|_p := \sup_{\|x\|_p=1} \|Ax\|_p$$

pour une matrice A et :

$$\|x\|_p := \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

pour un vecteur x .

Notez que :

$$\begin{aligned} \|A\|_1 &= \max_{1 \leq j \leq n} \sum_{i=1}^n |a_{i,j}| \\ \|A\|_\infty &= \max_{1 \leq i \leq n} \sum_{j=1}^n |a_{i,j}| = \|A^\top\|_1. \end{aligned}$$

Notez également que si $A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$ est une matrice inversible, alors son inverse est donnée par :

$$A^{-1} = \frac{1}{ad - bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}.$$

En effet :

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} = \begin{bmatrix} ad - bc & -ab + ab \\ -bc + bc & -bc + ad \end{bmatrix} = (ad - bc) \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}.$$

Exercice 6.1. Réutilisez le système :

$$\begin{bmatrix} 4 & 8 & 12 \\ 3 & 8 & 13 \\ 2 & 9 & 18 \end{bmatrix} x = \begin{bmatrix} 4 \\ 5 \\ 11 \end{bmatrix},$$

et donnez sa décomposition LU en utilisant la résolution du système par Gauss du TP précédent.

Résolution. Nous savons que la matrice L est donnée par :

$$\ell_{i,j} = \begin{cases} 0 & \text{si } i < j \\ 1 & \text{si } i = j \\ m_{i,j} & \text{si } i > j. \end{cases}$$

Dès lors puisque les coefficients ont été déterminés dans l'**Exercice 5.2**, nous savons que :

$$A = LU = \begin{bmatrix} 1 & 0 & 0 \\ \frac{3}{4} & 1 & 0 \\ \frac{1}{2} & \frac{5}{2} & 1 \end{bmatrix} \begin{bmatrix} 4 & 8 & 12 \\ 0 & 2 & 4 \\ 0 & 0 & 2 \end{bmatrix}.$$

Exercice 6.2. Résolvez le système suivant avec la méthode de Doolittle :

$$\begin{bmatrix} 4 & 3 & 2 & 1 \\ 3 & 4 & 3 & 2 \\ 2 & 3 & 4 & 3 \\ 1 & 2 & 3 & 4 \end{bmatrix} x = \begin{bmatrix} 1 \\ 1 \\ -1 \\ -1 \end{bmatrix}$$

Résolution. Nous allons procéder ici de manière vectorielle pour gagner du temps. Déterminons dans un premier temps la première ligne de U :

$$U_{1,\cdot} = A_{1,\cdot} = [4, 3, 2, 1].$$

Trouvons ensuite la première colonne de L grâce à ces valeurs (où nous commençons à l'indice 2 puisque l'indice 1 est sur la diagonale et donc vaut 1) :

$$L_{\cdot,1} = \frac{1}{u_{1,1}} (A_{\cdot,1}) = \frac{1}{4} [3, 2, 1]^\top = \frac{1}{4} \begin{bmatrix} 3 \\ 2 \\ 1 \end{bmatrix}.$$

Passons ensuite à la deuxième ligne de U (où à nouveau nous commençons à l'indice 2 puisque U doit être triangulaire supérieure) :

$$U_{2,\cdot} = A_{2,\cdot} - \ell_{2,1} U_{1,\cdot} = [4, 3, 2] - \frac{3}{4} [3, 2, 1] = \frac{1}{4} [7, 6, 5].$$

La deuxième colonne de L est donnée par :

$$L_{\cdot,2} = \frac{1}{u_{2,2}} (A_{\cdot,2} - L_{\cdot,1}u_{1,2}) = \frac{4}{7} \left([3, 2]^\top - \frac{3}{4}[2, 1]^\top \right) = \frac{1}{7}[6, 5]^\top = \frac{1}{7} \begin{bmatrix} 6 \\ 5 \end{bmatrix}.$$

Pour la troisième ligne de U :

$$U_{3,\cdot} = A_{3,\cdot} - \ell_{3,1}U_{1,\cdot} - \ell_{3,2}U_{2,\cdot} = [4, 3] - \frac{1}{2}[2, 1] - \frac{3}{14}[6, 5] = \frac{1}{7}[12, 10].$$

La troisième colonne de L ne contient que l'élément $\ell_{4,3}$ qui vaut :

$$\ell_{4,3} = \frac{1}{u_{3,3}} (a_{4,3} - \ell_{4,1}u_{1,3} - \ell_{4,2}u_{2,3}) = \frac{7}{12} \left(3 - \frac{1}{4}2 - \frac{5}{7}2 \right) = \frac{5}{6}.$$

Finalement, l'entrée $u_{4,4}$ est donnée par :

$$u_{4,4} = a_{4,4} - \ell_{4,1}u_{1,4} - \ell_{4,2}u_{2,4} - \ell_{4,3}u_{3,4} = 4 - \frac{1}{4}1 - \frac{5}{7}\frac{5}{4} - \frac{5}{6}\frac{10}{7} = \frac{5}{3}.$$

La factorisation LU est donc donnée par :

$$A = \begin{bmatrix} 1 & 0 & 0 & 0 \\ \frac{3}{4} & 1 & 0 & 0 \\ \frac{1}{2} & \frac{6}{7} & 1 & 0 \\ \frac{1}{4} & \frac{5}{7} & \frac{5}{6} & 1 \end{bmatrix} \begin{bmatrix} 4 & 3 & 2 & 1 \\ 0 & \frac{7}{4} & \frac{3}{2} & \frac{5}{4} \\ 0 & 0 & \frac{12}{7} & \frac{10}{7} \\ 0 & 0 & 0 & \frac{5}{3} \end{bmatrix}.$$

La vérification de la validité de la factorisation vous est laissée en exercice.

Maintenant nous devons d'abord résoudre le problème $Ly = b$ et ensuite résoudre le problème $Ux = y$. La solution y peut se trouver par substitution progressive :

$$\begin{aligned} y_1 &= 1 \\ y_2 &= 1 - \frac{3}{4} = \frac{1}{4} \\ y_3 &= -1 - \frac{1}{2} - \frac{3}{14} = \frac{-12}{7} \\ y_4 &= -1 - \frac{1}{4} - \frac{5}{28} + \frac{10}{7} = 0. \end{aligned}$$

Pour finir, la solution x peut être trouvée par substitution rétrograde :

$$\begin{aligned} x_4 &= \frac{y_4}{u_{4,4}} = 0 \\ x_3 &= \frac{1}{u_{3,3}} (y_3 - u_{3,4}x_4) = -1 \\ x_2 &= \frac{1}{u_{2,2}} (y_2 - u_{2,3}x_3 - u_{2,4}x_4) = \frac{4}{7} \left(\frac{1}{4} + \frac{3}{2} \right) = 1 \\ x_1 &= \frac{1}{u_{1,1}} (y_1 - u_{1,2}x_2 - u_{1,3}x_3 - u_{1,4}x_4) = \frac{1}{4} (1 - 3 + 2) = 0. \end{aligned}$$

La solution est donc $x^* = [0, 1, -1, 0]^\top$, ce que nous pouvons vérifier par :

$$Ax^* = A_{\cdot,2} - A_{\cdot,3} = \begin{bmatrix} 3 \\ 4 \\ 3 \\ 2 \end{bmatrix} - \begin{bmatrix} 2 \\ 3 \\ 4 \\ 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ -1 \\ -1 \end{bmatrix} = b.$$

Exercice 6.3. Résolvez le système suivant avec la méthode de Cholesky :

$$\begin{bmatrix} 3 & 1 & 0 & 0 \\ 1 & 3 & 1 & 0 \\ 0 & 1 & 3 & 1 \\ 0 & 0 & 1 & 3 \end{bmatrix} x = \begin{bmatrix} 1 \\ 0 \\ 0 \\ 0 \end{bmatrix}$$

Résolution. Commençons par factoriser la matrice A donnée. Appliquons l'algorithme de factorisation de Cholesky. La première ligne est donnée par :

- $h_{1,1} = \sqrt{3}$;
- $h_{1,2} = \frac{1}{\sqrt{3}}(1 - 0) = \frac{1}{\sqrt{3}}$;
- $h_{1,3} = h_{1,4} = 0$.

La deuxième ligne est donnée par :

- $h_{2,2} = \sqrt{3 - \frac{1}{3}} = \sqrt{\frac{8}{3}}$;
- $h_{2,3} = \sqrt{\frac{3}{8}}(1 - h_{1,2}h_{1,3}) = \sqrt{\frac{3}{8}}$;
- $h_{2,4} = 0$.

La troisième ligne est donnée par :

- $h_{3,3} = \sqrt{3 - \frac{3}{8}} = \sqrt{\frac{21}{8}}$;
- $h_{3,4} = \sqrt{\frac{8}{21}}(1 - h_{1,3}h_{1,4} - h_{2,3}h_{2,4}) = \sqrt{\frac{8}{21}}$.

Finalement la dernière ligne contient uniquement $h_{4,4} = \sqrt{3 - \frac{8}{21}} = \sqrt{\frac{55}{21}}$. La matrice H est donc :

$$H = \begin{bmatrix} \sqrt{3} & \frac{1}{\sqrt{3}} & 0 & 0 \\ 0 & \sqrt{\frac{8}{3}} & \sqrt{\frac{3}{8}} & 0 \\ 0 & 0 & \sqrt{\frac{21}{8}} & \sqrt{\frac{8}{21}} \\ 0 & 0 & 0 & \sqrt{\frac{55}{21}} \end{bmatrix}.$$

Nous pouvons le vérifier par :

$$H^T H = \begin{bmatrix} \sqrt{3}^2 & \sqrt{\frac{3}{3}} & 0 & 0 \\ \sqrt{\frac{3}{3}} & \frac{1}{3} + \frac{8}{3} & \sqrt{\frac{24}{24}} & 0 \\ 0 & \sqrt{\frac{24}{24}} & \frac{3}{8} + \frac{21}{8} & \sqrt{\frac{168}{168}} \\ 0 & 0 & \sqrt{\frac{168}{168}} & \frac{8}{21} + \frac{55}{21} \end{bmatrix} = \begin{bmatrix} 3 & 1 & 0 & 0 \\ 1 & 3 & 1 & 0 \\ 0 & 1 & 3 & 1 \\ 0 & 0 & 1 & 3 \end{bmatrix} = A.$$

Maintenant trouvons y tel que $H^T y = b$ par substitution progressive :

$$\begin{aligned} y_1 &= \frac{1}{\sqrt{3}} \\ y_2 &= \sqrt{\frac{3}{8}} \left(0 - \frac{1}{\sqrt{3}} \frac{1}{\sqrt{3}} \right) = \frac{-1}{\sqrt{24}} \\ y_3 &= \sqrt{\frac{8}{21}} \left(0 - \sqrt{\frac{3}{8}} \frac{-1}{\sqrt{24}} \right) = \frac{1}{\sqrt{168}} \\ y_4 &= \sqrt{\frac{21}{55}} \left(0 - \sqrt{\frac{8}{21}} \frac{1}{\sqrt{168}} \right) = \frac{-1}{\sqrt{1155}}. \end{aligned}$$

Finalement trouvons x tel que $Hx = y$ par substitution rétrograde :

$$\begin{aligned}x_4 &= \sqrt{\frac{21}{55}} \frac{-1}{\sqrt{1155}} = \frac{-1}{55} \\x_3 &= \sqrt{\frac{8}{21}} \left(\frac{1}{\sqrt{168}} - \sqrt{\frac{8}{21}} \frac{-1}{55} \right) = \frac{8}{21} \left(\frac{1}{8} + \frac{1}{55} \right) = \frac{3}{55} \\x_2 &= \sqrt{\frac{3}{8}} \left(\frac{-1}{\sqrt{24}} - \sqrt{\frac{3}{8}} \frac{3}{55} \right) = \frac{3}{8} \left(-\frac{1}{3} - \frac{3}{55} \right) = \frac{-8}{55} \\x_1 &= \sqrt{\frac{1}{3}} \left(\sqrt{\frac{1}{3}} - \sqrt{\frac{1}{3}} \frac{-8}{55} \right) = \frac{1}{3} \left(1 + \frac{8}{55} \right) = \frac{21}{55}.\end{aligned}$$

Nous avons dès lors trouvé la solution $x^* = \frac{1}{55}[21, -8, 3, -1]^\top$. Nous pouvons vérifier que cette solution en est bien une :

$$Ax^* = \frac{1}{55} \begin{bmatrix} 3 & 1 & 0 & 0 \\ 1 & 3 & 1 & 0 \\ 0 & 1 & 3 & 1 \\ 0 & 0 & 1 & 3 \end{bmatrix} \begin{bmatrix} 21 \\ -8 \\ 3 \\ -1 \end{bmatrix} = \frac{1}{55} \begin{bmatrix} 63 - 8 \\ 21 - 24 + 3 \\ -8 + 9 - 1 \\ 3 - 3 \end{bmatrix} = \frac{1}{55} \begin{bmatrix} 55 \\ 0 \\ 0 \\ 0 \end{bmatrix} = b.$$

Exercice 6.4. Soit le système suivant :

$$\begin{bmatrix} 7 & 10 \\ 5 & 7 \end{bmatrix} x = b.$$

Résolvez-le pour $b = [1, 0.7]^\top$ et pour $b = [1.01, 0.69]^\top$. Qu'en déduisez-vous du conditionnement de la matrice ? Que valent κ_1 et κ_∞ ?

Résolution. Nous savons que $A^{-1}b$ donne la solution au système $Ax = b$, or ici A est de dimension 2×2 donc est facile à inverser. De plus, puisque $A = \begin{bmatrix} 7 & 10 \\ 5 & 7 \end{bmatrix}$, son inverse est $A^{-1} = \frac{1}{49-50} \begin{bmatrix} 7 & -10 \\ -5 & 7 \end{bmatrix}$. Nous savons donc que pour $b_1 = [1, 0.7]^\top$, la solution est donnée par :

$$x_1 = \begin{bmatrix} -7 & 10 \\ 5 & -7 \end{bmatrix} \begin{bmatrix} 1 \\ 0.7 \end{bmatrix} = \begin{bmatrix} -7 + 7 \\ 5 - 4.9 \end{bmatrix} = \begin{bmatrix} 0 \\ 0.1 \end{bmatrix}.$$

De même, pour $b_2 = [1.01, 0.69]^\top$, la solution est donnée par :

$$x_2 = \begin{bmatrix} -7 & 10 \\ 5 & -7 \end{bmatrix} \begin{bmatrix} 1.01 \\ 0.69 \end{bmatrix} = \begin{bmatrix} -7.07 + 6.9 \\ 5.05 - 4.83 \end{bmatrix} = \begin{bmatrix} -0.17 \\ 0.22 \end{bmatrix}.$$

Une petite variation sur b a amené une plus grosse différence sur x . Nous en déduisons que la matrice A est très certainement mal conditionnée. En effet, la variation δb est de l'ordre de 10^{-2} alors que la variation δx est de l'ordre de 10^{-1} . Plus précisément, si nous regardons $\|A\|_1 = \|A^{-1}\|_1 = \|A\|_\infty = \|A^{-1}\|_\infty = 17$, nous déduisons que :

$$\kappa_1(A) = \kappa_\infty(A) = 17^2 = 289.$$

En effet, la matrice est mal conditionnée.

Exercice 6.5. Estimez une solution au système suivant avec (1) la méthode de Jacobi et (2) la méthode de Gauss-Seidel en prenant $x^{(0)} = [0, 0, 0]^\top$ comme solution initiale en effectuant 3 itérations :

$$\begin{bmatrix} 10 & -2 & 1 \\ -2 & 10 & -2 \\ -2 & -5 & 10 \end{bmatrix} x = \begin{bmatrix} 9 \\ 12 \\ 18 \end{bmatrix}.$$

Résolution. Regardons une approximation avec l'algorithme de Jacobi.

Puisqu'on commence avec $x^{(0)} = 0$, nous savons que :

$$x^{(1)} = D^{-1}b = \begin{bmatrix} \frac{1}{10} & 0 & 0 \\ 0 & \frac{1}{10} & 0 \\ 0 & 0 & \frac{1}{10} \end{bmatrix} b = \frac{1}{10} b = \begin{bmatrix} 0.9 \\ 1.2 \\ 1.8 \end{bmatrix}.$$

Ensuite, pour trouver les itérations suivantes, utilisons la formule :

$$x^{(2)} = \begin{bmatrix} x_1^{(2)} \\ x_2^{(2)} \\ x_3^{(2)} \end{bmatrix} = \frac{1}{10} \begin{bmatrix} 9 - (-2)x_2^{(1)} - 1x_3^{(1)} \\ 12 - (-2)x_1^{(1)} - (-2)x_3^{(1)} \\ 18 - (-2)x_1^{(1)} - (-5)x_2^{(1)} \end{bmatrix} = \frac{1}{10} \begin{bmatrix} 9 + 2.4 - 1.8 \\ 12 + 1.8 + 3.6 \\ 18 + 1.8 + 6 \end{bmatrix} = \begin{bmatrix} 0.96 \\ 1.74 \\ 2.58 \end{bmatrix}.$$

L'itération finale est donnée par :

$$x^{(3)} = \begin{bmatrix} x_1^{(3)} \\ x_2^{(3)} \\ x_3^{(3)} \end{bmatrix} = \frac{1}{10} \begin{bmatrix} 9 - (-2)x_2^{(2)} - 1x_3^{(2)} \\ 12 - (-2)x_1^{(2)} - (-2)x_3^{(2)} \\ 18 - (-2)x_1^{(2)} - (-5)x_2^{(2)} \end{bmatrix} = \frac{1}{10} \begin{bmatrix} 9 + 3.48 - 2.58 \\ 12 + 1.92 + 5.16 \\ 18 + 1.92 + 8.7 \end{bmatrix} = \begin{bmatrix} 0.99 \\ 1.908 \\ 2.862 \end{bmatrix}.$$

Regardons maintenant une approximation avec l'algorithme de Gauss-Seidel.

La première itération est donnée par :

$$\begin{aligned} x_1^{(1)} &= \frac{1}{10} 9 = 0.9 \\ x_2^{(1)} &= \frac{1}{10} (12 + 2 \cdot 0.9) = 1.38 \\ x_3^{(1)} &= \frac{1}{10} (18 + 2 \cdot 0.9 + 5 \cdot 1.38) = 2.67 \end{aligned}$$

La seconde itération est donnée par :

$$\begin{aligned} x_1^{(2)} &= \frac{1}{10} (9 + 2 \cdot 1.38 - 2.67) = 0.909 \\ x_2^{(2)} &= \frac{1}{10} (12 + 2 \cdot 0.909 + 2 \cdot 2.67) = 1.9158 \\ x_3^{(2)} &= \frac{1}{10} (18 + 2 \cdot 0.909 + 5 \cdot 1.9158) = 2.9397 \end{aligned}$$

La troisième itération est donnée par :

$$\begin{aligned} x_1^{(3)} &= \frac{1}{10} (9 + 2 \cdot 1.9158 - 2.9397) = 0.98919 \\ x_2^{(3)} &= \frac{1}{10} (12 + 2 \cdot 0.98919 + 2 \cdot 2.9397) = 1.985778 \end{aligned}$$

$$x_3^{(3)} = \frac{1}{10} (18 + 2 \cdot 0.9819 + 5 \cdot 1.985778) = 2.989269$$

On peut voir qu'après 3 itérations, l'erreur avec Jacobi est $[.01, .092, .138]^\top$, alors qu'elle est de $\approx [.011, .014, .011]^\top$ avec Gauss-Seidel. Cet algorithme converge donc plus vite sur cet exemple (et converge plus rapidement de manière générale).

Séance 7 — Équations différentielles ordinaires

Rappel théorique

Une *équation différentielle ordinaire* (EDO ou encore ODE en anglais) est une équation sous la forme :

$$F(t, y, y', y'', \dots, y^{(k)}) = 0,$$

où $y : I \rightarrow \mathbb{R}^d$ est la fonction inconnue. k est l'ordre de l'EDO. Nous nous concentrerons sur les EDOs d'ordre 1.

S'il y a une condition initiale $y(t_0) = y_0$, on parle de *problème de Cauchy*, i.e. :

$$\begin{cases} y'(t) &= f(t, y(t)) \\ y(t_0) &= y_0 \end{cases}$$

Une fonction $f : \Omega \subset \mathbb{R} \rightarrow \mathbb{R}$ est dite *Lipschitz-continue* de constante $L > 0$ si pour toute paire $(x, y) \in \Omega^2$, l'inégalité suivante est vérifiée :

$$|f(x) - f(y)| \leq L |x - y|.$$

La fonction $f : I \times \mathbb{R} \rightarrow \mathbb{R}$ est *Lipschitz-continue en espace* s'il existe un $L > 0$ tel que pour tout $t \in I$, la fonction $f_t : \mathbb{R} \rightarrow \mathbb{R} : y \mapsto f(t, y)$ est L -Lipschitz-continue. La fonction doit donc être Lipschitz de manière "uniforme" puisque cette constante L doit être la même pour toute valeur de t .

Théorème 4 (Cauchy-Lipschitz "fort"). Si $f : I \times \mathbb{R} \rightarrow \mathbb{R}$ est continue et L -Lipschitz-continue pour un certain $L > 0$, alors le problème de Cauchy suivant admet une unique solution $y \in C^1(I, \mathbb{R})$:

$$\begin{cases} y'(t) &= f(t, y(t)) \\ y(t_0) &= y_0 \end{cases}$$

De plus, cette solution est donnée par :

$$y : I \rightarrow \mathbb{R} : t \mapsto y_0 + \int_{t_0}^t f(s, y(s)) ds.$$

Proposition 5. Si $f \in C^1(I \times \mathbb{R})$ et $\frac{\partial f}{\partial y}$ est bornée en module, alors f est Lipschitz-continue. En particulier, si I est un intervalle fermé et $f \in C^1(I \times \mathbb{R}, \mathbb{R})$, alors f est Lipschitz-continue.

Corollaire 6. Soit $f \in C^1(I \times \mathbb{R}, \mathbb{R})$. f est L -Lipschitz-continue si et seulement si $\frac{\partial f}{\partial y}$ est bornée par L en module.

Approximations de Taylor

Théorème 7 (Taylor). Si $f : \mathbb{R} \rightarrow \mathbb{R}$ est k fois dérivable en $a \in \mathbb{R}$, alors il existe une fonction $R_{a,k} : \mathbb{R} \rightarrow \mathbb{R}$ telle que :

$$f(a + h) = \sum_{\ell=0}^k \frac{f^{(\ell)}(a)}{\ell!} h^\ell + R_{a,k}(h),$$

où $R_{a,k}(h) = o(h^k)$ (pour $h \rightarrow 0$).

En particulier, ce théorème nous dit que la meilleure approximation locale de la fonction f autour de a par un polynôme de degré k (où f est k fois dérivable en a) est donnée par le polynôme $\sum_{\ell=0}^k \beta_{\ell}(x-a)^{\ell}$ où les coefficients β_{ℓ} sont donnés par $\beta_{\ell} = \frac{1}{\ell!} f^{(\ell)}(a)$.

Nous allons utiliser ce principe pour avoir une forme fermée qui va nous servir d'approximation de la solution y au problème de Cauchy donné. En particulier, nous dirons que (au moins pour t proche de t_0) :

$$y(t) \approx \hat{y}(t) := \sum_{\ell=0}^k \frac{y^{(\ell)}(t_0)}{\ell!} (t - t_0)^{\ell}.$$

En particulier, nous n'avons besoin d'évaluer y et ses k premières dérivées qu'au point t_0 , ce que nous pouvons faire en utilisant la fonction f . En effet, nous savons que :

$$\begin{aligned} y^{(0)}(t_0) &= y(t_0) = y_0 \\ y^{(\ell+1)}(t_0) &= \left. \frac{d^{\ell}}{dt^{\ell}} f(t, y(t)) \right|_{t=t_0} \end{aligned}$$

L'approximation $\hat{y}$ est donc forcément un polynôme.

Méthodes itératives d'Euler

Une approximation de Taylor locale d'ordre 1 de la fonction y autour de t_0 nous donne (pour $h = t - t_0$) :

$$y(t) \approx y(t_0) + hy'(t_0) = y(t_0) + h \cdot f(t_0, y(t_0)).$$

Sur base de cette approximation, nous allons approximer la solution au problème de Cauchy en déterminant un vecteur de valeurs $\hat{y}(t_n)$ pour $0 \leq n \leq N$ (où $t_0 < t_1 < \dots < t_N$), où (normalement) $\hat{y}(t_n) \approx y(t_n)$. Nous allons plus précisément choisir $t_n = t_0 + n \cdot h$, où $h > 0$ est le pas qui est fixé.

La méthode *progressive* d'Euler est une approche explicite où nous définissons :

$$\begin{aligned} \hat{y}(t_0) &:= y_0 \\ \hat{y}(t_{n+1}) &:= \hat{y}(t_n) + h \cdot f(t_n, \hat{y}(t_n)). \end{aligned}$$

La méthode *rétrograde* d'Euler est une approche implicite qui ne donne pas une forme fermée pour déterminer les valeurs $\hat{y}(t_n)$. À la place, nous disons que pour $n > 0$, $\hat{y}(t_n)$ est solution au problème :

$$\hat{y}(t_n) = \hat{y}(t_{n-1}) + h \cdot f(t_n, \hat{y}(t_n)).$$

Exercice 7.1. Soient les deux fonctions suivantes :

$$f_1(t, y) := t^2 \cos^2 y + t \sin^2 y \quad \text{et} \quad f_2(t, y) := \sqrt{|y|}.$$

Montrez que f_1 est 4-Lipschitz-continue si $|t| < 1$ et montrez que f_2 n'est pas Lipschitz-continue.

Résolution. Par la proposition vue ci-dessus, puisque $f_1, f_2 \in \mathcal{C}^1$, il nous suffit de regarder si la dérivée de ces fonctions en espace est bornée.

$$\frac{\partial f_1}{\partial y}(t, y) = -2t^2 \cos y \sin y + 2t \sin y \cos y = \sin(2y)(t - t^2).$$

En particulier si $|t| < 1$, nous savons que $|1 - t| < 2$ et donc :

$$\left| \frac{\partial f_1}{\partial y}(t, y) \right| = |\sin 2y| |t| |1 - t| < 1 \cdot 1 \cdot 2 = 2.$$

Nous en déduisons que f_1 est 2-Lipschitz-continue sur l'intervalle ouvert $(-1, 1)$. De plus, puisque pour tout $C > 0$ et tout $\alpha \geq 1$, si une fonction f est C -Lipschitz-continue, alors elle est également αC -LC, nous en déduisons que f_1 est également 4-LC.

Maintenant pour la deuxième fonction, nous savons que si f_2 est L -Lipschitz-continue, alors en particulier la restriction de f_2 à $\mathbb{R}^+$ doit l'être également. Regardons dès lors, pour $y > 0$:

$$\frac{\partial f_2}{\partial y}(t, y) = \frac{d}{dy} \sqrt{y} = \frac{1}{2\sqrt{y}} \xrightarrow{y \rightarrow 0^+} +\infty.$$

Nous en déduisons que $\partial_y f_2|_{\mathbb{R}^+}$ n'est pas bornée, et donc en particulier $\partial_y f_2$ ne l'est pas non plus, i.e. f_2 n'est pas Lipschitz-continue.

Exercice 7.2. Approximez la solution du problème de Cauchy suivant autour de 0 à l'aide d'une approximation de Taylor d'ordre 3 :

$$\begin{cases} y'(t) &= f(t, y(t)) := t + y(t) \\ y(0) &= 2 \end{cases}$$

Résolution. Nous allons approximer la solution par la fonction suivante :

$$\hat{y}(t) = y(0) + y'(0)t + \frac{y''(0)}{2}t^2 + \frac{y'''(0)}{6}t^3.$$

Pour cela, nous avons besoin des quantités $y(0)$, $y'(0)$, $y''(0)$ et $y'''(0)$. Nous connaissons le premier : $y(0) = 2$. Pour trouver $y'(0)$, nous devons évaluer $f(0, y(0)) = 0 + y(0) = 2$. Pour trouver $y''(0)$:

$$y''(0) = \frac{d}{dt}(t + y(t)) \Big|_{t=0} = 1 + y'(t) \Big|_{t=0} = 1 + y'(0) = 3.$$

Finalement :

$$y'''(0) = \frac{d}{dt}(1 + y'(t)) \Big|_{t=0} = y''(0) = 3.$$

Nous en concluons que :

$$\hat{y}(t) = 2 + 2t + \frac{3}{2}t^2 + \frac{1}{2}t^3.$$

Notez que la solution analytique est $y(t) = 3 \exp(t) - t - 1$.

Vous trouverez une représentation de y et de $\hat{y}$ autour de 0 dans la **figure 1**.




FIGURE 1 – Solution approchée $\hat{y}(t) = 2 + 2t + 1.5t^2 + .5t^3$ en rouge et solution exacte $y(t) = 3\exp(t) - t - 1$ en bleu.

Exercice 7.3. Reprenez le même système de Cauchy et calculez les 4 premières approximations $\hat{y}(t_n)$ avec la méthode d'Euler progressive (pour $h = 0.1$). Calculez l'erreur absolue de l'approximation en sachant que la solution exacte est $y(t) = 3\exp(t) - (t + 1)$.

Résolution. Nous allons avoir besoin de la définition des $\hat{y}_n$, i.e. :

$$\hat{y}_n = \hat{y}(t_n) = \hat{y}(t_{n-1}) + hf(t_{n-1}, \hat{y}(t_{n-1})).$$

Dans notre cas, ça donne :

$$\hat{y}_n = \hat{y}_{n-1} + \frac{1}{10} \left(\frac{n-1}{10} + \hat{y}_{n-1} \right).$$

En commençant avec $n = 0$, nous avons $\hat{y}_0 = y(0) = 2$. Poursuivons pour $n = 1$:

$$\hat{y}_1 = 2 + \frac{1}{10} (0 + 2) = 2 + \frac{1}{5} = 2.2$$

Pour $n = 2$:

$$\hat{y}_2 = 2.2 + \frac{1}{10} (0.1 + 2.2) = 2.2 + 0.23 = 2.43$$

Pour $n = 3$:

$$\hat{y}_3 = 2.43 + \frac{1}{10} (0.2 + 2.43) = 2.43 + 0.263 = 2.693$$

Finalement pour $n = 4$:

$$\hat{y}_4 = 2.693 + \frac{1}{10} (0.3 + 2.693) = 2.693 + 0.2993 = 2.9923$$

Dans la **tableau 1**, les entrées t_n , $\hat{y}(t_n)$ et $y(t_n)$ sont représentées, ainsi que l'erreur à chaque étape. Nous pouvons y voir que la qualité de l'approximation diminue lorsque n

n	t_n	$\hat{y}_n$	$y(t_n)$	$ y(t_n) - \hat{y}_n $
0	0	2	2	0
1	0.1	2.2	2.21551	0.01551
2	0.2	2.43	2.46421	0.03421
3	0.3	2.693	2.74958	0.05658
4	0.4	2.9923	3.07547	0.08317

TABLE 1 – Comparaison de y et $\hat{y}$. Les données sont arrondies à 5 chiffres après la virgule.

augmente, ce qui est attendu : l'approximation à l'étape n se base sur l'approximation à l'étape $n - 1$. Dès lors (puisque $\hat{y}$ est toujours en dessous de y ici), à chaque étape on sous-évalue sur base d'une donnée déjà sous-évaluée elle-même. Notons tout de même que le choix de $h = 0.1$ est uniquement pédagogique et ne serait jamais utilisé en pratique car beaucoup trop grand. En effet un choix de $h = 0.01$ permet de trouver $\hat{y}(0.4) = 3.0665912$, et un choix de $h = 0.001$ permet de trouver $\hat{y}(0.4) = 3.07457968$.

Exercice 7.4. Résolvez le problème de Cauchy suivant par la méthode d'Euler progressive :

$$\begin{cases} y'(t) &= t^2 - y(t) \\ y(0) &= 1 \end{cases}$$

1. Utilisez $h = 0.2$ et faites deux itérations.
2. Utilisez $h = 0.1$ et faites 4 itérations.
3. Comparez avec la solution exacte $y(t) = -\exp(-t) + t^2 - 2t + 2$.

Résolution. Pour le premier point nous avons :

$$\hat{y}_n = \hat{y}_{n-1} + \frac{1}{5} \left(\frac{(n-1)^2}{25} - \hat{y}_{n-1} \right) = \frac{4}{5} \hat{y}_{n-1} + \frac{(n-1)^2}{125}.$$

Dès lors :

$$\begin{aligned} \hat{y}_0 &= 1 \\ \hat{y}_1 &= \frac{4}{5} = 0.8 \\ \hat{y}_2 &= \frac{4}{5} \frac{4}{5} + \frac{1}{125} = \frac{81}{125} = 0.648 \end{aligned}$$

Pour le second point, nous avons :

$$\hat{y}_n = \hat{y}_{n-1} + \frac{1}{10} \left(\frac{(n-1)^2}{100} - \hat{y}_{n-1} \right) = \frac{9}{10} \hat{y}_{n-1} + \frac{(n-1)^2}{10^3}.$$

Dès lors :

$$\begin{aligned} \hat{y}_0 &= 1 \\ \hat{y}_1 &= \frac{9}{10} = 0.9 \\ \hat{y}_2 &= \frac{81}{100} + \frac{1}{1000} = \frac{811}{1000} = 0.811 \\ \hat{y}_3 &= \frac{9}{10} \frac{811}{1000} + \frac{4}{1000} = \frac{7299 + 40}{10^4} = \frac{7339}{10^4} = 0.7339 \end{aligned}$$

$$\hat{y}_4 = \frac{9}{10} \frac{7339}{10000} + \frac{9}{1000} = \frac{66051 + 900}{10^5} = \frac{66951}{10^5} = 0.66951$$

Finalement, notons que $y(0.4) = -\exp(-0.4) + 0.16 - 0.8 + 2 = 1.36 - \exp(-0.4) = 0.689680$. En particulier, on voit que la première estimation a très clairement sous-estimé la bonne solution. La seconde a également sous-estimé, mais l'erreur est tout de même ≈ 2 fois plus petite. À nouveau, plus h est petit, moins l'erreur d'approximation sera grande.

Exercice 7.5. Résolvez le problème de Cauchy suivant sur l'intervalle $[0, 0.5]$ avec la méthode d'Euler rétrograde pour $h = 0.1$:

$$\begin{cases} y'(t) &= t(y(t) + 1) \\ y(0) &= 0. \end{cases}$$

Résolution. La méthode rétrograde est basée sur :

$$\hat{y}_n = \hat{y}_{n-1} + hf(t_n, \hat{y}_n) = \hat{y}_{n-1} + h(nh(\hat{y}_n + 1)) = \hat{y}_{n-1} + nh^2\hat{y}_n + nh^2.$$

Isolons alors $\hat{y}_n$, ce qui donne :

$$\hat{y}_n = \frac{\hat{y}_{n-1} + nh^2}{1 - nh^2} = \frac{\hat{y}_{n-1} + \frac{n}{100}}{\frac{100-n}{100}} = \frac{100\hat{y}_{n-1} + n}{100 - n}.$$

Dès lors :

$$\begin{aligned} \hat{y}_0 &= 0 \\ \hat{y}_1 &= \frac{100 \cdot 0 + 1}{100 - 1} = \frac{1}{99} = 0.010101 \\ \hat{y}_2 &= \frac{100 + 2 \cdot 99}{98 \cdot 99} = \frac{298}{9702} = 0.030715 \\ \hat{y}_3 &= \frac{100 + 3 \cdot 98 \cdot 99}{97 \cdot 98 \cdot 99} = \frac{29453}{470547} = 0.062593 \\ \hat{y}_4 &= \frac{100 + 4 \cdot 97 \cdot 98 \cdot 99}{96 \cdot 97 \cdot 98 \cdot 99} = \frac{150859}{1411641} = 0.106868 \\ \hat{y}_5 &= \frac{100 + 5 \cdot 96 \cdot 97 \cdot 98 \cdot 99}{95 \dots 99} = \frac{4428821}{26821179} = 0.165124 \end{aligned}$$

Séance 8 — Interpolation

Rappel théorique

Le principe de l'*interpolation* est de déterminer une fonction f de forme connue qui va passer par un ensemble de points donnés. Plus formellement, pour deux ensembles $X \subseteq \mathbb{R}^p$ et $Y \subseteq \mathbb{R}^q$ et pour $((x_i, y_i))_{i=1}^n$ où $x_i \in X$ et $y_i \in Y$, nous voulons une fonction $f : X \rightarrow Y$ satisfaisant $y_i = f(x_i)$ pour toute valeur de i . Ici, nous considérerons $X = Y = \mathbb{R}$.

Interpolation polynomiale

Théorème 8. Soient $n+1$ paires (x_i, y_i) ($0 \leq i \leq n$) telles que $x_i \neq x_j$ pour tous $i \neq j$. Il existe un unique polynôme Π_n de degré au plus n tel que $\Pi_n(x_i) = y_i$ pour tout $0 \leq i \leq n$.

Trouver ce polynôme peut se formuler comme la résolution du système linéaire suivant :

$$\begin{bmatrix} 1 & x_0 & x_0^2 & \dots & x_0^n \\ 1 & x_1 & x_1^2 & \dots & x_1^n \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_n & x_n^2 & \dots & x_n^n \end{bmatrix} \beta = \mathbf{y},$$

où $\mathbf{y}$ est le vecteur $[y_0, y_1, \dots, y_n]^\top$ et β est le vecteur de coefficients β_i satisfaisant $\Pi_n : x \mapsto \sum_{k=0}^n \beta_k x^k$. Cependant, la matrice (appelée *matrice de Vandermonde*) est très mal conditionnée (intuitivement, c'est dû au fait que le rapport entre la plus grande et la plus petite valeur dans cette matrice – en module – est très grande à cause de l'exponentiation). De plus, le nombre d'opérations nécessaires pour résoudre un système linéaire $n \times n$ est cubique en n .

Dès lors il est intéressant de résoudre ce problème différemment.

Interpolation de Lagrange

Les *polynômes de Lagrange* associés aux couples (x_i, y_i) sont les polynômes (tous d'ordre n) :

$$\ell_i : \mathbb{R} \rightarrow \mathbb{R} : x \mapsto \prod_{j \neq i} \frac{x - x_j}{x_i - x_j}.$$

Ces polynômes ont les propriétés suivantes (pour tous $i \neq j$) :

- $\ell_i(x_i) = 1$;
- $\ell_i(x_j) = 0$.

Dès lors nous pouvons définir le polynôme Π_n comme suit :

$$\Pi_n(x) := \sum_{i=0}^n y_i \cdot \ell_i(x).$$

Ce polynôme satisfait bien, par définition $\Pi_n(x_k) = x_k$ pour tout k puisque :

$$\Pi_n(x_k) = \sum_{i=0}^n y_i \cdot \ell_i(x_k) = \sum_{i \neq k} y_i \cdot \ell_i(x_k) + y_k \cdot \ell_k(x_k) = 0 + y_k \cdot 1 = y_k.$$

Déterminer les coefficients de ℓ_i se fait en temps $\Theta(n)$ pour tout i , dès lors le nombre d'opérations totales est quadratique en n .

Interpolation de Newton

Le polynôme suivant est appelé le *mème polynôme nodal* (et a degré m) :

$$\omega_m(x) = \prod_{i=0}^{m-1} (x - x_i).$$

Le polynôme ω_{n+1} est appelé le *polynôme nodal*.

Remarque. Avec cette notation, le polynôme de Lagrange $\ell_i(x)$ peut se réécrire comme suit :

$$\ell_i(x) = \frac{\omega_{n+1}(x)}{(x - x_i)\omega'_{n+1}(x_i)}. \quad (1)$$

En effet :

$$\begin{aligned} \frac{\omega_{n+1}(x)}{(x - x_i)} &= \prod_{j \neq i} (x - x_j), \\ \omega'_{n+1}(x) &= \frac{d \omega_{n+1}(x)}{d x} = \sum_{j=0}^n \frac{d(x - x_j)}{d x} \prod_{k \neq j} (x_i - x_k) = \sum_{j=0}^n \prod_{k \neq j} (x - x_k). \end{aligned}$$

En particulier $\omega'_{n+1}(x_i) = \sum_{j \neq i} \prod_{k \neq j} (x_i - x_k) + \prod_{k \neq i} (x_i - x_k) = \prod_{j \neq i} (x_i - x_j)$.

La méthode de Newton pour l'interpolation polynômiale consiste en le fait de construire itérativement les polynômes $\Pi_1, \dots$ jusqu'à Π_n , où la détermination du polynôme Π_{m+1} se fait sur la base du polynôme Π_m (utilisant les m premiers points) et du point (x_m, y_m) . Notons $q_{m+1}(x) := \Pi_{m+1}(x) - \Pi_m(x)$, et réalisons que (1) Π_m et Π_{m+1} s'annulent tous deux en les valeurs x_i pour $0 \leq i \leq m$ et (2) q_{m+1} est la différence entre un polynôme de degré au plus $m + 1$ et d'un polynôme de degré au plus m , et donc $\deg q_{m+1} \leq m + 1$ également. Dès lors nous savons que :

$$q_{m+1}(x) = a_{m+1}(x - x_0)(x - x_1) \dots (x - x_m) = a_{m+1}\omega_{m+1}(x),$$

pour un certain $a_{m+1} \in \mathbb{R}$. Dès lors, nous savons que :

$$a_{m+1} = \frac{q_{m+1}(x_{m+1})}{\omega_{m+1}(x_{m+1})} = \frac{\Pi_{m+1}(x_{m+1}) - \Pi_m(x_{m+1})}{\omega_{m+1}(x_{m+1})} = \frac{f(x_{m+1}) - \Pi_m(x_{m+1})}{\omega_{m+1}(x_{m+1})}.$$

Cette quantité est appelée *différence divisée de Newton* et est notée $f[x_0, \dots, x_{m+1}]$, ou encore $D^{m+1}f$. Nous avons alors que :

$$\begin{aligned} \Pi_n(x) &= q_n(x) + \Pi_{n-1}(x) = f[x_0, \dots, x_n]\omega_n(x) + \Pi_{n-1}(x) \\ &= f[x_0, \dots, x_n]\omega_n(x) + f[x_0, \dots, x_{n-1}]\omega_{n-1}(x) + \Pi_{n-2}(x) \\ &= \dots \\ &= \sum_{m=0}^n \omega_m(x) f[x_0, \dots, x_m]. \end{aligned}$$

Les différences divisées sont trouvées par la relation suivante :

$$f[x_i, \dots, x_{i+k}] = \begin{cases} f(x_i) = y_i & \text{si } k = 0 \\ \frac{f[x_{i+1}, \dots, x_{i+k}] - f[x_i, \dots, x_{i+k-1}]}{x_{i+k} - x_i} & \text{si } k \geq 1. \end{cases}$$

Démonstration. Pour montrer que cette relation de récurrence sur les différences divisées permet bien de reconstruire le polynôme interpolant, montrons quelque chose d'un peu plus fort. Pour le justifier, reprenons l'équation 1 qui nous dit que pour tout $1 \leq m \leq n+1$:

$$\Pi_m(x) = \sum_{i=0}^m \frac{y_i}{\omega'_{m+1}(x_i)} \frac{\omega_{m+1}(x)}{x - x_i},$$

dès lors, si $[x^k]\Pi_m$ désigne le coefficient de x^k dans le polynôme Π_m , nous avons :

$$f[x_0, \dots, x_m] = [x^m]\Pi_m = \sum_{i=0}^m \frac{y_i}{\omega'_{m+1}(x_i)} = \sum_{i=0}^m y_i \prod_{\substack{j=0 \\ j \neq i}}^m \frac{1}{(x_i - x_j)}.$$

Montrons alors que pour tous $0 \leq j \leq k \leq n$:

$$f[x_j, \dots, x_k] = \sum_{i=j}^k y_i \prod_{\substack{\ell=j \\ \ell \neq i}}^k \frac{1}{(x_i - x_\ell)}. \quad (2)$$

Pour cela, procédons par induction sur $k - j$.

Quand $k = j$, alors :

$$\sum_{i=j}^j y_i \prod_{\ell \in \emptyset} (x_i - x_\ell) = y_j = f[x_j].$$

Maintenant supposons que l'équation 2 est vérifiée pour toute paire (j', k') telle que $0 \leq j' \leq k' \leq m$ et $k' - j' < k - j$, et montrons qu'elle reste vraie pour (j, k) . Commençons par déterminer $f[x_{j+1}, \dots, x_k] - f[x_j, \dots, x_{k-1}]$. Pour cela, appliquons l'hypothèse d'induction afin d'obtenir :

$$\begin{aligned} f[x_{j+1}, \dots, x_k] - f[x_j, \dots, x_{k-1}] &= \sum_{i=j+1}^k y_i \prod_{\substack{\ell=j+1 \\ \ell \neq i}}^k \frac{1}{(x_i - x_\ell)} - \sum_{i=j}^{k-1} y_i \prod_{\substack{\ell=j \\ \ell \neq i}}^{k-1} \frac{1}{(x_i - x_\ell)} \\ &= y_k \prod_{\ell=j+1}^{k-1} \frac{1}{(x_k - x_\ell)} + \sum_{i=j+1}^{k-1} y_i \left(\prod_{\substack{\ell=j+1 \\ \ell \neq i}}^k \frac{1}{(x_i - x_\ell)} - \prod_{\substack{\ell=j \\ \ell \neq i}}^{k-1} \frac{1}{(x_i - x_\ell)} \right) - y_j \prod_{\ell=j+1}^k \frac{1}{(x_j - x_\ell)} \\ &= y_k \prod_{\ell=j+1}^{k-1} \frac{1}{(x_k - x_\ell)} + \sum_{i=j+1}^{k-1} y_i \left(\prod_{\substack{\ell=j+1 \\ \ell \neq i}}^{k-1} \frac{1}{(x_i - x_\ell)} \right) \left(\frac{1}{(x_i - x_k)} - \frac{1}{(x_i - x_j)} \right) - y_j \prod_{\ell=j+1}^k \frac{1}{(x_j - x_\ell)} \\ &= y_k \prod_{\ell=j+1}^{k-1} \frac{1}{(x_k - x_\ell)} + \sum_{i=j+1}^{k-1} y_i \left(\prod_{\substack{\ell=j+1 \\ \ell \neq i}}^{k-1} \frac{1}{(x_i - x_\ell)} \right) \frac{(x_k - x_j)}{(x_i - x_k)(x_i - x_j)} - y_j \prod_{\ell=j+1}^k \frac{1}{(x_j - x_\ell)} \\ &= y_k \prod_{\ell=j+1}^{k-1} \frac{1}{(x_k - x_\ell)} + (x_k - x_j) \sum_{i=j+1}^{k-1} y_i \prod_{\substack{\ell=j \\ \ell \neq i}}^k \frac{1}{(x_i - x_\ell)} - y_j \prod_{\ell=j+1}^k \frac{1}{(x_j - x_\ell)} \end{aligned}$$

$$\begin{aligned}
&= (x_k - x_j)y_k \prod_{\substack{\ell=j \\ \ell \neq k}}^k \frac{1}{(x_k - x_\ell)} + (x_k - x_j) \sum_{i=j+1}^{k-1} y_i \prod_{\substack{\ell=j \\ \ell \neq i}}^k \frac{1}{(x_i - x_\ell)} - (x_j - x_k)y_j \prod_{\substack{\ell=j \\ \ell \neq j}}^k \frac{1}{(x_j - x_\ell)} \\
&= (x_k - x_j)y_k \prod_{\substack{\ell=j \\ \ell \neq k}}^k \frac{1}{(x_k - x_\ell)} + (x_k - x_j) \sum_{i=j+1}^{k-1} y_i \prod_{\substack{\ell=j \\ \ell \neq i}}^k \frac{1}{(x_i - x_\ell)} + (x_k - x_j)y_j \prod_{\substack{\ell=j \\ \ell \neq j}}^k \frac{1}{(x_j - x_\ell)} \\
&= (x_k - x_j) \sum_{i=j}^k y_i \prod_{\substack{\ell=j \\ \ell \neq i}}^k \frac{1}{(x_i - x_\ell)}.
\end{aligned}$$

Dès lors, nous avons bien que :

$$f[x_j, \dots, x_k] = \frac{f[x_{j+1}, \dots, x_k] - f[x_j, \dots, x_{k-1}]}{x_k - x_j} = \sum_{i=j}^k y_i \prod_{\substack{\ell=j \\ \ell \neq i}}^k \frac{1}{(x_i - x_\ell)},$$

comme voulu dans l'équation 2.

Par induction, nous pouvons en déduire que $\sum_{t=0}^m f[x_0, \dots, x_t] \omega_t(x) = \Pi_{m+1}(x)$, et donc que la forme générale de polynôme interpolant de Newton est bien celui recherché. $\square$

Nous pouvons également définir le vecteur $D^k f$ qui contient toutes les différences divisées à k donné.

En pratique on calcule d'abord toutes les différences d'ordre 1, puis celles d'ordre 2, etc. Si on représente ces quantités dans une matrice triangulaire inférieure, on obtient les coefficients nécessaires dans la diagonale. Le nombre d'opérations nécessaires est donc à nouveau quadratique en n .

Remarque : les différences divisées sont en quelque sorte une généralisation discrète des dérivées. En effet : tout comme la dérivée d'un polynôme de degré $\leq n$ est un polynôme de degré $\leq n - 1$, l'opérateur de dérivée discrète Δ appliqué à un polynôme de degré $\leq n$ donne un polynôme de degré $\leq n - 1$:

$$\Delta \left(\sum_{k=0}^n a_k x^k \right) = \sum_{k=0}^n a_k (x+1)^k - \sum_{k=0}^n a_k x^k = \sum_{k=0}^n a_k \left(\sum_{j=0}^{k-1} \binom{k}{j} x^j \right) = \sum_{j=0}^{n-1} \left(\sum_{k=j+1}^n a_k \binom{k}{j} \right) x^j.$$

En particulier, appliquer itérativement ces différences (normalisées ou non) sur un polynôme (ayant donc degré fini) finira nécessairement par donner identiquement 0.

8.1 Interpolation de Lagrange

Exercice 8.1. Déterminez le polynôme de degré minimal passant par les points $(0, -2)$, $(-1, -2)$ et $(\frac{1}{2}, -\frac{5}{4})$ en utilisant la méthode de Lagrange.

Résolution. Puisque nous avons 3 points, nous allons avoir un polynôme de degré au plus 2. Les valeurs x_i sont donc $(0, -1, \frac{1}{2})$ et les valeurs y_i associées sont $(-2, -2, -\frac{5}{4})$. Construisons les polynômes de Lagrange :

$$\ell_0(x) = \frac{(x - x_1)(x - x_2)}{(x_0 - x_1)(x_0 - x_2)} = \frac{x^2 - (x_1 + x_2)x + x_1 x_2}{(x_0 - x_1)(x_0 - x_2)}$$

$$\begin{aligned}\ell_1(x) &= \frac{(x-x_0)(x-x_2)}{(x_1-x_0)(x_1-x_2)} = \frac{x^2 - (x_0+x_2)x + x_0x_2}{(x_1-x_0)(x_1-x_2)} \\ \ell_2(x) &= \frac{(x-x_0)(x-x_1)}{(x_2-x_0)(x_2-x_1)} = \frac{x^2 - (x_0+x_1)x + x_0x_1}{(x_2-x_0)(x_2-x_1)}.\end{aligned}$$

En substituant les valeurs de x_i , nous obtenons :

$$\begin{aligned}\ell_0(x) &= \frac{x^2 + \frac{1}{2}x - \frac{1}{2}}{-\frac{1}{2}} = -2x^2 - x + 1 \\ \ell_1(x) &= \frac{x^2 - \frac{1}{2}x}{\frac{3}{2}} = \frac{2}{3}x^2 - \frac{1}{3}x \\ \ell_2(x) &= \frac{x^2 + x}{\frac{3}{4}} = \frac{4}{3}x^2 + \frac{4}{3}x.\end{aligned}$$

Il nous reste alors à déterminer le polynôme interpolant comme suit :

$$\begin{aligned}\Pi(x) &= y_0\ell_0(x) + y_1\ell_1(x) + y_2\ell_2(x) = -2(-2x^2 - x + 1) - 2\left(\frac{2}{3}x^2 - \frac{1}{3}x\right) - \frac{5}{4}\left(\frac{4}{3}x^2 + \frac{4}{3}x\right) \\ &= \left(4 - \frac{4}{3} - \frac{5}{3}\right)x^2 + \left(2 + \frac{2}{3} - \frac{5}{3}\right)x + (-2) \\ &= x^2 + x - 2.\end{aligned}$$

Nous pouvons bien vérifier que :

$$\begin{aligned}\Pi(0) &= 0 + 0 - 2 = -2 \\ \Pi(-1) &= 1 - 1 - 2 = -2 \\ \Pi\left(\frac{1}{2}\right) &= \frac{1}{4} + \frac{1}{2} - 2 = -\frac{5}{4},\end{aligned}$$

comme désiré. Π est bien un polynôme interpolant les points demandés.

Exercice 8.2. Donnez une approximation de la valeur $\sqrt[3]{20}$ en utilisant l'interpolation de Lagrange.

Résolution. Nous allons interpoler la fonction $f : x \mapsto x^{1/3}$ autour de $x = 20$. Puisque $f(8) = 2$ et $f(27) = 3$, nous pouvons essayer d'interpoler avec ces deux points uniquement (en faisant donc une interpolation linéaire). Cela nous donne le polynôme :

$$\Pi_1(x) = \frac{1}{19}x + \frac{30}{19}.$$

Nous pouvons alors dire que $\sqrt[3]{20} = f(20) \approx \Pi_1(20) = \frac{20}{19} + \frac{30}{19} = \frac{50}{19} \approx 2.631\,579$. De fait, $\Pi_1(20)^3 \approx 18.224$, ce qui n'est *pas trop loin* de 20.

Afin d'améliorer l'approximation, nous pouvons augmenter le nombre de points mais attention à prendre un nouveau point *proche* de 20. Idéalement il faudrait le choisir entre les deux points déjà choisis. Prenons par exemple $f(15.625) = \frac{5}{2}$ (que nous trouvons en cherchant $(5/2)^3 = 125/8 = 15.625$). Dès lors les entrées sont $x = (8, 15.625, 27)$ et $y = (2, 2.5, 3)$ et les polynômes de Lagrange sont donnés par :

$$\ell_0(x) = \frac{\frac{1}{8}(8x^2 - 341x + 3375)}{\frac{1}{61} \cdot 19} = \frac{8x^2 - 341x + 3375}{1159}$$

$$\ell_1(x) = \frac{x^2 - 35x + 216}{-\frac{1}{8}61 \cdot \frac{1}{8}91} = \frac{-64}{5551} (x^2 - 35x + 216)$$

$$\ell_2(x) = \frac{\frac{1}{8} (8x^2 - 189x + 1000)}{19 \cdot \frac{1}{8}91} = \frac{8x^2 - 189x + 1000}{1729}.$$

Le polynôme interpolant est donc donné par :

$$\Pi_3(x) = \frac{-120}{105469}x^2 + \frac{1393}{15067} + \frac{140610}{105469},$$

qui nous donne $f(20) \approx \Pi_3(20) = \frac{41\,090}{15\,067} \approx 2.727\,152$. Nous pouvons voir que $\Pi_3(20)^3 \approx 20.283$, ce qui est en effet une meilleure approximation. Puisque $\sqrt[3]{20} \approx 2.714\,417\,617$, on peut voir que l'approximation se rapproche mais est toujours imparfaite.

8.2 Interpolation de Newton

Exercice 8.3. Déterminez le polynôme de Newton passant par les points $(6, 6)$, $(8, 24)$, $(10, 60)$ et $(12, 120)$.

Résolution. Calculons les différences divisées sur base de la relation donnée ci-dessus :

	$D^0 f$	$D^1 f$	$D^2 f$	$D^3 f$
$x_0 = 6$	6			
$x_1 = 8$	24	9		
$x_2 = 10$	60	18	$\frac{9}{4}$	
$x_3 = 12$	120	30	3	$\frac{1}{8}$

Le polynôme est donc :

$$\begin{aligned}\Pi_3(x) &= f[x_0] + (x - x_0)f[x_0, x_1] + (x - x_0)(x - x_1)f[x_0, x_1, x_2] \\ &\quad + (x - x_0)(x - x_1)(x - x_2)f[x_0, x_1, x_2, x_3] \\ &= 6 + 9(x - 6) + \frac{9}{4}(x^2 - 14x + 48) + \frac{1}{8}(x^3 - 24x^2 + 188x - 480) \\ &= \frac{1}{8}x^3 - \frac{3}{4}x^2 + x,\end{aligned}$$

ce que nous pouvons vérifier :

$$\begin{aligned}\Pi_3(6) &= \frac{1}{8}216 - \frac{3}{4}36 + 6 = 27 - 27 + 6 = 6 \\ \Pi_3(8) &= \frac{1}{8}8 \cdot 64 - \frac{3}{4}64 + 8 = 64 - 48 + 8 = 24 \\ \Pi_3(10) &= \frac{1}{8}1000 - \frac{3}{4}100 + 10 = 125 - 75 + 10 = 60 \\ \Pi_3(12) &= \frac{1}{8}27 \cdot 64 - \frac{3}{4}144 + 12 = 216 - 108 + 12 = 120.\end{aligned}$$

Exercice 8.4. Donnez une forme fermée pour la fonction $\varphi : \mathbb{N} \rightarrow \mathbb{R} : n \mapsto \sum_{k=0}^n k^2$ en utilisant la méthode de Newton.

Hint : Nous savons que φ est en réalité un polynôme. Quel est son degré ? Et en avons-

■ nous besoin pour commencer?

Résolution. Nous avons vu, en INFO-F103 — Algorithmique I, que $\varphi \sim \frac{1}{3}n^3$, nous savons donc que puisque φ est un polynôme, nous n'avons besoin que de 4 points. Nous allons donc fixer $n = 3$ et $x_i = i$ ($0 \leq i \leq n$). Observons maintenant que :

$$\varphi(n) = \begin{cases} 0^2 = 0 & \text{si } n = 0 \\ 0 + 1^2 = 1 & \text{si } n = 1 \\ 1 + 2^2 = 5 & \text{si } n = 2 \\ 5 + 3^2 = 14 & \text{si } n = 3 \end{cases}$$

Déterminons alors les différences divisées :

	$D^0\varphi$	$D^1\varphi$	$D^2\varphi$	$D^3\varphi$
$x_0 = 0$	0			
$x_1 = 1$	1	1		
$x_2 = 2$	5	4	$\frac{3}{2}$	
$x_3 = 3$	14	9	$\frac{5}{2}$	$\frac{1}{3}$

Dès lors nous avons que :

$$\begin{aligned} \Pi_4(n) = \varphi(n) &= 0 + 1(n-0) + \frac{3}{2}(n-0)(n-1) + \frac{1}{3}(n-0)(n-1)(n-2) \\ &= n + \frac{3}{2}n^2 - \frac{3}{2}n + \frac{1}{3}n^3 - n^2 + \frac{2}{3}n \\ &= \frac{1}{3}n^3 + \frac{1}{2}n^2 + \frac{1}{6}n \\ &= \frac{2n^3 + 3n^2 + n}{6} = \frac{n(n+1)(2n+1)}{6}. \end{aligned}$$

Exercice 8.5 (Pas fait en séance). Soit la fonction $f(x) = \sin x$. Considérons les valeurs $x = [0, 0.2, 0.4, 0.6, 0.8]$.

1. Donnez une borne supérieure pour l'erreur d'approximation de f en $x = 0.28$.
2. Comparez cette borne avec l'erreur réelle en sachant que $\sin(0.28) \approx 0.276\,355\,665$.

Résolution. On connaît la borne suivante pour l'erreur d'approximation en une valeur $x \in [x_0, x_n]$:

$$|f(x) - \Pi_n(x)| \leq \frac{\|f^{(n+1)}\|_\infty}{(n+1)!} |\omega_{n+1}(x)|.$$

Dans notre cas, on sait que $n = 4$, donc $(n+1)! = 5! = 120$ et $f^{(n+1)} = f^{(5)} = \sin^{(5)} = \sin' = \cos$. Dès lors :

$$|\sin x - \Pi_n(x)| \leq \frac{\|\cos\|_\infty}{120} |\omega_5(x)| = \frac{\prod_{k=0}^4 |x - \frac{k}{5}|}{120}.$$

En particulier pour $x = 0.28 = \frac{7}{25}$:

$$|\sin 0.28 - \Pi_n(0.28)| \leq \frac{1}{120} \prod_{k=0}^4 \left| \frac{7}{25} - \frac{5k}{25} \right| = \frac{1}{120} \frac{1}{25^5} \prod_{k=0}^4 |7 - 5k|$$

$$= \frac{1}{2 \cdot 3 \cdot 4 \cdot 5} \frac{7 \cdot 2 \cdot 3 \cdot 8 \cdot 13}{5^{10}} = \frac{2 \cdot 7 \cdot 13}{5^{11}} = \frac{182}{48828125} \\ \approx 3.727 \times 10^{-6}.$$

Maintenant trouvons explicitement le polynôme interpolant (par la méthode de Newton) pour déterminer l'erreur d'interpolation. Pour cela, il nous faut les points à interpoler, que l'on peut trouver facilement en évaluant la fonction $\sin$:

$$(0, 0), (0.2, 0.198\,669), (0.4, 0.389\,418), (0.6, 0.564\,642), (0.8, 0.717\,356).$$

Le tableau des différences divisées est donné par :

	$D^0 f$	$D^1 f$	$D^2 f$	$D^3 f$	$D^4 f$
$x_0 = 0$	0				
$x_1 = 0.2$	0.198 669	0.993 347			
$x_2 = 0.4$	0.389 418	0.953 745	-0.099 044		
$x_3 = 0.6$	0.564 642	0.876 121	-0.194 061	-0.158 428	
$x_4 = 0.8$	0.717 356	0.763 568	-0.281 381	-0.145 534	0.016 118

Nous pouvons alors reconstruire le polynôme :

$$\Pi_4(x) = 0.016\,117\,916x^4 - 0.177\,769\,857x^3 + 0.003\,144\,907x^2 + 0.999\,699\,524x,$$

qui donne :

$$\Pi_4(0.28) = 0.276\,359\,093\,125\,434.$$

En particulier on a :

$$E(0.28) = |\sin 0.28 - \Pi_4(0.28)| = |0.276\,355\,648\,564\,113 - 0.276\,359\,093\,125\,434| \\ = 3.444\,561\,321 \times 10^{-6} < 3.727 \times 10^{-6}.$$

L'erreur est bien plus petite que la borne supérieure obtenue au point 1.

Séance 9 — Interpolation (partie 2)

Rappel théorique

L'interpolation est un problème qui n'est pas stable, tout particulièrement lorsque les x_i sont équirépartis dans un intervalle $[a, b]$. Pour éviter ce problème, nous pouvons interpoler *localement* la fonction en sélectionnant itérativement un sous-ensemble de points *successifs* et en interpolant un polynôme entre ces points-là uniquement.

L'exemple de base est l'interpolation linéaire par morceaux : entre chaque paire de points consécutifs, nous déterminons l'unique droite qui passe par ces deux points. Cependant, cette fonction a beau être continue, elle n'est (*a priori*) pas dérivable en les points x_i .

Une *spline* d'ordre k pour les points $x_0, \dots, x_n$ est une fonction $s \in \mathcal{C}^{k-1}([a, b], \mathbb{R})$ telle que $s|_{[x_i, x_{i+1}]}$ est un polynôme de degré k . Notons $s_i := s|_{[x_i, x_{i+1}]}$. s peut donc être vue comme n polynômes de degré k collés les uns après les autres. Dès lors s est définie par $n(k+1)$ coefficients. Intuitivement, il va nous falloir autant de contraintes pour pouvoir déterminer s de manière unique. Nous imposons donc :

1. $s(x_i) = f(x_i)$ pour $0 \leq i \leq n$;
2. s est $k-1$ fois dérivable en les points x_i , donc les $s_i^{(m)}$ doivent se rejoindre en ces points :

$$s_i^{(m)}(x_{i+1}) = s_{i+1}^{(m)}(x_{i+1}) \quad \text{pour } 0 \leq i \leq n-2 \text{ et } 0 \leq m \leq k-1.$$

Ainsi nous avons $n+1 + (n-1)k$ contraintes, il nous en reste $(k+1)n - (n+1) - (n-1)k = k-1$ à déterminer.

- Si nous imposons $s^{(m)}(a) = s^{(m)}(b)$ pour $1 \leq m \leq k-1$, alors nous disons que s est une *spline périodique*.
- Si $k \geq 3$ est impair et que nous imposons $s^{(m)}(a) = s^{(m)}(b) = 0$ pour $\frac{k+1}{2} \leq m \leq k-1$, alors nous disons que s est une *spline naturelle*.

Nous nous concentrerons sur le cas $k=3$ ici (on parle alors de *splines cubiques*). Dans ce cas-ci, introduisons les notations suivantes (pour $0 \leq i \leq n$) :

$$\begin{aligned} y_i &:= s(x_i) \\ m_i &:= s'(x_i) \\ M_i &:= s''(x_i), \end{aligned}$$

et pour $1 \leq i \leq n$, nous notons $h_i := x_i - x_{i-1}$.

Nous savons que tous les s_i sont des polynômes de degré 3, dès lors s_i'' est une droite. De plus, nous savons que $s_i''(x_i) = M_i$ et $s_i''(x_{i+1}) = M_{i+1}$ par continuité de s'' . Dès lors :

$$s_i''(x) = M_i + \frac{M_{i+1} - M_i}{h_{i+1}}(x - x_i).$$

Nous en déduisons que :

$$s_i'(x) = m_i + \int_{x_i}^x s_i''(t) dt = m_i + M_i(x - x_i) + \frac{M_{i+1} - M_i}{2h_{i+1}}(x - x_i)^2,$$

et de plus :

$$s_i(x) = y_i + \int_{x_i}^x s'(t)dt = y_i + m_i(x - x_i) + \frac{M_i}{2}(x - x_i)^2 + \frac{M_{i+1} - M_i}{6h_{i+1}}(x - x_i)^3.$$

Puisque $s_i(x_{i+1}) = y_{i+1}$ par continuité de s , nous pouvons trouver m_i :

$$y_{i+1} = s_i(x_{i+1}) = y_i + m_i h_{i+1} + \frac{M_i}{2} h_{i+1}^2 + \frac{M_{i+1} - M_i}{6} h_{i+1}^3,$$

i.e. :

$$m_i = \frac{y_{i+1} - y_i}{h_{i+1}} - \frac{M_i}{3} h_{i+1} - \frac{M_{i+1} - M_i}{6} h_{i+1}.$$

La continuité de s' nous permet finalement d'exprimer la contrainte suivante (dite de M -continuité) :

$$\begin{aligned} s'_{i-1}(x_i) &= s'(x_i) = s'_i(x_i) \\ m_{i-1} + M_{i-1} h_i + \frac{M_i - M_{i-1}}{2} h_i &= m_i \\ \frac{y_i - y_{i-1}}{h_i} + \frac{M_{i-1}}{6} h_i + \frac{M_i}{3} h_i &= \frac{y_{i+1} - y_i}{h_{i+1}} - \frac{M_i}{3} h_{i+1} - \frac{M_{i+1} - M_i}{6} h_{i+1} \\ \frac{M_{i-1} h_i}{6} + \frac{M_i (h_i + h_{i+1})}{3} + \frac{M_{i+1} h_{i+1}}{6} &= \frac{y_{i+1} - y_i}{h_{i+1}} - \frac{y_i - y_{i-1}}{h_i} \end{aligned}$$

En particulier si $h_i = h$ pour tout i , alors ces équations peuvent être simplifiées en :

$$\frac{h^2}{6} M_{i-1} + \frac{2h^2}{3} M_i + \frac{h^2}{6} M_{i+1} = y_{i+1} + y_{i-1} - 2y_i.$$

Maintenant, si s est une spline naturelle, il reste à ajouter les contraintes $M_0 = 0$ et $M_n = 0$. Si par contre s est une spline périodique, il faut ajouter les contraintes $M_0 = M_n$ et $s'(x_0) = s'(x_n)$:

$$\frac{y_1 - y_0}{h_1} - \frac{M_0 h_1}{3} - \frac{M_1 h_1}{6} = s'_0(x_0) = s'_{n-1}(x_n) = \frac{y_n - y_{n-1}}{h_n} + \frac{M_{n-1} h_n}{6} + \frac{M_n h_n}{3},$$

ou encore :

$$\frac{y_1 - y_0}{h_1} - \frac{y_n - y_{n-1}}{h_n} = \frac{M_0 h_1}{3} + \frac{M_1 h_1}{6} + \frac{M_{n-1} h_n}{6} + \frac{M_n h_n}{3}.$$

Curve fitting

Le problème de *curve fitting* peut se formuler comme suit : pour (x_i, y_i) ($0 \leq i \leq n$) une séquence de points, quelle fonction h correspond au mieux à ces points ?

Pour définir tout ceci formellement, il faut définir quel est l'ensemble des fonctions h considérées et définir ce que veut dire *correspondre* ici. Nous noterons $\mathcal{H}$ l'ensemble des fonctions h considérées. Pour une fonction $h \in \mathcal{H}$, nous définissons l'erreur de h sur le point (x_i, y_i) par :

$$\mathcal{L}(x_i, y_i; h) := \|h(x_i) - y_i\|_2^2.$$

L'erreur sur l'ensemble des points est donné par :

$$\mathcal{L}(\mathbf{x}, \mathbf{y}; h) := \sum_{i=0}^n \mathcal{L}(x_i, y_i; h),$$

où $\mathbf{x}$ et $\mathbf{y}$ sont les vecteur $\mathbf{x} = [x_0, \dots, x_n]^\top$ et $\mathbf{y} = [y_0, \dots, y_n]^\top$.

Notez que dans le *cas paramétrique* (toutes les fonctions $h \in \mathcal{H}$ ont la même forme mais sont paramétrisées par un certain $\theta \in \Theta$), nous noterons $h_\theta \in \mathcal{H}$ pour expliciter la dépendance en θ .

Le problème de *curve fitting* consiste donc à trouver la fonction $h \in \mathcal{H}$ qui minimise $\mathcal{L}(\mathbf{x}, \mathbf{y}; h)$.

Restreignons-nous maintenant au cas où $\mathcal{H}$ est l'ensemble des polynômes de degré au plus m (à m fixé). Ici, $\Theta = \mathbb{R}^{m+1}$ et pour $\theta \in \Theta$, la fonction h_θ est définie par :

$$h_\theta(x) = \sum_{j=0}^m \theta_j x^j.$$

Nous cherchons donc à résoudre le problème :

$$\theta^* = \arg \min_{\theta \in \Theta} \mathcal{L}(\mathbf{x}, \mathbf{y}; h_\theta).$$

Nous savons qu'une telle solution doit satisfaire :

$$\nabla_\theta \mathcal{L}(\mathbf{x}, \mathbf{y}; h_\theta) = 0.$$

Notons également que, comme observé précédemment, puisque les x_i sont constants (par rapport à θ), nous pouvons voir le vecteur $h_\theta(\mathbf{x}) = [h_\theta(x_0), \dots, h_\theta(x_n)]^\top$ comme le produit :

$$h_\theta(\mathbf{x}) = V(\mathbf{x})\theta,$$

où $V(\mathbf{x})$ est la matrice de Vandermonde définie par $V(\mathbf{x})_{i,j} = x_i^j$. Nous voulons alors résoudre le système (où $0 \leq k \leq m$) :

$$0 = \frac{\partial}{\partial \theta_k} \mathcal{L}(\mathbf{x}, \mathbf{y}; h_\theta) = \sum_{i=0}^n \frac{\partial}{\partial \theta_k} (h_\theta(x_i) - y_i)^2 = 2 \sum_{i=0}^n (h_\theta(x_i) - y_i) \frac{\partial h_\theta(x_i)}{\partial \theta_k}.$$

Or dans notre cas :

$$\frac{\partial}{\partial \theta_k} h_\theta(x) = \sum_{j=0}^m \frac{\partial \theta_j}{\partial \theta_k} x^j = x^k.$$

Dès lors, le système à résoudre est donc (pour tout k) :

$$0 = \sum_{i=0}^n (h_\theta(x_i) - y_i) x_i^k = \sum_{i=0}^n ((V(\mathbf{x})\theta)_i - y_i) V(\mathbf{x})_{i,k} = \left(V(\mathbf{x})^\top (V(\mathbf{x})\theta - \mathbf{y}) \right)_k,$$

et donc de manière vectorielle :

$$V(\mathbf{x})^\top V(\mathbf{x})\theta = V(\mathbf{x})^\top \mathbf{y}.$$

Notez que contrairement au système $V(\mathbf{x})\theta = \mathbf{y}$, qui était surdimensionné, ce système-ci admet bien une unique solution (pour peu que les x_i soient bien deux à deux distincts) puisque la matrice $V(\mathbf{x})^\top V(\mathbf{x})$ est bien carrée (de dimension $(m+1) \times (m+1)$).

Remarque : puisque $V(\mathbf{x})^\top V(\mathbf{x})$ est inversible, cela revient à effectuer le calcul :

$$\theta^* = \underbrace{\left(V(\mathbf{x})^\top V(\mathbf{x}) \right)^{-1} V(\mathbf{x})^\top}_{=: V(\mathbf{x})^\dagger} y,$$

où $V(\mathbf{x})^\dagger$ est la *pseudo-inverse de Moore* de la matrice $V(\mathbf{x})$. Ce système est appelé le *système des équations normales* du problème.

Exercice 9.1. Interpolez les points $(-1, 0)$, $(0, 1)$ et $(1, -1)$ par splines cubiques naturelle et périodique.

Résolution. Notons que (i) $x_0 = -1$, $x_1 = 0$ et $x_2 = 1$; (ii) $y_1 = 0$, $y_1 = 1$ et $y_2 = -1$; et (iii) $h_1 = h_2 = 1$.

Les splines naturelles sont données par le système suivant :

$$\begin{cases} M_0 & = 0 \\ M_0 + 4M_1 + M_2 = 6(-1 + 0 - 2) & = -18 \\ M_2 & = 0 \end{cases}$$

Dès lors nous en déduisons $M_0 = M_2 = 0$ et $M_1 = \frac{-9}{2}$. Nous pouvons alors trouver les splines :

$$\begin{aligned} s_0(x) &= y_0 + m_0(x - x_0) + \frac{M_0}{2}(x - x_0)^2 + \frac{M_1 - M_0}{6}(x - x_0)^3 \\ &= \left(y_1 - y_0 - \frac{M_1}{6} \right) (x + 1) + \frac{M_1}{6}(x + 1)^3 \\ &= \frac{7}{4}(x + 1) - \frac{3}{4}(x + 1)^3 = -\frac{3}{4}x^3 - \frac{9}{4}x^2 - \frac{1}{2}x + 1 \end{aligned}$$

et

$$\begin{aligned} s_1(x) &= y_1 + m_1(x - x_1) + \frac{M_1}{2}(x - x_1)^2 + \frac{M_2 - M_1}{6}(x - x_1)^3 \\ &= 1 + \left(-2 + \frac{3}{2} \right) x - \frac{9}{4}x^2 + \frac{3}{4}x^3 \\ &= \frac{3}{4}x^3 - \frac{9}{4}x^2 - \frac{1}{2}x + 1. \end{aligned}$$

Les splines périodiques sont données par le système suivant :

$$\begin{cases} M_0 & = M_2 \\ M_0 + 4M_1 + M_2 = 6(-1 + 0 - 2) & = -18 \\ M_0 + M_1 + M_2 = 3(1 - 0 + 1 + 1) & = 9 \end{cases}$$

Nous trouvons :

$$M_1 = \frac{1}{3} ((M_0 + 4M_1 + M_2) - (M_0 + M_1 + M_2)) = \frac{1}{3} (-18 - 9) = -9,$$

et donc :

$$M_0 = M_2 = \frac{1}{2} (9 - M_1) = 9.$$

Dès lors nous pouvons reconstruire la spline périodique :

$$\begin{aligned} s_0(x) &= \left(1 - 0 - \frac{9}{3} + \frac{9}{6}\right)(x+1) + \frac{9}{2}(x+1)^2 + \frac{-18}{6}(x+1)^3 \\ &= \frac{-1}{2}(x+1) + \frac{9}{2}(x+1)^2 - 3(x+1)^3 \\ &= -3x^3 - \frac{9}{2}x^2 - \frac{1}{2}x + 1 \end{aligned}$$

et :

$$\begin{aligned} s_1(x) &= 1 + \left(-1 - 1 + \frac{9}{3} - \frac{9}{6}\right)x - \frac{9}{2}x^2 + \frac{18}{6}x^3 \\ &= 3x^3 - \frac{9}{2}x^2 - \frac{1}{2}x + 1. \end{aligned}$$

Une comparaison graphique des deux splines est donnée dans la **figure 2**.




FIGURE 2 – Spline naturelle en bleu et périodique en rouge.

Exercice 9.2. Déterminez la spline naturelle cubique passant par les points donnés dans le tableau suivant :

x	$f(x)$
0	2
1	4.4366
$\frac{3}{2}$	6.7134
$\frac{9}{4}$	13.9130

En sachant que $f(x) = 2 \exp(x) - x^2$, évaluez la spline en $x = 0.66$ et $x = 1.75$. Qu'en déduisez-vous ?

Résolution. Les quantités M_i à déterminer satisfont le système linéaire suivant :

$$\begin{bmatrix} 1 & 0 & 0 & 0 \\ \frac{h_1}{6} & \frac{h_1+h_2}{3} & \frac{h_2}{6} & 0 \\ 0 & \frac{h_2}{6} & \frac{h_2+h_3}{3} & \frac{h_3}{6} \\ 0 & 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} M_0 \\ M_1 \\ M_2 \\ M_3 \end{bmatrix} = \begin{bmatrix} 0 \\ \frac{y_2-y_1}{h_2} - \frac{y_1-y_0}{h_1} \\ \frac{y_3-y_2}{h_3} - \frac{y_2-y_1}{h_2} \\ 0 \end{bmatrix}.$$

Donc puisque $M_0 = M_3 = 0$, le système devient 2x2, et puisque $h_1 = 1 - 0 = 1$, $h_2 = \frac{3}{2} - 1 = \frac{1}{2}$ et $h_3 = \frac{9}{4} - \frac{3}{2} = \frac{3}{4}$, nous avons le système :

$$\begin{aligned} \begin{bmatrix} \frac{1}{2} & \frac{1}{12} \\ \frac{1}{12} & \frac{5}{12} \end{bmatrix} \begin{bmatrix} M_1 \\ M_2 \end{bmatrix} &= \begin{bmatrix} \frac{y_2-y_1}{h_2} - \frac{y_1-y_0}{h_1} \\ \frac{y_3-y_2}{h_3} - \frac{y_2-y_1}{h_2} \end{bmatrix} = \begin{bmatrix} 2(y_2 - y_1) - (y_1 - y_0) \\ \frac{4}{3}(y_3 - y_2) - 2(y_2 - y_1) \end{bmatrix} \\ &= \begin{bmatrix} 2 \cdot 6.7134 - 3 \cdot 4.4366 + 2 \\ \frac{4}{3} \cdot 13.913 - \frac{10}{3} \cdot 6.7134 + 2 \cdot 4.4366 \end{bmatrix} \\ &= \begin{bmatrix} 2.117 \\ 5.04587 \end{bmatrix} \end{aligned}$$

La matrice de coefficients est facilement inversible :

$$\begin{bmatrix} \frac{1}{2} & \frac{1}{12} \\ \frac{1}{12} & \frac{5}{12} \end{bmatrix}^{-1} = 12 \begin{bmatrix} 6 & 1 \\ 1 & 5 \end{bmatrix}^{-1} = \frac{12}{29} \begin{bmatrix} 5 & -1 \\ -1 & 6 \end{bmatrix}$$

Nous en déduisons alors que :

$$\begin{bmatrix} M_1 \\ M_2 \end{bmatrix} = \frac{12}{29} \begin{bmatrix} 5 & -1 \\ -1 & 6 \end{bmatrix} \begin{bmatrix} 2.117 \\ 5.04587 \end{bmatrix} = \begin{bmatrix} 2.2921 \\ 11.6517 \end{bmatrix}$$

Il ne nous reste plus qu'à reconstruire la spline par ses morceaux :

$$\begin{aligned} s_0(x) &= 2 + \left(2.4366 - \frac{M_1}{6} \right) x + \frac{M_1}{6} x^3 \\ &= 0.382x^3 + 2.0546x + 2 \\ s_1(x) &= 4.4366 + \left(2 \cdot 2.2768 - \frac{M_1}{6} - \frac{M_2}{24} \right) (x-1) + \frac{M_1}{2} (x-1)^2 + \frac{M_2 - M_1}{3} (x-1)^3 \\ &= 3.11987x^3 - 8.21359x^2 + 10.26818x - 0.73786 \\ s_2(x) &= -2.58926x^3 + 17.4775x^2 - 28.26846x + 18.53046 \end{aligned}$$

Maintenant évaluons la spline en $x = 0.66$ et $x = 1.75$. Puisque $0 < 0.66 < 1$, nous en déduisons :

$$s(0.66) = s_0(0.66) = 3.46586 \quad \text{et} \quad f(0.66) = 2 \exp(0.66) - 0.66^2 = 3.43399,$$

i.e. l'erreur est $< 1\%$. Puisque $1.5 < 1.75 < 2.25$, nous en déduisons :

$$s(1.75) = s_2(1.75) = 8.70870 \quad \text{et} \quad f(1.75) = 2 \exp(1.75) - 1.75^2 = 8.44670,$$

i.e. l'erreur est $> 3\%$. Nous en déduisons que le fit de la courbe de $f(x)$ est moins bonne entre x_2 et x_3 . De fait, en voici une représentation graphique :




FIGURE 3 – $f(x)$ en rouge et $s(x)$ en bleu.

Exercice 9.3. Déterminez le polynôme quadratique qui approxime au mieux les points suivants :

x	y
1	-2
3	-0.8
4	-0.5
5	0.1
6	0.7
8	1

Résolution. Commençons par écrire la matrice de Vandermonde :

$$V = V(\mathbf{x}) = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 3 & 9 \\ 1 & 4 & 16 \\ 1 & 5 & 25 \\ 1 & 6 & 36 \\ 1 & 8 & 64 \end{bmatrix}$$

Notons ensuite que $(V^\top V)_{i,j} = \sum_{k=0}^5 V_{k,i} V_{k,j}$, i.e. les entrées de $V^\top V$ correspondent aux produits scalaires des colonnes de V . De plus, par construction, nous savons que $V^\top V$ est symétrique puisque $(V^\top V)^\top = V^\top (V^\top)^\top = V^\top V$, i.e. il nous suffit de calculer une sous-matrice triangulaire et nous pourrions en déduire l'autre.

De plus, nous savons que $V_{i,k} = x_i^k$, donc $V_{k,i} V_{k,j} = x_k^{i+j}$. En particulier, nous devons uniquement déterminer $M_k := \sum_{i=0}^5 x_i^k$ pour $0 \leq k \leq 4$, et ensuite nous définirons $(V^\top V)_{i,j} = M_{i+j}$.

$$M_0 = 6$$

$$M_1 = 1 + 3 + 4 + 5 + 6 + 8 = 27$$

$$M_2 = 1 + 9 + 16 + 25 + 36 + 64 = 151$$

$$M_3 = 1 + 27 + 64 + 125 + 216 + 512 = 945$$

$$M_4 = 1 + 81 + 256 + 625 + 1296 + 4069 = 6355$$

Dès lors :

$$V^T V = \begin{bmatrix} 6 & 27 & 151 \\ 27 & 151 & 945 \\ 151 & 945 & 6355 \end{bmatrix}$$

Maintenant il nous faut aussi déterminer :

$$V^T \mathbf{y} = \begin{bmatrix} -2 - 0.8 - 0.5 + 0.1 + 0.7 + 1 \\ -2 - 2.4 - 2 + 0.5 + 4.2 + 8 \\ -2 - 7.2 - 8 + 2.5 + 25.2 + 64 \end{bmatrix} = \begin{bmatrix} -1.5 \\ 6.3 \\ 74.5 \end{bmatrix}$$

Le système des équations normales est donc :

$$\begin{bmatrix} 6 & 27 & 151 \\ 27 & 151 & 945 \\ 151 & 945 & 6355 \end{bmatrix} \beta = \begin{bmatrix} -1.5 \\ 6.3 \\ 74.5 \end{bmatrix}.$$

La solution de ce système est donnée par :

$$\beta^* = \begin{bmatrix} -\frac{19921}{7316} \\ \frac{53073}{73160} \\ -\frac{39}{1240} \end{bmatrix},$$

et donc nous déduisons que la meilleure fonction quadratique d'approximation de ces données est :

$$h_{\beta^*}(x) = -\frac{39}{1240}x^2 + \frac{53073}{73160}x - \frac{19921}{7316} \approx -0.03145x^2 + 0.72544x - 0.27229.$$

Séance 10 — Résolution d'équations non-linéaires

Rappel théorique

Nous voulons déterminer une solution à l'équation $f(x) = 0$ pour une certaine fonction $f : [a, b] \subset \mathbb{R} \rightarrow \mathbb{R}$. De manière équivalente, nous pouvons regarder l'équation $f(x) = d$. Notons que ce problème peut s'exprimer comme $x^* = F(d)$ pour $F(d) = f^{-1}(d)$.

La fonction f peut potentiellement n'avoir aucune racine, peut en avoir une seule, mais peut également en avoir plusieurs. De plus une solution peut être de *multiplicité* $m \geq 1$. Ces différents cas ne sont pas équivalents. En effet, le problème n'est bien posé que si une unique solution existe.

Le conditionnement absolu du problème est alors :

$$\kappa_{\text{abs}}(d) = \|F'(d)\| = \left\| \frac{1}{f'(x^*)} \right\| = \frac{1}{|f'(x^*)|},$$

où x^* satisfait $f(x^*) = d$.

Dès lors, nous en déduisons que le problème n'est bien conditionné que lorsque $|f'(x^*)| \gg 0$. En particulier, si la racine x^* est de multiplicité $m \geq 2$, alors le problème est très mal conditionné.

Méthode de la bisection

Théorème 9 (Théorème des valeurs intermédiaires (IVT)). Soient $f \in \mathcal{C}^0([a, b], \mathbb{R})$ et $y \in \mathbb{R}$. Si $\min\{f(a), f(b)\} \leq y \leq \max\{f(a), f(b)\}$, alors il existe $x \in [a, b]$ tel que $f(x) = y$.

Corollaire 10. Sous les mêmes conditions, si $f(a)f(b) < 0$, alors il existe $x^* \in [a, b]$ tel que $f(x^*) = 0$.

En utilisant ce principe, nous pouvons alors définir les séquences $x^{(k)}, a^{(k)}, b^{(k)}$ comme suit :

$$\begin{aligned} x^{(k)} &= \frac{1}{2} (a^{(k)} + b^{(k)}), \\ a^{(0)} &= a \quad a^{(k)} = \begin{cases} a^{(k-1)} & \text{si } \text{sign}(f(x^{(k-1)})) = \text{sign}(f(b^{(k-1)})), \\ x^{(k-1)} & \text{sinon,} \end{cases} \\ b^{(0)} &= b \quad b^{(k)} = \begin{cases} b^{(k-1)} & \text{si } \text{sign}(f(x^{(k-1)})) = \text{sign}(f(a^{(k-1)})), \\ x^{(k-1)} & \text{sinon.} \end{cases} \end{aligned}$$

Méthodes linéarisées

Notons x^* la solution au problème et supposons que $f \in \mathcal{C}^1([a, b])$. Par le théorème de Taylor d'ordre 1 (avec évaluation de l'erreur) autour de x^* , nous savons que pour tout x , il existe un certain $\xi = \xi(x) \in [a, x^*]$ tel que :

$$f(x) = f(x^*) + f'(\xi)(x - x^*) = f'(\xi)(x - x^*).$$

En particulier :

$$x^* = x - \frac{f(x)}{f'(\xi)}.$$

Dès lors, nous pouvons établir la méthode (explicite) suivante (pour $k \geq 0$) :

$$x^{(k+1)} = x^{(k)} - f(x)q_k^{-1},$$

où $q_k \approx f'(\xi)$.

- Si $q_k = q = \frac{f(b)-f(a)}{b-a}$, alors nous parlons de *méthode de la corde*.
- Si $q_k = \frac{f(x^{(k)})-f(x^{(k-1)})}{x^{(k)}-x^{(k-1)}}$, alors nous parlons de *méthode de la sécante*.
- Si $q_k = \frac{f(x^{(k)})-f(x^{(k')})}{x^{(k)}-x^{(k')}} (où k' est le plus grande entier $< k$ tel que $f(x^{(k)})f(x^{(k')}) < 0$), alors nous parlons de *méthode de la fausse position*.$
- Si $q_k = f'(x^{(k)})$, alors nous parlons de la méthode de Newton-Raphson.

La méthode de la fausse position admet une convergence globale, alors que les trois autres convergent localement, c-à-d qu'il existe un certain $\delta > 0$ tel que si $|x^{(0)} - x^*| < \delta$, alors $x^{(k)} \xrightarrow[k \rightarrow +\infty]{} x^*$.

Définition 1. Considérons une suite $(x^{(k)})_k$ convergente vers x^* . S'il existe $C, k_0 > 0$ et $p \geq 1$ tels que pour tout $k \geq k_0$:

$$|x^{(k+1)} - x^*| < C |x^{(k)} - x^*|^p,$$

alors nous disons que la convergence est d'ordre p et de facteur C .

Si la méthode de la corde converge, alors cette convergence est linéaire. La méthode de la sécante admet une convergence d'ordre $p \in (1, 2)$. Si $f'(x^*) \neq 0$, alors la méthode de Newton-Raphson admet une convergence quadratique. La méthode de la fausse position admet également une convergence linéaire.

Exercice 10.1. Trouvez une racine de la fonction $f(x) = x^3 + 3x^2 - 1$ dans l'intervalle $[-2, 0]$ à l'aide de la méthode de la bisection. Faites 5 itérations.

Résolution. Procédons sous forme de tableau. Tout d'abord nous allons avoir besoin des données $f(a^{(0)}) = f(a) = f(-2) = 3$ et $f(b^{(0)}) = f(b) = f(0) = -1$.

k	$a^{(k)}$	$b^{(k)}$	$x^{(k)}$	$f(x^{(k)})$	Remarque
0	-2	0	-1	1	Signe de $f(a^{(0)})$
1	-1	0	$-\frac{1}{2}$	$-\frac{3}{8}$	Signe de $f(b^{(1)})$
2	-1	$-\frac{1}{2}$	$-\frac{3}{4}$	$\frac{17}{64}$	Signe de $f(a^{(2)})$
3	$-\frac{3}{4}$	$-\frac{1}{2}$	$-\frac{5}{8}$	$-\frac{37}{512}$	Signe de $f(b^{(3)})$
4	$-\frac{3}{4}$	$-\frac{5}{8}$	$-\frac{11}{16}$	$\frac{381}{4096}$	

Nous avons alors pour solution approximée $x^* \approx x^{(4)} = -\frac{11}{16} = -0.6875$. Notons tout de même que $f(x^{(4)}) = \frac{381}{4096} \approx 0.0930$, ce qui n'est pas très satisfaisant, même en 5 itérations.

Exercice 10.2. Que va-t-il se passer si on cherche une racine de la fonction $\tan(x)$ sur les intervalles suivants $I_1 = [1, 3]$ et $I_2 = [3, 4]$?

Résolution. La fonction $\tan$ s'annule quand $\sin$ s'annule, i.e. pour $x \in \mathbb{Z}\pi$ et a une asymptote verticale quand $\cos$ s'annule, i.e. pour $x \in \frac{\pi}{2} + \mathbb{Z}\pi$. Notons également que $\tan$ est

π -périodique puisque :

$$\tan(x + \pi) = \frac{\sin(x + \pi)}{\cos(x + \pi)} = \frac{-\sin x}{-\cos x} = \frac{\sin x}{\cos x} = \tan x.$$

Dès lors, nous savons que sur l'intervalle $I_2 = [3, 4]$, la fonction $\tan$ est continue et admet une racine (puisque $\tan \pi = 0$). Dès lors, la méthode de la bisection se passera normalement et convergera vers cette valeur.

Cependant, sur l'intervalle $[1, 3]$, la fonction $\tan$ n'est pas continue ! Elle n'est même pas définie partout puisqu'elle n'existe pas en $\frac{\pi}{2}$, qui est clairement dans cet intervalle. De plus, bien que $\tan(1) \approx 1.557 > 0 > -0.142 \approx \tan(3)$, $\tan$ n'admet pas de racine sur l'intervalle I_1 . En effet, le corollaire d'IVT nécessite bien la continuité de la fonction utilisée sur l'intervalle donné, ce qui n'est pas le cas ici.

La méthode de la bisection peut tout de même être appliquée et convergera vers $\frac{\pi}{2}$ puisque $\tan$ est positive sur $[1, \pi/2)$ et négative sur $(\pi/2, 3]$.

Exercice 10.3. Soit une fonction f continue et soit l'intervalle $I = [2, 7]$. Combien d'itérations de la méthode de la bisection sont nécessaires pour garantir une précision de 5×10^{-8} ?

Résolution. Puisque $|x^{(k)} - x^*| \leq \frac{b^{(k)} - a^{(k)}}{2} = \frac{|I^{(k)}|}{2} = \frac{|I^{(0)}|}{2^{k+1}}$, nous savons que si cette dernière quantité est bornée par 5×10^{-8} , alors $|x^{(k)} - x^*|$ l'est aussi. Il nous reste alors à résoudre l'inégalité :

$$\frac{b - a}{2^{k+1}} \leq 5 \times 10^{-8},$$

i.e. $k \geq \lceil 8 \log_2 10 - 1 \rceil = 26$.

Exercice 10.4. Trouvez une racine de la fonction $f(x) = x^3 - x^2 - 4x - 3$ dans l'intervalle $[2, 3]$ avec la méthode de la corde. Faites 5 itérations et prenez $x^{(0)} = \frac{5}{2}$.

Résolution. Notons bien que $f(2) = 8 - 4 - 8 - 3 = -7 < 0$ et $f(3) = 27 - 9 - 12 - 3 = 3 > 0$, dès lors nous savons que f admet une racine sur l'intervalle $[2, 3]$ par continuité de f .

Pour la méthode de la corde, nous prenons $q_k = q = \frac{f(b) - f(a)}{b - a} = \frac{3 - (-7)}{3 - 2} = 10$. Calculons ensuite :

$$\begin{aligned} x^{(0)} &= \frac{5}{2} \\ x^{(1)} &= x^{(0)} - \frac{1}{q} f(x^{(0)}) = \frac{5}{2} - \frac{1}{10} \left(\frac{-29}{80} \right) = \frac{229}{80} = 2.8625 \\ x^{(2)} &= x^{(1)} - \frac{1}{q} f(x^{(1)}) \approx 2.78138 \\ x^{(3)} &= x^{(2)} - \frac{1}{q} f(x^{(2)}) \approx 2.81584 \\ x^{(4)} &= x^{(3)} - \frac{1}{q} f(x^{(3)}) \approx 2.80240 \\ x^{(5)} &= x^{(4)} - \frac{1}{q} f(x^{(4)}) \approx 2.80785 \end{aligned}$$

Remarquons tout de même que même après 5 itérations, nous trouvons :

$$f(x^{(5)}) \approx 2.17750 \times 10^{-2},$$

ce qui n'est pas une très bonne approximation de la racine qui est en réalité $x \approx 2.80630$. Il faut près d'une quarantaine d'itérations de la méthode de la corde afin de converger (au sens des floats, i.e. $x^{(k)} = x^{(k+1)}$ pour $k \geq 38$).

Exercice 10.5. Trouvez une racine de la fonction $f(x) = 6x^3 - 23x^2 + 20x$ dans l'intervalle $[1, 2]$ avec la méthode de la sécante (faites 4 itérations).

Résolution. À nouveau : $f(1) = 6 - 23 + 20 = 3 > 0$ et $f(2) = 48 - 92 + 40 = -4$, donc f admet une racine dans l'intervalle $[1, 2]$ par continuité.

Pour la méthode de la sécante, nous utilisons $q_k = \frac{f(x^{(k)}) - f(x^{(k-1)})}{x^{(k)} - x^{(k-1)}}$. Puisque chaque nouvelle itération requiert deux itérations précédentes, fixons $x^{(-1)} = 1$ et $x^{(0)} = 2$ (qui sont donc les extrémités de l'intervalle considéré). Calculons alors :

$$\begin{array}{lll} q_1 = \frac{-4 - 3}{2 - 1} = -7 & x^{(1)} = \frac{10}{7} \approx 1.42857 & f(x^{(1)}) = \frac{-300}{343} \\ q_2 = \frac{\frac{-300}{343} - (-4)}{\frac{10}{7} - 2} = \frac{-268}{49} & x^{(2)} = \frac{85}{67} \approx 1.26866 & f(x^{(2)}) \approx 0.60621 \\ q_3 = \frac{-2036885}{219961} & x^{(3)} = \frac{543490}{407377} \approx 1.33412 & f(x^{(3)}) \approx -0.0073461 \\ q_4 \approx -9.37243 & x^{(4)} \approx 1.33334 & f(x^{(4)}) \approx -3.12635 \times 10^{-5}. \end{array}$$

De fait, il est aisé de voir que $f(x) = 6x(x - \frac{5}{2})(x - \frac{4}{3})$, et donc la racine dans l'intervalle $[1, 2]$ est $\frac{4}{3}$.

Exercice 10.6. Déterminez une racine des fonctions suivantes dans les intervalles donnés via la méthode de la fausse position en 4 itérations :

1. $f(x) = \exp(x) - 2 - x$ et $I = [-2.4, -1.6]$;
2. $f(x) = \cos x + 1 - x$ et $I = [0.8, 1.6]$;
3. $f(x) = \ln x - 5 + x$ et $I = [3.2, 4]$;
4. $f(x) = x^2 - 10x + 23$ et $I = [6, 6.8]$.

Résolution.

Exercice 10.7. Trouvez une racine de la fonction $f(x) = x^3 - 9x + 2$ dans l'intervalle $I = [-4, -3]$ avec la méthode de Newton-Raphson. Faites 4 itérations et prenez $x^{(0)} = -\frac{7}{2}$.

Résolution. Pour la méthode N-R, nous avons besoin, en plus d'évaluer f , d'évaluer sa dérivée f' qui est :

$$f'(x) = 3x^2 - 9.$$

Calculons alors :

$$\begin{array}{lll} x^{(0)} = \frac{-7}{2} & f(x^{(0)}) = \frac{-75}{8} & f'(x^{(0)}) = \frac{111}{4} \\ x^{(1)} = \frac{-7}{2} - \frac{-75/8}{111/4} = \frac{-117}{37} \approx -3.162162 & f(x^{(1)}) \approx -1.15985 & f'(x^{(1)}) \approx 20.9978 \\ x^{(2)} \approx -3.10693 & f(x^{(2)}) \approx -0.028776 & f'(x^{(2)}) \approx 19.9590 \\ x^{(3)} \approx -3.10548 & f(x^{(3)}) \approx -1.93715 \times 10^{-5} & f'(x^{(3)}) \approx 19.9321 \end{array}$$

$$x^{(4)} \approx -3.10548$$

$$f(x^{(4)}) \approx -8.80362 \times 10^{-12} \quad f'(x^{(4)}) \approx 19.9321$$

Séance 11 — Résolution d'équations non-linéaires par itération de point fixe

Rappel théorique

Un raffinement itératif peut être vu comme une application répétée d'une fonction ϕ :

$$x^{(k+1)} = \phi(x^{(k)}).$$

Dans ce formalisme, trouver une solution à $f(x) = 0$ correspond à trouver un *point fixe* de la fonction ϕ , i.e. un point x tel que $\phi(x) = x$.

Théorème 11. Soit $\phi \in \mathcal{C}^1([a, b], \mathbb{R})$.

1. Si $\phi([a, b]) \subseteq [a, b]$, alors ϕ admet un point fixe dans l'intervalle $[a, b]$.
2. Si en plus $\phi' < 1$ sur $[a, b]$, alors pour tout choix de $x^{(0)} \in [a, b]$, la suite $(x^{(k)})_k$ des applications itérées de ϕ converge vers l'unique point fixe de ϕ sur $[a, b]$.
3. Si par contre $\phi' > 1$ sur $[a, b]$, alors pour tout choix de $x^{(0)}$ qui n'est pas un point fixe de ϕ , la suite $(x^{(k)})_k$ des applications itérées de ϕ ne converge pas.

Notons que par contraposée, le point 3 de ce théorème nous dit que pour avoir convergence, il faut nécessairement que $|\phi'(x^*)| \leq 1$.

Théorème 12 (Ostrowski). Soit $\phi \in \mathcal{C}^1([a, b], \mathbb{R})$ et soit $x^* \in [a, b]$, un point fixe de ϕ . Si $|\phi'(x^*)| < 1$, alors il existe $\delta > 0$ tel que pour tout $x^{(0)} \in (x^* \pm \delta)$, la limite suivante est vérifiée :

$$x^{(k)} \xrightarrow[k \rightarrow +\infty]{} x^*.$$

Si la dérivée de ϕ est trop grande en valeur absolue autour du point fixe, nous pouvons toujours changer de fonction ϕ . De manière générale, si nous voulons résoudre une équation de la forme $f(x) = 0$, pour toute fonction continue F telle que $F(0) = 0$, alors nous pouvons définir $\phi = \phi_F$ comme ceci :

$$\phi(x) = F(f(x)) + x.$$

De fait, si x^* satisfait $f(x^*) = 0$, alors :

$$\phi(x^*) = F(f(x^*)) + x^* = F(0) + x^* = x^*,$$

et donc x^* est un point fixe de ϕ . Attention cependant : si F s'annule en un point $z \neq 0$ et s'il existe un $\hat{x} \neq x^*$ tel que $f(\hat{x}) = z$, alors $\phi(\hat{x}) = \hat{x}$ (donc $\hat{x}$ est un point fixe de ϕ), même si $f(\hat{x}) = z \neq 0$.

Exercice 11.1. Trouvez un zéro de $f(x) = 2x^2 - 5x + 1$ en trouvant un point fixe. Utilisez d'abord 0, puis 1 comme valeur initiale. Faites 5 itérations.

Résolution. Notons que $f(0) = 1 > 0$, mais $f(1) = -2 < 0$. Dès lors nous savons (par IVT) que f admet une racine dans l'intervalle $[0, 1]$.

Déterminons une fonction $\phi(x)$. Si nous utilisons :

$$\phi(x) = f(x) + x = 2x^2 - 4x + 1,$$

et que nous regardons $\phi'(x) = 4x - 4 = 4(x - 1)$, nous remarquons que $\phi'(1) = 0$ mais $|\phi'(0)| = 4 > 1$. Nous n'aurons alors pas la convergence voulue.

Notons que nous pouvons plutôt définir :

$$\phi(x) = \frac{1}{5}f(x) + x = \frac{2}{5}x^2 - x + \frac{1}{5} + x = \frac{1}{5}(2x^2 + 1).$$

Dans ce cas, $|\phi'(x)| = \frac{4}{5}x < 1$ sur $[0, 1]$. Appliquons maintenant la fonction ϕ itérativement :

$$\begin{aligned} x^{(0)} &= 0 \\ x^{(1)} &= \phi(x^{(0)}) = \frac{2}{5}(x^{(0)})^2 + \frac{1}{5} = \frac{1}{5} = 0.2 \\ x^{(2)} &= \phi(x^{(1)}) = \frac{2}{5}(x^{(1)})^2 + \frac{1}{5} = \frac{27}{125} = 0.216 \\ x^{(3)} &= \phi(x^{(2)}) = \frac{2}{5}(x^{(2)})^2 + \frac{1}{5} = 0.2186624 \\ x^{(4)} &= \phi(x^{(3)}) = \frac{2}{5}(x^{(3)})^2 + \frac{1}{5} \approx 0.21913 \\ x^{(5)} &= \phi(x^{(4)}) = \frac{2}{5}(x^{(4)})^2 + \frac{1}{5} \approx 0.21921 \end{aligned}$$

En partant de 1 :

$$\begin{aligned} x^{(0)} &= 1 \\ x^{(1)} &= 0.6 \\ x^{(2)} &= 0.344 \\ x^{(3)} &\approx 0.24733 \\ x^{(4)} &\approx 0.22447 \\ x^{(5)} &\approx 0.22015 \end{aligned}$$

Exercice 11.2. Déterminez si les fonctions suivantes admettent un point fixe sur l'intervalle donné :

- $\phi_1(x) = 1 - \frac{x^2}{4}$ sur $[0, 1]$;
- $\phi_2(x) = 2^{-x}$ sur $[0, 1]$;
- $\phi_3(x) = x^{-1}$ sur $[0.5, 5.2]$;

Résolution.

- $\phi_1([0, 1]) = [3/4, 1] \subset [0, 1]$, donc ϕ_1 admet un point fixe. De plus $|\phi_1'(x)| = x/2 < 1$ sur $[0, 1]$, donc ce point fixe est unique.
- $\phi_2([0, 1]) = [1/2, 1] \subset [0, 1]$, donc ϕ_2 admet un point fixe. De plus $|\phi_2'(x)| = \ln 2 \cdot 2^{-x} < \ln 2$.
- $\phi_3([0, 1]) = [1/5.2, 2] \not\subset [0.5, 5.2]$, donc on ne sait pas conclure par le théorème ci-dessus. Cependant, nous savons que $\phi_3(5.2) < 5.2 = \text{Id}(5.2)$ et $\phi_3(0.5) > 0.5 = \text{Id}(0.5)$. Dès lors, nous en déduisons que ϕ_3 et Id doivent se croiser sur l'intervalle $[0.5, 5.2]$.

Exercice 11.3. Soit la fonction ϕ suivante :

$$\phi(x) = -\frac{1}{2}x^2 + 4x - 4.$$

Que pouvez-vous dire du comportement de l'itération de point fixe quand :

1. Résolvez $\phi(x) = x$ et montrez que 2 et 4 sont les seuls points fixes de ϕ .
2. Utilisez $x^{(0)} = 1.9$ pour l'itération de point fixe en 3 itérations.
3. Utilisez $x^{(0)} = 3.8$ pour l'itération de point fixe en 3 itérations.
4. Que peut-on en conclure ? Comment peut-on le vérifier ?

Résolution.

1. x est un point fixe de ϕ si et seulement si x est une racine de $\phi(x) - x = -\frac{1}{2}x^2 + 3x - 4$. Or :

$$-\frac{1}{2}x^2 + 3x - 4 = -\frac{1}{2}(x-2)(x-4),$$

donc $x = 2$ et $x = 4$ sont les seuls points fixes de ϕ . On aurait aussi pu constater que $\phi(2) = -2 + 8 - 4 = 2$ et $\phi(4) = -8 + 16 - 4 = 4$, et que $\phi(x) - x$ étant un polynôme de degré 2, il peut n'avoir qu'au plus deux racines réelles.

2.

$$x^{(0)} = 1.9$$

$$x^{(1)} = 1.795$$

$$x^{(2)} = 1.56899$$

$$x^{(3)} = 1.04509$$

3.

$$x^{(0)} = 3.8$$

$$x^{(1)} = 3.98000$$

$$x^{(2)} = 3.99980$$

$$x^{(3)} = 4.00000$$

4. On en déduit que $\phi'(4)$ doit être bornée par 1 en module, mais que soit $\phi'(2)$ l'est aussi, mais le voisinage donné par le théorème d'Ostrowski ne contient pas 1.9 ; soit $|\phi'(2)| > 1$. De fait :

$$\phi'(2) = (-2 + 4) = 2 > 1,$$

$$\phi'(4) = (-4 + 4) = 0 < 1.$$

Exercice 11.4. Soit $f(x) = x^2 + x - 4$. Peut-on utiliser une itération de point fixe pour trouver les solutions de l'équation $f(x) = 0$? Pourquoi ?

Résolution. Il est toujours possible de trouver les racines d'une fonction par itération de point fixe, il suffit de choisir une bonne fonction ϕ .

Ici, nous savons aisément que $f(0) = -4$ et $f(2) = 2$. Dès lors, nous savons qu'une racine existe dans l'intervalle $[0, 2]$ (par continuité). Il nous faudrait alors une fonction $\phi(x) = \lambda f(x) + x$ telle que $|\phi'|$ soit < 1 sur $[0, 2]$. Or :

$$|\phi'(x)| = |\lambda f'(x) + 1| = |2\lambda x + \lambda + 1|.$$

Dès lors :

$$|\phi'(x)| < 1 \quad \text{ssi} \quad -1 < \phi'(x) < 1 \quad \text{ssi} \quad -2 < \lambda(2x+1) < 0.$$

Puisque $x \in [0, 2]$, nous savons que $2x+1 \in [1, 5]$. Dès lors :

$$0 > \lambda > \frac{-2}{2x+1},$$

i.e. $\lambda \geq \frac{-2}{5}$. Par exemple pour $\lambda = -\frac{1}{5}$:

$$\phi(x) = -\frac{1}{5}f(x) + x = -\frac{1}{5}x^2 + \frac{4}{5}x + \frac{4}{5}.$$

Notons que $\phi(x)$ est une parabole de coefficient principal négatif, donc son maximum est atteint en $\frac{-b}{2a} = \frac{-4/5}{-2/5} = 2$:

$$\phi(2) = -\frac{4}{5} + \frac{8}{5} + \frac{4}{5} = \frac{8}{5} = 1.6$$

De plus, puisque ϕ est une parabole, elle est monotone sur tout intervalle dont sont extrémités l'extrémum et une extrémité, en particulier ϕ est croissante sur $[0, 2]$, donc nous savons que $\phi([0, 2]) = [\phi(0), \phi(2)] = [.8, 1.6] \subset [0, 2]$, donc le **Théorème 11** nous garantit que peu importe le choix de $x^{(0)}$ dans $[0, 2]$, l'itération de points fixes convergera vers l'unique point fixe $x^* \in [0, 2]$. De fait, prenons $x^{(0)} = 1$:

$$x^{(0)} = 1.0$$

$$x^{(1)} = 1.4$$

$$x^{(2)} = 1.528$$

$$x^{(3)} \approx 1.55544$$

$$x^{(4)} \approx 1.56047$$

$$x^{(5)} \approx 1.56136$$

Notons que cette racine correspond à $\frac{-1+\sqrt{17}}{2} \approx 1.561553$.

L'autre racine peut être localisée par symétrie de la parabole : si nous notons la première racine x_1 et la seconde x_2 , pour l'extrémum en $x = \frac{-b}{2a} = -\frac{1}{2}$, alors nous savons que $x - x_2 = x_1 - x$, et donc $x_2 = 2x - x_1$, où x_1 est la racine trouvée ci-dessus.

Sinon, nous pouvons chercher une valeur $x < 0$ telle que $f(x) > 0$, par exemple $x = -5$ puisque $f(-5) = 26 > 0$, et recommencer. Nous prendrons plutôt $x = -1$ comme borne supérieure de l'intervalle afin de garantir que le signe de ϕ' reste constant.

$$\phi(x) = \lambda f(x) + x,$$

donc pour $x \in [-5, -1]$, nous avons $-9 \leq 2x+1 \leq -1$:

$$|\phi'(x)| < 1 \iff -2 < \lambda(2x+1) < 0 \iff 0 < \lambda < \frac{-2}{2x+1},$$

i.e. $\lambda < \frac{2}{9}$. Prenons alors $\lambda = \frac{1}{9}$.

$$\phi(x) = \frac{1}{9}x^2 + \frac{10}{9}x - \frac{4}{9}.$$

À nouveau, $\phi([-5, -1]) = [\phi(-1), \phi(-5)] = [-29/9, -13/9] \subset [-45/9, -9/9] = [-5, -1]$, dès lors ϕ admet un unique point fixe et tout choix de $x^{(0)} \in [-5, -1]$ fera converger l'itération. Prenons alors $x^{(0)} = -3$:

$$x^{(0)} = -3.00000$$

$$x^{(1)} \approx -2.77778$$

$$x^{(2)} \approx -2.67353$$

$$x^{(3)} \approx -2.62084$$

$$x^{(4)} \approx -2.59329$$

$$x^{(5)} \approx -2.57864$$

Cette deuxième racine correspond à $\frac{-1-\sqrt{17}}{2} \approx -2.561553$.

Exercice 11.5. Trouver une racine de $f(x) = x - x^3$ en utilisant une itération de point fixe.

Résolution. Nous savons que $f(x) = x(1-x)(1+x)$, et donc les racines de f sont $-1, 0$ et 1 . Nous pouvons également remarquer que f est un polynôme de degré 3, donc a au plus 3 racines et :

$$f(-2) = -2 - (-2)^3 = 6 > 0$$

$$f(-1/2) = -\frac{1}{2} - \frac{-1}{8} = -\frac{3}{8} < 0$$

$$f(1/2) = -f(-1/2) = \frac{3}{8} > 0$$

$$f(2) = -f(-2) = -6 < 0.$$

Dès lors la plus petite racine se trouve entre -2 et $-1/2$, la seconde entre $-1/2$ et $1/2$, et la dernière se trouve entre $1/2$ et 2 .

Choisissons alors $\phi(x) = -f(x) + x = x^3$. Notons que $\phi'(x) = 3x^2$, et en particulier $|\phi'| \leq \frac{3}{4} < 1$ sur l'intervalle $[-1/2, 1/2]$. Nous savons donc par le **Théorème 11** que ϕ admet un unique point fixe sur cet intervalle et que pour toute valeur $x^{(0)}$ telle que $-1/2 \leq x^{(0)} \leq 1/2$, la suite des itérations de points fixes convergera vers ce point fixe. Prenons alors $x^{(0)} = 1/2$:

$$x^{(0)} = \frac{1}{2} = 2^{-1} = 0.5$$

$$x^{(1)} = (2^{-1})^3 = 2^{-3} = 0.125$$

$$x^{(2)} = 2^{-6} = 0.015625$$

$$x^{(3)} = 2^{-9} = 1.953125 \times 10^{-3}$$

$$x^{(4)} = 2^{-12} = 2.44140625 \times 10^{-5}$$

En réalité, pour tout $x^{(0)} \in (-1, +1)$, la suite de terme général $|x^{(k+1)}|$ converge vers 0.