

Séance 2 — Représentation à virgule fixe et virgule flottante

Rappel théorique

Dans ce qui suit, nous devons toujours travailler dans une base b fixée (typiquement $b = 2$ dans un ordinateur ou $b = 10$ lorsque nous raisonnons sur papier).

La représentation à *virgule fixe* consiste à se fixer une base $b \geq 2$, un signe $s \in \{0, 1\}$ (où $s = 0$ désigne qu'un nombre est positif et $s = 1$ désigne qu'un nombre est négatif) et $n + m + 1$ chiffres (en base b toujours) dont les $n + 1$ premiers sont utilisés pour représenter la partie entière d'un nombre et les m suivants sont utilisés pour représenter la partie décimale, i.e. :

$$x = ([x_n, x_{n-1}, \dots, x_1, x_0, x_{-1}, \dots, x_{-m}], b, s),$$

où les x_k sont entre 0 et $b - 1$ (donc des chiffres en base b). Cette représentation représente le nombre :

$$x = (-1)^s \sum_{k=-m}^n x_k \cdot b^k.$$

Attention, nous identifions ici la représentation et la valeur du nombre représenté.

Travailler en virgule fixe correspond en réalité à travailler uniquement sur des entiers sur $m + 1 + n$ chiffres, mais de les interpréter $\times b^{-m}$.

Cependant, en fonction du contexte, on pourrait vouloir avoir plus de précision pour la partie entière ou plus de précision pour la partie décimale, ce qui n'est pas possible.

La *virgule flottante* cherche à contourner ce problème en travaillant sur une *mantisse* de taille t fixée, mais également avec un exposant e (généralisant la notation scientifique). Le nombre à virgule flottante suivant

$$x = ([x_1, \dots, x_t], e, b, s)$$

est donc à interpréter comme le nombre réel suivant

$$x = (-1)^s m b^{e-t} = (-1)^s \sum_{k=1}^t x_k b^{e-k}.$$

Attention, nous imposons à nouveau ici $s \in \{0, 1\}$, $b \geq 2$, $e \in \mathbb{Z}$ (en effet cet exposant peut très bien être négatif), mais également $1 \leq x_1 \leq b - 1$ et $0 \leq x_k \leq b - 1$ pour $k \geq 2$. En particulier x_1 ne peut pas être nul (ce qui garantit l'unicité de la représentation d'un nombre sous cette forme).

À base b fixée, pour t, L, U des entiers tels que $L \leq U$, nous définissons l'ensemble $\mathbb{F}(b, t, L, U)$ comme l'ensemble contenant tous les réels $x \in \mathbb{R}$ qui admettent une représentation à virgule flottante avec (i) une mantisse de taille t ; (ii) la base b ; et (iii) $L \leq e \leq U$.

Notons qu'il est possible de montrer que $|\mathbb{F}(b, t, L, U)| = 2(U - L + 1)(b - 1)b^{t-1}$. En effet, dans la représentation $([x_1, \dots, x_t], e, b, s)$ peut prendre :

- 2 valeurs pour s (à savoir 0, 1) ;

- $U - L + 1$ valeurs pour e (à savoir $L, L + 1, \dots, U - 1, U$);
- $b - 1$ valeurs pour x_1 (à savoir $1, 2, \dots, b - 1$);
- et b valeurs pour chacun des x_k pour $2 \leq k \leq t$ (à savoir $0, 1, \dots, b - 1$).

Le produit de ces différentes entrées vaut bien $2(U - L + 1)(b - 1)b^{t-1}$.

Notons tout de même que le fait d'imposer $x_1 \neq 0$ nous empêche de représenter 0 en virgule flottante. Nous appelons ces représentations sous *forme normalisée*. Évidemment, en pratique, la possibilité de tout de même mettre x_1 à 0 permet de représenter des *valeurs spéciales*, e.g. la valeur 0, mais également $\pm\infty$, ou encore NaN.

2.1 Virgule fixe

■ **Exercice 2.1.** Si $b = 10, n = 3, m = 6$ et $s = 0$, à quel nombre correspond $[0012200000]$?

Résolution. Puisque $n = 3$, nous savons que les 4 premiers chiffres représentent la partie entière, et les 6 derniers représentent la partie fractionnaire. De plus $s = 0$, donc le nombre considéré est positif. Dès lors il correspond à $0012.200000 = 12.2$, ou encore :

$$1 \times 10^1 + 2 \times 10^0 + 2 \times 10^{-1} = 10 + 2 + 0.2 = 12.2$$

■ **Exercice 2.2.** Même question si $b = 3$?

Résolution. Si $b = 3$, alors ce nombre correspond à :

$$1 \times 3^1 + 2 \times 3^0 + 2 \times 3^{-1} = 3 + 2 + \frac{2}{3} = 5 + \frac{2}{3} = \frac{17}{3}.$$

■ **Exercice 2.3.** Si $b = 3, n = 3, m = 6$ et $s = 0$, à quel nombre correspond $[3012200000]$?

Résolution. Puisque nous travaillons en base $b = 3$, tous les chiffres doivent être entre 0 et $b - 1 = 3 - 1 = 2$. Or le premier chiffre donné est 3, la représentation n'est donc pas valide.

2.2 Virgule flottante

■ **Exercice 2.4.** A quels nombres correspondent :

- $([34], e = 2, b = 10, s = 0)$;
- $([34], e = 1, b = 16, s = 1)$;
- $([10001], e = 6, b = 2, s = 0)$?

Résolution.

$$(-1)^0 \times (3 \times 10^1 + 4 \times 10^0) \times 10^{2-2} = 30 + 4 = 34.$$

$$(-1)^1 \times (3 \times 16^1 + 4 \times 16^0) \times 16^{1-2} = -(48 + 4) \times 16^{-1} = -\frac{52}{16} = -\frac{13}{4}.$$

$$(-1)^0 \times (2^4 + 2^0) \times 2^{6-5} = 17 \times 2^1 = 34.$$

Exercice 2.5. Représentez le nombre 234.5 en virgule flottante avec $b = 2$ et les autres paramètres suffisamment grands.

Résolution. Notons que $234.5 = 234 + \frac{1}{2}$. Dès lors tant la partie entière que la partie fractionnaire sont aisément représentables en binaire. En effet, la partie entière 234 peut s'écrire 11101010. Dès lors $(234.5)_{10} = (11101010.1)_2$, et donc en virgule flottante :

- la mantisse est donnée par [111010101];
- donc $t = 9$;
- le signe est $s = 0$ puisque $234.5 > 0$;
- la base est $b = 2$;
- et l'exposant e peut être trouvé via la formule :

$$e = 9 + \log_2 \frac{234.5}{(-1)^0 \times 469} = 9 + \log_2 \frac{1}{2} = 9 - 1 = 8.$$

Afin de trouver e , notez que nous partons de l'expression (où m est à interpréter comme un nombre entier) :

$$x = (-1)^s m b^{e-t}.$$

Dès lors :

$$b^{e-t} = \frac{x}{(-1)^s m},$$

et finalement :

$$e - t = \log_b \frac{x}{(-1)^s m}.$$

Il ne reste plus qu'à ajouter t des deux côtés pour obtenir la forme générale :

$$e = t + \log_b \frac{x}{(-1)^s m} = t + \log_b \frac{|x|}{m}.$$

Remarque. Notons également que l'exposant e peut, en un sens, être vu comme le nombre de chiffres (de la mantisse) à lire avant de placer la séparation décimale. En effet, si $e = t$, alors c'est que la mantisse donne en réalité un nombre entier. Ici, nous voulons que, parmi les 9 bits, il n'y en ait qu'un seul dans la partie décimale, donc $e = 9 - 1 = 8$.

Exercice 2.6. Combien de nombres peut-on représenter en virgule flottante en base $b = 4$, et avec les paramètres $L = -2$, $U = 2$, et $t = 2$?

Résolution. Utilisons la formule donnée ci-dessus :

$$|\mathbb{F}(4, 2, -2, 2)| = 2(2 - (-2) + 1) \cdot 3 \cdot 4^1 = 2 \times 5 \times 3 \times 4 = 120.$$

Il y a donc 120 nombres représentable sous forme normalisée avec 2 chiffres significatifs, en base 4, et avec un exposant entre -2 et 2 . Il est bien sûr possible d'ajouter à cela des valeurs spéciales, mais nous n'en parlons pas ici.

Exercice 2.7. Considérons le système linéaire suivant :

$$\begin{cases} 0.461x_1 + 0.311x_2 &= 0.150 \\ 0.209x_1 + 0.141x_2 &= 0.068 \end{cases}$$

Il admet pour solution $(x_1, x_2) = (1, -1)$. Montrez que la résolution de ce système en

■ utilisant une représentation en virgule flottante ($b = 10, t = 3$) manque de précision.

Résolution. Nous allons résoudre ce système par méthode de substitution : d'abord isolons x_1 dans la première équation, et puis substituons ce que nous obtenons dans la seconde. Ainsi nous n'aurons plus que x_2 comme inconnue dans cette seconde équation, et ainsi nous pourrions la résoudre pour x_2 . Il ne restera plus qu'à substituer la valeur trouvée pour x_2 dans la première équation pour retrouver x_1 .

Commençons par réécrire tous les nombres en notation scientifique à 3 chiffres significatifs :

$$\begin{cases} 4.61 \times 10^{-1}x_1 + 3.11 \times 10^{-1}x_2 = 1.50 \times 10^{-1} \\ 2.09 \times 10^{-1}x_1 + 1.41 \times 10^{-1}x_2 = 6.80 \times 10^{-2} \end{cases}$$

Isolons ainsi x_1 dans la première équation en arrondissant systématiquement à 3 chiffres :

$$x_1 = \frac{1.50 \times 10^{-1}}{4.61 \times 10^{-1}} - \frac{3.11 \times 10^{-1}}{4.61 \times 10^{-1}}x_2 \stackrel{t=3}{=} 3.26 \times 10^{-1} - 6.75 \times 10^{-1}x_2.$$

Dès lors :

$$\begin{aligned} 2.09 \times 10^{-1} (3.26 \times 10^{-1} - 6.75 \times 10^{-1}x_2) + 1.41 \times 10^{-1}x_2 &= 6.80 \times 10^{-2} \\ 2.09 \cdot 3.26 \times 10^{-2} - 2.09 \cdot 6.75 \times 10^{-2}x_2 + 1.41 \times 10^{-1}x_2 &= 6.80 \times 10^{-2} \\ 6.81 \times 10^{-2} - 1.41 \times 10^{-1}x_2 + 1.41 \times 10^{-1}x_2 &= 6.80 \times 10^{-2} \\ 6.81 \times 10^{-2} &= 6.80 \times 10^{-2}, \end{aligned}$$

il y a donc un problème.

Nous pouvons alors plutôt isoler x_2 dans la première équation et la substituer dans la seconde :

$$x_2 = \frac{1.50 \times 10^{-1}}{3.11 \times 10^{-1}} - \frac{4.61 \times 10^{-1}}{3.11 \times 10^{-1}}x_1 \stackrel{t=3}{=} 4.82 \times 10^{-1} - 1.48 \times 10^0x_1.$$

Dès lors :

$$\begin{aligned} 2.09 \times 10^{-1}x_1 + 1.41 \times 10^{-1} (4.82 \times 10^{-1} - 1.48 \times 10^0x_1) &= 6.80 \times 10^{-2} \\ 2.09 \times 10^{-1}x_1 + 6.80 \times 10^{-2} - 2.09 \times 10^{-1}x_1 &= 6.80 \times 10^{-2} \\ 6.80 \times 10^{-2} &= 6.80 \times 10^{-2}, \end{aligned}$$

et à nouveau : oups. Il n'est pas possible de trouver x_2 .

Remarque : en résolvant le système donné ici, nous tombons systématiquement sur un problème. En effet, après une première substitution, il n'est pas possible d'aller plus loin, tout se comporte comme si la matrice n'était pas inversible. De fait, si nous regardons le déterminant de cette matrice :

$$\det \begin{bmatrix} 0.461 & 0.311 \\ 0.209 & 0.141 \end{bmatrix} = \left(\frac{1}{10^3} \right)^2 \det \begin{bmatrix} 461 & 311 \\ 209 & 141 \end{bmatrix} = 10^{-6} (461 \cdot 141 - 311 \cdot 209) = 2 \times 10^{-6},$$

ce qui est très mauvais signe, et de fait : le problème de résolution du système est très mal conditionné. En effet nous pouvons calculer $\kappa(A) \approx 181\,200$ (c.f. la [section 3](#) et la [section 6](#)).

Exercice 2.8. Considérez l'équation $\alpha x + \beta = 0$ pour $\alpha = 0.111$ et $\beta = -2$. $z = 18$ en est une solution approchée. Utilisez l'arithmétique décimale (donc en base $b = 10$) tronquée à 3 chiffres (donc $t = 3$) pour calculer le reste $r = -\beta - \alpha \cdot z$. Comparez avec le résultat en arithmétique exacte.

Résolution. En effet puisque $0.111 \approx \frac{1}{9}$, il n'est pas compliqué de se convaincre que 18 est une approximation de solution.

Le résidu est donné par :

$$-\beta - \alpha z = 2 - 0.111 \cdot 18 = 2 - \frac{111 \times 18}{1000} = 2 - \frac{999}{500} = \frac{1}{500} = 2 \times 10^{-3}.$$

Cependant en arithmétique tronquée à trois chiffres :

$$\alpha z = 1.11 \times 10^{-1} \times 1.8 \times 10^1 = 1.11 \cdot 1.8 \times 10^0 = 1.998 =_{t=3} 1.99 \times 10^0.$$

Dès lors :

$$-\beta - \alpha z =_{t=3} 2.00 \times 10^0 - 1.99 \times 10^0 = 0.01 = 1 \times 10^{-2}.$$

Il y a donc un facteur 5 entre le résidu approximé et le résidu réel.