

Séance 3 — Conditionnement et arithmétique tronquée

Rappel théorique

Conditionnement

Nous considérons un *problème* au sens mathématique, c'est-à-dire une expression sous la forme

$$F(x, d) = 0$$

pour $F : \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$ une fonction et $d \in \mathbb{R}^m$ le vecteur représentant les *données*. Résoudre ce problème correspond à trouver une valeur $x \in \mathbb{R}^n$ satisfaisant cette équation.

Si nous pouvons réécrire cette expression sous la forme

$$x = F(d),$$

nous disons que le problème est en *forme explicite*, et sinon il est en *forme implicite*. Nous considérons généralement des problèmes en forme explicite.

Nous notons δd une *perturbation* des données d , et nous notons δx la *perturbation* associée de la solution. Plus précisément, si $\hat{d} = d + \delta d$ est la donnée sur laquelle nous travaillons, alors nous définissons

$$\delta x = F(\hat{d}) - x = F(\hat{d}) - F(d) = F(d + \delta d) - F(d).$$

Nous écrivons également cela

$$x + \delta x = F(d + \delta d).$$

Si $\|x\| \neq 0$ et $\|d\| \neq 0$, nous définissons le *conditionnement relatif* du problème F en la donnée d par :

$$\begin{aligned} \kappa_{\text{rel}}(d) &:= \lim_{D \rightarrow 0} \sup_{\delta d \in B(0, D)} \frac{\|\delta x\| / \|x\|}{\|\delta d\| / \|d\|} \\ &= \frac{\|d\|}{\|x\|} \lim_{D \rightarrow 0} \sup_{\delta d \in B(0, D)} \frac{\|\delta x\|}{\|\delta d\|}. \end{aligned}$$

En particulier si $F \in \mathcal{C}^1(\mathbb{R}, \mathbb{R})$, alors :

$$\kappa_{\text{rel}}(d) = \frac{|d|}{|x|} \lim_{\delta d \rightarrow 0} \left| \frac{F(d + \delta d) - F(d)}{\delta d} \right| = \left| \frac{d \cdot F'(d)}{F(d)} \right|.$$

S'il n'est pas possible de regarder le conditionnement relatif, nous pouvons également regarder le *conditionnement absolu* :

$$\kappa_{\text{abs}}(d) := \lim_{D \rightarrow 0} \sup_{\delta d \in B(0, D)} \frac{\|\delta x\|}{\|\delta d\|}.$$

Notez bien que la raison pour laquelle nous passons par $\lim_{D \rightarrow 0} \sup_{\delta d \in B(0,D)}(\dots)$ dans ces définitions est pour ne pas s'encombrer du cas où $\lim_{\delta d \rightarrow 0}(\dots)$ n'existe pas. En effet pour une suite $(D_n)_n$ décroissante, $n \mapsto \sup_{\delta d \in B(0,D_n)} \varphi(\delta d)$ est également une suite décroissante, et donc cette suite converge (potentiellement vers $+\infty$ si toutes les valeurs sont infinies).

Erreurs

À partir d'ici, fixons un certain $x \in \mathbb{R}$, et considérons $\hat{x} \approx x$ une approximation de x . Nous appelons

- *erreur absolue* la quantité $\delta = |\hat{x} - x|$;
- *écart relatif* la quantité $\rho = \frac{\hat{x} - x}{x}$;
- *erreur relative* la quantité $\varepsilon = |\rho| = \frac{|\hat{x} - x|}{|x|} = \frac{\delta}{|x|}$.

Dans le cas où nous parlons d'erreurs ou d'écarts sur plusieurs quantités différentes, nous ajoutons le nom de la variable considérée en indice, e.g. δ_x ou encore ρ_d .

Notons que $\rho_x = \frac{\hat{x} - x}{x}$, et donc $x\rho_x = \hat{x} - x$, ou encore $\hat{x} = x\rho_x + x = x(1 + \rho_x)$.

Si $x \in \mathbb{R} \setminus \mathbb{F}(b, t, L, U)$, nous ne pouvons représenter qu'une valeur approchée de x . Nous considérons ici les cas suivants :

- un *arrondi* : $\hat{x} = \text{fl}(x)$;
- une *valeur tronquée* : $\hat{x} = \text{tr}(x)$.

Dans le cas d'un arrondi, nous prenons la valeur $\hat{x} \in \mathbb{F}(b, t, L, U)$ qui minimise la distance $|\hat{x} - x|$, alors que dans le cas d'une troncature, nous prenons le plus grand nombre $\hat{x}$ tel que $\hat{x} \leq x$.

Si x et x' sont deux valeurs consécutives de $\mathbb{F}(b, t, L, U)$ (dans le sens où $x < x'$ et il n'existe aucun $\xi \in \mathbb{F}(b, t, L, U)$ tel que $x < \xi < x'$), alors nous pouvons montrer les inégalités suivantes :

$$\frac{1}{b}\varepsilon \leq \frac{|x - x'|}{|x|} \leq \varepsilon,$$

où la quantité $\varepsilon := b^{1-t}$ est appelée *epsilon machine*. De plus, dans le cas d'un arrondi, nous pouvons observer que :

$$\left| \frac{\text{fl}(x) - x}{x} \right| \leq u,$$

où la quantité $u := \frac{1}{2}\varepsilon$ est appelée *précision machine* (ou parfois *unit roundoff* d'où la lettre u).

Erreur de propagation Si nous travaillons sur la valeur $\hat{d} = \text{fl}(d)$ (au lieu de d) et que nous résolvons le problème $F(d)$ associé, nous obtenons une solution $x + \delta x$. L'*erreur de propagation* est l'erreur obtenue sur x , exprimé sur base de l'erreur sur d :

$$\begin{aligned} F(\hat{d}) &= F(d + \delta d) = F(d(1 + \rho_d)) = F(d + d \cdot \rho_d) \\ &\approx F(d) + d\rho_d F'(d) = F(d) + F(d) \frac{d\rho_d F'(d)}{F(d)} = F(d) \left(1 + \frac{d\rho_d F'(d)}{F(d)} \right) \\ &= x(1 + \rho_d \kappa(d)) \end{aligned}$$

où le symbole $\approx$ cache en réalité l'application d'une expansion de Taylor d'ordre 1.

Finalement, la solution *obtenue* est :

$$\hat{x} = \text{fl}(F(\hat{d})) = \text{fl}(x(1 + \rho_d \kappa(d))) = x(1 + \rho_d \kappa)(1 + \rho_{F(d)}).$$

Les erreurs d'*annulation* et d'*absorption* sont deux exemples importants d'erreurs de génération. Une erreur d'annulation arrive lorsque deux nombres proches sont soustraits. Dans ce cas, la valeur résultante est certes petite en valeur absolue, mais peut être potentiellement très grande par rapport à la *vraie* valeur de cette différence, surtout dans le cas où les opérandes sont déjà des valeurs arrondies. Une erreur d'absorption arrive lorsque qu'un nombre très grand est ajouté à un nombre très petit. Dans ce cas, par manque de chiffres significatifs, une grande partie des chiffres composant la *petite* valeur n'apparaîtront pas dans la valeur résultante.

Erreur de génération L'erreur de génération apparaît lorsque le problème $x = F(d)$ est résolu par un algorithme itératif :

$$\begin{aligned} x_1 &= F_1(d) \\ x_2 &= F_2(x_1) \\ &\vdots \\ x &= x_n = F_n(x_{n-1}) \end{aligned}$$

Ici, des erreurs sont produites à chaque étape, et nous pouvons les calculer comme ceci :

$$\hat{x}_1 = x_1(1 + \kappa_1 \rho_d)(1 + \rho_{x_1}) = x_1(1 + \kappa_1 \rho_d \rho_{x_1} + \kappa_1 \rho_d + \rho_{x_1}) \approx x_1(1 + \underbrace{\kappa_1 \rho_d + \rho_{x_1}}_{=: \rho_{x_1}^C}),$$

où nous prenons l'approximation $\rho_a \times \rho_b \approx 0$ (l'ordre de grandeur des erreurs relatives est suffisamment grand pour être pris en compte, mais suffisamment petit pour que le produit de deux telles erreurs puisse être approximé à 0) et où $\rho_{x_1}^C$ est l'écart relatif cumulé (total) sur x_1 . Dès lors :

$$\begin{aligned} \hat{x}_2 &\approx x_2(1 + \kappa_2 \rho_{x_1}^C)(1 + \rho_{x_2}) \\ &\vdots \\ \hat{x} &\approx x \left[1 + \underbrace{\underbrace{\rho_n}_{\text{arrondi}} + \sum_{k=1}^{n-1} \left(\underbrace{\prod_{m=k+1}^n \kappa_m}_{\text{génération}} \right) \rho_k + \rho_d \underbrace{\prod_{m=1}^n \kappa_m}_{\text{propagation}}}_{=: \rho_{x_n}^C} \right]. \end{aligned}$$

Nous observons que le conditionnement des différents sous-problèmes finissent multipliés, et donc si ces sous-problèmes sont mal conditionnés, $|\hat{x} - x|$ peut se retrouver arbitrairement grand.

Remarque. Pour une preuve de cette assertion, nous pouvons procéder par récurrence sur n . Nous voulons montrer que :

$$\frac{\hat{x}_j}{x_j} - 1 \approx \rho_{x_j}^C = \rho_j + \sum_{k=1}^{j-1} \left(\prod_{m=k+1}^j \kappa_m \right) \rho_k + \rho_d \prod_{m=1}^j \kappa_m.$$

Comme vu ci-dessus, $\hat{x}_1 \approx x_1 (1 + \rho_1 + \kappa_1 \rho_d) = x_1 (1 + \rho_{x_1}^C)$.

$$\begin{aligned}
\hat{x}_j &= x_j \left(1 + \kappa_j \left(\frac{\hat{x}_{j-1}}{x_{j-1}} - 1 \right) \right) (1 + \rho_j) \\
&= x_j \left(1 + \kappa_j \rho_{x_{j-1}}^C \right) (1 + \rho_j) \\
&\approx x_j \left[1 + \rho_j + \kappa_j \left(\rho_{j-1} + \sum_{k=1}^{j-2} \left(\prod_{m=k+1}^{j-1} \kappa_m \right) \rho_k + \rho_d \prod_{m=1}^{j-1} \kappa_m \right) \right] \\
&= x_j \left[1 + \rho_j + \left(\prod_{m=j}^j \kappa_m \right) \rho_{j-1} + \sum_{k=1}^{j-1} \left(\prod_{m=k+1}^{j-1} \kappa_m \right) \kappa_j \rho_k + \rho_d \prod_{m=1}^j \kappa_j \right] \\
&= x_j \left[1 + \rho_j + \sum_{k=1}^{j-1} \left(\prod_{m=k+1}^j \kappa_m \right) \rho_k + \rho_d \prod_{m=1}^j \kappa_m \right] \\
&= x_1 \left(1 + \rho_{x_j}^C \right).
\end{aligned}$$

Notations Pour une opérations $\star : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{R}$, nous considérons l'opération associée $\oplus : \mathbb{R} \times \mathbb{R} \rightarrow \mathbb{F}$ définie comme suit :

$$x \oplus y := \text{fl}(\text{fl}(x) \star \text{fl}(y)).$$

En particulier $\oplus$ désigne l'addition arrondie et $\odot$ désigne la multiplication arrondie. Maintenant par induction :

3.1 Conditionnement

Exercice 3.1. Que peut-on dire du conditionnement de la fonction $F(d) = d-1$ autour de 1 ?

Résolution. Nous ne pouvons pas calculer le conditionnement relatif en $d = 1$ puisque dans ce cas $x = F(d) = 0$. Cependant, pour δd tel que $0 < |\delta d|$, nous pouvons observer que :

$$\kappa_{\text{rel}}(1 + \delta d) = \left| \frac{(1 + \delta d) \cdot 1}{(1 + \delta d) - 1} \right| = \left| \frac{1 + \delta d}{\delta d} \right| \xrightarrow{\delta d \rightarrow 0} +\infty.$$

En particulier pour $|\delta d| \ll 1$, le problème est très mal conditionné en $1 + \delta d$, i.e. le problème est très mal conditionné autour de $d = 1$. Cependant, c'était attendu puisque $F(1) = 0$. Dès lors, il faudrait plutôt regarder le conditionnement absolu en 1, qui est ici :

$$\kappa_{\text{abs}}(1) = |F'(1)| = 1.$$

Le problème est donc lié au fait qu'on approche une situation où la solution est $x = 0$, et non au fait que le problème en lui-même est mal conditionné.

Exercice 3.2. Calculez le conditionnement $\kappa(d)$ des expressions $F(x, d)$ suivantes :

- $x - a^d = 0$ ($a > 0$) ;
- $d - x + 1 = 0$.

Résolution. Rappelons-nous que $\frac{d}{dx}a^x = \ln(a)a^x$. En effet puisque $a^x = \exp(\ln(a)x)$, nous savons :

$$\frac{d}{dx}a^x = \frac{d}{dx}\exp(\ln(a)x) = \ln(a)\exp(\ln(a)x) = \ln(a)a^x.$$

Dès lors dans le premier cas, $x = F(d) = a^d$ et donc :

$$\kappa(d) = \left| \frac{d \ln(a)a^d}{a^d} \right| = |\ln(a)d|.$$

Le conditionnement est donc linéaire en d , i.e. pour de petites valeurs de d , le problème est bien conditionné, mais pour de grandes valeurs de d , le problème est mal conditionné. Intuitivement cela a un sens puisque les exponentielles sont des fonctions de très grande croissance. Dès lors, $a^{d+\delta d}$ peut être arbitrairement loin de a^d , même si δd est très petit, du moment que d soit suffisamment grand. De plus, au plus la base de l'expression est grande, au plus $\ln(a)$ sera grand également. Cependant, cette base apparaît dans un log, donc ce n'est pas elle qui va dominer le comportement. Attention cependant au cas d'une base $0 < a \ll 1$ en quel cas, a^d est très vite très proche de 0, même pour d relativement petit. Dès lors, $|x| \approx 0$, et donc le conditionnement relatif est rapidement très grand. Cela peut se voir avec le coefficient $|\ln(a)|$ qui devient arbitrairement grand à mesure que a s'approche de 0 (par la droite). De plus, dans le cas où $a = 1 - \varepsilon$ pour un certain $\varepsilon > 0$, le conditionnement absolu est donné par :

$$\kappa_{\text{abs}}(d) = |\ln(1 - \varepsilon)| (1 - \varepsilon)^d.$$

Donc pour d petit, le problème est fondamentalement mal conditionné.

Dans le second cas, $x = F(d) = d + 1$, et similairement à l'exercice précédent, on obtient (pour $d \neq -1$) :

$$\kappa(d) = \left| \frac{d}{d+1} \right| \xrightarrow{d \rightarrow -1} +\infty.$$

Contrairement au premier exemple, ce problème-ci est bien conditionné pour de grandes valeurs de d (en valeur absolue), mais est très mal conditionné pour d proche de -1 .

Exercice 3.3. Montrez que l'évaluation de $F(d) = \cos d$ est bien conditionnée près de $d = 0$.

Résolution. Le conditionnement relatif en 0 ne peut être pris, il faut donc à nouveau regarder le conditionnement *autour* de 0 :

$$\kappa(\delta d) = \left| \frac{\delta d \sin \delta d}{\cos \delta d} \right| \xrightarrow{\delta d \rightarrow 0} 0,$$

i.e. pour d se rapprochant de 0, le conditionnement du problème se rapproche également de 0, i.e. le problème est bien conditionné autour de 0.

Exercice 3.4. Que peut-on dire du conditionnement de $F(d) = (d - 1)^2$ autour de $d = 1$?

Résolution. À nouveau, le problème ici est que $F(1) = 0$. Dès lors :

$$\kappa(1 + \delta d) = \left| \frac{(1 + \delta d)2(1 + \delta d - 1)}{(1 + \delta d - 1)^2} \right| = \left| \frac{2(1 + \delta d)\delta d}{\delta d^2} \right| \xrightarrow{\delta d \rightarrow 0} +\infty.$$

Cependant, le conditionnement absolu est donné par :

$$\kappa_{\text{abs}}(1 + \delta d) = |F'(1 + \delta)| = 2(1 + \delta) - 2 = 2\delta d \xrightarrow{\delta d \rightarrow 0} 0.$$

3.2 Erreur d'annulation

Exercice 3.5. Vérifiez que pour $d_1 = 0.1656$, $d_2 = 7.4409$ et $d_3 = 2.9168$ dans un système à virgule flottante où $b = 10$ et $t = 2$:

$$d_1 \oplus (d_2 \oplus d_3) \neq (d_1 \oplus d_2) \oplus d_3,$$

i.e. $\oplus$ n'est pas associatif.

Trouvez un exemple de valeurs distinctes x, y, z satisfaisant :

$$x \oplus (y \oplus z) = (x \oplus y) \oplus z.$$

Résolution. Commençons par arrondir les différentes valeurs : $\text{fl}(d_1) = 0.17 = 1.7 \times 10^{-1}$; $\text{fl}(d_2) = 7.4$; et $\text{fl}(d_3) = 2.9$. Dès lors :

$$d_1 \oplus (d_2 \oplus d_3) = \text{fl}(0.17 + \text{fl}(7.4 + 2.9)) = \text{fl}(0.17 + \text{fl}(10.3)) = \text{fl}(0.17 + 10) = \text{fl}(10.17) = 10.$$

Maintenant :

$$(d_1 \oplus d_2) \oplus d_3 = \text{fl}(\text{fl}(0.17 + 7.4) + 2.9) = \text{fl}(7.6 + 2.9) = \text{fl}(10.5) = 11.$$

Exercice 3.6. Pour un système en virgule flottante où $b = 10$ et $t = 4$ montrez que l'évaluation de la fonction $F(d) = d - 1$ est sujette à une importante erreur d'annulation dans le cas où $d = 1.00098$.

Résolution. Les erreurs d'annulation sont une affaire d'erreur relative après une différence. Ici : $\text{fl}(d) = 1.001$, et donc :

$$\varepsilon_d = \left| \frac{\text{fl}(d) - d}{d} \right| = \frac{1.001 - 1.00098}{1.00098} = \frac{0.00002}{1.00098} < 2 \times 10^{-5}.$$

Cependant, pour $x = F(d)$ et $\hat{x} = \text{fl}(F(\text{fl}(d)))$:

$$\varepsilon_x = \left| \frac{(1.001 - 1) - (1.00098 - 1)}{1.00098 - 1} \right| = \frac{0.00002}{0.00098} = \frac{2}{98} > 2 \times 10^{-2}.$$

Donc même si ε_d est faible et donc *a priori* négligeable, ε_x ne l'est pas du tout : le rapport entre l'erreur relative en sortie et l'erreur relative en entrée est $\frac{\varepsilon_x}{\varepsilon_d} > 10^3$.

3.3 Erreur de génération

Exercice 3.7. Pour $\alpha = 0.8717$ et $\beta = 0.8719$, calculez le point milieu de l'intervalle $(\alpha + \beta)/2$. Utilisez d'abord l'arithmétique décimale *tronquée* à 4 chiffres, et ensuite l'arithmétique décimale *arrondie* à 4 chiffres. Enfin, proposez une autre séquence d'évaluation qui génère moins d'erreur.

Résolution. Puisque $\alpha < \beta$, nous savons que $\alpha < \frac{\alpha+\beta}{2} < \beta$. De plus, $\frac{\alpha+\beta}{2} = 0.8718$.

En arithmétique tronquée :

$$(\alpha \oplus \beta) \odot 2 = \text{tr}(\text{tr}(1.7436)/2) = \text{tr}(1.743/2) = \text{tr}(0.8715) = 0.8715 < \alpha.$$

En arithmétique arrondie :

$$(\alpha \oplus \beta) \odot 2 = \text{fl}(\text{fl}(1.7436)/2) = \text{fl}(1.744/2) = \text{fl}(0.8720) = 0.8720 > \beta.$$

Notons que $\frac{\alpha+\beta}{2} = \alpha + \frac{\beta-\alpha}{2}$. Dans ce cas, regardons :

$$\alpha \oplus ((\beta \ominus \alpha) \odot 2) = \alpha \oplus \text{fl}(2 \times 10^{-4} / 2) = \text{fl}(\alpha + 10^{-4}) = 0.8718,$$

ce qui est la bonne réponse.

Exercice 3.8. Dans un système en virgule flottante où $b = 10$ et $t = 3$, comparez les deux algorithmes suivants d'évaluation de la fonction $F(d) = d^2 - 1$:

- algorithme 1 : $y_1 = d \cdot d$; $x_1 = y_1 - 1$;
- algorithme 2 : $y_2 = d - 1$; $x_2 = y_2 \cdot (y_2 + 2)$.

Résolution. Les deux algorithmes sont équivalents et calculent bien $d^2 - 1$. En effet : $x_1 = y_1 - 1 = d \cdot d - 1 = d^2 - 1$, et $x_2 = y_2(y_2 + 2) = (d - 1)(d - 1 + 2) = (d - 1)(d + 1) = d^2 - 1$.

Intuitivement, le deuxième algorithme devrait être plus stable puisque l'opération avec le conditionnement le plus mauvais (ici la soustraction) a été faite en premier.

Pour l'illustrer, choisissons une valeur de d proche de 1 telle que d soit représentable exactement en virgule flottante $b = 10$ et $t = 3$, et telle que $F(d)$ le soit également. Pour cela, prenons $d = 1.02$ (qui donne $F(d) = 4.04 \times 10^{-2}$).

Pour le premier algorithme, nous avons :

$$\hat{x}_1 = \text{fl}(\text{fl}(1.02^2) - 1) = \text{fl}(\text{fl}(1.0404) - 1) = \text{fl}(1.04 - 1) = 0.04 = 4 \times 10^{-2}.$$

Pour le deuxième algorithme nous avons :

$$\hat{x}_2 = \text{fl}(\text{fl}(0.02) \cdot \text{fl}(2.02)) = \text{fl}(2 \times 10^{-2} \times 2.02) = 4.04 \times 10^{-2}.$$

Nous pouvons observer que $\hat{x}_2$ est ici une solution exacte, alors que $\hat{x}_1$ n'en est pas une. De plus, son erreur relative est donnée par :

$$\varepsilon_{x_1} = \left| \frac{4.04 \times 10^{-2} - 4 \times 10^{-2}}{4 \times 10^{-2}} \right| = 10^{-2}.$$