

Questions examens INFO-F-205 des années précédentes

2 Représentation machine, Conditionnement et stabilité

-
1. Soient donnés trois nombres positifs d_1 , d_2 et d_3 , où $d_1 \ll d_2$ (c'.-à-d., d_2 beaucoup plus grand que d_1), il faut trouver le résultat de $y = d_1 + d_2 - d_3$. Quel algorithme est préférable, et pourquoi :
- $y = d_1 + (d_2 - d_3)$
 - $y = d_2 + (d_1 - d_3)$
 - $y = (d_1 + d_2) - d_3$

corrigé

-
2. Considérer un instrument de mesure d'une variable réelle x qui utilise un système de représentation à virgule flottante en base $b = 16$. Soit la variable x bornée dans l'intervalle $[400 \ 16000]$.

Calculer le plus petit nombre t^* de chiffres significatifs tel que l'erreur absolue d'arrondi $\text{err}(x)$ soit inférieure à $\epsilon = 1/b$ pour toute valeur de x .

corrigé

Solution formelle

Soit x la variable à représenter. Alors, l'erreur d'arrondi pour un système à virgule flottante est

$$\text{err}(x) = |x - \text{fl}(x)| \leq \frac{1}{2}|x_{i+1} - x_i| = \frac{1}{2}b^{e-t},$$

où e est l'exposant de x_i . Il faut donc imposer (pour tout exposant e) que

$$\frac{1}{2}b^{e-t} \leq \frac{1}{b} \Leftrightarrow e-t \leq \log_b(2/b) = \ln(2/b)/\ln(b) = \ln(2)/\ln(b)-1 = -3/4$$

Donc,

$$t \geq e + 3/4$$

L'exposant maximal correspond au maximum des nombres représentés, donc, $\max(e) = \lceil \log_b(16000) \rceil = 4$. Donc, $t^* = \lceil 4 + 3/4 \rceil = 5$

Solution plus intuitive (mais aussi correcte)

On nous impose que $\text{err}(x) = |x - \text{fl}(x)|$ soit inférieure à $1/b$, ce qui est garanti par un chiffre après la virgule (quelque soit la valeur de la base b). Ici, la base est $b = 16$. Le plus grand nombre dans l'intervalle donné est $16000 = 3E1C$, sa représentation requiert 4 chiffres avant la virgule. En total, on a donc besoin de $4+1=5$ chiffres.

3. Soit $\mathbb{F}(b, t, L, U)$ une représentation à virgule flottante en base $b = 2$. On impose que la distance relative entre deux nombres consécutifs de $\mathbb{F}(b, t, L, U)$ soit majorée par 10^{-8} , tandis que les nombres $\pm 10^{\pm 64}$ soient représentés sans “overflow” ou “underflow”. Combien de bits (symbols binaires) sont nécessaires pour achever ces objectifs ?

corrigé

La distance relative maximale entre deux nombres consécutifs de $\mathbb{F}(b, t, L, U)$ satisfait à $\epsilon = b^{1-t}$, t étant le nombre de chiffres significatifs. Il faut donc que $2^{1-t} \leq 10^{-8} \Leftrightarrow t \geq 1 - \log_2(10^{-8}) = 27,58$. Puisque le premier bit sera toujours un 1, on a besoin de 27 bits pour représenter la mantisse. A ces 27 bits s'ajoutent les bits pour représenter l'exposant. En base 2, la borne 10^{64} est majorée par 2^{213} , tandis que la borne $10^{-64} > 2^{-213}$. L'exposant en base 2 peut donc prendre toute valeur entière comprise entre -213 et 213. Pour représenter $213+214=427$ valeurs différentes, il nous faut au moins $\log_2(427)$ bits, ce qui revient à 9 bits. En total, nous avons besoin de $1 + 9 + 27 = 37$ bits (dont l'un est pour le signe).

4. Considérer la fonction $x = \cos(2d)$ autour de $d = \pi/4$. Est-ce que ce problème est bien conditionné ?

Classer les formes équivalentes ci-dessous par leur stabilité pour $d \approx \pi/4$, c'est-à-dire : quelle est la forme la plus stable, quelle est la moins stable. Argumenter *sans* faire une analyse formelle. (NB : une multiplication par 2 n'entraîne pas d'arrondi) :

- $x = \cos(2d)$
- $x = [\cos(d)]^2 - [\sin(d)]^2$
- $x = 1 - 2[\sin(d)]^2$

corrigé

Le conditionnement est $\kappa(d) = \left| \frac{F'(d) \cdot d}{F(d)} \right| = \left| \frac{-2d \sin(2d)}{\cos(2d)} \right| \rightarrow \infty$ pour $d \rightarrow \pi/4$, donc le problème est mal conditionné.


Pour l'analyse de la stabilité, nous supposons que les données soient représentées en machine de manière exacte.

- (a) Le seul arrondi qui se manifeste lors de l'exécution de $\cos(2d)$ est celui de la sortie du $\cos$, c'est-à-dire, tout à la fin du calcul. L'arrondi est proportionnel à la valeur du résultat : $\bar{x} = x(1 + \rho)$. Cette forme est stable et aussi la plus stable de la liste.
- (b) Pour $d \approx \pi/4$, la forme $\cos^2(d) - \sin^2(d)$ comprend, comme dernière étape, la soustraction de deux nombres autour de 1/2. Ces deux nombres sont entachées d'erreurs d'arrondi, suite au calculs précédents (notamment le calcul du $\sin(d)$ et $\cos(d)$, suivi d'une exponentiation par carrés). Cette forme est la moins stable.
- (c) La troisième forme comprend également une soustraction de deux nombres à peu près égaux, mais l'un des deux est représenté exactement (1), il n'est pas le résultat de calculs précédents.

5. Est-ce que l'évaluation $F(d)$ est bien conditionnée pour les points d et les fonctions $F(d)$ dans les quatre graphiques suivants ? Choisir l'une des possibilités suivantes

- (a) le conditionnement (relatif) est bon
- (b) le conditionnement (relatif) est mauvais
- (c) le graphique ne permet pas de tirer une conclusion

Si possible, donner la valeur *numérique* du conditionnement relatif. Les tirets représentent la tangente au graphe de $F(d)$ en d (le point concerné)



corrigé

- $\kappa(d) = 1$; le conditionnement est bon.
- $\kappa(d) = 1$; le conditionnement est bon.
- $\kappa(d) = 0$; le conditionnement est bon.
- $\kappa(d) = \infty$; le conditionnement est mauvais.

6. Considérer un instrument de mesure d'une variable réelle et positive x qui utilise un système de représentation à virgule flottante en base $b = 2$. On impose que l'instrument soit capable d'identifier le nombre 10^{-10} comme étant non-nul et le nombre 10^8 comme un nombre fini. L'écart relatif entre deux nombres représentés ne peut pas dépasser 10^{-5} .

Calculer le nombre minimal de chiffres (bits) pour cet instrument de mesure.

corrigé

On a

- (a) $b^L = 2^L \leq 10^{-10} \Rightarrow L \leq \log_2(10^{-10}) = -33,2$
- (b) $b^U = 2^U \geq 10^8 \Rightarrow U \geq \log_2(10^8) = 26,6$

$$(c) \epsilon = b^{1-t} \leq 10^{-5} \Rightarrow t \geq 1 - \log_2(10^{-5}) = 17,6$$

Le premier bit étant toujours égal à 1, il nous faut donc $18-1=17$ bits pour la mantisse. Pour l'exposant, il faut couvrir l'intervalle $[-34, 27]$, ce qui nous amène à $27+34+1=62$ valeurs uniques, à représenter par 6 bits. Toutes les valeurs de x étant positives, il n'y a pas de signe à encoder. En total, on a donc besoin de $17+6 = 23$ bits pour représenter la variable x .

7. Considérer la fonction (= le problème) $F(d) = d^2 - a^2$ pour $d \in [-2a, 2a]$.

- Discuter le conditionnement du problème.
- Expliquer que la forme équivalente $F(d) = (d - a)(d + a)$ est préférable du point de vue de la stabilité. (L'explication peut être formelle ou informelle).

corrigé

- $\kappa(d) = \left| \frac{F'(d) \cdot d}{F(d)} \right| = \left| \frac{2d \cdot d}{(d^2 - a^2)} \right| \rightarrow \infty$ pour $d \rightarrow \pm a$. Le problème est mal conditionné pour d autour de $\pm a$ et bien conditionné dans le reste de l'intervalle.
- Pour l'analyse de la stabilité, nous supposons que les données soient représentées en machine de manière exacte.

• Analyse informelle

Dans la forme $(d-a)(d+a)$, la soustraction des deux nombres proches se situe au début, avec deux nombres pas entachés d'erreurs de génération. Dans la forme $d^2 - a^2$, par contre, la soustraction se trouve à la fin des calculs et les opérandes sont entachés d'erreurs de génération (lors des calculs des carrés).

• Formellement

La forme $(d - a)(d + a)$ génèrera trois arrondi : lors de la soustraction, lors de l'addition et enfin, lors de la multiplication. En négligeant les termes d'ordre supérieur, nous obtenons $\overline{F}(d) = [(d - a)(1 + \rho_1)(d + a)(1 + \rho_2)](1 + \rho_3) \approx F(d)(1 + \rho_1 + \rho_2 + \rho_3)$, un résultat qui s'interprète ainsi : l'erreur de génération n'est qu'une simple somme des erreurs d'arrondi.

NB. : On peut aussi écrire (pour compléter) $\frac{\overline{F}(d) - F(d)}{F(d)} \approx \rho_1 + \rho_2 + \rho_3$. L'erreur de génération ne dépend pas de d .

La forme $d^2 - a^2$ a pour effet (en premier ordre) : $\overline{F}(d) = [d^2(1 + \rho_1) - a^2(1 + \rho_2)](1 + \rho_3) \approx F(d) + (\rho_1 + \rho_3)d^2 - (\rho_2 + \rho_3)a^2$, et donc $\frac{\overline{F}(d) - F(d)}{F(d)} \approx \frac{(\rho_1 + \rho_3)d^2 - (\rho_2 + \rho_3)a^2}{d^2 - a^2}$ ce qui pointe vers un souci d'instabilité pour des valeurs de d autour de a ou $-a$.

8. Considérer une machine équipée d'une représentation à virgule flottante en base $b = 2$ et $t = 10$ chiffres significatifs. Soient d un réel borné dans l'intervalle $[17000, 18000]$ et a un nombre en $\mathbb{F}(b, t, L, U) \cap [15000, 16000]$. Calculer l'erreur relative maximale du résultat de $x = d - a$? On peut supposer que U est suffisamment grand pour que le domaine $[\text{realmin}, \text{realmax}]$ couvre $[15000, 18000]$.

corrigé

Le conditionnement d'une soustraction est donnée par

$$\kappa_x(d) = \frac{d}{d-a},$$

Le conditionnement est maximal pour l'écart $d-a$ minimal et, ensuite, pour d minimal,

$$\kappa_x(d) \leq \frac{17000}{1000} = 17,$$

et donc, puisque le conditionnement, par définition, représente la croissance maximale de l'erreur relative,

$$\frac{|\delta x|}{|x|} \leq \kappa_x(d) \frac{|\delta d|}{|d|} = \kappa_x(d) \varepsilon_d \leq \kappa_x(d) \frac{\epsilon}{2} = \kappa_x(d) \frac{b^{1-t}}{2} = 17 \cdot 2^{-9} / 2 = 0,0166$$

9. Considérer la fonction (= le problème) $F(d) = 1 - \cos(d)$ pour d autour de l'origine.
- Discuter le conditionnement du problème.
 - Expliquer de manières informelle **et** formelle que la forme équivalente $F(d) = 2 \sin^2(d/2)$ est préférable du point de vue de la stabilité.

corrigé

- (a) $\kappa(d) = \left| \frac{F'(d) \cdot d}{F(d)} \right| = \left| \frac{\sin(d)d}{1-\cos(d)} \right|$ Il y a plusieurs pistes pour démontrer que le problème est bien conditionné :

- En utilisant les décompositions Taylor $\sin(d) \approx d$ et $\cos(d) \approx 1 - d^2/2$ on trouve $\kappa(d) \approx d^2 / (d^2/2) = 2$.
- En utilisant l'expression alternative de l'énoncé et l'expression $\sin(d) = 2 \sin(d/2) \cos(d/2)$, nous arrivons à $\kappa(d) = \frac{2 \sin(d/2) \cos(d/2) d}{2 \sin^2(d/2)} = \frac{\cos(d/2) d}{\sin(d/2)} \approx d / (d/2) = 2$.

- (b) Pour l'analyse de la stabilité, nous supposons que les entrées soient représentées en machine de manière exacte.

- Analyse informelle**
La forme $2 \sin^2(d/2)$ ne comprend aucune opération instable, alors que l'expression $1 - \cos(d)$ comprend une soustraction.
- Formellement**
Pour la forme $F(d) = 1 - \cos(d)$, on a

$$\begin{aligned}
\overline{F}(d) &= [1 - \cos(d)(1 + \rho_1)](1 + \rho_2) \\
&= (1 - \cos(d))(1 + \rho_2) - \cos(d)\rho_1(1 + \rho_2) \\
&= F(d)(1 + \rho_2) - \cos(d)\rho_1(1 + \rho_2) \\
&\approx F(d)(1 + \rho_2) - \cos(d)\rho_1 \\
&= F(d) \left(1 + \rho_2 - \frac{\cos(d)}{F(d)} \rho_1 \right) \\
&= F(d) \left(1 + \rho_2 - \frac{\cos(d)}{1 - \cos(d)} \rho_1 \right)
\end{aligned}$$

ce qui pose des problèmes pour d proche de zéro. Compte tenu du fait que la division ou la multiplication par deux consiste d'un simple changement de la position de la virgule flottante, la forme $F(d) = 2 \sin^2(d/2)$ est calculée comme

$$\begin{aligned}
\overline{F}(d) &= 2 [\sin(d/2)(1 + \rho_1)]^2 (1 + \rho_2) = 2 \sin^2(d/2)(1 + \rho_1)^2(1 + \rho_2) \\
&= F(d)(1 + 2\rho_1 + \rho_1^2)(1 + \rho_2) \\
&\approx F(d)(1 + 2\rho_1 + \rho_2)
\end{aligned}$$

Du coup, la propagation des arrondis ρ_1 (lors du calcul du sinus) et ρ_2 (lors de du calcul du carré) est bornée pour toute valeur de d .

10. Considérer une fonction $F(d)$ différentiable en $d = 0$.

- Sachant que $F(0) = 0$ et $F'(0) \neq 0$, montrer que $\kappa(0) = 1$.
- Considérer la fonction $F_1(d) = 1 + d - \sqrt{1 + d^2}$ et la version équivalente $F_2(d) = 2d / [1 + d + \sqrt{1 + d^2}]$. Expliquer de manière informelle pourquoi $F_2(d)$ est préférable.
- Quelles seront les réponses de matlab pour `x1` et `x2` dans les lignes de code suivantes, sachant que `eps=2.2204e-16` ?

```

d = eps/2;
x1 = 1+d-sqrt(1+d^2)
x2 = 2*d/(1+d+sqrt(1+d^2))

```

corrigé

- $\kappa(0) = \lim_{d \rightarrow 0} \kappa(d) = \lim_{d \rightarrow 0} \left| \frac{F'(d) \cdot d}{F(d)} \right| = \lim_{d \rightarrow 0} |F'(d)| \cdot \lim_{d \rightarrow 0} \left| \frac{d - 0}{F(d) - F(0)} \right|$
 $= F'(0) \cdot \frac{1}{F'(0)} = 1$
- La forme $F_2(d)$ est préférable, car la forme $F_1(d)$ comprend la soustraction de deux grands nombres, proches l'un de l'autre. Cette forme est donc *instable*.
Remarque en changeant l'ordre des calculs en $F_1(d)$, notamment en calculant $F_1(d) = [1 - \sqrt{1 + d^2}] + d$, on peut diminuer l'effet de l'instabilité (voir aussi la partie suivante)
- On trouvera que $1 + d = 1$ et $1 + d^2 = 1$,
d'où vient que `x1 = 0` et `x2 = 2d/2 = d = eps/2 = 1.1102e - 16`.
Attention : `d` ne prendra pas la valeur de 0. Ce nombre est représentée en machine par `1.1102e - 16`. En effet, `eps` n'est pas le nombre le plus petit en valeur absolue représenté en machine!!
Remarque en changeant l'ordre des calculs, on trouve `x1 = d`

11. Considérer une machine équipée d'une représentation à virgule flottante en base $b = 2$. La machine dispose de 32 bits, c'est-à-dire, cases mémoires binaires pour la représentation du signe, de la mantisse et de l'exposant. La distance relative entre deux nombres doit être bornée par 10^{-8} , alors que le nombre non nul le plus petit en valeur absolue doit être inférieur à 10^{-100} .

- Combien de chiffres sont nécessaires pour la représentation de la mantisse ?
- Quelles sont les distances relatives *minimale* et *maximale* de la représentation ?
- Trouver le nombre maximal représenté par cette machine.

corrigé

- La solution d'un tel exercice revient toujours à la détermination des paramètres de l'ensemble $\mathbb{F}(b, t, L, U)$. On sait que $b = 2$. La distance relative est donnée par $\eta(x_i) = \frac{1}{m[x_i]}$ où la mantisse est bornée par $b^{t-1} \leq m[x_i] \leq b^t - 1$, donc $\eta(x_i) < b^{1-t}$. En imposant $b^{1-t} < 10^{-8}$, c'est-à-dire, $2^{1-t} < 10^{-8}$, on arrive à la condition $t > 1 - \log_2(10^{-8}) = 27,57$, ce qui nécessite 28 bits, ou 27, si on laisse tomber le premier chiffre, qui vaut toujours un (mais le paramètre t garde sa valeur de 28).
- La distance relative fluctuera entre $1/(b^t - 1)$ et b^{1-t} , c'est-à-dire, entre $1/(2^{28} - 1)$ et $1/2^{27}$, en notation décimale, c'est entre $3,7253 \cdot 10^{-9}$ et $7,4506 \cdot 10^{-9}$.
- Avec 27 chiffres pour la mantisse et 1 pour le signe, il nous restent $32-28=4$ bits pour l'exposant, ce qui nous permet de représenter 16 exposants. Le nombre le plus petit, en valeur absolue, est majorée par 10^{-100} , ce qui signifie que $b^{(L-1)} \leq 10^{-100} \Leftrightarrow L \leq \log_2(10^{-100}) + 1 = -331,19$. En prenant $L = -332$, on a $U = -332 + 16 - 1 = -317$, d'où vient une valeur absolue maximale de $b^U(1 - b^{-t}) = 3,745 \cdot 10^{-96}$

12. Considérer la fonction $F(d) = \sqrt{1 - e^{-d^2}}$, pour laquelle on peut déduire $F'(d) = de^{-d^2} / \sqrt{1 - e^{-d^2}}$.

- En utilisant que pour $|d|$ très petit, $1 - e^{-d^2} \sim d^2$ (c'est-à-dire, dans le calcul d'une limite pour $d \rightarrow 0$, on peut remplacer $1 - e^{-d^2}$ par d^2), discuter le conditionnement pour d autour de l'origine.
- D'où vient l'approximation $1 - e^{-d^2} \sim d^2$?
- Pour l'analyse de la stabilité, on définit la fonction

$$\overline{F}(d, \vec{\rho}) = \sqrt{[1 - e^{-d^2(1+\rho_1)}(1 + \rho_2)] (1 + \rho_3)(1 + \rho_4)}.$$

Sachant que

$$\frac{\partial \bar{F}(d, \vec{\rho})}{\partial \rho_3} = \frac{(1 + \rho_4)}{2\sqrt{[1 - e^{-d^2(1+\rho_1)}(1 + \rho_2)](1 + \rho_3)}} \left[1 - e^{-d^2(1+\rho_1)}(1 + \rho_2) \right],$$

utiliser la série de Taylor autour de $\vec{\rho} = \vec{0}$

$$\bar{F}(d, \vec{\rho}) \approx \bar{F}(d, \vec{0}) + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_1} \cdot \rho_1 + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_2} \cdot \rho_2 + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_3} \cdot \rho_3 + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_4} \cdot \rho_4$$

pour vérifier si l'arrondi modélisé par ρ_3 est une source d'instabilité.

(d) Quelle est l'opération dont l'arrondi est modélisé par ρ_3 ?

corrigé

(a) Le conditionnement est bon, car

$$\lim_{d \rightarrow 0} \frac{F'(d)d}{F(d)} = \lim_{d \rightarrow 0} \frac{d^2 e^{-d^2}}{(1 - e^{-d^2})} = \lim_{d \rightarrow 0} \frac{d^2 e^{-d^2}}{d^2} = 1.$$

(b) L'approximation provient d'une série de Taylor de la fonction $1 - e^{-d^2}$ autour de $d = 0$.

Une explication alternative passe par la règle de l'Hôpital dans le calcul de la limite

$$\lim_{d \rightarrow 0} \frac{1 - e^{-d^2}}{d^2} = \lim_{u \rightarrow 0} \frac{1 - e^{-u}}{u} = \lim_{u \rightarrow 0} \frac{e^{-u}}{1} = 1$$

(c) Evaluer la dérivée partielle

$$\frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_3} = \frac{1}{2\sqrt{1 - e^{-d^2}}} (1 - e^{-d^2}) = \frac{\sqrt{1 - e^{-d^2}}}{2} \approx \frac{d}{2}$$

Pour $d \rightarrow 0$, on a $\lim_{d \rightarrow 0} \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_3} = 0$, donc l'arrondi (la perturbation) associé à ρ_3 ne représente aucun problème au niveau de la stabilité.

(d) Il s'agit de la soustraction $1 - e^{-d^2}$. La soustraction est sensible à la propagation des erreurs d'arrondi lors des calculs précédents (conditionnement – erreurs d'annulation), mais elle ne pose pas de problème au niveau des erreurs de génération (erreur d'absorption – stabilité)

13. Considérer la fonction $F(d) = e^{-1/|d|^\alpha}$, pour laquelle on peut déduire $F'(d) = F(d) \cdot \alpha/|d|^{\alpha+1} \cdot \text{sign}(d)$, où $\text{sign}(d)$ représente le signe de d . Dans l'expression de $F(d)$, α est un réel positif, non-nul.

(a) Discuter le conditionnement de $F(d)$ pour d autour de l'origine.

(b) Pour l'analyse de la stabilité, on définit la fonction

$$\bar{F}(d, \vec{\rho}) = e^{-1/[|d|^\alpha(1+\rho_1)]}(1 + \rho_2)$$

Sachant que $\frac{\partial \bar{F}(d, \vec{\rho})}{\partial \rho_1} = \frac{e^{-1/[|d|^\alpha(1+\rho_1)]}(1 + \rho_2)}{|d|^\alpha(1 + \rho_1)^2}$ et $\frac{\partial \bar{F}(d, \vec{\rho})}{\partial \rho_2} = e^{-1/[|d|^\alpha(1+\rho_1)]}$ utiliser la série de Taylor autour de $\vec{\rho} = \vec{0}$

$$\bar{F}(d, \vec{\rho}) \approx \bar{F}(d, \vec{0}) + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_1} \cdot \rho_1 + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_2} \cdot \rho_2$$

pour discuter la stabilité de l'expression (par rapport à tous les arrondis). On peut se servir du résultat

$$\lim_{u \rightarrow 0} \frac{e^{-1/u}}{u} = \lim_{v \rightarrow \infty} v e^{-v} = \lim_{v \rightarrow \infty} v/e^v = 0, \text{ avec } u = |d|^\alpha$$

- (c) Les écarts relatifs ρ_1 et ρ_2 modélisent les arrondis lors des exponentiations. Pour les calculs de la valeur absolue et l'inversion, le modèle ne prévoit pas d'arrondi. Expliquer pour chacun de ces deux derniers cas pourquoi le risque d'erreur d'arrondi peut être négligé dans ce modèle ?
- (d) Avec $\alpha = 1/2$ et $d_1 = (0, 123 \pm 0, 001) \cdot 10^{-4}$, et en partant d'une expression pour $F(d(1 \pm \rho))$, trouver la valeur (y compris l'erreur) de $F(d_1)$, en se basant sur une seule évaluation de $F(d_1)$ et une évaluation de $\kappa(d_1)$. Répéter l'exercice pour $d_2 = (0, 123 \pm 0, 001) \cdot 10^0$. Comparer et interpréter les résultats.

corrigé

(a) Le conditionnement est grand (mauvais), car

$$\lim_{d \rightarrow 0} \frac{F'(d)d}{F(d)} = \lim_{d \rightarrow 0} \frac{\alpha}{|d|^{\alpha+1}} \text{sign}(d) \cdot d = \lim_{d \rightarrow 0} \frac{\alpha}{|d|^\alpha} = +\infty.$$

(b) Evaluer les dérivées partielles : $\frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_1} = \frac{e^{-1/|d|^\alpha}}{|d|^\alpha}$, ce qui converge vers 0 pour $d \rightarrow 0$ (voir énoncé).

$\frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_2} = e^{-1/|d|^\alpha}$, ce qui converge vers 0 pour $d \rightarrow 0$. Il n'y a donc pas de souci au niveau de la stabilité.

(c) Le calcul de la valeur absolue ne touche que le signe du nombre représenté. Il n'y a donc pas d'arrondi. L'inversion revient à un changement de signe de l'exposant, une opération qui, elle non plus, ne porte aucun risque d'arrondi.

(d) En se basant sur l'expression $F(d(1 \pm \rho)) \approx F(d)(1 \pm \kappa(d)\rho)$, on a

- $F(0, 123 \cdot 10^{-4}(1 + 1/123)) \approx F(0, 123 \cdot 10^{-4})(1 \pm \kappa(0, 123 \cdot 10^{-4})/123) = 0, 14734 \cdot 10^{-123} \cdot (1 \pm 142, 57/123) \approx [0, 3] \cdot 10^{-123}$
- $F(0, 123(1+1/123)) \approx F(0, 123)(1 \pm \kappa(0, 123)/123) = 0, 5777 \cdot 10^{-1} \cdot (1 \pm 1, 4257/123) \approx 0, 57 \cdot 10^{-1} \cdot (1 \pm 0, 01) = [0, 56; 0, 58] \cdot 10^{-1}$

La réponse $F(d_1)$ ne porte aucun chiffre décimal tout-à-fait significatif, alors que la réponse $F(d_2)$ en garde deux.

14. (a) Expliquer pourquoi n'utilise pas huit zéros binaires pour la représentation de l'exposant le plus petit et huit uns binaires pour la représentation de l'exposant maximal.

- (b) Sachant que la commande Matlab

```
format hex
pi
a pour résultat
ans = 400921fb54442d18
écrire le résultat de
```

- ```
format hex
-pi
```
- (c) La commande

```
format hex
pi+1
a pour résultat
ans = 401090fdaa22168c
```

Expliquer pourquoi les représentations hexadécimales de  $\pi$  et de  $\pi + 1$  ont très peu de chiffres en commun.

### corrigé

- (a) si on utilisait la représentation de huit zéros pour associer à un exposant, il n'y aurait pas de représentation possible pour le nombre (la valeur) de 0 (car la représentation 00000... correspond à la mantisse 100000...). De même, il faut réserver un espace pour la représentation des nombres spéciaux, comme  $\pm\infty$  et NaN.

- (b) `format hex`

```
-pi
ans = c00921fb54442d18
```

Le signe change, donc le premier groupe de quatre bits, 4 = 0100, devient c = 1100.

- (c)  $\pi + 1 > 4$ , alors que  $\pi < 4$ . Du coup, l'exposant change, ce qui veut dire que la virgule flotte, ce qui a pour effet que les groupes de bits dans un symbole hexadécimal changent (la composition des symboles hexadécimaux change)

- 
15. (a) Expliquer, en se basant sur l'expression appropriée dans le formulaire, qu'une opération mal conditionnée doit être exécutée au plus tôt dans l'algorithme.

- (b) Sachant que la commande Matlab

```
format hex
1
a pour résultat
ans = 3ff0000000000000
```

donner le résultat de  
 format hex  
 1+eps  
 et expliquer.

### corrigé

- (a) En utilisant la formule de la propagation, génération et arrondi

$$\hat{x} \approx x(1 + \underbrace{\rho_n}_{\text{err. arr}} + \underbrace{\kappa_n \rho_{n-1} + \kappa_n \kappa_{n-1} \rho_{n-2} + \dots + \kappa_n \dots \kappa_2 \rho_1}_{\text{erreur génération}} + \underbrace{\kappa_n \dots \kappa_1 \rho_d}_{\text{err. prop}})$$

on constate que la valeur de  $\kappa_n$  apparaît dans tous les termes. En général, plus grande l'indice  $r$ , plus de termes contiennent le conditionnement  $\kappa_r$ . Il est donc important de minimiser le  $\kappa_n$  en repoussant les calculs avec grandes valeurs de  $\kappa_r$  vers le début

**Explication alternative :** Le conditionnement est une mesure de la sensibilité d'une opération vis-à-vis d'erreurs d'entrée (c'est-à-dire, la tendance à gonfler l'erreur d'entrée au fil de l'opération). Du coup, une opération mal conditionnée devrait être réalisée au plus vite, car qu'au début les erreurs d'entrée sont relativement petites et bien contrôlées.

- (b) format hex  
 1+eps  
 ans = 3ff0000000000001

Explication : eps est le plus petit nombre qui, ajouté à 1, donne le nombre suivant dans l'ensemble  $\mathbb{F}$ .

16. (a) La commande Matlab `format long; eps`  
 a pour résultat : `ans = 2.220446049250313e-16`  
 Expliquer l'origine de l'ensemble des chiffres apparemment arbitraires dans la notation décimale de la réponse.
- (b) La commande Matlab `format hex; (5:10)` a pour résultat (en une ligne)
- |                  |                  |                  |
|------------------|------------------|------------------|
| 4014000000000000 | 4018000000000000 | 401c000000000000 |
| 4020000000000000 | 4022000000000000 | 4024000000000000 |

Expliquer pourquoi dans les trois premières représentations, les pas entre les quatrièmes symboles sont de 4, alors que dans les trois dernières ils sont de 2.

### corrigé

- (a) Le nombre `eps` est donné par  $b^{1-t} = 2^{-52} = 2,220446049250313 \cdot 10^{-16}$ . Les chiffres décimaux ne sont que le résultat de la transformation d'un nombre binaire avec un chiffre significatif en notation décimale. Ils n'ont pas de signification spéciale.

(b) Les trois premiers symboles de la notation hexadécimale correspondent au signe et à l'exposant. On constate que la seconde ligne de l'output a un exposant plus élevé qu'à la première ligne. Le reste de la notation correspond à la mantisse. Puisque l'intervalle entre deux nombres est toujours de 1, les pas dans la mantisse doivent dépendre de la valeur de l'exposant : plus grand l'exposant, plus petit sera le pas dans la mantisse pour correspondre au même intervalle numérique. C'est la virgule qui flotte. L'observation est liée au phénomène de wobbling.

- 
17. (a) Considérer le nombre  $x_i$  dans l'ensemble  $\mathbb{F}(b, t, L, U)$ . Montrer (en se basant sur les formules de la représentation en machine) que la distance absolue est donnée par  $b^{e-t}$ , où  $e$  est l'exposant dans la représentation de  $x_i$ .  
 (b) Trouver la valeur maximale des distances absolues dans  $\mathbb{F}(b, t, L, U) \cap [0, 1000]$  où  $b = 2$  et  $t = 10$ .

**corrigé**

Avec  $m[x_i]$  la mantisse du nombre  $x_i$ , la distance absolue est donnée par  $|x_i| \cdot \eta(x_i) = |x_i|/m[x_i] = m[x_i] \cdot b^{e-t}/m[x_i] = b^{e-t}$ . Les distances absolues sont les mêmes pour tous les nombres avec le même exposant. Elles sont maximales pour l'exposant le plus grand possible. En base  $b = 2$ , l'exposant maximal sur  $[0, 1000]$  est donné par  $e = \lfloor \log_2(1000) + 1 \rfloor = 10$ . On a donc une distance absolue maximale de  $2^{10-10} = 1$ . Effectivement, avec 10 chiffres significatifs, on a besoin de tous les chiffres pour représenter les entiers autour de 1000.

- 
18. Montrer que  $\text{realmin} = b^{L-1}$  et que  $\text{realmax} = b^U(1 - b^{-t})$

**corrigé**


Le premier nombre après 0 est donné par la mantisse minimale multipliée par l'exposant minimal :  $\text{realmin} = 10000000... \cdot b^{L-t} = b^{t-1} \cdot b^{L-t} = b^{L-1}$ . Le nombre maximal de  $\mathbb{F}$  est donné par la mantisse maximale et l'exposant maximal :  $\text{realmax} = (b^t - 1) \cdot b^{U-t} = b^U(1 - b^{-t})$ .

- 
19. Voici la définition d'un algorithme stable :  
 Un algorithme numérique est dit stable si
- (a) il existe pour tout  $n$  une solution unique  $\vec{x}^{(n)}$
  - (b) pour chaque  $\epsilon > 0$  il existe un  $\eta > 0$  et un  $n_0$  tel que pour tout  $n > n_0$  :
 
$$\|\delta \vec{d}^{(n,i)}\| \leq \eta \quad \text{pour tout } i = 1, \dots, m \Rightarrow \|\vec{x}^{(n)} - \vec{x}^{(n)}\| \leq \epsilon$$
- Expliquer (en une, max deux phrases) pourquoi on prend  $i = 1, \dots, m$  et pas  $i = 0, \dots, m$ .

### corrigé

La stabilité ne concerne pas les erreurs (les fluctuations) sur les données à l'entrée. Du coup, on suppose que  $\delta \vec{d}^{(n,0)} = 0$ .

20. Considérer la fonction  $f(x) = -\log_{10} \left( \frac{1}{x^4} - \frac{1}{\sqrt{x^8 + 1}} \right)$  dont le graphique tracé par Matlab est donné par



Le problème qui se manifeste pour les grandes valeurs de  $x$ , s'explique-t-il par la notion de conditionnement ou de stabilité ? Expliquer. Est-ce que les calculs produisent quelque part un underflow ou un overflow ?

### corrigé

Avec  $m[x_i]$  la mantisse du nombre  $x_i$ , la distance absolue est donnée par  $|x_i| \cdot \eta(x_i) = |x_i|/m[x_i] = m[x_i] \cdot b^{e-t}/m[x_i] = b^{e-t}$ . Les distances absolues sont les mêmes pour tous les nombres avec le même exposant. Elles sont maximales pour l'exposant le plus grand possible. En base  $b = 2$ , l'exposant maximal sur  $[0, 1000]$  est donné par  $e = \lfloor \log_2(1000) + 1 \rfloor = 10$ . On a donc une distance absolue maximale de  $2^{10-10} = 1$ . Effectivement, avec 10 chiffres significatifs, on a besoin de tous les chiffres pour représenter les entiers autour de 1000.

## 3 Systèmes linéaires

1. Quelle est l'importance/ l'impact du théorème ci-dessous :

Soit  $A_{(n \times n)}$  une matrice inversible et  $\|A^{-1}\| \|\delta A\| < 1$ , alors

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \frac{\|\delta A\|}{\|A\|}} \left( \frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right)$$

où  $\kappa(A)$  est le conditionnement de  $A$ .

### corrigé

Ce théorème indique qu'une seule mesure de conditionnement décrit la sensibilité du système à des perturbations sur  $A$  ainsi qu'à des