

Questions examens INFO-F-205 des années précédentes

2 Représentation machine, Conditionnement et stabilité

1. Soient donnés trois nombres positifs d_1 , d_2 et d_3 , où $d_1 \ll d_2$ (c'.-à-d., d_2 beaucoup plus grand que d_1), il faut trouver le résultat de $y = d_1 + d_2 - d_3$. Quel algorithme est préférable, et pourquoi :
- $y = d_1 + (d_2 - d_3)$
 - $y = d_2 + (d_1 - d_3)$
 - $y = (d_1 + d_2) - d_3$

corrigé

2. Considérer un instrument de mesure d'une variable réelle x qui utilise un système de représentation à virgule flottante en base $b = 16$. Soit la variable x bornée dans l'intervalle $[400 \ 16000]$.

Calculer le plus petit nombre t^* de chiffres significatifs tel que l'erreur absolue d'arrondi $\text{err}(x)$ soit inférieure à $\epsilon = 1/b$ pour toute valeur de x .

corrigé

Solution formelle

Soit x la variable à représenter. Alors, l'erreur d'arrondi pour un système à virgule flottante est

$$\text{err}(x) = |x - \text{fl}(x)| \leq \frac{1}{2}|x_{i+1} - x_i| = \frac{1}{2}b^{e-t},$$

où e est l'exposant de x_i . Il faut donc imposer (pour tout exposant e) que

$$\frac{1}{2}b^{e-t} \leq \frac{1}{b} \Leftrightarrow e-t \leq \log_b(2/b) = \ln(2/b)/\ln(b) = \ln(2)/\ln(b)-1 = -3/4$$

Donc,

$$t \geq e + 3/4$$

L'exposant maximal correspond au maximum des nombres représentés, donc, $\max(e) = \lceil \log_b(16000) \rceil = 4$. Donc, $t^* = \lceil 4 + 3/4 \rceil = 5$

Solution plus intuitive (mais aussi correcte)

On nous impose que $\text{err}(x) = |x - \text{fl}(x)|$ soit inférieure à $1/b$, ce qui est garanti par un chiffre après la virgule (quelque soit la valeur de la base b). Ici, la base est $b = 16$. Le plus grand nombre dans l'intervalle donné est $16000 = 3E1C$, sa représentation requiert 4 chiffres avant la virgule. En total, on a donc besoin de $4+1=5$ chiffres.

3. Soit $\mathbb{F}(b, t, L, U)$ une représentation à virgule flottante en base $b = 2$. On impose que la distance relative entre deux nombres consécutifs de $\mathbb{F}(b, t, L, U)$ soit majorée par 10^{-8} , tandis que les nombres $\pm 10^{\pm 64}$ soient représentés sans “overflow” ou “underflow”. Combien de bits (symbols binaires) sont nécessaires pour achever ces objectifs ?

corrigé

La distance relative maximale entre deux nombres consécutifs de $\mathbb{F}(b, t, L, U)$ satisfait à $\epsilon = b^{1-t}$, t étant le nombre de chiffres significatifs. Il faut donc que $2^{1-t} \leq 10^{-8} \Leftrightarrow t \geq 1 - \log_2(10^{-8}) = 27,58$. Puisque le premier bit sera toujours un 1, on a besoin de 27 bits pour représenter la mantisse. A ces 27 bits s'ajoutent les bits pour représenter l'exposant. En base 2, la borne 10^{64} est majorée par 2^{213} , tandis que la borne $10^{-64} > 2^{-213}$. L'exposant en base 2 peut donc prendre toute valeur entière comprise entre -213 et 213. Pour représenter $213+214=427$ valeurs différentes, il nous faut au moins $\log_2(427)$ bits, ce qui revient à 9 bits. En total, nous avons besoin de $1 + 9 + 27 = 37$ bits (dont l'un est pour le signe).

4. Considérer la fonction $x = \cos(2d)$ autour de $d = \pi/4$. Est-ce que ce problème est bien conditionné ?

Classer les formes équivalentes ci-dessous par leur stabilité pour $d \approx \pi/4$, c'est-à-dire : quelle est la forme la plus stable, quelle est la moins stable. Argumenter *sans* faire une analyse formelle. (NB : une multiplication par 2 n'entraîne pas d'arrondi) :

- $x = \cos(2d)$
- $x = [\cos(d)]^2 - [\sin(d)]^2$
- $x = 1 - 2[\sin(d)]^2$

corrigé

Le conditionnement est $\kappa(d) = \left| \frac{F'(d) \cdot d}{F(d)} \right| = \left| \frac{-2d \sin(2d)}{\cos(2d)} \right| \rightarrow \infty$ pour $d \rightarrow \pi/4$, donc le problème est mal conditionné.


Pour l'analyse de la stabilité, nous supposons que les données soient représentées en machine de manière exacte.

- (a) Le seul arrondi qui se manifeste lors de l'exécution de $\cos(2d)$ est celui de la sortie du $\cos$, c'est-à-dire, tout à la fin du calcul. L'arrondi est proportionnel à la valeur du résultat : $\bar{x} = x(1 + \rho)$. Cette forme est stable et aussi la plus stable de la liste.
- (b) Pour $d \approx \pi/4$, la forme $\cos^2(d) - \sin^2(d)$ comprend, comme dernière étape, la soustraction de deux nombres autour de 1/2. Ces deux nombres sont entachées d'erreurs d'arrondi, suite au calculs précédents (notamment le calcul du $\sin(d)$ et $\cos(d)$, suivi d'une exponentiation par carrés). Cette forme est la moins stable.
- (c) La troisième forme comprend également une soustraction de deux nombres à peu près égaux, mais l'un des deux est représenté exactement (1), il n'est pas le résultat de calculs précédents.

5. Est-ce que l'évaluation $F(d)$ est bien conditionnée pour les points d et les fonctions $F(d)$ dans les quatre graphiques suivants ? Choisir l'une des possibilités suivantes

- (a) le conditionnement (relatif) est bon
- (b) le conditionnement (relatif) est mauvais
- (c) le graphique ne permet pas de tirer une conclusion

Si possible, donner la valeur *numérique* du conditionnement relatif. Les tirets représentent la tangente au graphe de $F(d)$ en d (le point concerné)



corrigé

- $\kappa(d) = 1$; le conditionnement est bon.
- $\kappa(d) = 1$; le conditionnement est bon.
- $\kappa(d) = 0$; le conditionnement est bon.
- $\kappa(d) = \infty$; le conditionnement est mauvais.

6. Considérer un instrument de mesure d'une variable réelle et positive x qui utilise un système de représentation à virgule flottante en base $b = 2$. On impose que l'instrument soit capable d'identifier le nombre 10^{-10} comme étant non-nul et le nombre 10^8 comme un nombre fini. L'écart relatif entre deux nombres représentés ne peut pas dépasser 10^{-5} .

Calculer le nombre minimal de chiffres (bits) pour cet instrument de mesure.

corrigé

On a

- (a) $b^L = 2^L \leq 10^{-10} \Rightarrow L \leq \log_2(10^{-10}) = -33,2$
- (b) $b^U = 2^U \geq 10^8 \Rightarrow U \geq \log_2(10^8) = 26,6$

$$(c) \epsilon = b^{1-t} \leq 10^{-5} \Rightarrow t \geq 1 - \log_2(10^{-5}) = 17,6$$

Le premier bit étant toujours égal à 1, il nous faut donc $18-1=17$ bits pour la mantisse. Pour l'exposant, il faut couvrir l'intervalle $[-34, 27]$, ce qui nous amène à $27+34+1=62$ valeurs uniques, à représenter par 6 bits. Toutes les valeurs de x étant positives, il n'y a pas de signe à encoder. En total, on a donc besoin de $17+6 = 23$ bits pour représenter la variable x .

7. Considérer la fonction (= le problème) $F(d) = d^2 - a^2$ pour $d \in [-2a, 2a]$.

- (a) Discuter le conditionnement du problème.
- (b) Expliquer que la forme équivalente $F(d) = (d - a)(d + a)$ est préférable du point de vue de la stabilité. (L'explication peut être formelle ou informelle).

corrigé

- (a) $\kappa(d) = \left| \frac{F'(d) \cdot d}{F(d)} \right| = \left| \frac{2d \cdot d}{(d^2 - a^2)} \right| \rightarrow \infty$ pour $d \rightarrow \pm a$. Le problème est mal conditionné pour d autour de $\pm a$ et bien conditionné dans le reste de l'intervalle.
- (b) Pour l'analyse de la stabilité, nous supposons que les données soient représentées en machine de manière exacte.

• Analyse informelle

Dans la forme $(d-a)(d+a)$, la soustraction des deux nombres proches se situe au début, avec deux nombres pas entachés d'erreurs de génération. Dans la forme $d^2 - a^2$, par contre, la soustraction se trouve à la fin des calculs et les opérandes sont entachés d'erreurs de génération (lors des calculs des carrés).

• Formellement

La forme $(d - a)(d + a)$ génèrera trois arrondi : lors de la soustraction, lors de l'addition et enfin, lors de la multiplication. En négligeant les termes d'ordre supérieur, nous obtenons $\overline{F}(d) = [(d - a)(1 + \rho_1)(d + a)(1 + \rho_2)](1 + \rho_3) \approx F(d)(1 + \rho_1 + \rho_2 + \rho_3)$, un résultat qui s'interprète ainsi : l'erreur de génération n'est qu'une simple somme des erreurs d'arrondi.

NB. : On peut aussi écrire (pour compléter) $\frac{\overline{F}(d) - F(d)}{F(d)} \approx \rho_1 + \rho_2 + \rho_3$. L'erreur de génération ne dépend pas de d .

La forme $d^2 - a^2$ a pour effet (en premier ordre) : $\overline{F}(d) = [d^2(1 + \rho_1) - a^2(1 + \rho_2)](1 + \rho_3) \approx F(d) + (\rho_1 + \rho_3)d^2 - (\rho_2 + \rho_3)a^2$, et donc $\frac{\overline{F}(d) - F(d)}{F(d)} \approx \frac{(\rho_1 + \rho_3)d^2 - (\rho_2 + \rho_3)a^2}{d^2 - a^2}$ ce qui pointe vers un souci d'instabilité pour des valeurs de d autour de a ou $-a$.

8. Considérer une machine équipée d'une représentation à virgule flottante en base $b = 2$ et $t = 10$ chiffres significatifs. Soient d un réel borné dans l'intervalle $[17000, 18000]$ et a un nombre en $\mathbb{F}(b, t, L, U) \cap [15000, 16000]$. Calculer l'erreur relative maximale du résultat de $x = d - a$? On peut supposer que U est suffisamment grand pour que le domaine $[\text{realmin}, \text{realmax}]$ couvre $[15000, 18000]$.

corrigé

Le conditionnement d'une soustraction est donnée par

$$\kappa_x(d) = \frac{d}{d-a},$$

Le conditionnement est maximal pour l'écart $d-a$ minimal et, ensuite, pour d minimal,

$$\kappa_x(d) \leq \frac{17000}{1000} = 17,$$

et donc, puisque le conditionnement, par définition, représente la croissance maximale de l'erreur relative,

$$\frac{|\delta x|}{|x|} \leq \kappa_x(d) \frac{|\delta d|}{|d|} = \kappa_x(d) \varepsilon_d \leq \kappa_x(d) \frac{\epsilon}{2} = \kappa_x(d) \frac{b^{1-t}}{2} = 17 \cdot 2^{-9} / 2 = 0,0166$$

9. Considérer la fonction (= le problème) $F(d) = 1 - \cos(d)$ pour d autour de l'origine.
- Discuter le conditionnement du problème.
 - Expliquer de manières informelle **et** formelle que la forme équivalente $F(d) = 2 \sin^2(d/2)$ est préférable du point de vue de la stabilité.

corrigé

- (a) $\kappa(d) = \left| \frac{F'(d) \cdot d}{F(d)} \right| = \left| \frac{\sin(d)d}{1-\cos(d)} \right|$ Il y a plusieurs pistes pour démontrer que le problème est bien conditionné :

- En utilisant les décompositions Taylor $\sin(d) \approx d$ et $\cos(d) \approx 1 - d^2/2$ on trouve $\kappa(d) \approx d^2 / (d^2/2) = 2$.
- En utilisant l'expression alternative de l'énoncé et l'expression $\sin(d) = 2 \sin(d/2) \cos(d/2)$, nous arrivons à $\kappa(d) = \frac{2 \sin(d/2) \cos(d/2) d}{2 \sin^2(d/2)} = \frac{\cos(d/2) d}{\sin(d/2)} \approx d / (d/2) = 2$.

- (b) Pour l'analyse de la stabilité, nous supposons que les entrées soient représentées en machine de manière exacte.

- Analyse informelle**
La forme $2 \sin^2(d/2)$ ne comprend aucune opération instable, alors que l'expression $1 - \cos(d)$ comprend une soustraction.
- Formellement**
Pour la forme $F(d) = 1 - \cos(d)$, on a

$$\begin{aligned}
\overline{F}(d) &= [1 - \cos(d)(1 + \rho_1)](1 + \rho_2) \\
&= (1 - \cos(d))(1 + \rho_2) - \cos(d)\rho_1(1 + \rho_2) \\
&= F(d)(1 + \rho_2) - \cos(d)\rho_1(1 + \rho_2) \\
&\approx F(d)(1 + \rho_2) - \cos(d)\rho_1 \\
&= F(d) \left(1 + \rho_2 - \frac{\cos(d)}{F(d)} \rho_1 \right) \\
&= F(d) \left(1 + \rho_2 - \frac{\cos(d)}{1 - \cos(d)} \rho_1 \right)
\end{aligned}$$

ce qui pose des problèmes pour d proche de zéro. Compte tenu du fait que la division ou la multiplication par deux consiste d'un simple changement de la position de la virgule flottante, la forme $F(d) = 2 \sin^2(d/2)$ est calculée comme

$$\begin{aligned}
\overline{F}(d) &= 2 [\sin(d/2)(1 + \rho_1)]^2 (1 + \rho_2) = 2 \sin^2(d/2)(1 + \rho_1)^2(1 + \rho_2) \\
&= F(d)(1 + 2\rho_1 + \rho_1^2)(1 + \rho_2) \\
&\approx F(d)(1 + 2\rho_1 + \rho_2)
\end{aligned}$$

Du coup, la propagation des arrondis ρ_1 (lors du calcul du sinus) et ρ_2 (lors de du calcul du carré) est bornée pour toute valeur de d .

10. Considérer une fonction $F(d)$ différentiable en $d = 0$.

- Sachant que $F(0) = 0$ et $F'(0) \neq 0$, montrer que $\kappa(0) = 1$.
- Considérer la fonction $F_1(d) = 1 + d - \sqrt{1 + d^2}$ et la version équivalente $F_2(d) = 2d / [1 + d + \sqrt{1 + d^2}]$. Expliquer de manière informelle pourquoi $F_2(d)$ est préférable.
- Quelles seront les réponses de matlab pour x1 et x2 dans les lignes de code suivantes, sachant que $\text{eps} = 2.2204e-16$?

```

d = eps/2;
x1 = 1+d-sqrt(1+d^2)
x2 = 2*d/(1+d+sqrt(1+d^2))

```

corrigé

- $\kappa(0) = \lim_{d \rightarrow 0} \kappa(d) = \lim_{d \rightarrow 0} \left| \frac{F'(d) \cdot d}{F(d)} \right| = \lim_{d \rightarrow 0} |F'(d)| \cdot \lim_{d \rightarrow 0} \left| \frac{d - 0}{F(d) - F(0)} \right|$
 $= F'(0) \cdot \frac{1}{F'(0)} = 1$
- La forme $F_2(d)$ est préférable, car la forme $F_1(d)$ comprend la soustraction de deux grands nombres, proches l'un de l'autre. Cette forme est donc *instable*.
Remarque en changeant l'ordre des calculs en $F_1(d)$, notamment en calculant $F_1(d) = [1 - \sqrt{1 + d^2}] + d$, on peut diminuer l'effet de l'instabilité (voir aussi la partie suivante)
- On trouvera que $1 + d = 1$ et $1 + d^2 = 1$,
d'où vient que $x1 = 0$ et $x2 = 2d/2 = d = \text{eps}/2 = 1.1102e - 16$.
Attention : d ne prendra pas la valeur de 0. Ce nombre est représentée en machine par $1.1102e - 16$. En effet, eps n'est pas le nombre le plus petit en valeur absolue représenté en machine!!
Remarque en changeant l'ordre des calculs, on trouve $x1 = d$

11. Considérer une machine équipée d'une représentation à virgule flottante en base $b = 2$. La machine dispose de 32 bits, c'est-à-dire, cases mémoires binaires pour la représentation du signe, de la mantisse et de l'exposant. La distance relative entre deux nombres doit être bornée par 10^{-8} , alors que le nombre non nul le plus petit en valeur absolue doit être inférieur à 10^{-100} .

- Combien de chiffres sont nécessaires pour la représentation de la mantisse ?
- Quelles sont les distances relatives *minimale* et *maximale* de la représentation ?
- Trouver le nombre maximal représenté par cette machine.

corrigé

- La solution d'un tel exercice revient toujours à la détermination des paramètres de l'ensemble $\mathbb{F}(b, t, L, U)$. On sait que $b = 2$. La distance relative est donnée par $\eta(x_i) = \frac{1}{m[x_i]}$ où la mantisse est bornée par $b^{t-1} \leq m[x_i] \leq b^t - 1$, donc $\eta(x_i) < b^{1-t}$. En imposant $b^{1-t} < 10^{-8}$, c'est-à-dire, $2^{1-t} < 10^{-8}$, on arrive à la condition $t > 1 - \log_2(10^{-8}) = 27,57$, ce qui nécessite 28 bits, ou 27, si on laisse tomber le premier chiffre, qui vaut toujours un (mais le paramètre t garde sa valeur de 28).
- La distance relative fluctuera entre $1/(b^t - 1)$ et b^{1-t} , c'est-à-dire, entre $1/(2^{28} - 1)$ et $1/2^{27}$, en notation décimale, c'est entre $3,7253 \cdot 10^{-9}$ et $7,4506 \cdot 10^{-9}$.
- Avec 27 chiffres pour la mantisse et 1 pour le signe, il nous restent $32-28=4$ bits pour l'exposant, ce qui nous permet de représenter 16 exposants. Le nombre le plus petit, en valeur absolue, est majorée par 10^{-100} , ce qui signifie que $b^{(L-1)} \leq 10^{-100} \Leftrightarrow L \leq \log_2(10^{-100}) + 1 = -331,19$. En prenant $L = -332$, on a $U = -332 + 16 - 1 = -317$, d'où vient une valeur absolue maximale de $b^U(1 - b^{-t}) = 3,745 \cdot 10^{-96}$

12. Considérer la fonction $F(d) = \sqrt{1 - e^{-d^2}}$, pour laquelle on peut déduire $F'(d) = de^{-d^2} / \sqrt{1 - e^{-d^2}}$.

- En utilisant que pour $|d|$ très petit, $1 - e^{-d^2} \sim d^2$ (c'est-à-dire, dans le calcul d'une limite pour $d \rightarrow 0$, on peut remplacer $1 - e^{-d^2}$ par d^2), discuter le conditionnement pour d autour de l'origine.
- D'où vient l'approximation $1 - e^{-d^2} \sim d^2$?
- Pour l'analyse de la stabilité, on définit la fonction

$$\overline{F}(d, \vec{\rho}) = \sqrt{[1 - e^{-d^2(1+\rho_1)}(1 + \rho_2)] (1 + \rho_3)(1 + \rho_4)}.$$

Sachant que

$$\frac{\partial \bar{F}(d, \vec{\rho})}{\partial \rho_3} = \frac{(1 + \rho_4)}{2\sqrt{[1 - e^{-d^2(1+\rho_1)}](1 + \rho_2)}} \left[1 - e^{-d^2(1+\rho_1)}(1 + \rho_2) \right],$$

utiliser la série de Taylor autour de $\vec{\rho} = \vec{0}$

$$\bar{F}(d, \vec{\rho}) \approx \bar{F}(d, \vec{0}) + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_1} \cdot \rho_1 + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_2} \cdot \rho_2 + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_3} \cdot \rho_3 + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_4} \cdot \rho_4$$

pour vérifier si l'arrondi modélisé par ρ_3 est une source d'instabilité.

(d) Quelle est l'opération dont l'arrondi est modélisé par ρ_3 ?

corrigé

(a) Le conditionnement est bon, car

$$\lim_{d \rightarrow 0} \frac{F'(d)d}{F(d)} = \lim_{d \rightarrow 0} \frac{d^2 e^{-d^2}}{(1 - e^{-d^2})} = \lim_{d \rightarrow 0} \frac{d^2 e^{-d^2}}{d^2} = 1.$$

(b) L'approximation provient d'une série de Taylor de la fonction $1 - e^{-d^2}$ autour de $d = 0$.

Une explication alternative passe par la règle de l'Hôpital dans le calcul de la limite

$$\lim_{d \rightarrow 0} \frac{1 - e^{-d^2}}{d^2} = \lim_{u \rightarrow 0} \frac{1 - e^{-u}}{u} = \lim_{u \rightarrow 0} \frac{e^{-u}}{1} = 1$$

(c) Evaluer la dérivée partielle

$$\frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_3} = \frac{1}{2\sqrt{1 - e^{-d^2}}} (1 - e^{-d^2}) = \frac{\sqrt{1 - e^{-d^2}}}{2} \approx \frac{d}{2}$$

Pour $d \rightarrow 0$, on a $\lim_{d \rightarrow 0} \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_3} = 0$, donc l'arrondi (la perturbation) associé à ρ_3 ne représente aucun problème au niveau de la stabilité.

(d) Il s'agit de la soustraction $1 - e^{-d^2}$. La soustraction est sensible à la propagation des erreurs d'arrondi lors des calculs précédents (conditionnement – erreurs d'annulation), mais elle ne pose pas de problème au niveau des erreurs de génération (erreur d'absorption – stabilité)

13. Considérer la fonction $F(d) = e^{-1/|d|^\alpha}$, pour laquelle on peut déduire $F'(d) = F(d) \cdot \alpha/|d|^{\alpha+1} \cdot \text{sign}(d)$, où $\text{sign}(d)$ représente le signe de d . Dans l'expression de $F(d)$, α est un réel positif, non-nul.

(a) Discuter le conditionnement de $F(d)$ pour d autour de l'origine.

(b) Pour l'analyse de la stabilité, on définit la fonction

$$\bar{F}(d, \vec{\rho}) = e^{-1/[|d|^\alpha(1+\rho_1)]}(1 + \rho_2)$$

Sachant que $\frac{\partial \bar{F}(d, \vec{\rho})}{\partial \rho_1} = \frac{e^{-1/[|d|^\alpha(1+\rho_1)]}(1 + \rho_2)}{|d|^\alpha(1 + \rho_1)^2}$ et $\frac{\partial \bar{F}(d, \vec{\rho})}{\partial \rho_2} = e^{-1/[|d|^\alpha(1+\rho_1)]}$ utiliser la série de Taylor autour de $\vec{\rho} = \vec{0}$

$$\bar{F}(d, \vec{\rho}) \approx \bar{F}(d, \vec{0}) + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_1} \cdot \rho_1 + \frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_2} \cdot \rho_2$$

pour discuter la stabilité de l'expression (par rapport à tous les arrondis). On peut se servir du résultat

$$\lim_{u \rightarrow 0} \frac{e^{-1/u}}{u} = \lim_{v \rightarrow \infty} v e^{-v} = \lim_{v \rightarrow \infty} v/e^v = 0, \text{ avec } u = |d|^\alpha$$

- (c) Les écarts relatifs ρ_1 et ρ_2 modélisent les arrondis lors des exponentiations. Pour les calculs de la valeur absolue et l'inversion, le modèle ne prévoit pas d'arrondi. Expliquer pour chacun de ces deux derniers cas pourquoi le risque d'erreur d'arrondi peut être négligé dans ce modèle ?
- (d) Avec $\alpha = 1/2$ et $d_1 = (0, 123 \pm 0, 001) \cdot 10^{-4}$, et en partant d'une expression pour $F(d(1 \pm \rho))$, trouver la valeur (y compris l'erreur) de $F(d_1)$, en se basant sur une seule évaluation de $F(d_1)$ et une évaluation de $\kappa(d_1)$. Répéter l'exercice pour $d_2 = (0, 123 \pm 0, 001) \cdot 10^0$. Comparer et interpréter les résultats.

corrigé

(a) Le conditionnement est grand (mauvais), car

$$\lim_{d \rightarrow 0} \frac{F'(d)d}{F(d)} = \lim_{d \rightarrow 0} \frac{\alpha}{|d|^{\alpha+1}} \text{sign}(d) \cdot d = \lim_{d \rightarrow 0} \frac{\alpha}{|d|^\alpha} = +\infty.$$

(b) Evaluer les dérivées partielles : $\frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_1} = \frac{e^{-1/|d|^\alpha}}{|d|^\alpha}$, ce qui converge vers 0 pour $d \rightarrow 0$ (voir énoncé).

$\frac{\partial \bar{F}(d, \vec{0})}{\partial \rho_2} = e^{-1/|d|^\alpha}$, ce qui converge vers 0 pour $d \rightarrow 0$. Il n'y a donc pas de souci au niveau de la stabilité.

(c) Le calcul de la valeur absolue ne touche que le signe du nombre représenté. Il n'y a donc pas d'arrondi. L'inversion revient à un changement de signe de l'exposant, une opération qui, elle non plus, ne porte aucun risque d'arrondi.

(d) En se basant sur l'expression $F(d(1 \pm \rho)) \approx F(d)(1 \pm \kappa(d)\rho)$, on a

- $F(0, 123 \cdot 10^{-4}(1 + 1/123)) \approx F(0, 123 \cdot 10^{-4})(1 \pm \kappa(0, 123 \cdot 10^{-4})/123) = 0, 14734 \cdot 10^{-123} \cdot (1 \pm 142, 57/123) \approx [0, 3] \cdot 10^{-123}$
- $F(0, 123(1+1/123)) \approx F(0, 123)(1 \pm \kappa(0, 123)/123) = 0, 5777 \cdot 10^{-1} \cdot (1 \pm 1, 4257/123) \approx 0, 57 \cdot 10^{-1} \cdot (1 \pm 0, 01) = [0, 56; 0, 58] \cdot 10^{-1}$

La réponse $F(d_1)$ ne porte aucun chiffre décimal tout-à-fait significatif, alors que la réponse $F(d_2)$ en garde deux.

-
14. (a) Expliquer pourquoi n'utilise pas huit zéros binaires pour la représentation de l'exposant le plus petit et huit uns binaires pour la représentation de l'exposant maximal.

- (b) Sachant que la commande Matlab

```
format hex
pi
a pour résultat
ans = 400921fb54442d18
écrire le résultat de
```

- ```
format hex
-pi
```
- (c) La commande

```
format hex
pi+1
a pour résultat
ans = 401090fdaa22168c
```

Expliquer pourquoi les représentations hexadécimales de  $\pi$  et de  $\pi + 1$  ont très peu de chiffres en commun.

### corrigé

- (a) si on utilisait la représentation de huit zéros pour associer à un exposant, il n'y aurait pas de représentation possible pour le nombre (la valeur) de 0 (car la représentation 00000... correspond à la mantisse 100000...). De même, il faut réserver un espace pour la représentation des nombres spéciaux, comme  $\pm\infty$  et NaN.

- (b) `format hex`

```
-pi
ans = c00921fb54442d18
```

Le signe change, donc le premier groupe de quatre bits, 4 = 0100, devient c = 1100.

- (c)  $\pi + 1 > 4$ , alors que  $\pi < 4$ . Du coup, l'exposant change, ce qui veut dire que la virgule flotte, ce qui a pour effet que les groupes de bits dans un symbole hexadécimal changent (la composition des symboles hexadécimaux change)

- 
15. (a) Expliquer, en se basant sur l'expression appropriée dans le formulaire, qu'une opération mal conditionnée doit être exécutée au plus tôt dans l'algorithme.

- (b) Sachant que la commande Matlab

```
format hex
1
a pour résultat
ans = 3ff0000000000000
```

donner le résultat de  
 format hex  
 1+eps  
 et expliquer.

### corrigé

- (a) En utilisant la formule de la propagation, génération et arrondi

$$\hat{x} \approx x(1 + \underbrace{\rho_n}_{\text{err. arr}} + \underbrace{\kappa_n \rho_{n-1} + \kappa_n \kappa_{n-1} \rho_{n-2} + \dots + \kappa_n \dots \kappa_2 \rho_1}_{\text{erreur génération}} + \underbrace{\kappa_n \dots \kappa_1 \rho_d}_{\text{err. prop}})$$

on constate que la valeur de  $\kappa_n$  apparaît dans tous les termes. En général, plus grande l'indice  $r$ , plus de termes contiennent le conditionnement  $\kappa_r$ . Il est donc important de minimiser le  $\kappa_n$  en repoussant les calculs avec grandes valeurs de  $\kappa_r$  vers le début

**Explication alternative :** Le conditionnement est une mesure de la sensibilité d'une opération vis-à-vis d'erreurs d'entrée (c'est-à-dire, la tendance à gonfler l'erreur d'entrée au fil de l'opération). Du coup, une opération mal conditionnée devrait être réalisée au plus vite, car qu'au début les erreurs d'entrée sont relativement petites et bien contrôlées.

- (b) format hex  
 1+eps  
 ans = 3ff0000000000001

Explication : eps est le plus petit nombre qui, ajouté à 1, donne le nombre suivant dans l'ensemble  $\mathbb{F}$ .

- 
16. (a) La commande Matlab `format long; eps`  
 a pour résultat : `ans = 2.220446049250313e-16`  
 Expliquer l'origine de l'ensemble des chiffres apparemment arbitraires dans la notation décimale de la réponse.
- (b) La commande Matlab `format hex; (5:10)` a pour résultat (en une ligne)
- |                  |                  |                  |
|------------------|------------------|------------------|
| 4014000000000000 | 4018000000000000 | 401c000000000000 |
| 4020000000000000 | 4022000000000000 | 4024000000000000 |

Expliquer pourquoi dans les trois premières représentations, les pas entre les quatrièmes symboles sont de 4, alors que dans les trois dernières ils sont de 2.

### corrigé

- (a) Le nombre `eps` est donné par  $b^{1-t} = 2^{-52} = 2,220446049250313 \cdot 10^{-16}$ . Les chiffres décimaux ne sont que le résultat de la transformation d'un nombre binaire avec un chiffre significatif en notation décimale. Ils n'ont pas de signification spéciale.

(b) Les trois premiers symboles de la notation hexadécimale correspondent au signe et à l'exposant. On constate que la seconde ligne de l'output a un exposant plus élevé qu'à la première ligne. Le reste de la notation correspond à la mantisse. Puisque l'intervalle entre deux nombres est toujours de 1, les pas dans la mantisse doivent dépendre de la valeur de l'exposant : plus grand l'exposant, plus petit sera le pas dans la mantisse pour correspondre au même intervalle numérique. C'est la virgule qui flotte. L'observation est liée au phénomène de wobbling.

- 
17. (a) Considérer le nombre  $x_i$  dans l'ensemble  $\mathbb{F}(b, t, L, U)$ . Montrer (en se basant sur les formules de la représentation en machine) que la distance absolue est donnée par  $b^{e-t}$ , où  $e$  est l'exposant dans la représentation de  $x_i$ .  
 (b) Trouver la valeur maximale des distances absolues dans  $\mathbb{F}(b, t, L, U) \cap [0, 1000]$  où  $b = 2$  et  $t = 10$ .

**corrigé**

Avec  $m[x_i]$  la mantisse du nombre  $x_i$ , la distance absolue est donnée par  $|x_i| \cdot \eta(x_i) = |x_i|/m[x_i] = m[x_i] \cdot b^{e-t}/m[x_i] = b^{e-t}$ . Les distances absolues sont les mêmes pour tous les nombres avec le même exposant. Elles sont maximales pour l'exposant le plus grand possible. En base  $b = 2$ , l'exposant maximal sur  $[0, 1000]$  est donné par  $e = \lfloor \log_2(1000) + 1 \rfloor = 10$ . On a donc une distance absolue maximale de  $2^{10-10} = 1$ . Effectivement, avec 10 chiffres significatifs, on a besoin de tous les chiffres pour représenter les entiers autour de 1000.

- 
18. Montrer que  $\text{realmin} = b^{L-1}$  et que  $\text{realmax} = b^U(1 - b^{-t})$

**corrigé**


Le premier nombre après 0 est donné par la mantisse minimale multipliée par l'exposant minimal :  $\text{realmin} = 10000000... \cdot b^{L-t} = b^{t-1} \cdot b^{L-t} = b^{L-1}$ . Le nombre maximal de  $\mathbb{F}$  est donné par la mantisse maximale et l'exposant maximal :  $\text{realmax} = (b^t - 1) \cdot b^{U-t} = b^U(1 - b^{-t})$ .

- 
19. Voici la définition d'un algorithme stable :  
 Un algorithme numérique est dit stable si
- (a) il existe pour tout  $n$  une solution unique  $\vec{x}^{(n)}$
  - (b) pour chaque  $\epsilon > 0$  il existe un  $\eta > 0$  et un  $n_0$  tel que pour tout  $n > n_0$  :
 
$$\|\delta \vec{d}^{(n,i)}\| \leq \eta \quad \text{pour tout } i = 1, \dots, m \Rightarrow \|\vec{x}^{(n)} - \vec{x}^{(n)}\| \leq \epsilon$$
- Expliquer (en une, max deux phrases) pourquoi on prend  $i = 1, \dots, m$  et pas  $i = 0, \dots, m$ .

### corrigé

La stabilité ne concerne pas les erreurs (les fluctuations) sur les données à l'entrée. Du coup, on suppose que  $\delta \vec{d}^{(n,0)} = 0$ .

20. Considérer la fonction  $f(x) = -\log_{10} \left( \frac{1}{x^4} - \frac{1}{\sqrt{x^8 + 1}} \right)$  dont le graphique tracé par Matlab est donné par



Le problème qui se manifeste pour les grandes valeurs de  $x$ , s'explique-t-il par la notion de conditionnement ou de stabilité ? Expliquer. Est-ce que les calculs produisent quelque part un underflow ou un overflow ?

### corrigé

Avec  $m[x_i]$  la mantisse du nombre  $x_i$ , la distance absolue est donnée par  $|x_i| \cdot \eta(x_i) = |x_i|/m[x_i] = m[x_i] \cdot b^{e-t}/m[x_i] = b^{e-t}$ . Les distances absolues sont les mêmes pour tous les nombres avec le même exposant. Elles sont maximales pour l'exposant le plus grand possible. En base  $b = 2$ , l'exposant maximal sur  $[0, 1000]$  est donné par  $e = \lfloor \log_2(1000) + 1 \rfloor = 10$ . On a donc une distance absolue maximale de  $2^{10-10} = 1$ . Effectivement, avec 10 chiffres significatifs, on a besoin de tous les chiffres pour représenter les entiers autour de 1000.

## 3 Systèmes linéaires

1. Quelle est l'importance/ l'impact du théorème ci-dessous :

Soit  $A_{(n \times n)}$  une matrice inversible et  $\|A^{-1}\| \|\delta A\| < 1$ , alors

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \frac{\|\delta A\|}{\|A\|}} \left( \frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right)$$

où  $\kappa(A)$  est le conditionnement de  $A$ .

### corrigé

Ce théorème indique qu'une seule mesure de conditionnement décrit la sensibilité du système à des perturbations sur  $A$  ainsi qu'à des

### perturbations sur $\vec{b}$

---

2. Considérons le système linéaire  $Ax = b$ , où

$$A = \begin{bmatrix} 1 & -1 & 1 \\ 2 & 1 & -1 \\ 1 & 2 & -2 \end{bmatrix}$$

Trouver la factorisation  $A = LU$  en utilisant la méthode de Gauss avec pivot partiel.

**corrigé**

---

3. Considérons le système linéaire  $Ax = b$ , où

$$A = \begin{bmatrix} 2 & 0 & x \\ 0 & 2 & 4 \\ 1 & 0 & 2 \end{bmatrix}$$

Déterminer les valeurs (l'intervalle) de  $x$  telles que la méthode de Jacobi converge. Répéter l'exercice pour la méthode de Gauss-Seidel.

**corrigé**

---

4. Soient  $W, \Sigma, V$  des matrices carrées de taille  $n \times n$ , où  $W$  et  $V$  sont orthogonales, tandis que  $\Sigma$  est diagonale. On demande la solution du système  $A\vec{z} = \vec{b}$ , où  $A = W\Sigma V$ .

- (a) Considérer l'algorithme

1. Calculer  $A = W \cdot \Sigma \cdot V$
2. Résoudre le système  $A\vec{z} = \vec{b}$  (en utilisant la factorisation  $LU$ )

Quelle est sa complexité ?

- (b) Expliquer : Il est possible de résoudre le système  $V\vec{x} = \vec{b}$ , avec une simple multiplication matrice-vecteur (pas besoin d'inversion d'une matrice ou d'une décomposition LU).
- (c) Utiliser l'observation de la question précédente pour formuler un algorithme plus rapide pour la résolution du système  $A\vec{z} = \vec{b}$ . Quelle est la complexité computationnelle ?

**corrigé**

- (a) (à compléter) Le calcul de  $A$  requiert pour la multiplication  $\Sigma \cdot V : \mathcal{O}(n^2)$ , pour la multiplication  $W \cdot (\Sigma \cdot V) : \mathcal{O}(n^3)$ . Ensuite la solution du système :  $\mathcal{O}(n^3)$
- (b) Puisque  $V$  est orthogonale, c.-à-d.,  $V^T V = I = V V^T$ , nous avons :  $V\vec{x} = \vec{b} \Leftrightarrow \vec{x} = V^T \vec{b}$   
Ceci revient à une simple multiplication matrice-vecteur, qui est de complexité  $\mathcal{O}(n^2)$

- (c)  $\vec{z} = V^T \cdot \Sigma^{-1} \cdot W^T \vec{b}$  : deux multiplications matrice-vecteur :  $W^T \vec{b}$  et  $V^T(\Sigma^{-1} \cdot W^T \vec{b})$  + les éléments de la matrice diagonale  $\Sigma^{-1}$  sont les inverses de la diagonale de  $\Sigma$ , donc multiplication avec  $\Sigma^{-1}$  revient à une simple division des composants du vecteur par les éléments sur la diagonale correspondants :  $\mathcal{O}(n^2)$

5. (a) Etant donnée la matrice  $A = \begin{bmatrix} 1 & 2 \\ 3 & x \end{bmatrix}$ , trouver les valeurs (c.à.d., l'intervalle) de  $x$  telles que la méthode de Jacobi converge. Répéter l'exercice pour la méthode de Gauss-Seidel.

**Remarque** vous pouvez utiliser la formule ci-dessous pour l'inverse d'une matrice de taille  $2 \times 2$

$$\text{Pour } A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}, \quad A^{-1} = \frac{1}{\det(A)} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

- (b) Qu'est-ce qui se passe pour  $x = 6$ ? (Est-ce que les méthodes convergent?)  
 (c) Considérons une valeur  $x$  pour laquelle les deux méthodes convergent. Alors, montrer que le taux de convergence de Gauss-Seidel est plus élevé que celui de Jacobi (pour n'importe quelle valeur de  $x$ ).

### corrigé

- (a) La convergence dépend du rayon spectral de la matrice d'itération.

- Pour Jacobi, on trouve  $B_J = D^{-1}(D - A)$  c-à-d. :  $B_J = \begin{bmatrix} 1 & 0 \\ 0 & 1/x \end{bmatrix} \begin{bmatrix} 0 & -2 \\ -3 & 0 \end{bmatrix} = \begin{bmatrix} 0 & -2 \\ -3/x & 0 \end{bmatrix}$  dont le spectre est  $\det(B_J - \lambda I) = 0 \Leftrightarrow \lambda^2 = 6/x$ . On a  $|\lambda| < 1 \Leftrightarrow \lambda^2 < 1 \Leftrightarrow x > 6$
- Pour Gauss-Seidel, on trouve  $B_{GS} = (D - E)^{-1}F$  c-à-d. :  $B_{GS} = \begin{bmatrix} 1 & 0 \\ 3 & x \end{bmatrix}^{-1} \begin{bmatrix} 0 & -2 \\ 0 & 0 \end{bmatrix} = \frac{1}{x} \begin{bmatrix} 0 & -2x \\ 0 & 6 \end{bmatrix}$  dont le spectre est  $\det(B_{GS} - \lambda I) = 0 \Leftrightarrow \lambda = 0$  ou  $\lambda = -6/x$ . On a  $|\lambda| < 1 \Leftrightarrow x > 6$

- (b) Pour  $x = 6$ , la matrice  $A$  est singulière, le système n'a pas de solution unique  
 (c) Pour  $x > 6$ , les rayons spectraux sont  $\rho_J = \sqrt{6/x}$  tandis que  $\rho_{GS} = 6/x = \rho_J^2 < \rho_J$ .

6. Etant donnée la matrice  $A = \begin{bmatrix} 1 & 2 & 0 \\ 3 & 4 & 0 \\ 0 & 0 & 9 \end{bmatrix}$ , Est-ce que la méthode de Jacobi converge pour cette matrice? Répéter l'exercice pour la méthode de Gauss-Seidel.

corrigé

$$B_J = \begin{bmatrix} 0 & -2 & 0 \\ -3/4 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \text{ dont le spectre est } \det(B_J - \lambda I) = 0 \Leftrightarrow \lambda^3 -$$

$3/2\lambda = 0$ . Les racines de l'équation sont  $\lambda \in \{0, \pm\sqrt{3/2}\}$ . Puisque le rayon spectral est plus que 1, la méthode de Jacobi ne converge pas.

Pour Gauss-Seidel, on trouve  $B_{GS} = (D - E)^{-1}F$  c-à-d. :  $B_{GS} =$

$$\begin{bmatrix} 0 & -2 & 0 \\ 0 & 3/2 & 0 \\ 0 & 0 & 0 \end{bmatrix} \text{ dont le spectre est l'ensemble } \{0, 3/2\}. \text{ La méthode}$$

ne converge pas.

---

7. Soit donnée la matrice  $A = \begin{bmatrix} 1 & 2 & 3 \\ 0 & 4 & 5 \\ 0 & 0 & 6 \end{bmatrix}$ .

- (a) Est-ce que la méthode de Jacobi converge pour cette matrice ?
- (b) Répéter l'exercice pour la méthode de Gauss-Seidel.
- (c) Est-ce que c'est une bonne idée d'utiliser une méthode itérative pour la résolution du système  $Ax = b$  où  $A$  est une matrice avec la structure de l'exemple ci-dessus et  $b$  est un vecteur quelconque ?

corrigé

(a)  $B_J = \begin{bmatrix} 0 & -2 & -3 \\ 0 & 0 & -5/4 \\ 0 & 0 & 0 \end{bmatrix}$  dont le spectre est  $\det(B_J - \lambda I) = 0 \Leftrightarrow$

$\lambda^3 = 0$ . Le spectre a une racine triple  $\lambda = 0$ . Les itérations convergeront.

(b) Pour Gauss-Seidel, on trouve  $B_{GS} = (D - E)^{-1}F$  c-à-d. :  $B_{GS} =$

$$\begin{bmatrix} 0 & -2 & -3 \\ 0 & 0 & -5/4 \\ 0 & 0 & 0 \end{bmatrix} = B_J \text{ Les itérations convergeront.}$$

(c) Non, la matrice  $A$  est une matrice triangulaire : sa résolution par une méthode directe ne comprend que  $\mathcal{O}(n)$  opérations à virgule flottante pour les substitutions.

(d) **Remarque** (réponse alternative) On peut vérifier que les méthodes de Gauss-Seidel et Jacobi convergeront toujours pour une matrice triangulaire supérieure : en effet, après une itération, le dernier élément de  $x^{(1)}$  est correct. Après deux étapes, le dernier et l'avant-dernier composant de  $x^{(2)}$  sont corrects, etc. Evidemment, une grande partie des calculs intermédiaires sont assez inutiles, puisqu'il suffit de parcourir les lignes de la matrice au sens rétrograde dans un algorithme de substitution.


---

8. Soit  $\vec{x}^* = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$  la solution du système  $A\vec{x} = \vec{b}$ , où  $A = \begin{bmatrix} 5 & 1 & 9 \\ 1 & 3 & 9 \\ 1 & 0 & 2 \end{bmatrix}$  et  $\vec{b} = \begin{bmatrix} 34 \\ 34 \\ 7 \end{bmatrix}$ .

- (a) Trouver la matrice d'itération,  $B_J$  de la méthode de Jacobi.  
 (b) Spécifier les matrices  $(D - E)$  et  $F$  dans le produit  $B_{GS} = (D - E)^{-1}F$ . (où GS = Gauss-Seidel)  
 (c) Soient BJ et BGS les variables en matlab représentant les matrices  $B_J$  et  $B_{GS}$ . Voici deux commandes et les réponses de Matlab :

```
Matlab :
>> eig(BGS) >> eig(BJ)
ans = ans =
 0 -1.1120
0.4833 + 0.2577i 0.7543
0.4833 - 0.2577i 0.3577
```

Utiliser ces résultats pour associer les graphiques (gauche) et (droite) ci-dessous aux deux itérations : quel graphique correspond à Jacobi et quel à Gauss-Seidel ?



- (d) Après 40 itérations, on retrouve, dans le cas de Gauss-Seidel

$$\vec{x}^{(40)} - \vec{x}^* = 10^a \begin{bmatrix} 0,4193 \\ 0,6825 \\ -0,2096 \end{bmatrix}$$

Trouver l'exposant  $a$  (en utilisant les graphiques ; pas de calcul).

- (e) Avec  $A = \begin{bmatrix} 5 & 1 & 9 \\ 1 & 0 & 9 \\ 1 & 0 & 2 \end{bmatrix}$  (c'est-à-dire, en remplaçant  $A_{2,2} = 3$  par

$A_{2,2} = 0$ ), l'itération de Jacobi crash, parce que la matrice d'itération contient des éléments infinis. Ces infinis, d'où viennent-ils et comment remédier ?

**corrigé**

(a)  $B_J = D^{-1}(D - A) = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 2 \end{bmatrix}^{-1} \begin{bmatrix} 0 & -1 & -9 \\ -1 & 0 & -9 \\ -1 & 0 & 0 \end{bmatrix} = \begin{bmatrix} 0 & -1/5 & -9/5 \\ -1/3 & 0 & -3 \\ -1/2 & 0 & 0 \end{bmatrix}$

(b)  $B_{GS} = (D - E)^{-1}F = \begin{bmatrix} 5 & 0 & 0 \\ 1 & 3 & 0 \\ 1 & 0 & 2 \end{bmatrix}^{-1} \begin{bmatrix} 0 & -1 & -9 \\ 0 & 0 & -9 \\ 0 & 0 & 0 \end{bmatrix}$

- (c) Le graphique à gauche correspond à Jacobi, le graphique à droite correspond à Gauss-Seidel. En effet, l'itération à gauche ne converge pas, car  $\log_{10}(\|\vec{x}^{(k)} - \vec{x}^*\|_2)$  tend vers l'infini. La divergence est due à une valeur propre absolument plus grand que 1.
- (d)  $a = -9$ , car  $\log_{10}(\|\vec{x}^{(40)} - \vec{x}^*\|_2)$  est proche de  $-9$  (voir le graphique à droite).
- (e) L'origine des problèmes se situe dans le zéro sur la diagonale, qui a pour conséquent que la matrice  $D$  est singulière. On peut résoudre la situation en pivotant deux lignes.

9. (a) Soit  $A$  une matrice de taille  $n \times n$ , qu'est-ce qui est calculé par la commande

`A \ eye(n)`

Quel est le rôle et l'importance de la factorisation LU dans cette commande ?

- (b) Quelle est l'importance de la factorisation spectrale,  $B = E\Lambda E^{-1}$ , d'une matrice d'itération ?

### corrigé

- (a) La ligne de matlab calcule  $A^{-1} \cdot I = A^{-1}$ , en résolvant les systèmes  $A\vec{x} = \vec{e}_i$ , où les  $\vec{e}_i$  représentent les colonnes de la matrice d'identité (c'est-à-dire, les vecteurs canoniques). L'implémentation interne de Matlab se base sur la factorisation LU, ce qui permet de réutiliser la même factorisation pour tous les seconds membres.
- (b) La factorisation spectrale permet d'analyser la convergence d'une matrice d'itération consistante, car effectivement  $B^n = E\Lambda E^{-1} \cdot E\Lambda E^{-1} \dots E\Lambda E^{-1} = E\Lambda^n E^{-1}$ . La puissance d'une matrice diagonale  $\Lambda^n$  se fait élément par élément. Quand tous les éléments diagonaux sont en dessous de 1, la suite des puissances convergera vers 0.

10. Calculer les matrices  $L$  et  $U$  de la factorisation LU de la matrice  $A = \begin{bmatrix} 1 & 3 \\ 2 & 4 \end{bmatrix}$  en utilisant la méthode de Doolittle. La réponse doit com-

prendre une conclusion de la forme  $L = \begin{bmatrix} x & x \\ x & x \end{bmatrix}$  et  $U = \begin{bmatrix} x & x \\ x & x \end{bmatrix}$

### corrigé

$$\begin{aligned}
 u_{11} &= a_{11} = 1 \\
 u_{12} &= a_{12} = 3 \\
 l_{21} &= a_{21}/u_{11} = 2/1 = 2 \\
 l_{22} &= a_{22}/u_{11} = 4/1 = 4 \\
 u_{22} &= a_{22} - l_{21}u_{12} = 4 - 2 \cdot 3 = -2
 \end{aligned}$$

On a donc  $U = \begin{bmatrix} 1 & 3 \\ 0 & -2 \end{bmatrix}$        $L = \begin{bmatrix} 1 & 0 \\ 2 & 1 \end{bmatrix}$

11. (a) Expliquer : si la factorisation de Cholesky d'une matrice  $A$  existe, alors les itérations de la méthode de Gauss-Seidel convergent.  
 (b) Qu'est-ce que l'on peut dire sur la convergence de Jacobi pour la même matrice  $A$ ?  
 (c) Discuter quatre problèmes par rapport à un grand conditionnement  $\kappa(A)$ .

**corrigé**

- (a) Pour que la factorisation de Cholesky existe, il faut que  $A$  soit symétrique, définie positive. Pour une matrice symétrique, définie positive, la méthode de Gauss-Seidel converge.  
 (b) Pour que la méthode de Jacobi converge, il faut aussi que  $2D - A$  soit symétrique, définie positive.  
 (c) i. Si  $\kappa(A)$  est grand, le conditionnement du problème  $Ax = b$  est mauvais.  
 ii. Si  $\kappa(A)$  est grand, la stabilité d'une méthode directe est mauvaise.  
 iii. Le calcul de  $\kappa(A)$  comprend l'inversion de la matrice  $A$ , ce qui est difficile si  $\kappa(A)$  est grand. Par conséquent, le problème d'un grand  $\kappa(A)$  est difficile à détecter a priori.  
 iv. Un grand  $\kappa(A)$  rend l'analyse a posteriori plus difficile, car le lien résidu-erreur est moins clair.

12. (a) Considérer le système linéaire  $A\vec{x} = \vec{b}$ , avec

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 1 & 4 & 9 \\ 1 & 8 & 27 \end{bmatrix} \text{ et } \vec{b} = \begin{bmatrix} 14 \\ 36 \\ 98 \end{bmatrix}.$$

Ecrire les matrices d'itération  $B$  et les vecteurs  $\vec{f}$  dans les procédures itératives  $\vec{x}^{(k+1)} = B\vec{x}^{(k)} + \vec{f}$  de Jacobi et de Gauss-Seidel.

- (b) Pour toute méthode itérative consistante, démontrer la consistance de variante  $\vec{x}^{(k+1)} = (\alpha B + (1 - \alpha)I)\vec{x}^{(k)} + \alpha\vec{f}$  pour toute valeur  $\alpha$ .  
 (c) Montrer que si  $\vec{e}$  est un vecteur propre de  $B$  de valeur propre  $\lambda$ , alors  $\vec{e}$  est également un vecteur propre de  $\alpha B + (1 - \alpha)I$ . La valeur propre correspondante est  $\alpha\lambda + (1 - \alpha)$ .  
 (d) Pour le système ci-dessus, voici quelque lignes de code Matlab avec la réponse

```
>> D = diag(diag(A));
>> BJ = D \ (D-A);
>> eig(BJ)
ans =
 -1.2596
 0.3333
```

0.9262

Trouver l'intervalle des  $\alpha$  pour lesquels l'itération  $\vec{x}^{(k+1)} = (\alpha B + (1 - \alpha)I)\vec{x}^{(k)} + \alpha \vec{f}$  converge, où  $B = B_J$ , la matrice d'itération de Jacobi.

corrigé

(a)  $B_J =$

$$\begin{bmatrix} 0 & -2.0000 & -3.0000 \\ -0.2500 & 0 & -2.2500 \\ -0.0370 & -0.2963 & 0 \end{bmatrix}$$

$f_J =$

$$\begin{bmatrix} 14.0000 \\ 9.0000 \\ 3.6296 \end{bmatrix}$$

$B_{GS} =$

$$\begin{bmatrix} 0 & -2.0000 & -3.0000 \\ 0 & 0.5000 & -1.5000 \\ 0 & -0.0741 & 0.5556 \end{bmatrix}$$

$f_{GS} =$

$$\begin{bmatrix} 14.0000 \\ 5.5000 \\ 1.4815 \end{bmatrix}$$

(b) La variante est consistante si et seulement si la solution du système  $A\vec{x} = \vec{f}$  satisfait à  $\vec{x} = (\alpha B + (1 - \alpha)I)\vec{x} + \alpha \vec{f} \Leftrightarrow \vec{0} = \alpha B\vec{x} - \alpha \vec{x} + \alpha \vec{f} \Leftrightarrow \vec{x} = B\vec{x} + \vec{f}$ . La dernière expression est vérifiée si la méthode originale est consistante.

(c)  $B\vec{e} = \lambda \vec{e} \Rightarrow (\alpha B + (1 - \alpha)I)\vec{e} = (\alpha\lambda + 1 - \alpha)\vec{e}$

(d) Les valeurs propres de la variante de Jacobi sont données par  $\alpha\lambda + 1 - \alpha$  où  $\lambda \in \{-1, 2596; 0, 3333; 0, 9262\}$ .

Ces valeurs doivent être comprises dans l'intervalle  $(-1, 1)$ . On a donc

$-1 < \alpha\lambda + 1 - \alpha < 1 \Leftrightarrow -2 < \alpha(\lambda - 1) < 0 \Leftrightarrow 0 < \alpha < 2/(1 - \lambda)$ ,  
puisque, dans notre cas, les valeurs  $1 - \lambda$  sont positives.

On arrive à  $\alpha \in (0; 0, 8851) \cap (0; 3) \cap (0; 27, 11) = (0; 0, 8851)$ .

---

13. Trouver la factorisation de Cholesky pour la matrice

$$A = \begin{bmatrix} 36 & 30 & 24 \\ 30 & 34 & 26 \\ 24 & 26 & 21 \end{bmatrix}$$

La solution est-elle unique ?

### corrigé

On cherche la matrice

$$H = \begin{bmatrix} h_{11} & h_{12} & h_{13} \\ 0 & h_{22} & h_{23} \\ 0 & 0 & h_{33} \end{bmatrix}$$

pour laquelle

$$H^T H = A = \begin{bmatrix} 36 & 30 & 24 \\ 30 & 34 & 26 \\ 24 & 26 & 21 \end{bmatrix} \Leftrightarrow \begin{bmatrix} h_{11}^2 & h_{11}h_{12} & h_{11}h_{13} \\ \dots & h_{12}^2 + h_{22}^2 & h_{12}h_{13} + h_{22}h_{23} \\ \dots & \dots & h_{13}^2 + h_{23}^2 + h_{33}^2 \end{bmatrix} = \begin{bmatrix} 36 & 30 & 24 \\ \dots & 34 & 26 \\ \dots & \dots & 21 \end{bmatrix}$$

On retrouve

$$\begin{aligned} h_{11}^2 &= 36 \Leftrightarrow h_{11} = \pm 6 \\ h_{11}h_{12} &= 30 \Leftrightarrow h_{12} = \pm 5 \\ h_{11}h_{13} &= 24 \Leftrightarrow h_{13} = \pm 4 \\ h_{12}^2 + h_{22}^2 &= 34 \Leftrightarrow h_{22} = \pm\sqrt{34-25} = \pm 3 \\ h_{12}h_{13} + h_{22}h_{23} &= 26 \Leftrightarrow h_{23} = (26-20)/\pm 3 = \pm 2 \\ h_{13}^2 + h_{23}^2 + h_{33}^2 &= 21 \Leftrightarrow h_{33} = \pm\sqrt{21-16-4} = \pm 1 \end{aligned}$$

La solution n'est pas unique. On peut vérifier que les signes sur chaque ligne de  $H$  doivent être les mêmes, mais que l'on peut choisir librement le signe sur chaque ligne.

- 
14. Considérer le système linéaire  $Ax = b$  et les itérations  $x^{(k+1)} = (\alpha A + I)x^{(k)} - \alpha b$  (où  $I$  est la matrice d'identité).

(a) Montrer la consistance des itérations

- (b) Prendre  $A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$  et examiner la convergence des itérations en fonction de  $\alpha$ . Ecrire la condition de convergence. L'expression en  $\alpha$  peut être simplifiée pour arriver à l'ensemble de deux droites, l'une descendante, l'autre montante en fonction de  $\alpha$ . Les deux droites se croisent pour  $\alpha = 0$  à une hauteur de 1. Quelle est la conclusion pour la convergence ?

### corrigé

(a)  $x = (\alpha A + I)x - \alpha b \Leftrightarrow 0 = \alpha Ax - \alpha b \Leftrightarrow Ax = b$

(b) Les valeurs propres sont données par

$$\det(B - \lambda I) = 0 \Leftrightarrow \det(\alpha A + I - \lambda I) = 0 \Leftrightarrow \det(\alpha A - (\lambda - 1)I) = 0$$

$$\Leftrightarrow \det\left(\alpha \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} - (\lambda - 1) \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}\right) = 0$$

$$\Leftrightarrow \det\left(\begin{bmatrix} \alpha - \lambda + 1 & 2\alpha \\ 3\alpha & 4\alpha - \lambda + 1 \end{bmatrix}\right) = 0 \Leftrightarrow (\alpha - \lambda + 1)(4\alpha - \lambda + 1) -$$

$$\Leftrightarrow 4\alpha^2 - \alpha\lambda + \alpha - 4\alpha\lambda + \lambda^2 - \lambda + 4\alpha - \lambda + 1 - 6\alpha^2 = 0$$

$$\begin{aligned}
&\Leftrightarrow \lambda^2 - (5\alpha + 2)\lambda + (-2\alpha^2 + 5\alpha + 1) = 0 \\
&\Leftrightarrow \lambda = \frac{(5\alpha + 2) \pm \sqrt{(5\alpha + 2)^2 - 4(-2\alpha^2 + 5\alpha + 1)}}{2} \\
&\Leftrightarrow \lambda = \frac{(5\alpha + 2) \pm \sqrt{25\alpha^2 + 10\alpha + 4 + 8\alpha^2 - 20\alpha - 4}}{2} \\
&\Leftrightarrow \lambda = \frac{(5\alpha + 2) \pm \sqrt{33}\alpha}{2} = 1 + \frac{5 \pm \sqrt{33}}{2}\alpha
\end{aligned}$$

On a deux droites dont l'une est descendante, l'autre montante. L'intersection des deux droites est située dans  $(0, 1)$ . Du coup, pour chaque valeur de  $\alpha$ , on a une des droites au dessus de 1. Il n'y a jamais de convergence.

15. Expliquer comment le facteur  $\|\delta A\|$  dans le théorème

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\kappa(A)}{1 - \kappa(A) \frac{\|\delta A\|}{\|A\|}} \left( \frac{\|\delta b\|}{\|b\|} + \frac{\|\delta A\|}{\|A\|} \right)$$

est *un modèle* pour les erreurs de génération. Qu'est-ce qui est modélisé par le facteur  $\|\delta b\|$  ?

**corrigé**

Pour modéliser les erreurs de génération, on suppose que la solution numérique d'un système linéaire corresponde à une solution en **arithmétique exacte**, mais partant d'une matrice  $A + \delta A$  perturbée.

Autrement dit, l'analyse de l'erreur de génération lors de la résolution d'un système linéaire est basée sur un modèle dans lequel les erreurs d'arrondi sont remplacées par des erreurs sur la matrice  $A$ .

Les erreurs au fil des calculs (opérations) sont modélisées par des erreurs sur la matrice avec laquelle les calculs sont effectués, mais qui, elle-même, est connue sans erreurs.

Le facteur  $\|\delta b\|$  décrit l'influence des erreurs à l'entrée, donc le **conditionnement** du système, les erreurs de **propagation**.

16. Considérer la matrice  $A = \frac{1}{100} \begin{bmatrix} 25 & 2 & 3 \\ 4 & 50 & 6 \\ 7 & 8 & 75 \end{bmatrix}$  et la matrice d'itération

$$B = I - A.$$

- Ecrire la formule d'une étape de l'itération (avec deuxième membre  $\vec{b}$ ), en imposant la consistance.
- Calculer  $\|B\|_1$  pour examiner la convergence des itérations.

**corrigé**

- On a  $A\vec{x} = \vec{b} \Leftrightarrow (I - A)\vec{x} = \vec{x} - \vec{b} \Leftrightarrow \vec{x} = \vec{b} + (I - A)\vec{x}$ . Par conséquent, l'itération s'énonce  $\vec{x}^{(k+1)} = \vec{b} + (I - A)\vec{x}^{(k)}$ .

(b) On retrouve  $B = \frac{1}{100} \begin{bmatrix} 75 & -2 & -3 \\ -4 & 50 & -6 \\ -7 & -8 & 25 \end{bmatrix}$  Les sommes absolues des colonnes sont alors  $[86 \ 60 \ 34]/100$  d'où il s'ensuit que  $\|B\|_1 = 0,86$  Puisque  $\rho(B) \leq \|B\|_1$ , le rayon spectral est inférieur à 1, donc les itérations convergeront.

---

17. Considérer un grand système linéaire, non creux  $Ax=b$  où la commande Matlab `cond(A)` a pour résultat `ans = 5.3529e+14`. Considérer une matrice  $B$  et un vecteur `f = (I-B)*(A\b)`. La commande `max(abs(eig(B)))` a pour résultat `ans = 0.9013`. Comparer la méthode directe pour la résolution du système (sur base de la factorisation LU) avec la méthode itérative qui utilise  $B$  comme matrice d'itération pour ce qui est

- des erreurs de génération,
- des erreurs de propagation,
- des erreurs d'approximation,
- du temps de calcul, sachant que la matrice  $A$  n'est pas creuse.

#### corrigé

- Les erreurs de génération seront considérables dans la méthode directe, parce que le conditionnement  $\kappa(A)$  contrôle aussi la stabilité de la résolution directe.  
Les erreurs de génération seront absentes dans la méthode itérative, car la convergence implique la stabilité de la méthode (Lax-Richtmyer).
- Les erreurs de propagation concernent une propriété du problème et en tant que tel, elles seront les mêmes pour les deux méthodes. Elles seront très grandes dans les deux cas.
- Les erreurs d'approximation sont absentes dans une méthode directe, alors que dans la méthode itérative, elles convergent vers zéro. Donc, pour un nombre d'itérations suffisamment grand, ces erreurs seront arbitrairement petites.
- Sachant que  $\rho(B) = 0,9\dots$ , la convergence sera plutôt lente et peut-être même pas réalisable dans un délai raisonnable. Du coup, du point de vue de la complexité, la méthode directe (qui est complexité cubique) sera probablement supérieure.

---

18. Considérer l'algorithme suivant pour simuler la convergence d'une méthode itérative dont la matrice  $B$  a un rayon spectral de  $\rho(B) < 1$  :

```
x = (1:n)';
b = A*x;
x_it = zeros(n,1);
while max(abs(x-x_it))>eps,
```

```

 x_it = B*x_it+f;
end

```

La boucle devrait se terminer dès que la convergence se manifeste (à l'exception d'erreurs d'arrondi), mais en réalité la boucle n'aura pas de fin. Expliquer en vous référant vers les trois formes d'erreurs (génération, propagation, approximation).

### corrigé

Le calcul de  $b = A*x$  donnera lieu à des erreurs de génération et d'arrondi. Par conséquent, le vecteur  $b$  est sujet à une erreur qui sera *propagée* au fil des calculs. Il s'agit donc d'un problème de conditionnement non parfait.

Pour une bonne compréhension : l'algorithme itératif, étant convergent, est stable (Lax-Richtmyer). Les erreurs générées au fil des itérations disparaîtront.

Les itérations convergeront toujours, mais vers une solution perturbée. Dénnotant par  $b(1+\rho_b)$  le résultat numérique de la multiplication  $b = Ax$  et par  $x(1+\rho_x)$  la solution *exacte* du système  $Au = b(1+\rho_b)$ , on constate que l'algorithme itératif convergera vers  $x(1+\rho_x)$ , alors que le vecteur  $x$  est "inaccessible" dès le début. Une boucle qui cherche la convergence vers  $x$  est donc vouée à l'échec.

---

## 4 EDO

---

1. Considérons le problème aux valeurs initiales  $y'(t) = f(t, y(t))$  où  $f(t, y(t)) = \sin(t) \cdot y(t)$ , et  $y(\pi) = \pi$ .

(a) Vérifier qu'une forme de la solution théorique est  $y(t) = K \cdot \exp(-\cos(t))$ . (Il ne faut pas démontrer l'unicité de cette forme)

(b) Déterminer la constante  $K$ .

### corrigé

$$y(\pi) = \pi \Leftrightarrow K \cdot \exp(-\cos(\pi)) = \pi \Leftrightarrow K = \pi/e$$


---

2. Considérons le problème aux valeurs initiales

$$y' = -2y/\sqrt{t},$$

et  $y(1) = 1$ .

(a) Montrer que la solution exacte est de la forme  $y(t) = K \cdot e^{a\sqrt{t}}$ .

(b) Trouver les constantes  $K$  et  $a$ .

- (c) En écrivant  $y'(t) = -2y \cdot t^{-1/2}$  et donc  $y''(t) = -2 \left[ y' \cdot t^{-1/2} + y \cdot (-1/2)t^{-3/2} \right]$  etc., déterminer l'approximation de la solution pour  $y(1, 6)$  avec la méthode du développement de Taylor d'ordre 2 (c'est-à-dire, trouver les  $a_i$  dans  $\hat{y}(1+h) = a_0 + a_1h + a_2h^2$ )
- (d) Déterminer l'approximation de la solution renvoyée par la méthode d'Euler explicite avec  $h = 0,2$  et avec  $h = 0,3$  pour  $y(1, 6)$ .

### corrigé

3. Considérer l'EDO  $y'(t) = 2 \cos(t) \sin(y(t)) + 4e^{-t}y(t)$  avec la valeur initiale  $y(0) = 1$ .

Montrer que le problème possède une solution unique pour tout  $t \in \mathbb{R}^+$  (l'ensembles des réels positifs).

### corrigé

Ceci revient à montrer que la fonction  $f(t,y)$  satisfait la condition Lipschitzienne La fonction  $f(t, y) = 2 \cos(t) \sin(y(t)) + 4e^{-t}y(t)$  satisfait la condition de Lipschitz pour tout  $t \in D$  et pour tout  $y \in \mathbb{R}$  si et seulement si  $\left| \frac{\partial f}{\partial y} \right|$  est majorée. Or,

$$\left| \frac{\partial f}{\partial y} \right| = |2 \cos(t) \cos(y(t)) + 4e^{-t}| \leq 2 + 4 = 6$$

4. Considérer l'EDO  $y'(t) = \cos(t^2y(t)) + y(t)$  avec la valeur initiale  $y(0) = 1$ .

- (a) Montrer que le problème possède une solution unique pour tout  $t \in D$  où  $D = [-2, 2]$ .
- (b) Déterminer par la méthode d'Euler explicite avec un pas  $h = 0,2$  la valeur de la solution pour  $t = 1$ . (Ecrire la formule récursive, puis évaluer)

### corrigé

- (a) Ceci revient à montrer que la fonction  $f(t,y)$  satisfait la condition Lipschitzienne La fonction  $f(t, y) = \cos(t^2y(t)) + y(t)$  satisfait la condition de Lipschitz pour tout  $t \in D$  et pour tout  $y \in \mathbb{R}$  si et seulement si  $\left| \frac{\partial f}{\partial y} \right|$  est majorée. Or,

$$\left| \frac{\partial f}{\partial y} \right| = |t^2 \sin(t^2y(t)) + 1| \leq 4 + 1 = 5$$

(b)

5. (a) Expliquer : pour la convergence d'une méthode explicite à un pas en **arithmétique exacte** il faut que la méthode soit stable sous de petits arrondis (zéro-stabilité ; donc arithmétique numérique).

- (b) Illustrer avec une formule que ceci n'implique pas que les vrais arrondis sont annihilés dans l'exécution des itérations d'une méthode convergente.
- (c) Quelle est alors la différence entre les arrondis supposés (artificiels) dans l'analyse de la convergence et les arrondis réels ?

### corrigé

- (a) Selon le théorème de Lax-Richtmyer, l'effet de l'erreur de troncature (c'est-à-dire, l'erreur de l'approximation) se décrit comme si c'était une erreur numérique d'arrondi. Donc, la (zéro-)stabilité (c'est-à-dire, la robustesse face à des erreurs d'arrondi/des erreurs de génération), tout en étant une propriété numérique, joue un rôle pour la robustesse face à des erreurs d'approximation en arithmétique exacte.
- (b) Pour la méthode d'Euler en arithmétique numérique on a


$$\max_{0 \leq n \leq N_h} |y(t_n) - \hat{y}(t_n)| \leq \frac{e^{LT} - 1}{L} \left( \frac{M_2}{2} h + \epsilon + \frac{\rho}{h} \right),$$

où  $\epsilon$  et  $\rho$  décrivent les effets des erreurs d'arrondi réelles. Ces effets ne sont pas nuls pour  $h \rightarrow 0$ . Ceci est en contraste avec l'effet de la troncature, décrit par le terme  $\frac{M_2}{2} h$ .

- (c) Pour une méthode consistante, l'erreur de troncature globale  $\tau(h)$  se manifeste comme une erreur d'arrondi qui tend vers 0 si  $h \rightarrow 0$ . Les erreurs d'arrondi réelles, par contre, ne dépendent pas de  $h$ .

6. Considérer le problème aux valeurs initiales  $y'(t) = f(t, y(t))$  et  $y(1) = e$  où  $f(t, u) = -u \ln(t)$ .

- (a) Vérifier que la solution du problème s'écrit sous la forme  $y(t) = \exp[t(1 - \ln(t))]$ .
- (b) Est-ce que le problème est bien conditionné ? (Soutenir votre réponse par un argument)
- (c) Déterminer par la méthode du **trapèze** avec un pas  $h = 0,2$  la valeur de la solution pour  $t = 2$ . (Ecrire la formule récursive, puis effectuer la récursion)
- (d) Expliquer l'origine du terme "méthode du trapèze", c'est-à-dire, compléter l'interprétation géométrique dans le graphique à côté. En particulier, quelle est la fonction représentée par le graphique ?
- (e) Argumenter que la méthode d'Euler pour le même problème est convergente. (ne pas reproduire les démonstrations des résultats du syllabus.)



### corrigé

- (a) i. La fonction satisfait l'EDO :  $y'(t) = y(t) \cdot (t - t \ln(t))' = y(t)(1 - t/t - \ln(t))$   
ii. La fonction satisfait à la condition initiale  $y(1) = e$ .
- (b) Le problème est bien conditionné parce que la fonction  $f(t, u) = -u \ln(t)$  est continue pour tout  $t \in [1, \infty[$  et parce qu'elle satisfait la condition Lipschitz pour tout  $u$ .
- (c) Méthode du trapèze :  $\hat{y}(t_{n+1}) = \hat{y}(t_n) + \frac{h}{2} [f(t_n, \hat{y}(t_n)) + f(t_{n+1}, \hat{y}(t_{n+1}))]$   
Dans notre cas :  
 $\hat{y}(t_{n+1}) = \hat{y}(t_n) + \frac{h}{2} [-\hat{y}(t_n) \ln(t_n) - \hat{y}(t_{n+1}) \ln(t_{n+1})]$ , ce qui nous amène à l'itération suivante  
 $\hat{y}(t_{n+1}) = \hat{y}(t_n) \left[ 1 - \frac{h}{2} \ln(t_n) \right] / \left[ 1 + \frac{h}{2} \ln(t_{n+1}) \right]$  On retrouve  $\hat{y}(2) = \hat{y}(t_5) = 1,8542$
- (d) Le graphique représente la fonction  $y'(t) = f(t, y(t))$ . La fonction inconnue,  $y(t)$  en est l'intégrale. L'approximation adoptée dans la méthode du trapèze consiste d'une approximation de l'aire sous la courbe de  $y'(t)$  entre  $t_n$  et  $t_{n+1}$  par l'aire du trapèze.
- (e) La méthode est consistante. En plus, elle est zéro stable, car la fonction d'incrément  $\Phi(t, u) = f(t, u) = -u \ln(t)$  satisfait la condition Lipschitz par rapport à la variable  $u$ . La convergence vient de la combinaison de consistance et zéro-stabilité (Lax-Richtmyer).

- 
7. Considérer le problème aux valeurs initiales  $y' = \sqrt{|y|}$  avec  $y(0) = y_0$ . Quand  $y_0 \neq 0$ , la solution unique autour de  $t = 0$  est donnée par

$$y(t) = \text{sign}(y_0)(t + c)^2/4,$$

où  $\text{sign}(x)$  représente le signe d'un réel  $x$  et  $c = 2\text{sign}(y_0)\sqrt{|y_0|}$ . Quand  $y_0 = 0$ , l'équation admet deux solutions, notamment  $y(t) = t^2/4$  et  $y(t) = 0$ .

- (a) La fonction  $f(t, y)$  dans la forme  $y' = f(t, y)$ , vérifie-t-elle la condition Lipschitz ? Que pouvez-vous en conclure au niveau de l'existence et de l'unicité de la solution ?
- (b) Pour  $y_0 = 1$  et un pas de  $h = 0,1$ , effectuer 3 étapes de la méthode de Euler explicite (ou progressive). Comparer avec la valeur théorique  $y(t_3)$  où  $t_3 = t_0 + 3h = 0,3$ .
- (c) Ecrire (sans effectuer) l'itération pour la méthode de Euler implicite (ou rétrograde).
- (d) Qu'est-ce que la théorie prédit par rapport à la convergence de la méthode de Euler explicite pour un pas infinitésimal pour les valeurs initiales  $y_0 = 1$  et  $y_0 = 0$  ?

corrigé

**Remarque : démonstration de la solution de l'EDO**

$$\begin{aligned}y'(t) = \sqrt{|y(t)|} &\Leftrightarrow |y(t)|^{-1/2} y'(t) = 1 \Leftrightarrow \left[|y(t)|^{1/2}\right]' = 1/2 \Leftrightarrow |y(t)|^{1/2} = (t+c)/2 \\&\Leftrightarrow |y(t)| = (t+c)^2/4 \Leftrightarrow y(t) = \pm(t+c)^2/4\end{aligned}$$

Quand  $y(0) = y_0 \neq 0$ , il n'y a une solution qui passe par  $y(0)$ , notamment celle donnée par  $y(t) = \text{sign}(y(0))(t+c)^2/4$ . La constante  $c$  suit de

$$y(0) = \text{sign}(y(0))(0+c)^2/4 \Leftrightarrow c^2 = 4y(0)/\text{sign}(y(0)) = 4|y(0)| \Leftrightarrow c = \pm 2\sqrt{|y_0|}$$

Le signe de  $c$  suit de la condition que  $y'(0) = \sqrt{|y_0|} \geq 0$ .

(a) En écrivant l'équation différentielle sous la forme générale  $y' = f(t, y)$ , on peut identifier  $f(t, y) = \sqrt{|y|}$ . La fonction  $f(t, y)$  ne vérifie pas la condition Lipschitz en  $y = 0$ , donnant ainsi lieu à la possibilité d'une solution multiple.

(b) Euler, explicite :  $\hat{y}(t_{n+1}) = \hat{y}(t_n) + hf(t_n, \hat{y}(t_n))$   
Ici :  $\hat{y}(t_{n+1}) = \hat{y}(t_n) + h\sqrt{|y(t_n)|}$

On a

$$\begin{aligned}y(0) &= 1 \\ \hat{y}(0, 1) &= 1 + 0,1 \cdot \sqrt{1} = 1,1 \\ \hat{y}(0, 2) &= 1,1 + 0,1 \cdot \sqrt{1,1} = 1,2049 \\ \hat{y}(0, 3) &= 1,2032 + 0,1 \cdot \sqrt{1,2032} = 1,3146\end{aligned}$$

En revanche,  $y(0, 3) = \text{sign}(y(0))(0,3+c)^2/4$ , où  $c = 2\text{sign}(y_0)\sqrt{|y_0|} = 2$ , donc  $y(0, 3) = 2,3^2/4 = 1,3225$ .

(c) Euler, implicite/rétrograde :  $\hat{y}(t_{n+1}) = \hat{y}(t_n) + hf(t_{n+1}, \hat{y}(t_{n+1}))$   
Ici :  $\hat{y}(t_{n+1}) = \hat{y}(t_n) + h\sqrt{|y(t_{n+1})|}$


(d) La méthode de Euler explicite converge quand la fonction d'incrément  $\Phi(t, y)$  vérifie la condition Lipschitz par rapport à la variable  $y$ . La condition est vérifiée en  $y = 1$ , mais pas en  $y = 0$ . Ceci veut dire que la convergence n'est pas garantie (ni exclue) quand  $y_0 = 0$ .

---

**8. Considérer le problème aux valeurs initiales**

$$y'(t) = -4t^3 \cdot y(t) \text{ avec } y(0) = 1.$$

- (a) Vérifier que  $y(t) = \exp(-t^4)$  est une solution du problème.
- (b) Ecrire la formule de l'itération pour la méthode d'Euler progressive (ou explicite). Effectuer deux étapes avec un pas de  $h = 0,2$ .
- (c) Ecrire la formule de l'itération pour la méthode d'Euler rétrograde (ou implicite). Effectuer deux étapes avec un pas de  $h = 0,2$ .
- (d) Les graphiques ci-dessus représentent en tiret la fonction  $y(t)$ . Les solides pointillés représentent la sorties des méthodes d'Euler à un pas de  $h = 0,2$ .



Comment ce graphique illustre-t-il le bénéfice d'une méthode rétrograde ? Quelle figure correspond à la méthode rétrograde (gauche ou droite) ? Nommer le bénéfice.

**corrigé**

(a)  $y'(t) = \frac{d}{dt} \exp(-t^4) = \exp(-t^4) \cdot \frac{d(-t^4)}{dt} = y(t) \cdot (-4t^3)$

(b) Euler progressif, en général :

$$\hat{y}_{n+1} = \hat{y}_n + h \cdot f(t_n, \hat{y}_n).$$

Ici :

$$\hat{y}_{n+1} = \hat{y}_n + h(-4t_n^3 \cdot \hat{y}_n) \text{ d'où vient } \hat{y}_{n+1} = (1 - 4ht_n^3)\hat{y}_n$$

(c) Euler rétrograde, en général :

$$\hat{y}_{n+1} = \hat{y}_n + h \cdot f(t_{n+1}, \hat{y}_{n+1}).$$

Ici :

$$\hat{y}_{n+1} = \hat{y}_n + h(-4t_{n+1}^3 \cdot \hat{y}_{n+1}) \text{ d'où vient } \hat{y}_{n+1} = \hat{y}_n / (1 + 4ht_{n+1}^3).$$

(d) La méthode rétrograde est **absolument stable** pour  $h = 0, 2$ . Il s'agit du graphique à gauche. Pour un pas de  $h = 0, 2$ , la méthode progressive

9. Considérer le problème d'intégration

$$z(t) = \int_{t_0}^t g(u) du, \text{ avec } g(u) \text{ une fonction quelconque.}$$

En posant  $y(t) = \exp[z(t)]$ , l'énoncé se réduit à un problème aux valeurs initiales, avec l'équation différentielle

$$y'(t) = g(t)y(t)$$

(a) Formuler la condition initiale.

(b) Démontrer que la méthode d'Euler implicite aboutit à la récursion

$$\hat{y}_{n+1} = \hat{y}_n / [1 - hg(t_{n+1})],$$

où  $h$  est le pas.

(c) Trouver  $\hat{z}(0, 4)$  en utilisant la méthode d'Euler implicite avec  $h = 0, 1$  et pour  $g(t) = \cos(t)$ . Comparer avec  $z(0, 4)$ .

(d) Trouver la récursion sortant de la méthode d'Euler explicite.

(e) Trouver la récursion sortant de la méthode du trapèze (la méthode d'Euler modifiée)

**corrigé**

- (a)  $y(t_0) = \exp[z(t_0)] = \exp(0) = 1$ .
- (b) Euler rétrograde, en général :  
 $\hat{y}_{n+1} = \hat{y}_n + h \cdot f(t_{n+1}, \hat{y}_{n+1})$ .  
Ici :  
 $\hat{y}_{n+1} = \hat{y}_n + hg(t_{n+1}) \cdot \hat{y}_{n+1}$  d'où vient  $\hat{y}_{n+1} = \hat{y}_n / [1 - hg(t_{n+1})]$ .
- (c)  $\hat{y}_1 = 1,1105$ ;  $\hat{y}_2 = 1,2312$ ;  $\hat{y}_3 = 1,3612$ ;  $\hat{y}_4 = 1,4993$ ;  $\hat{z}_4 = \ln(1,4993) = 0,4050$ .  
 $z(0,4) = \sin(0,4) = 0,3894$ .
- (d) Euler progressif, en général :  
 $\hat{y}_{n+1} = \hat{y}_n + h \cdot f(t_n, \hat{y}_n)$ .  
Ici :  
 $\hat{y}_{n+1} = \hat{y}_n + hg(t_n) \cdot \hat{y}_n$  d'où vient  $\hat{y}_{n+1} = [1 + hg(t_n)] \hat{y}_n$ .
- (e) Euler modifié (trapèze), en général :  
 $\hat{y}_{n+1} = \hat{y}_n + \frac{h}{2} \cdot [f(t_n, \hat{y}_n) + f(t_{n+1}, \hat{y}_{n+1})]$ .  
Ici :  
 $\hat{y}_{n+1} = \hat{y}_n + \frac{h}{2} \cdot [g(t_n) \cdot \hat{y}_n + g(t_{n+1}) \cdot \hat{y}_{n+1}]$ .  
d'où vient  $\hat{y}_{n+1} = \hat{y}_n \cdot \left[ \frac{1 + \frac{h}{2}g(t_n)}{1 - \frac{h}{2}g(t_{n+1})} \right]$ .

---

10. Considérer le problème aux valeurs initiales

$$y'(t) = [y(t)]^2 \text{ avec } y(t_0) = 1.$$

- (a) Vérifier que  $y(t) = \frac{1}{c-t}$  est une solution du problème et trouver la valeur de la constante  $c$  en fonction de  $t_0$ .
- (b) Est-ce qu'il y a d'autres solutions ? Si oui, écrire une autre solution ; si non, pourquoi pas ?
- (c) Trouver les coefficients  $a_0, a_1, a_2, a_3$  de la forme  $y(t_0 + h) = a_0 + a_1h + a_2h^2 + a_3h^3$  en utilisant la méthode de Taylor.
- (d) Ecrire la formule de l'itération pour la méthode d'Euler progressive (ou explicite). Effectuer deux étapes avec un pas de  $h = 0,2$ .
- (e) Ecrire la formule de l'itération pour la méthode d'Euler rétrograde (ou implicite).

**corrigé**

- (a)  $y'(t) = \frac{d}{dt} \frac{1}{c-t} = \frac{-1}{(c-t)^2} \cdot (-1) = [y(t)]^2$  La valeur de  $c$  suit de la condition initiale :  $y(t_0) = 1 \Leftrightarrow c = t_0 + 1$
- (b) La solution est unique, car la fonction  $f(t, y) = y^2$  dans la forme générale  $y'(t) = f(t, y(t))$  est dérivable par rapport à sa seconde variable indépendante, donc elle satisfait la condition Lipschitz.
- (c) On a :
- $$\begin{aligned} y(t_0) &= 1 \\ y'(t_0) &= [y(t_0)]^2 = 1 \\ y''(t_0) &= 2y(t_0)y'(t_0) = 2 \\ y'''(t_0) &= 2y(t_0)y''(t_0) + 2y'(t_0)y'(t_0) = 2 \cdot 1 \cdot 2 + 2 \cdot 1 \cdot 1 = 6 \end{aligned}$$

Par conséquent, on obtient  $y(t_0+h) \approx y(t_0) + y'(t_0)h + \frac{y''(t_0)}{2!}h^2 + \frac{y'''(t_0)}{3!}h^3 = 1 + h + h^2 + h^3$  (donc  $a_0 = a_1 = a_2 = a_3 = 1$ )

(d) Euler progressif, en général :

$$\hat{y}_{n+1} = \hat{y}_n + h \cdot f(t_n, \hat{y}_n).$$

Ici :

$$\hat{y}_{n+1} = \hat{y}_n + h\hat{y}_n^2, \text{ d'où vient } \hat{y}_{n+1} = (1 + h\hat{y}_n)\hat{y}_n$$

$$\hat{y}_0 = 1; \hat{y}_1 = 1, 2; \hat{y}_2 = 1, 488.$$

(e) Euler rétrograde, en général :

$$\hat{y}_{n+1} = \hat{y}_n + h \cdot f(t_{n+1}, \hat{y}_{n+1}).$$

Ici :

$$\hat{y}_{n+1} = \hat{y}_n + h\hat{y}_{n+1}^2$$

(Optionnellement) Cette forme peut être développée comme

$$\hat{y}_{n+1} = \frac{1 \pm \sqrt{1 - 4h\hat{y}_n}}{2h}$$

11. Considérer l'équation différentielle  $y'' - y = e^{-x} + e^{-2x}$  avec les valeurs initiales  $y(0) = 0$  et  $y'(0) = -5/6$ .

- Pourquoi l'énoncé ne comprend-il pas seulement la valeur initiale de la fonction, mais aussi celle de la fonction dérivée ?
- Argumenter que la solution vérifie la forme  $y(x) = a_1 e^{-x} + a_2 e^x + b_1 x e^{-x} + b_2 e^{-2x}$
- Expliquer que les constantes  $a_1$  et  $a_2$  suivent d'un autre raisonnement que les constantes  $b_1$  et  $b_2$  (il n'est pas demandé, ni est-il interdit de trouver les valeurs de ces constantes).
- Trouver les coefficients  $c_0, c_1, c_2, c_3$  de la forme  $y(h) = c_0 + c_1 h + c_2 h^2 + c_3 h^3$  en utilisant la méthode de Taylor. (Attention, puisque l'EDO est d'ordre 2, les valeurs de  $y(0)$  et  $y'(0)$  sont données par les conditions initiales. Il suffit de trouver les valeurs de  $y''(0)$  et  $y'''(0)$  en utilisant l'équation différentielle et sa dérivée)

### corrigé

- C'est parce que l'équation différentielle est d'ordre deux (c'est-à-dire, qu'elle contient une dérivée seconde de la fonction inconnue). Une EDO d'ordre deux nécessite deux valeurs initiales.
- (L'explication suivante est plus complète et plus longue que la réponse nécessaire.)

La solution de l'équation prend la forme de  $y(x) = y_p(x) + y_h(x)$ , où  $y_p(x)$  est une solution particulière de l'équation et  $y_h(x)$  une solution de l'équation homogène associée,  $y'' - y = 0$ . La solution de l'équation homogène associée est donnée par  $y_h(x) = a_1 e^{\lambda_1 x} + a_2 e^{\lambda_2 x}$  où  $\lambda_1$  et  $\lambda_2$  sont les racines du polynôme caractéristique, c'est-à-dire,  $\lambda^2 - 1 = 0$ . On a donc  $\lambda_1 = -1$  et  $\lambda_2 = 1$ .

Pour trouver la forme générale de la solution particulière, on utilise la notation de l'opérateur différentiel,  $D$ , pour écrire :

$$\begin{aligned} y'' - y &= e^{-x} + e^{-2x} \Leftrightarrow (D^2 - 1)y = e^{-x} + e^{-2x} \\ &\Rightarrow (D + 1)(D + 2)(D^2 - 1)y = (D + 1)(D + 2) [e^{-x} + e^{-2x}] \\ &\Leftrightarrow (D + 1)(D + 2)(D^2 - 1)y = 0 \end{aligned}$$

Le polynôme caractéristique de cette équation homogène a donc pour racines  $\lambda_1 = -1$ ,  $\lambda_2 = 1$ ,  $\lambda_3 = -2$ , où  $\lambda_1 = -1$  est une double racine. On a donc

$$y_p(x) = b_1 x e^{-x} + b_2 e^{-2x} + b_3 e^{-x} + b_4 e^x$$

La partie  $b_3 e^{-x} + b_4 e^x$  est déjà comprise dans la solution homogène : il est donc légitime de proposer une solution particulière dans laquelle  $b_3 = 0 = b_4$  (puisque toute solution peut être reconstruite à partir de la forme avec  $b_3 = 0 = b_4$  et un choix approprié de  $a_1$  et  $a_2$ ).

- (c) Les constantes  $b_1$  et  $b_2$  suivent d'une substitution de la forme de la solution particulière dans l'équation.

**Explication :** La forme proposée suit d'une équation homogène obtenue par annihilation de second membre de l'équation originale :

$$(D^2 - 1)y = e^{-x} + e^{-2x} \Rightarrow (D + 1)(D + 2)(D^2 - 1)y = (D + 1)(D + 2) [e^{-x} + e^{-2x}] = 0$$

Cette annihilation est une opération non-inversible. Plus précisément, toute solution de  $(D^2 - 1)y = e^{-x} + e^{-2x}$  vérifie l'équation homogène, mais pas l'inverse.

On a  $y_p(x) = b_1 x e^{-x} + b_2 e^{-2x}$ , alors  $y_p''(x) - y_p(x) = b_1 [(x - 2)e^{-x} - x e^{-x}] + b_2 [4e^{-2x} - e^{-2x}] = b_1 (-2)e^{-x} + b_2 3e^{-2x}$ . Par identification avec le membre à droite, on retrouve  $-2b_1 = 1 \Leftrightarrow b_1 = -1/2$  et  $3b_2 = 1 \Leftrightarrow b_2 = 1/3$ .

Les constantes  $a_1$  et  $a_2$  suivent des conditions initiales. On a  $y(0) = a_1 + a_2 + b_2$  et  $y'(0) = -a_1 + a_2 + b_1 - 2b_2$ , d'où s'ensuit, en additionnant les équations, que  $2a_2 + b_1 - b_2 = y(0) + y'(0) \Rightarrow a_2 = 0$  et en soustrayant les expressions on arrive à  $2a_1 = y(0) - y'(0) + b_1 - 3b_2 = -2/3 \Rightarrow a_1 = -1/3$ .

- (d) On a :

$$\begin{aligned} y(0) &= 0 \\ y'(0) &= -5/6 \\ y''(0) &= y(0) + e^{-0} + e^{-2 \cdot 0} = 2 \\ y'''(0) &= y'(0) - e^{-0} - 2e^{-2 \cdot 0} = -5/6 - 1 - 2 = -23/6 \end{aligned}$$

Par conséquent, on obtient  $y(h) \approx y(0) + y'(0)h + \frac{y''(0)}{2!}h^2 + \frac{y'''(0)}{3!}h^3 = -5h/6 + h^2 - 23h^3/36$  (donc  $c_0 = 0$ ,  $c_1 = -5/6$ ,  $c_2 = 1$ ,  $c_3 = -23/36$ )

- 
12. Expliquer la phrase suivante dans le contexte de la résolution des EDOs : “même sur une machine en arithmétique exacte (c’est-à-dire, en absence d’erreurs d’arrondi), l’analyse de stabilité est importante”

**corrigé**

La résolution numérique d’une EDO comprend une **approximation**, et donc des erreurs de **troncature**. Le théorème de Lax-Richtmyer stipule que l’analyse de la convergence pour une méthode **convergente** revient à une analyse de sa stabilité. Plus précisément, en arithmétique exacte, les erreurs de troncature peuvent être analysées comme si elles étaient des erreurs d’arrondi avec la différence que les erreurs de troncature s’annulent quand la sophistication augmente, c’est-à-dire quand  $h \rightarrow 0$ .

- 
13. Expliquer pourquoi dans le cadre de la résolution des EDOs, la zéro-stabilité reste une notion théorique (qui nécessite l’introduction de la stabilité absolue).

**corrigé**

La zéro-stabilité concerne la stabilité de la méthode pour des perturbations (erreurs d’arrondi) lors de l’évaluation de la fonction d’incrément pour un pas tendant vers zéro. En pratique, on ne peut pas raffiner infiniment en laissant  $h$  tendre vers 0, parce que les **erreurs d’arrondi** se manifestent aussi hors de l’évaluation de la fonction d’incrément et les erreurs d’arrondi ne sont pas contrôlées en laissant  $h \rightarrow 0$ . Au contraire, quand  $h \rightarrow 0$ , les erreurs d’arrondis deviennent de plus en plus nombreux, avec une accumulation croissante.

- 
14. Considérer le problème aux valeurs initiales

$$(1 + t^2)y'(t)y(t) = t \text{ avec } y(0) = y_0$$

- (a) Vérifier que  $y(t) = \sqrt{\ln(1 + t^2) + y_0^2}$  est une solution du problème, à condition que la valeur de  $y_0$  soit positive. Quelle sera la solution si  $y_0 < 0$  ?
- (b) Cette solution est-elle unique, en particulier si  $y_0 = 0$  ? Expliquer en se basant sur la théorie.
- (c) Ecrire la formule de l’itération pour la méthode d’Euler progressive (ou explicite).
- (d) Ecrire la formule de l’itération pour la méthode d’Euler rétrograde (ou implicite), sans développement.

**corrigé**

- (a) La solution satisfait à l’EDO  $y(t) = \sqrt{\ln(1 + t^2) + y_0^2} \Rightarrow [y(t)]^2 = \ln(1 + t^2) + y_0^2 \Rightarrow 2y(t)y'(t) = \frac{2t}{1+t^2}$

Une méthode équivalente utilise la séparation des variables

$$(1+t^2)y(t)y'(t) = t \Leftrightarrow y(t)y'(t) = t/(1+t^2) \Leftrightarrow \int y(t)y'(t)dt = \int \frac{t}{1+t^2} dt + C \Leftrightarrow \frac{[y(t)]^2}{2} = \frac{\ln(1+t^2)}{2} + C$$

La condition initiale est satisfaite si  $y_0 > 0$ , puisque  $y(0) = \sqrt{\ln(1) + y_0^2}$ . Si  $y_0 < 0$ , la solution sera  $y(t) = -\sqrt{\ln(1+t^2) + y_0^2}$ . Pour  $y_0 = 0$ , les deux solutions sont valides.

- (b) L'équation prend la forme de  $y'(t) = f(t, y(t))$  où  $f(t, y) = \frac{t}{(1+t^2)y}$ .

La fonction  $f(t, y)$  ne satisfait pas à la condition Lipschitz pour  $y = 0$ . Cette observation explique la double solution pour  $y_0 = 0$ . (Le suivant est au delà de la réponse nécessaire)

Si  $y_0 \neq 0$ , une analyse à posteriori montre que la solution  $y(t)$  sera une fonction monotone qui n'aura pas de racine. Par conséquent, le point  $y = 0$  ne se manifeste pas, et la fonction  $f(t, y)$  satisfait à la condition de Lipschitz dans tous les points d'intérêt. La solution sera donc unique.

- (c) Euler progressif, en général :

$$\hat{y}_{n+1} = \hat{y}_n + h \cdot f(t_n, \hat{y}_n).$$

Ici :

$$\hat{y}_{n+1} = \hat{y}_n + h \frac{t_n}{(1+t_n^2)\hat{y}_n}$$

- (d) Euler rétrograde, en général :

$$\hat{y}_{n+1} = \hat{y}_n + h \cdot f(t_{n+1}, \hat{y}_{n+1}).$$

Ici :

$$\hat{y}_{n+1} = \hat{y}_n + h \frac{t_{n+1}}{(1+t_{n+1}^2)\hat{y}_{n+1}} \text{ ce qui amène à une expression quadratique en } \hat{y}_{n+1}.$$

## 15. Considérer le problème aux valeurs initiales

$$y'(t) = \frac{4t}{1+t^2} \sqrt{|y(t)|} \text{ avec } y(0) = y_0$$

- Vérifier que  $y(t) = [\ln(1+t^2) + \sqrt{y_0}]^2$  est une solution du problème, à condition que la valeur de  $y_0$  soit positive. Quelle sera la solution si  $y_0 < 0$  ?
- Cette solution est-elle unique, en particulier si  $y_0 = 0$  ? Expliquer en se basant sur la théorie.
- Ecrire la formule de l'itération pour la méthode d'Euler progressive (ou explicite).
- Ecrire la formule de l'itération pour la méthode d'Euler rétrograde (ou implicite), sans développement.

### corrigé

- (a) La solution est positive partout et vérifie l'EDO  $y(t) = [\ln(1+t^2) + \sqrt{y_0}]^2 \Rightarrow y'(t) = 2[\ln(1+t^2) + \sqrt{y_0}] \cdot \frac{2t}{1+t^2} = \sqrt{y(t)} \cdot \frac{4t}{1+t^2}$

Une méthode équivalente utilise la séparation des variables

$$y'(t) = \frac{4t}{1+t^2} \sqrt{|y(t)|} \Leftrightarrow \frac{y'(t)}{2\sqrt{|y(t)|}} = 2t/(1+t^2) \Leftrightarrow \int \frac{y'(t)}{2\sqrt{|y(t)|}} dt = \int \frac{2t}{1+t^2} dt + C \Leftrightarrow \sqrt{|y(t)|} = \ln(1+t^2) + C \Leftrightarrow |y(t)| = [\ln(1+t^2) + C]^2$$

La condition initiale est satisfaite si  $y_0 > 0$ , puisque  $y(0) =$

$[\ln(1) + \sqrt{y_0}]^2$ . Si  $y_0 < 0$ , la solution sera  $y(t) = -[\ln(1 + t^2) + \sqrt{|y_0|}]^2$ . Pour  $y_0 = 0$ , les deux solutions sont valides.

- (b) L'équation prend la forme de  $y'(t) = f(t, y(t))$  où  $f(t, y) = \frac{4t\sqrt{|y|}}{(1+t^2)}$ . La fonction  $f(t, y)$  ne satisfait pas à la condition Lipschitz pour  $y = 0$ . Cette observation explique la double solution pour  $y_0 = 0$ . (Le suivant est au delà de la réponse nécessaire)  
Si  $y_0 \neq 0$ , une analyse à posteriori montre que la solution  $y(t)$  sera une fonction monotone qui n'aura pas de racine. Par conséquent, le point  $y = 0$  ne se manifeste pas, et la fonction  $f(t, y)$  satisfait à la condition de Lipschitz dans tous les points d'intérêt. La solution sera donc unique.

- (c) Euler progressif, en général :

$$\hat{y}_{n+1} = \hat{y}_n + h \cdot f(t_n, \hat{y}_n).$$

Ici :

$$\hat{y}_{n+1} = \hat{y}_n + h \frac{4t_n \sqrt{\hat{y}_n}}{(1+t_n^2)}$$

- (d) Euler rétrograde, en général :

$$\hat{y}_{n+1} = \hat{y}_n + h \cdot f(t_{n+1}, \hat{y}_{n+1}).$$

Ici :


$$\hat{y}_{n+1} = \hat{y}_n + h \frac{4t_{n+1} \sqrt{\hat{y}_{n+1}}}{(1+t_{n+1}^2)} \text{ ce qui amène à une expression non-linéaire en } \hat{y}_{n+1}.$$

16. Considérer l'EDO  $y'(t) = r\lambda t^{r-1}[y(t)]^2$  avec la condition initiale  $y(0) = y_0$ .

- (a) Vérifier que  $y(t) = \frac{y_0}{1 - y_0 \lambda t^r}$  est une solution.  
(b) La solution est-elle unique ? Pourquoi (pas) ?  
(c) Montrer que l'itération de Euler *rétrograde/implicite* est donnée par

$$\hat{y}(t+h) = \frac{1 - \sqrt{1 - 4hr\lambda(t+h)^{r-1}y(t)}}{2hr\lambda(t+h)^{r-1}}$$

- (d) Les graphiques ci-dessus représentent en tiret la fonction  $y(t)$  pour  $\lambda = -2$ ,  $r = 8$  et  $y_0 = 1$ . Les solides pointillés représentent les sorties des méthodes d'Euler progressive et rétrograde à un pas de  $h = 0.2$ .



Comment ce graphique illustre-t-il le bénéfice d'une méthode rétrograde ? Quelle figure correspond à la méthode rétrograde (gauche ou droite) ? Nommer le bénéfice.

**corrigé**

(a) Pour

$$y(t) = \frac{y_0}{1 - y_0 \lambda t^r},$$

on a

$$y'(t) = \frac{-y_0}{(1 - y_0 \lambda t^r)^2} \cdot (-y_0 \lambda r t^{r-1})$$

ce qui revient à dire que  $y'(t) = [y(t)]^2 \cdot \lambda r t^{r-1}$ .

(b) La solution est unique parce que la fonction  $f(t, y) = \lambda r t^{r-1} y^2$  est Lipschitz-continue dans toutes les valeurs de  $y$ .

(c) En général, la méthode de Euler rétrograde s'énonce

$$\hat{y}(t+h) = \hat{y}(t) + h f(t+h, \hat{y}(t+h))$$

Ici :

$$\hat{y}(t+h) = \hat{y}(t) + h r (t+h)^{r-1} [\hat{y}(t+h)]^2$$

Ceci est une équation quadratique pour l'inconnue  $\hat{y}(t+h)$ . La forme générale d'une telle équation  $ax^2 + bx + c$  a pour solution

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a},$$

ce qui devient

$$\hat{y}(t+h) = \frac{1 \pm \sqrt{1 - 4hr(t+h)^{r-1} \cdot \hat{y}(t)}}{2hr(t+h)^{r-1}}$$

(d) La méthode rétrograde est **absolument stable** pour  $h = 0, 2$ . Il s'agit du graphique à gauche. Pour un pas de  $h = 0, 2$ , la méthode progressive ne converge pas.

---

17. Considérer les trois expressions suivantes

$$\lim_{h \rightarrow 0} \frac{y(t+h) - y(t)}{h} = \Phi(t, y(t), t, y(t))$$

$$\lim_{h \rightarrow 0} \frac{\hat{y}^*(t+h) - y(t)}{h} = \Phi(t, y(t), t, y(t))$$

$$\frac{\hat{y}(t+h) - \hat{y}(t)}{h} = \Phi(t, \hat{y}(t), t+h, \hat{y}(t+h))$$

- L'une des trois représente l'algorithme à un pas pour la résolution d'une EDO. L'autre exprime la condition de consistance de cet algorithme alors que la troisième concerne le comportement de l'algorithme pour une sophistication infiniment précise et en partant d'une valeur exacte. Identifier les trois expressions.
- La combinaison de deux de ces expressions conduit tout de suite à l'expression de l'erreur de troncature locale. Lesquelles sont-elles ? Développer.

### corrigé

- L'algorithme à un pas pour la résolution d'une est donné par

$$\frac{\widehat{y}(t+h) - \widehat{y}(t)}{h} = \Phi(t, \widehat{y}(t), t+h, \widehat{y}(t+h))$$

La condition de consistance est donnée par

$$\lim_{h \rightarrow 0} \frac{y(t+h) - y(t)}{h} = \Phi(t, y(t), t, y(t))$$

Le comportement de l'algorithme pour une sophistication infiniment précise et en partant d'une valeur exacte est formalisé par

$$\lim_{h \rightarrow 0} \frac{\widehat{y}^*(t+h) - y(t)}{h} = \Phi(t, y(t), t, y(t))$$

- La combinaison de ces deux dernières expressions conduit à l'expression de la troncature locale. En effet, les seconds membres des deux expressions étant identiques, ils permettent d'établir une condition de consistance

$$\lim_{h \rightarrow 0} \frac{y(t+h) - y(t)}{h} = \lim_{h \rightarrow 0} \frac{\widehat{y}^*(t+h) - y(t)}{h} \Leftrightarrow \lim_{h \rightarrow 0} \frac{\widehat{y}^*(t+h) - y(t+h)}{h} = 0,$$

dans laquelle on peut prendre

$$\tau(t, h) = \frac{\widehat{y}^*(t+h) - y(t+h)}{h}$$

comme définition de l'erreur de troncature locale.

---

18. Considérer l'EDO  $y'(t) = 3\sqrt{y(t)} - t$  avec la condition initiale  $y(0) = 0$ .

- Vérifier que les fonctions  $y(t) = t^2$  et  $y(t) = t^2/4$  sont des solutions du problème aux valeurs initiales.
- Expliquer pourquoi ce problème aux valeurs initiales admet deux solutions.
- Ecrire la formule de Euler rétrograde pour la résolution numérique du problème

### corrigé

- On a  $y(t) = t^2$  et  $y'(t) = 2t$ , donc  $y'(t) - 3\sqrt{y(t)} = 2t - 3t = -t$ .  
Même chose pour  $y(t) = t^2/4$  et  $y'(t) = t/2$  où on retrouve  $y'(t) - 3\sqrt{y(t)} = t/2 - 3t/2 = -t$ .
- L'EDO s'écrit sous la forme  $y'(t) = f(t, y(t))$  où la fonction  $f(t, y) = 3\sqrt{y} - t$  ne satisfait à la condition Lipschitz pour  $y = 0$ . Effectivement, on a

$$\sqrt{y_1} - \sqrt{y_2} = \frac{y_1 - y_2}{\sqrt{y_1} + \sqrt{y_2}}$$

expression dans laquelle pour  $y_1$  et  $y_2$  autour de l'origine le dénominateur est arbitrairement petit. Par conséquent, l'écart  $\sqrt{y_1} - \sqrt{y_2}$  ne peut pas être borné par un écart  $y_1 - y_2$ .

- (c) La méthode de Euler rétrograde :  $\hat{y}_{n+1} = \hat{y}_n + h \left[ \sqrt{\hat{y}_{n+1}} - t_{n+1} \right]$  nous amène à une équation quadratique en  $\sqrt{\hat{y}_{n+1}}$ .
- 

## 5 Interpolation

---

1. En référant vers le théorème concerné, quels sont les deux facteurs qui déterminent la qualité d'une approximation interpolante ?

corrigé

---

2. Soient  $\vec{x} = [1 \ 3 \ 7]$  un vecteur d'abscisses et  $y_i = f(x_i) + \varepsilon_i$  et soient  $p(x)$  le polynôme interpolant, défini par les points  $(x_i, f(x_i))$  et  $\hat{p}(x)$  le polynôme interpolant perturbé, défini par les points  $(x_i, y_i)$ .

- (a) En arithmétique exacte, montrer (en utilisant l'expression du polynôme par Lagrange) que les perturbations du polynôme satisfont

$$|p(x) - \hat{p}(x)| < \sum_{i=0}^n |\varepsilon_i| |l_i(x)|$$

- (b) Utiliser la formule pour trouver une borne supérieure pour l'erreur  $|p(5) - \hat{p}(5)|$   
(c) Est-ce que cette borne est un exemple d'une analyse du conditionnement du problème de l'interpolation ou plutôt un exemple d'une analyse de stabilité de la méthode de Lagrange ?

corrigé

- (a) On peut écrire

$$p(x) = \sum_{i=0}^n f(x_i) l_i(x)$$
$$\hat{p}(x) = \sum_{i=0}^n y_i l_i(x)$$

- (b) et donc  $p(x) - \hat{p}(x) = \sum_{i=0}^n \varepsilon_i l_i(x)$

$$|p(5) - \hat{p}(5)| < \frac{1}{3} |\varepsilon_0| + |\varepsilon_1| + \frac{1}{3} |\varepsilon_2|$$

- (c) Il s'agit d'une analyse du conditionnement du problème. La méthode de Lagrange n'est utilisée que pour effectuer l'analyse, mais l'analyse n'est pas conduite sur l'expression de Lagrange elle-même.
-

3. Donner deux résultats qui confirment l'importance de la répartition des noeuds dans une interpolation polynomiale. Identifier dans les deux résultats les facteurs qui dépendent de la répartition? Quelle sont les propriétés numériques expliquées par chacun des résultats?

### corrigé

- (a) **L'erreur de l'interpolation** (erreur d'approximation - convergence)

$$E_n(x) = \frac{f^{(n+1)}(\xi)}{(n+1)!} \omega_{n+1}(x)$$

L'erreur de l'interpolation dépend de la répartition des noeuds à travers le polynôme nodal  $\omega_{n+1}(x)$ .

- (b) **L'erreur de propagation, le conditionnement**

$$\frac{\|\pi_n - \hat{\pi}_n\|_\infty}{\|\pi_n\|_\infty} \leq \Lambda_n \frac{\|\delta\|_\infty}{\|f\|_\infty} \text{ où } \Lambda_n = \left\| \sum_{i=0}^n |l_i(x)| \right\|_\infty$$

Le conditionnement dépend de la répartition des noeuds par les polynômes de Lagrange  $l_i(x)$ .

4. Soit  $\pi_2(x) = 2x^2 - 4x + 5$  un polynôme interpolant et  $\omega_3(x) = x^3 - 2x^2 - x + 2 = (x-2)(x-1)(x+1)$  le polynôme nodal associé.
- (a) Identifier les points  $x_0, x_1, x_2$ .
  - (b) Trouver le polynôme interpolant (sous forme  $a_n x^n + \dots + a_2 x^2 + a_1 x + a_0$ ) résultant de l'ajout du point  $x_3 = 0$ , avec  $f(x_3) = 3$ .
  - (c) Expliquer pourquoi les cas  $f(x_3) = 5$  et  $f(x_3) = 0$  ne nécessitent aucun calcul.

### corrigé

- (a)  $x_0 = 2, x_1 = 1, x_2 = -1$  (ou une permutation quelconque de ce triple)
- (b)  $\pi_3(x) = \pi_2(x) + \frac{f(x_3) - \pi_2(x_3)}{\omega_3(x_3)} \omega_3(x) = 2x^2 - 4x + 5 + \frac{3-5}{2} (x^3 - 2x^2 - x + 2) = -x^3 + 4x^2 - 3x + 3$
- (c) Dans le cas où  $f(x_3) = 5$ , on a  $\pi_2(x_3) = f(x_3)$ , et donc  $\pi_3(x) = \pi_2(x)$ . Le cas où  $f(x_3) = 0$  est résolu en posant  $\pi_3(x) = \pi_2(x)(x - x_3)$

5. Considérer le polynôme  $\pi(x) = x - 1$  qui est le résultat d'une interpolation polynômial dans les noeuds  $x_0 = 0, x_1 = 1, x_2 = 2$ .
- (a) Identifier  $y_i$  et  $l_i(x)$  dans la décomposition de Lagrange  $\pi(x) = \sum_{i=0}^n y_i l_i(x)$ .
  - (b) Quel sera le polynôme après avoir ajouté le noeud et l'observation  $x_3 = 3, y_3 = 0$ ? (Donner la réponse en minimisant les calculs)

- (c) En repartant de  $\pi(x)$ , quel sera le polynôme après avoir ajouté le noeud et l'observation  $x_3 = 3, y_3 = 1$  ?
- (d) En repartant de  $\pi(x)$ , quel sera le polynôme après avoir ajouté le noeud et l'observation  $x_3 = 3, y_3 = 2$  ?

**corrigé**

- (a) On a  $y_0 = -1, y_1 = 0, y_2 = 1$ , donc

$$\pi(x) = -\frac{(x-1)(x-2)}{(0-1)(0-2)} + \frac{(x-0)(x-1)}{2 \cdot 1} = -\frac{1}{2}(x-1)(x-2) + \frac{1}{2}x(x-1)$$

- (b)  $\pi_3(x) = \pi(x) + \frac{x(x-1)(x-2)}{3(3-1)(3-2)} \cdot (y_3 - \pi(3)) = (x-1) + \frac{x(x-1)(x-2)}{6}$
- (c)  $\pi_3(x) = \pi(x) + \frac{x(x-1)(x-2)}{3(3-1)(3-2)} \cdot (y_3 - \pi(3)) = (x-1) + \frac{x(x-1)(x-2)}{6} \cdot (1-2)$
- (d)  $\pi_3(x) = \pi(x)$

6. Considérer le polynôme nodal  $\omega_3(x) = x^3 - x$ . Quel est le polynôme  $\pi_2(x)$  interpolant la fonction  $f(x) = \exp(|x|)$  auquel s'accocie  $\omega_3(x)$  ?

**corrigé**

Les racines du polynôme nodal sont les noeuds de l'interpolation :  $x_0 = -1, x_1 = 0, x_2 = 1$ . Il faut donc interpoler les valeurs  $(-1, e), (0, 1), (1, e)$ . Par symétrie, le polynôme interpolant sera une parabole sans terme linéaire. On trouve donc  $\pi_2(x) = c_0 + c_2x^2$ , où  $c_0 = \pi_2(0) = f(0) = 1$  et  $\pi_2(1) = c_0 + c_2 \Rightarrow c_2 = \pi_2(1) - c_0 = f(1) - c_0 = e - 1$ .

7. Considérer  $\vec{x} = (1, 2, 3, 4, 5, 6)$  un vecteur de noeuds et  $\vec{y} = (4, 1, 3, 1, 1, 3)$  les observations d'une fonction  $y = f(x)$  pour les éléments de  $\vec{x}$ .
- (a) Trouver les valeurs de la spline interpolante de degré 1,  $s_1(x)$ , relative aux noeuds  $\vec{x}$ , pour les valeurs de l'abscisse  $x = 1.2$ ;  $x = 3.4$  et  $x = 5.6$  (c.-à-d.,  $x = 6/5$ ;  $x = 17/5$  et  $x = 28/5$ ).
- (b) Expliquer pourquoi la spline périodique et la spline naturelle sont les mêmes dans ce cas.

**corrigé**

- (a) Pour tout intervalle entre les noeuds, la fonction interpolante est une simple droite connectant les noeuds. Et donc, par exemple,  $s_1(1.2) = 0.8 \cdot s(1) + 0.2 \cdot s(2) = 3.2 + 0.2 = 3.4$ . On trouve ainsi :  $s_1(1.2) = 3.4, s_1(3.4) = 2.2, s_1(5.6) = 2.2$
- (b) (p.110 du syllabus) En général le nombre de coefficients polynomiaux est égal à  $(k+1)n$ ,  $n+1$  étant le nombre de noeuds. Le nombre de contraintes de continuité (c.-à-d., sur les dérivées) revient à  $k(n-1)$ , tandis que le nombre de contraintes d'interpolations revient à  $n+1$ , ce qui nous conduit à  $k-1$  paramètres à fixer. Puisque  $k = 1$ , il n'y a aucun paramètre à fixer.

8. Construire la spline quadratique périodique pour les noeuds 0 et 1 et les observations  $f(0) = 0$  et  $f(1) = 1$ . Pourquoi est-ce qu'il n'existe pas de définition pour la spline quadratique *naturelle* ?

### corrigé

- (a) La spline quadratique prend la forme d'un polynôme de degré deux entre chaque pair de noeuds. Etant donné juste deux noeuds, nous sommes à la recherche des trois coefficients  $a, b, c$ , dans l'expression polynomiale  $s(x) = ax^2 + bx + c$ . On impose les conditions d'interpolation :  $s(0) = f(0) = 0$  et  $s(1) = f(1) = 1$ , d'où viennent les équations  $c = 0$  et  $b + c = 1$ . La condition périodique revient à  $s'(0) = s'(1)$ , où  $s'(x) = 2ax + b$ , et donc  $b = 2a + b \Rightarrow a = 0$  et  $b = 1$ .
- (b) Après les conditions pour les dérivées et les interpolations, il nous reste  $k - 1$  conditions additionnelles à fixer, où  $k$  dénote l'ordre de la spline. Nous avons  $k = 2$ , donc, on dispose d'un seul degré de liberté. Ceci ne suffit pas pour imposer une condition naturelle aux deux extrémités de l'intervalle.

- 
9. Montrer que la spline quadratique, périodique, interpolant les noeuds et les valeurs  $(-1, 1), (0, 0), (1, 1)$  n'existe pas.

### corrigé

Posons  $s_1(x) = a_1x^2 + b_1x + c_1$  pour le polynôme quadratique sur l'intervalle  $[-1, 0]$  et  $s_2(x) = a_2x^2 + b_2x + c_2$  pour le polynôme quadratique sur l'intervalle  $[0, 1]$ . Les deux polynômes ont une racine dans l'origine, dont il s'ensuit immédiatement que  $c_1 = 0 = c_2$ . La continuité de la dérivée en  $x_1 = 0$  nous amène à la contrainte  $b_1 = b_2$ , car  $s'_1(x) = 2a_1x + b_1$ , donc  $s'_1(0) = b_1$ , tandis que  $s'_2(0) = b_2$ . Les interpolations :  $s_1(x_0) = s_1(-1) = 1 \Rightarrow a_1 - b_1 = 1$  ;  $s_2(x_2) = s_2(1) = 1 \Rightarrow a_2 + b_1 = 1$ . Les conditions périodiques :  $s'_1(-1) = s'_2(1) \Rightarrow -2a_1 + b_1 = 2a_2 + b_1 \Rightarrow a_1 = -a_2$ . En substituant dans les conditions d'interpolations, on retrouve  $a_1 - b_1 = 1$  et  $-a_1 + b_1 = 1$ , c'est-à-dire, deux conditions contradictoires.

- 
10. (a) Quel est l'avantage principal des splines, en comparaison à l'usage des polynômes, dans une interpolation ?  
(b) Donner deux exemples de fonctions qui se manifestent comme des vecteurs dans une base vectorielle.

### corrigé

- (a) L'interpolation par splines permet d'ajouter des noeuds sans devoir augmenter le degré du polynôme. Ceci évite les fluctuations/oscillations.
- (b) Les polynômes de Lagrange et les fonctions  $\phi_i(x)$  utilisées dans une régression linéaire.

- 
11. Etant donné le polynôme nodal  $\omega(x) = x^3 + x^2 - 4x - 4 = (x^2 - 4)(x + 1)$ , écrire les polynômes caractéristiques de Lagrange et le polynôme interpolant la fonction  $\sin(x)$ . (Il suffit de laisser le polynôme

dans la forme de Lagrange, pas besoin de réarranger les termes par puissance de  $x$ ).

**corrigé**

En écrivant  $\omega(x) = (x+2)(x+1)(x-2)$  on voit que les noeuds sont  $x_0 = -2$ ,  $x_1 = -1$  et  $x_2 = 2$ . Les polynômes de Lagrange seront

$$\begin{aligned} l_0(x) &= \frac{(x+1)(x-2)}{(-1)(-4)} = \frac{1}{4}(x^2 - x - 2) \\ l_1(x) &= \frac{(x+2)(x-2)}{1 \cdot (-3)} = \frac{1}{3}(4 - x^2) \\ l_2(x) &= \frac{(x+2)(x+1)}{4 \cdot 3} = \frac{1}{12}(x^2 + 3x + 2) \end{aligned}$$

Le polynôme interpolant pour la fonction  $\sin(x)$  dans ces noeuds sera alors

$$\pi(x) = l_0(x) \cdot \sin(-2) + l_1(x) \cdot \sin(-1) + l_2(x) \cdot \sin(2)$$

12. Donner pour chacun des polynômes suivants un argument pour lequel ce polynôme ne peut pas être un polynôme nodal dans le cadre d'une interpolation polynomiale sur  $\mathbb{R}$ , ou bien, s'il s'agit d'un polynôme nodal, donner les noeuds,

- (a)  $\omega_1(x) = (3x-1)(5x+2)(7x-3)$
- (b)  $\omega_2(x) = (x^2-2)(x+2)$
- (c)  $\omega_3(x) = (x^2+2)(x-2)$

**corrigé**

- (a)  $\omega_1(x)$  n'est pas un polynôme nodal parce qu'un polynôme nodal doit être normalisé tel que le coefficient de la puissance maximale vaille 1.
- (b)  $\omega_2(x)$  est un polynôme nodal. Les noeuds sont  $x_0 = -2$ ,  $x_1 = -\sqrt{2}$ ,  $x_2 = \sqrt{2}$ .
- (c)  $\omega_3(x)$  n'est pas un polynôme nodal parce qu'il a des racines imaginaires.

13. Etant donné le polynôme interpolant  $\pi_2(x) = x^2 + 3x + 1$ , dans les noeuds  $x_0 = 0$ ,  $x_1 = 1$ ,  $x_2 = 2$ , ajouter le noeud  $x_3 = 3$  avec la valeur  $f(x_3) = 0$ .  
Donner aussi les valeurs de  $f(x_i)$  pour  $i = 0, 1, 2$ .

**corrigé**

On a

$$\pi_3(x) = \pi_2(x) + q_3(x) = \pi_2(x) + a_3\omega_3(x) = \pi_2(x) + \frac{f(x_3) - \pi_2(x_3)}{\omega_3(x_3)}\omega_3(x)$$

$$\begin{aligned}
&= x^2 + 3x + 1 + \frac{3-19}{(3-0)(3-1)(3-2)}(x-0)(x-1)(x-2) \\
&= x^2 + 3x + 1 - \frac{16}{6}(x^3 - 3x^2 + 2x) = -\frac{8}{3}x^3 + 9x^2 - \frac{7}{3}x + 1
\end{aligned}$$

Les valeurs  $f(x_i)$  sont données par  $f(x_i) = \pi_2(x_i)$   $f(x_0) = 1, f(x_1) = 5, f(x_2) = 11$

---

14. Considérer le modèle  $\pi_2(x) = \varphi_0(x)c_0 + \varphi_1(x)c_1 + \varphi_2(x)c_2$  où  $\varphi_0(x) = 1$  et pour  $j = 1, 2 : \varphi_j(x) = l_j(x)$ , avec  $l_j(x)$  les polynômes de Lagrange définis sur la grille de noeuds  $x_j, j = 0, 1, 2, 3, 4$ .

- (a) Ecrire la matrice  $X$  du système surdéterminé  $X\vec{c} = \vec{y}$  pour l'approximation  $y_i$  par  $\pi(x_i)$  au sens des moindres carrés dans le mêmes noeuds  $x_i, i = 0, 1, 2, 3, 4$ .  
(b) Trouver les valeurs singulières de  $X$ .

**corrigé**

- (a) Puisque  $\varphi_j(x_i) = 0$  si  $i \neq j$  et  $\varphi_j(x_j) = 1$  pour les polynômes caractéristiques de Lagrange, la matrice du système surdéterminé devient :

$$X = \begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \\ 1 & 0 & 0 \end{bmatrix}$$

- (b) On a

$$X^T X = \begin{bmatrix} 5 & 1 & 1 \\ 1 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

Les valeurs propres :

$$\det(X^T X - \lambda I) = 0 \Leftrightarrow (5-\lambda)(1-\lambda)^2 - (1-\lambda) - (1-\lambda) = 0 \Leftrightarrow (1-\lambda)[(5-\lambda)(1-\lambda) - 1 - 1] = 0$$

On retrouve

$$\lambda \in \{1, 3 - \sqrt{6}, 3 + \sqrt{6}\} = \{1; 0, 5505; 5, 4495\}$$

Les valeurs singulières de  $X$  en sont les racines carrées :

$$\sigma \in \{1; 0, 7420; 2, 3344\}$$


---

## 6 Systèmes surdéterminés

---

1. Etant donné le système surdéterminé  $A\vec{x} = \vec{b}$ , où

$$A = \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \quad \vec{b} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix}$$

Trouver

- Le pseudo-inverse  $A^\dagger$
- Le vecteur  $\vec{x}$  avec la norme minimale parmi les vecteurs qui minimisent la norme du résidu  $\|A\vec{x} - \vec{b}\|_2$ .
- Un autre vecteur  $\vec{x}'$  qui minimise également la norme du résidu, sans avoir, lui-même, la norme minimale.

corrigé

•

$$A^\dagger = \begin{bmatrix} \frac{1}{2} & 0 & 0 & 0 & 0 \\ 0 & \frac{1}{3} & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

$$\bullet \vec{x} = A^\dagger \vec{b} = \begin{bmatrix} \frac{1}{2} \\ \frac{2}{3} \\ 0 \end{bmatrix}$$

- Il faut trouver un vecteur  $\vec{x}'$  tel que la norme du résidu soit la même que celle du résidu pour  $\vec{x}$ . On peut construire un vecteur avec le même résidu (donc avec la même norme – condition suffisante) en se réalisant que le troisième composant du vecteur  $\vec{x}'$  est toujours annihilé par la multiplication avec  $A$ . On peut donc

choisir  $\vec{x} = \begin{bmatrix} \frac{1}{2} \\ \frac{2}{3} \\ a \end{bmatrix}$  où  $a \in \mathbb{R}_0$ , par exemple  $a = 1$ .

---

2. Etant données les observations suivantes :

|       |   |         |       |          |        |
|-------|---|---------|-------|----------|--------|
| $x_i$ | 0 | $\pi/2$ | $\pi$ | $3\pi/2$ | $2\pi$ |
| $y_i$ | 3 | 5       | 1     | -1       | 3      |

trouvez les coefficients  $c_0, c_1, c_2$  de la fonction  $\Pi(x) = c_0 + c_1 \cos(x) + c_2 \sin(x)$ , en utilisant la méthode des moindres carrés. Quels sont les résidus ?

**corrigé**

Le système surdéterminé est :

$$\begin{bmatrix} 1 & 1 & 0 \\ 1 & 0 & 1 \\ 1 & -1 & 0 \\ 1 & 0 & -1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 3 \\ 5 \\ 1 \\ -1 \\ 3 \end{bmatrix}$$

Equation normale :

$$A^T A = \begin{bmatrix} 5 & 1 & 0 \\ 1 & 3 & 0 \\ 0 & 0 & 2 \end{bmatrix} \quad A^T b = \begin{bmatrix} 11 \\ 5 \\ 6 \end{bmatrix}$$

Solution :

$$\vec{c} = \begin{bmatrix} 2 \\ 1 \\ 3 \end{bmatrix}$$

Tous les résidus sont nuls.

- 
3. Soit  $A$  une matrice carrée. Montrer que  $\text{cond}_2(A^T A) = [\text{cond}_2(A)]^2$  (en utilisant la décomposition en valeurs singulières).

**corrigé**

Soit  $A = U\Sigma V^T$ , où  $V^T = V^{-1}$ , alors  $A^T A = V\Sigma^T U^T U \Sigma V^T = V\Sigma^T \Sigma V^T$ , ce qui prend la forme d'une décomposition en valeurs singulières pour la matrice  $A^T A$ . Le conditionnement est basé sur les valeurs singulières. On constate que les valeurs singulières de  $A^T A$  sont les valeurs carrées de  $A$ .

- 
4. Etant données les observations suivantes :
- |       |   |   |   |   |       |
|-------|---|---|---|---|-------|
| $x_i$ | 0 | 1 | 2 | 3 | 4     |
| $y_i$ | 1 | 0 | 1 | 0 | $y_4$ |
- trouvez les coefficients  $c_0, c_1, c_2$  de la fonction  $\hat{y}(x) = c_0\varphi_0(x) + c_1\varphi_1(x) + c_2\varphi_2(x)$ , en utilisant la méthode des moindres carrés, pour
- $$\begin{aligned} \varphi_0(x) &= 1 \\ \text{les fonctions de base : } \varphi_1(x) &= x(x-4) \\ \varphi_2(x) &= x(x-2)(x-4) \end{aligned}$$

**corrigé**

Le système surdéterminé est :

$$\begin{bmatrix} 1 & 0 & 0 \\ 1 & -3 & 3 \\ 1 & -4 & 0 \\ 1 & -3 & -3 \\ 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 0 \\ 1 \\ 0 \\ y_4 \end{bmatrix}$$

Equation normale :

$$A^T A = \begin{bmatrix} 5 & -10 & 0 \\ -10 & 34 & 0 \\ 0 & 0 & 18 \end{bmatrix} \quad A^T b = \begin{bmatrix} y_4 + 2 \\ -4 \\ 0 \end{bmatrix}$$

Solution :

$$\vec{c} = \begin{bmatrix} \begin{bmatrix} 5 & -10 \\ -10 & 34 \end{bmatrix}^{-1} \begin{bmatrix} y_4 + 2 \\ -4 \end{bmatrix} \\ 0 \end{bmatrix}$$

5. Etant données deux matrices  $A$  et  $B$ , écrites sous la forme

$$A = \begin{bmatrix} A_{1,1} & A_{1,2} \\ A_{2,1} & A_{2,2} \end{bmatrix}, \quad B = \begin{bmatrix} B_{1,1} & B_{1,2} \\ B_{2,1} & B_{2,2} \end{bmatrix},$$

où  $A_{ij}$  et  $B_{ij}$  sont des sousmatrices de tailles appropriées, alors on peut décomposer le produit matriciel sous la forme

$$AB = \begin{bmatrix} A_{1,1}B_{1,1} + A_{1,2}B_{2,1} & A_{1,1}B_{1,2} + A_{1,2}B_{2,2} \\ A_{2,1}B_{1,1} + A_{2,2}B_{2,1} & A_{2,1}B_{1,2} + A_{2,2}B_{2,2} \end{bmatrix}.$$

Soient  $A_{1,1}$  et  $A_{2,2}$  deux matrices carrées non-singulières de tailles  $n_1 \times n_1$  et  $n_2 \times n_2$ . Soit  $A$  une matrice rectangulaire de taille  $n \times m$ ,

où  $n > n_1 + n_2$  et  $m = n_1 + n_2$ . On définit  $A = \begin{bmatrix} A_{1,1} & O_{1,2} \\ O_{2,1} & A_{2,2} \\ O_{3,1} & O_{3,2} \end{bmatrix}$ . Les

matrices  $O_{i,j}$  ne contiennent que des zéros.

(a) En utilisant les propriétés définissantes (1)  $AA^\dagger A = A$ , (2)  $A^\dagger AA^\dagger = A^\dagger$ , (3)  $(AA^\dagger)^T = AA^\dagger$ , (4)  $(A^\dagger A)^T = A^\dagger A$ , on peut montrer

que le pseudo-inverse  $A^\dagger$  est égal à  $A^\dagger = \begin{bmatrix} A_{1,1}^{-1} & O_{2,1}^T & O_{3,1}^T \\ O_{1,2}^T & A_{2,2}^{-1} & O_{3,2}^T \end{bmatrix}$ .

Vérifier la première propriété,  $AA^\dagger A = A$ . 
$$A = \begin{bmatrix} 4 & 0 & 0 & 0 \\ 0 & 5 & 2 & 0 \\ 0 & 3 & 3 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

(c) Trouver le vecteur  $\vec{x}$  avec la norme minimale parmi les vecteurs qui minimisent la norme du résidu  $\|A\vec{x} - \vec{b}\|_2$ , où  $\vec{b} = \begin{bmatrix} 1 & 2 & 3 & 4 & 5 \end{bmatrix}^T$

(d) Trouver un autre vecteur  $\vec{x}'$  qui minimise également la norme du résidu, sans avoir, lui-même, la norme minimale.

corrigé

$$\begin{aligned} (a) \quad AA^\dagger A &= \begin{bmatrix} A_{1,1} & O_{1,2} \\ O_{2,1} & A_{2,2} \\ O_{3,1} & O_{3,2} \end{bmatrix} \begin{bmatrix} A_{1,1}^{-1} & O_{2,1}^T & O_{3,1}^T \\ O_{1,2}^T & A_{2,2}^{-1} & O_{3,2}^T \end{bmatrix} \begin{bmatrix} A_{1,1} & O_{1,2} \\ O_{2,1} & A_{2,2} \\ O_{3,1} & O_{3,2} \end{bmatrix} \\ &= \begin{bmatrix} A_{1,1} & O_{1,2} \\ O_{2,1} & A_{2,2} \\ O_{3,1} & O_{3,2} \end{bmatrix} \begin{bmatrix} I_{1,1} & O \\ O & I_{2,2} \end{bmatrix} = A \end{aligned}$$

(b) Considérer les blocks  $A_{1,1} = [4]$ ,  $A_{2,2} = \begin{bmatrix} 5 & 2 \\ 3 & 3 \end{bmatrix}$ .

$$\text{Alors } A_{2,2}^{-1} = \frac{1}{\det(A)} \begin{bmatrix} 3 & -3 \\ -2 & 5 \end{bmatrix}^T = \frac{1}{9} \begin{bmatrix} 3 & -2 \\ -3 & 5 \end{bmatrix}$$

$$\text{et donc } A^\dagger = \begin{bmatrix} \frac{1}{4} & 0 & 0 & 0 & 0 \\ 0 & \frac{1}{3} & -\frac{2}{9} & 0 & 0 \\ 0 & -\frac{1}{3} & \frac{5}{9} & 0 & 0 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

Faire attention à la taille de  $A^\dagger$ , qui est égale à celle de  $A^T$  !

(c)  $\vec{x} = A^\dagger \vec{b} = \begin{bmatrix} \frac{1}{4} & 0 & 1 & 0 \end{bmatrix}^T$

(d)  $\vec{x}' = \begin{bmatrix} \frac{1}{4} & 0 & 1 & a \end{bmatrix}^T$  où  $a \in \mathbb{R} \setminus \{0\}$ .

6. (a) Trouver les valeurs singulières de la matrice  $A = \begin{bmatrix} 0 & 1 \\ 2 & 0 \\ 0 & \sqrt{8} \end{bmatrix}$ , en

utilisant la décomposition spectrale de  $A^T A$ .

(b) Ecrire la matrice  $\Sigma$  et sa pseudo-inverse  $\Sigma^\dagger$  dans la décomposition en valeurs singulières  $A = U \Sigma V^T$ .

(c) Ecrire la matrice  $V$ .

(d) En pratique, le calcul de la décomposition en valeurs singulières ne se fait pas par la décomposition spectrale de  $A^T A$ . Pourquoi pas ?

**corrigé**

(a)  $A^T A = \begin{bmatrix} 4 & 0 \\ 0 & 9 \end{bmatrix}$ ,

Les valeurs propres sont  $\sigma_1^2 = 9$  et  $\sigma_2^2 = 4$ , donc  $\sigma_1 = 3$  et  $\sigma_2 = 2$ .

(b)  $\Sigma = \begin{bmatrix} 3 & 0 \\ 0 & 2 \\ 0 & 0 \end{bmatrix}$ ,

$$\Sigma^\dagger = \begin{bmatrix} 1/3 & 0 & 0 \\ 0 & 1/2 & 0 \end{bmatrix}$$

(c)  $V = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}$

(d) La calcul de  $A^T A$  a un effet négatif sur le conditionnement.

7. Soit la matrice

$$R = \begin{bmatrix} 1 & 2 \\ 0 & 3 \\ 0 & 0 \\ 0 & 0 \end{bmatrix}$$

- (a) Argumenter que la pseudo-inverse de  $R$  est donnée par

$$R^\dagger = \begin{bmatrix} 1 & -2/3 & 0 & 0 \\ 0 & 1/3 & 0 & 0 \end{bmatrix}$$

Vous pouvez vous baser sur  $RR^\dagger = \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$  et  $R^\dagger R = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$

- (b) Étant donné le vecteur  $\vec{b} = [1 \ 2 \ 3 \ 4]^T$ , trouver le vecteur  $\vec{x}$  avec la norme minimale parmi les vecteurs qui minimisent la norme du résidu  $\|R\vec{x} - \vec{b}\|_2$ .
- (c) Est-ce qu'il existe d'autres vecteurs  $\vec{x}'$  qui minimisent également la norme du résidu, sans avoir, lui-même, la norme minimale.
- (d) Soit donnée la matrice orthogonale

$$Q = \begin{bmatrix} \sqrt{2}/2 & 0 & 1/2 & 1/2 \\ -\sqrt{2}/2 & 0 & 1/2 & 1/2 \\ 0 & \sqrt{2}/2 & -1/2 & 1/2 \\ 0 & -\sqrt{2}/2 & -1/2 & 1/2 \end{bmatrix},$$

et  $A = QR$ .

Alors, trouver le vecteur  $\vec{u}$  avec la norme minimale parmi les vecteurs qui minimisent la norme du résidu  $\|A\vec{u} - \vec{b}\|_2$ .

### corrigé

- (a) Une stratégie possible est de vérifier les 4 propriétés définissantes. On a  $RR^\dagger R = R$ ,  $R^\dagger RR^\dagger = R^\dagger$ ,  $RR^\dagger$  et  $R^\dagger R$  sont symétriques.

(b)  $\vec{x} = R^\dagger \vec{b} = \begin{bmatrix} -1/3 \\ 2/3 \end{bmatrix}$

- (c) Il n'y a pas d'autres vecteurs qui minimisent la norme du résidu, car la matrice  $R$  a le rang maximal.

- (d) La norme

$$\|A\vec{u} - \vec{b}\|_2 = \|QR\vec{u} - \vec{b}\|_2 = \|Q^T(QR\vec{u} - \vec{b})\|_2 = \|R\vec{u} - Q^T\vec{b}\|_2$$

est minimisée par

$$\vec{u} = R^\dagger Q^T \vec{b} = \begin{bmatrix} 1 & -2/3 \\ 0 & 1/3 \end{bmatrix} \begin{bmatrix} -\sqrt{2}/2 \\ -\sqrt{2}/2 \end{bmatrix} = \begin{bmatrix} -\sqrt{2}/6 \\ -\sqrt{2}/6 \end{bmatrix} = \begin{bmatrix} -0,2357 \\ -0,2357 \end{bmatrix}$$

8. Considérer les observations suivantes

|       |   |   |   |
|-------|---|---|---|
| $x_i$ | 0 | 1 | 2 |
| $y_i$ | 1 | 2 | 3 |

- (a) Trouvez toutes les valeurs possibles des coefficients  $c_0$  et  $c_1$  de la fonction  $f_1(x) = c_0 + c_1 \cos(\pi x)$ , minimisant la somme des carrés des résidus.
- (b) Trouvez toutes les valeurs possibles des coefficients  $c_0$ ,  $c_1$  et  $c_2$  de la fonction  $f_2(x) = c_0 + c_1 \cos(\pi x) + c_2 \sin(\pi x)$ , minimisant la somme des carrés des résidus.

corrigé

(a) Le système surdéterminé est : 
$$\begin{bmatrix} 1 & 1 \\ 1 & -1 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

Equation normale :  $A^T A = \begin{bmatrix} 3 & 1 \\ 1 & 3 \end{bmatrix} \quad A^T b = \begin{bmatrix} 6 \\ 2 \end{bmatrix}$

Solution :  $\vec{c} = \begin{bmatrix} 2 \\ 0 \end{bmatrix}$

(b) Le système surdéterminé est : 
$$\begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 0 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} c_0 \\ c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

Equation normale :  $A^T A = \begin{bmatrix} 3 & 1 & 0 \\ 1 & 3 & 0 \\ 0 & 0 & 0 \end{bmatrix} \quad A^T b = \begin{bmatrix} 6 \\ 2 \\ 0 \end{bmatrix}$

Solution :  $\vec{c} = \begin{bmatrix} 2 \\ 0 \\ r \end{bmatrix}$ , où  $r \in \mathbb{R}$  quelconque.

9. (a) Considérer la matrice carrée

$$Q = \begin{bmatrix} \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ q_1 & q_2 & q_3 \end{bmatrix}$$

Ecrire les trois équations (deux linéaires, une non-linéaire) en  $q_1, q_2, q_3$ , exprimant l'orthogonalité de  $Q$ .

(b) Une solution des trois équations étant donnée par  $q_1 = -1/\sqrt{6} = q_3$ ,  $q_2 = 2/\sqrt{6}$ , trouver la solution au sens des moindres carrés du système surdéterminé  $A\vec{x} = \vec{b}$ , où

$$\vec{b} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \text{ et } A = QR \text{ où } R = \begin{bmatrix} 3 & 4 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$$

corrigé

(a)

$$\begin{cases} \frac{1}{\sqrt{3}}(q_1 + q_2 + q_3) = 0 \\ -\frac{1}{\sqrt{2}}q_1 + \frac{1}{\sqrt{2}}q_3 = 0 \\ q_1^2 + q_2^2 + q_3^2 = 1 \end{cases}$$

(b) En utilisant l'orthogonalité de  $Q$ , on a  $\|A\vec{x} - \vec{b}\|_2 = \|QR\vec{x} - \vec{b}\|_2$

$$\|\vec{b}\|_2 = \|Q^T(QR\vec{x} - \vec{b})\|_2 = \|R\vec{x} - Q^T\vec{b}\|_2 \text{ Ici, } Q^T\vec{b} = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \text{ La}$$

troisième composante de  $R\vec{x}$  s'annule, quelque soit la composante correspondante au second membre  $Q^T\vec{b}$ . La minimisation

n'a donc aucun effet au niveau de la troisième ligne. Il nous reste de résoudre les deux premières lignes du système, ce qui nous amène à

$$\vec{x}^* = \frac{1}{\sqrt{3}} \begin{bmatrix} 1 \\ -1/2 \end{bmatrix}$$

10. Pour cette question, il est interdit d'utiliser la calculatrice ! (Votre solution doit comprendre une stratégie qui n'a pas besoin d'une calculatrice)

- (a) Etant données les observations suivantes :

|       |   |   |   |   |   |
|-------|---|---|---|---|---|
| $x_i$ | 1 | 2 | 3 | 4 | 5 |
| $y_i$ | 1 | 2 | 3 | 4 | 5 |

trouvez les coefficients  $c_1, c_2, c_3$  de la fonction  $\hat{y}(x) = c_1\varphi_1(x) + c_2\varphi_2(x) + c_3\varphi_3(x)$ , en utilisant la méthode des moindres carrés, où les fonctions de base  $\varphi_i(x)$  sont les polynômes caractéristiques de Lagrange, définis par les noeuds  $x_i = i$  avec  $i \in \{1, 2, 3, 4, 5\}$  (on n'utilise que les trois premiers des cinq polynômes dans l'approximation)

- (b) Répétez l'exercice avec les mêmes observations pour les fonctions de base :

$$\begin{aligned} \varphi_1(x) &= 1 \\ \varphi_2(x) &= x - 2 \\ \varphi_3(x) &= x^2 + 4 \end{aligned}$$

### corrigé

- (a) Puisque  $\varphi_j(x_i) = 0$  si  $i \neq j$  et  $\varphi_j(x_j) = 1$  pour les polynômes caractéristiques de Lagrange, le système surdéterminé devient :

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ c_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \\ 4 \\ 5 \end{bmatrix}$$


Chaque colonne de la matrice correspond à l'une des trois fonctions de base (les trois polynômes caractéristiques de Lagrange retenus), alors que chaque ligne correspond à une observation ( $i = 1, 2, 3, 4, 5$ ).

La solution de l'équation normale est donnée par

$$\vec{c} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

- (b) Les données se trouvent sur la droite identité et peuvent être interpolées par une combinaison linéaire des fonctions de base en prenant  $c_1 = 2$  et  $c_2 = 1$  (et  $c_3 = 0$ ).

11. Considérer les fonctions  $\varphi_k(x) = x - (k - 1)$  pour  $x \in [k - 1, k]$ ,  $\varphi_k(x) = (k + 1) - x$  pour  $x \in [k, k + 1]$ , et  $\varphi_k(x) = 0$  ailleurs.



Ecrire le système surdéterminé pour approcher la fonction  $y(x) = x^2$  par  $y(x) \approx \sum_{k=1}^4 \varphi_k(x)c_k$  depuis les observations en  $x_i = i/2$  avec  $i = 1, 2, \dots, 9$  et avec  $k = 1, 2, 3, 4$ .

**corrigé**

$A\vec{c} = \vec{b}$ , ou bien

$$\begin{bmatrix} \frac{1}{2} & & & \\ 1 & & & \\ \frac{1}{2} & & & \\ & \frac{1}{2} & & \\ & 1 & & \\ & \frac{1}{2} & & \\ & & \frac{1}{2} & \\ & & 1 & \\ & & \frac{1}{2} & \\ & & & \frac{1}{2} \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \\ c_3 \\ c_4 \end{bmatrix} = \begin{bmatrix} \frac{1}{4} \\ 1 \\ \frac{9}{4} \\ 4 \\ \frac{25}{4} \\ 9 \\ \frac{49}{4} \\ 16 \\ \frac{81}{4} \end{bmatrix}$$

12. La réponse Matlab aux commandes

`A = [1 2 3; 2 4 6]'; b = [7 3 5]'; z = pinv(A)*b`

est donnée par

`z =`  
`0.4000`  
`0.8000`

Ecrire l'équation de l'ensemble des vecteurs  $\vec{x} = (x_1, x_2)$  minimisant  $\|A\vec{x} - \vec{b}\|_2$ .

**corrigé**

Vu que  $\text{rang}(A) = 1$ , on sait que l'ensemble des points minimisant  $\|A\vec{x} - \vec{b}\|_2$  contiendra tous les vecteurs  $\vec{x}$  pour lesquels  $(\vec{x} - \vec{z})^T \vec{z} = 0$ . Donc on retrouve la droite  $(x_1 - z_1)z_1 + (x_2 - z_2)z_2 = 0 \Leftrightarrow x_1 z_1 + x_2 z_2 = z_1^2 + z_2^2$ . Avec  $z_1 = 0, 4$  et  $z_2 = 0, 8$ , on a  $x_1 + 2x_2 = 2$ .

13. Pour une matrice rectangulaire  $A \in \mathbb{R}^{n \times m}$  (avec  $n > m$ ) de rang égal à 1, expliquer que toute solution  $\vec{z}$  de l'équation  $A^T A \vec{z} = A^T \vec{b}$  satisfait

à

$$\sum_{i=1}^m (z_i - z_i^*) z_i^* = 0,$$

où le vecteur  $\vec{z}^*$  est donné par  $\vec{z}^* = A^\dagger \vec{b}$

### corrigé

L'équation énoncée est l'équation normale associée au problème surdéterminé  $A\vec{z} = \vec{b}$ . Puisque le  $\text{rang}(A) = 1$ , on sait que l'ensemble des solutions aux moindres carrés est donné par un hyperplan (droite, plan,...) tangent au sphère qui passe par  $\vec{z}^*$ . Cet hyperplan contient tous les points  $\vec{z}$  pour lesquels  $(\vec{z} - \vec{z}^*) \perp \vec{z}^*$ , c'est-à-dire,  $(\vec{z} - \vec{z}^*)^T \vec{z}^* = 0$ , ce qui revient à l'expression énoncée.

---

14. La matrice  $A \in \mathbb{R}^{n \times m}$  est composée des  $m$  premières colonnes de la matrice orthogonale  $Q$ .

- (a) Montrer que  $U = Q$  peut servir comme matrice orthogonale dans la décomposition en valeurs singulières de  $A = U\Sigma V^T$ . Quelles seront les matrices  $\Sigma$  et  $V$  ?
- (b) Quel est le rang de  $A$  ?
- (c) Montrer que  $A^\dagger = A^T$  (en argumentant que  $\Sigma^\dagger = \Sigma^T$ ).

### corrigé

- (a)  $A = Q\Sigma V^T \Leftrightarrow \Sigma V^T = Q^T A$ . Sachant que  $Q^T Q = I_n$  et  $Q = [AB]$  où  $B$  contient les colonnes  $m+1$  à  $n$  de  $Q$ , on a  $[Q^T A Q^T B] = I$ , donc  $\Sigma$  contient les  $m$  premières colonnes de  $I_n$  si on prend  $V = I_m$ .
- (b) Le rang de  $A$  est égal à  $m$ , parce que les colonnes de  $A$  sont des colonnes de  $Q$ , donc elles sont mutuellement indépendantes (même orthogonales).
- (c) Ou bien on passe par la décomposition en valeurs singulières. Puisque  $\Sigma$  ne contient que des colonnes de  $I_n$ , on sait que  $\Sigma^\dagger = \Sigma^T$ .

$$A^\dagger = V\Sigma^\dagger U^T = I_m \Sigma^T Q^T = A^T$$

Ou bien on vérifie les quatre propriétés définissantes, en se basant sur le fait que les colonnes de  $A$  sont orthogonales l'une à l'autre.

---

15. (a) Les commandes Matlab  $A = [1 \ 2 \ 3; 4 \ 5 \ 6; 7 \ 8 \ 0]$ ;  $\text{svd}(A)$  ont pour résultat

```
ans =
 13.2015
 5.4388
 0.3760
```

(b) Les commandes  $B = [1 \ 2 \ 3; 4 \ 5 \ 6; 7 \ 8 \ 9]$ ;  $\text{svd}(B)$  ont pour résultat

```
ans =
 16.8481
 1.0684
 0.0000
```

Utiliser ces deux résultats pour associer les commandes `inv(A)-A\eye(3)` et `inv(B)-B\eye(3)` à l'une des sorties ci-dessous

```
ans1 = 1.0e-15 * ans2 =
 0.2220 -0.1110 0.0833 -1.0000 1.0000 -2.0000
 0 0 -0.0555 0 0 2.0000
 0 0 0 0 0 -0.5000
```

Donc, `ans1` vient-il de A ou de B ? Expliquer.

### corrigé

`ans1` vient de A et `ans2` vient de B, parce que B a une valeur singulière de zéro, ce qui veut dire que  $\kappa(B) = 16.8481/0.0000 = \infty$ , donc B est singulière. Par conséquent le calcul de l'inverse donne lieu à des résultats non cohérents. `inv(B)` et `B\eye(3)` sont en théorie deux manières équivalentes pour calculer l'inverse, mais en réalité, les erreurs numériques peuvent entraîner deux résultats totalement différents quand la matrice est mal conditionnée, voire singulière.

### 16. Considérer les commandes Matlab suivantes

- (a) `A = [1 0 0; 2 1 0; 4 0 1; 0 0 0]; B = pinv(A)`
- (b) `A = [1 0 0 8; 2 1 1 0; 4 0 1 1]; B = pinv(A)`
- (c) `A = [1 0 0; 2 1 0; 4 0 1; 8 0 0]; B = pinv(A)`

Les réponses de Matlab, en ordre arbitraire, sont

|     |         |         |         |         |         |         |         |
|-----|---------|---------|---------|---------|---------|---------|---------|
|     | -0.0360 | -0.0959 | 0.2942  | 0.0154  | -0.0000 | 0.0000  | 0.1231  |
| (a) | 0.0576  | 0.8201  | -0.4484 | -0.0308 | 1.0000  | 0.0000  | -0.2462 |
|     | 0.0144  | 0.3717  | -0.1399 | -0.0615 | -0.0000 | 1.0000  | -0.4923 |
|     | 0.1295  | 0.0120  | -0.0368 | -----   | 1.0000  | -0.0000 | 0.0000  |
|     |         |         |         |         | -2.0000 | 1.0000  | -0.0000 |
|     |         |         |         |         | -4.0000 | 0.0000  | 1.0000  |
|     |         |         |         |         |         |         | 0       |
|     |         |         |         |         |         |         | 0       |
|     |         |         |         |         |         |         | 0       |

Associer les réponses aux commandes et expliquer sans se baser sur des calculs.

### corrigé

La réponse (a) correspond à la commande (b), car cette réponse est la seule de taille  $4 \times 3$  alors que la taille de la matrice A dans la commande (b) est de  $3 \times 4$ , et il faut que la taille de  $A^\dagger$  soit celle de  $A^T$ .

La réponse (c) correspond à la commande (a), car la matrice A contient une sous-matrice de taille  $3 \times 3$  qui est la forme d'une opération dans la factorisation LU. Cette opération a pour effet la soustraction ou l'addition d'un multiple de la première ligne aux autres. Son inverse est donnée par la même opération avec les signes opposés. A cette

sous-matrice s'ajoute une ligne de zéros, qui restent zéros dans la pseudo-inverse.

17. Considérer le modèle  $\pi_2(x) = \varphi_0(x)c_0 + \varphi_1(x)c_1 + \varphi_2(x)c_2$  où  $\varphi_0(x) = 1$ ,  $\varphi_1(x) = x^2 - 1$ , et  $\varphi_2(x) = (5x^4 - x^6)/4$ , pour les observations

|       |    |    |   |   |   |
|-------|----|----|---|---|---|
| $x_i$ | -2 | -1 | 0 | 1 | 2 |
| $y_i$ | 1  | 1  | 1 | 1 | 1 |

- (a) Ecrire la matrice  $X$  du système surdéterminé  $X\vec{c} = \vec{y}$  pour l'approximation  $y_i$  par  $\pi(x_i)$  au sens des moindres carrés.  
 (b) Sachant que la commande Matlab `eig(X'*X)` a pour résultat

```
ans =
 0.0000
 3.8803
 54.1197
```

trouver les valeurs singulières de  $X$ .

**corrigé**

$$(a) X = \begin{bmatrix} \varphi_0(x_0) & \varphi_1(x_0) & \varphi_2(x_0) \\ \varphi_0(x_1) & \varphi_1(x_1) & \varphi_2(x_1) \\ \varphi_0(x_2) & \varphi_1(x_2) & \varphi_2(x_2) \\ \varphi_0(x_3) & \varphi_1(x_3) & \varphi_2(x_3) \\ \varphi_0(x_4) & \varphi_1(x_4) & \varphi_2(x_4) \end{bmatrix} = \begin{bmatrix} 1 & 3 & 4 \\ 1 & 0 & 1 \\ 1 & -1 & 0 \\ 1 & 0 & 1 \\ 1 & 3 & 4 \end{bmatrix}$$

- (b) Les valeurs singulières de  $X$  sont données par les racines carrées des valeurs propres de  $X^T X$ , donc, on a  $(\sigma_1; \sigma_2; \sigma_3) = (\sqrt{54,1197}; \sqrt{3,8803}; 0) = (7,3566; 1,9698; 0)$

## 7 Systèmes non-linéaires

1. Considérons l'itération de point fixe  $x^{(k+1)} = \phi(x^{(k)})$ , où

$$\phi(x) = \frac{2}{1 + e^x}.$$

- (a) Montrer que l'itération converge pour chaque valeur de départ.  
 (b) Définir une fonction  $f(x)$  telle que l'itération ci-dessus puisse être utilisée pour trouver la racine de  $f(x) = 0$ .  
 (c) Trouver une autre fonction  $\phi_1(x) \neq \phi(x)$  telle que la racine de  $f(x) = 0$  soit le point fixe de  $\phi_1(x)$ .

**corrigé**

- (a) Pour montrer la convergence globale, il faut que la dérivée  $|\phi'(x)|$  (en valeur absolue) soit majorée par une constante  $K < 1$  pour toutes les valeurs de  $x$  concernées (ici : toutes les valeurs réelles).

Calculons cette dérivée.  $\phi'(x) = \frac{-2e^x}{(1+e^x)^2}$ . Cette dérivée est bornée par  $-1/2 \leq \phi'(x) \leq 0$ , car, en substituant  $u = e^x$ , on peut considérer la fonction  $-2u/(1+u)^2$  qui n'est jamais positive et qui a son minimum dans l'origine où elle prend la valeur de  $-1/2$ .

- (b)  $\phi(x) = x \Leftrightarrow \frac{2}{1+e^x} = x \Leftrightarrow 2 - xe^x - x = 0$   
(c) (Par exemple)  $2 - xe^x - x = 0 \Leftrightarrow x = 2 - xe^x$

2. Chercher les racines de la fonction  $f(x) = -3\sin(x) - \ln(1+x)$  :

- (a) Montrer que  $x_0 = 0$  est une racine.  
(b) Est-ce que le nombre de racines positives est pair ou impair (la racine  $x_0 = 0$  exclue), étant donné qu'il existe au moins une racine positive, et qu'il n'y a pas de racines multiples ? Un graphique de la situation peut être utilisé pour illustrer votre argument.  
(c) Voici une méthode de point fixe :  $\phi(x) = x + \alpha [\exp(-3\sin(x)) - 1 - x]$   
i. Vérifier que pour toute valeur de  $\alpha$ , les points fixes de  $\phi(x)$  correspondent aux racines de  $f(x)$ .  
ii. Trouver la valeur de  $\alpha$  telle que  $\phi'(0) = 0$ .  
iii. Quelque soit le point initial, les itérations ne convergent pas vers la plus petite racine au delà de 0 avec cette valeur de  $\alpha$ . Expliquer pourquoi, en se basant sur l'allure de  $\phi(x)$  autour de la racine  $x_0$  (et donc, sans calculer la racine  $x_1$ ).  
(d) i. Calculer 8 étapes  $x_1, \dots, x_8$  de l'itération pour  $x_0 = 3$  et  $\alpha = -1/8$ .  
ii. Quels sont le résidu et l'incrément lors de la huitième étape  $x_8$  ?  
iii. Pour confirmer la conjecture de convergence vers une racine tout proche de  $x_8$ , on peut calculer  $\phi'(x_8)$ . Expliquer.  
(e) Qu'est-ce que la fonction d'itération pour la méthode de Newton-Raphson dans ce cas ?

### corrigé

- (a)  
(b) Le nombre est pair parce que  $\lim_{x \rightarrow \infty} f(x) = -\infty < 0$ , tandis que  $\lim_{x \rightarrow 0+} f'(x) < 0$ .  
(c) i.  
ii.  $\phi'(x) = 1 + \alpha [\exp(-3\sin(x))(-3\cos(x)) - 1]$   
 $\phi'(0) = 1 - 4\alpha$   
 $\phi'(0) = 0 \Leftrightarrow \alpha = 1/4$   
iii. La fonction  $\phi(x)$ , tout en étant continue, ne peut attraper la droite  $y = x$  en  $x_1$  qu'avec une dérivée supérieure à 1, excluant ainsi la convergence de la méthode du point fixe.

(d) i.

| $x_0$  | $x_1$  | $x_2$  | $x_3$  | $x_4$  | $x_5$  | $x_6$  | $x_7$  | $x_8$  |
|--------|--------|--------|--------|--------|--------|--------|--------|--------|
| 3.0000 | 3.4181 | 3.6868 | 3.6803 | 3.6828 | 3.6818 | 3.6822 | 3.6821 | 3.6821 |

- ii. résidu :  $r_8 = f(x_8) = 3.4336 \cdot 10^{-5}$   
incrément  $x_8 - x_7 = 5.2822 \cdot 10^{-5}$
- iii. La dérivé  $\phi'(x_1)$  détermine la convergence locale : condition  $|\phi'(x_1)| < 1$
- (e)  $\phi(x) = x - \frac{f(x)}{f'(x)} = x - \frac{3 \sin(x) + \ln(1+x)}{3 \cos(x) + 1/(1+x)}$

3. Quels sont les deux arguments qui motivent la recherche d'une fonction  $\phi(x)$  telle que  $|\phi'(x)|$  autour de la racine  $x^*$  soit la plus petite possible ? (parmi les fonctions d'itération  $x^{(k+1)} = \phi(x^{(k)})$ , dans un algorithme de point fixe.)

**corrigé**

- (a) Quand  $\phi'(x) = 0$ , la convergence de l'erreur est d'ordre plus grande que 1
- (b) Quand  $\phi'(x) = 0$ , l'erreur peut être estimée par l'incrément de manière quasi parfaite.

Donc, l'erreur est très petite et en plus facile à estimer.

4. Considérer l'équation non-linéaire  $x = \cos(x)$  et 4 étapes d'un algorithme itératif

```
x0 = 0;
x1 = cos(x0);
x2 = cos(x1);
x3 = cos(x2);
x4 = cos(x3);
```

Que peut-on dire sur


- (a) la consistance de l'algorithme ?
- (b) la convergence (locale, globale, ou divergence) ?
- (c) la forme de la convergence ou divergence : spirale ou escalier ?
- (d) le conditionnement : chercher une borne supérieure pour l'erreur de propagation à l'étape 4 (voir chapitre 2) en utilisant l'expression  $\kappa_n(d_n) \approx |F'_n(d_n)|/|F_n(d_n)|$  et la formule de l'erreur de propagation  $e_4 = \kappa_3(x_3)\kappa_2(x_2)\kappa_1(x_1)\kappa_0(x_0)\rho$

**corrigé**

- (a) L'algorithme est fortement consistant.
- (b) La convergence est globale pour tout  $x \in \mathbb{R}$ , car après une itération,  $x_1 = \phi(x_0)$  se trouve dans l'intervalle  $[-1, 1]$  et sur cet intervalle, il existe une  $K < 1$  telle que  $|\phi'(x)| = |\sin(x)| \leq K$ .
- (c) La convergence prend la forme d'une spirale, car  $\phi'(x) < 0$  autour de la solution.
- (d)  $|e_4| \leq |\kappa_3(x_3)| \cdot |\kappa_2(x_2)| \cdot |\kappa_1(x_1)| \cdot |\kappa_0(x_0)| \cdot \rho$  où  $\kappa_i(x_i) = |\phi'(x_i)| |x_i| / |\phi(x_i)| = |x_i \tan(x_i)|$

5. Considérer l'équation non-linéaire  $x + \ln(|x|) = 0$  et la fonction d'itération  $\phi(x) = -\ln(|x|)$ .

- (a) Argumenter que l'intervalle  $]1/e, 1[$  contient une racine de  $f(x)$ , en utilisant la définition de  $e = \exp(1)$ , un nombre strictement plus grand que 1.
- (b) Argumenter que l'itération  $x^{(i+1)} = \phi(x^{(i)})$  ne peut pas converger vers une racine dans l'intervalle  $]1/e, 1[$ .
- (c) Le graphique ci-dessous trace le point d'itération  $x^{(i)}$  en fonction de l'étape  $i$ , ainsi que la solution  $x^*$  (en ligne grise et constante).



On constate que l'itération, bien qu'elle ne soit pas convergente, a la tendance de retourner vers des valeurs autour de la solution  $x^*$  de l'équation non-linéaire, dans une sorte de fluctuation irrégulière.

Expliquer ce comportement de l'itération.

- (d) Montrer que toute fonction d'itération  $\phi_c(x) = cx + (c-1)\ln(|x|)$  (pour  $c \neq 1$ ) donne lieu à une itération consistante.
- (e) (*question bonus ; 2 points à gagner, rien à perdre*) Trouver les valeurs de  $c \in [0, 1]$  telles que l'itération associée à  $\phi_c(x)$  converge sur l'intervalle  $]1/e, 1[$ .


### corrigé

- (a) (1) La fonction  $f(x)$  est continue. (2)  $f(1/e) = 1/e + \ln(1/e) < 1 - \ln(e) = 1 - 1 = 0$ . (3)  $f(1) = 1 + \ln(1) = 1 > 0$ . (3) Une fonction continue sur l'intervalle  $[a, b]$  où  $f(a)f(b) < 0$  prend un zéro sur l'intervalle  $[a, b]$ . (Théorème 7.1 du syllabus)
- (b) La fonction  $\phi(x)$  a pour dérivée la fonction  $1/x$ . Cette fonction prend des valeurs (absolues) supérieures à 1, dans tout l'intervalle concerné.
- (c) Deux explications possibles : (1) Pour les valeurs supérieures à 1, la fonction  $\phi(x)$  satisfait  $|\phi(x)| < |x|$ , et donc, tant que  $|x^{(i)}| \geq 1$ , on constate  $|x^{(i+1)}| < |x^{(i)}|$ . (2) ou bien : pour les valeurs supérieures à 1, la dérivée  $\phi'(x)$  a une valeur absolue inférieure à 1, ce qui donne lieu à une convergence momentanée.
- (d)  $cx + (c-1)\ln(|x|) = x \Leftrightarrow (c-1)(x + \ln(|x|)) = 0 \Leftrightarrow x + \ln(|x|) = 0$
- (e) Il faut imposer que la dérivée  $\phi'_c(x)$  soit bornée par 1. On re-

trouve (sachant que  $c - 1$  est négative !!)  $|\phi'_c(x)| \leq 1 \Leftrightarrow |c + (c - 1)/x| \leq 1 \Leftrightarrow -1 \leq c + (c - 1)/x \leq 1 \Leftrightarrow -1 - c \leq (c - 1)/x \leq 1 - c \Leftrightarrow -(1 + c)/(c - 1) \geq 1/x \geq (1 - c)/(c - 1) \Leftrightarrow -1 \leq 1/x \leq (1 + c)/(1 - c) \Leftrightarrow x \leq -1$  ou bien  $x \geq (1 - c)/(1 + c)$ . L'intervalle  $[(1 - c)/(1 + c), \infty]$  couvre l'intervalle  $]1/e, 1[$  si et seulement si  $(1 - c)/(1 + c) < 1/e \Leftrightarrow c > (e - 1)/(e + 1)$

6. Considérer l'équation  $x \cos(x) - 1 = 0$ .

- (a) Montrer que la fonction d'itération  $\phi(x) = \frac{1 - x^2 \sin(x)}{\cos(x) - x \sin(x)}$  sort du développement de la méthode de Newton
- (b) Le graphique ci-dessous trace la fonction  $\phi(x)$ , ainsi que la fonction  $y(x) = x$  (en ligne grise). Quelle caractéristique de la fonction  $\phi(x)$  confirme le résultat que la méthode de Newton a une convergence d'ordre deux ?




corrigé

- (a) Pour la fonction  $f(x) = x \cos(x) - 1$ , la fonction d'itération de la méthode de Newton devient

$$\phi(x) = x - \frac{f(x)}{f'(x)} = x - \frac{x \cos(x) - 1}{\cos(x) - x \sin(x)}$$

- (b) La dérivée  $\phi'(x)$  s'annule dans les points fixes de  $\phi(x)$ .



7.

Considérer la fonction  $f(x) = c - \cos(\pi(3x^2 - 2x^3))$  sur l'intervalle  $[a, b] = [0, 1]$ , pour  $c$  quelconque. L'objectif est de trouver la racine  $x^* \in [0, 1]$ . Le graphique illustre la méthode de la corde sur  $[a, b]$ , traçant la fonction d'itération  $\phi(x)$  ainsi que les valeurs itérées.

- (a) Donner l'expression de  $\phi(x)$ .
- (b) Donner la valeur initiale  $x_0$ .

- (c) Comment le graphique illustre-t-il la consistance de la méthode ?
- (d) Est-ce que la méthode converge ?
- (e) Quelle conclusion peut-on tirer de la convergence (ou l'absence de convergence) au niveau de la dérivée  $f'(x^*)$  (PAS la dérivée  $\phi'(x^*)$ ) ? (Notamment quelle(s) borne(s) supérieure(s) et/ou inférieure(s) peut-on déduire)
- (f) Est-ce que la convergence ou l'absence de convergence est un phénomène global sur  $[a, b]$  ?
- (g) (*question bonus ; 1 point à gagner, rien à perdre*) Prouver que  $0 \leq f'(x) \leq M = 3\pi/2$  pour toute valeur de  $x \in [a, b] = [0, 1]$ .
- (h) Etant donné la valeur de  $M$ , et soit  $0 \leq q \leq 1/M$ . Tout en tenant compte de la positivité de  $f'(x)$ , prouver que  $\phi(x) = x - qf(x)$  est une fonction d'itération telle que les itérations  $x^{(i+1)} = \phi(x^{(i)})$  convergent vers  $x^*$  sous forme d'un escalier.

### corrigé

- (a)  $\phi(x) = x - \frac{b-a}{f(b)-f(a)}f(x) = x - \frac{1}{-\cos(\pi)+\cos(0)}[c - \cos(\pi(3x^2 - 2x^3))] = x - [c - \cos(\pi(3x^2 - 2x^3))]/2$
- (b)  $x_0 = a = 0$
- (c) La ligne en tiret verticale indique que le point fixe de  $\phi(x)$  et la racine de  $f(x)$  coïncident.
- (d) Non, la racine n'est jamais atteinte.
- (e) Un algorithme de la corde converge localement si et seulement si  $0 < f'(x^*) < 2$ . Puisque  $f'(x^*) > 0$ , il s'ensuit que  $f'(x^*) \geq 2$ .
- (f) La divergence n'est que locale.
- (g)  $f'(x) = \sin(\pi(3x^2 - 2x^3))\pi(6x - 6x^2)$ , donc, pour  $x \in [0, 1]$ ,  $0 \leq f'(x) \leq 1 \cdot \pi \cdot 6x(1-x) \leq \pi 6 \cdot \frac{1}{4} = 3\pi/2$
- (h) Les itérations convergent sous forme d'un escalier si et seulement si  $0 \leq \phi'(x) < 1$ . Puisque  $\phi'(x) = 1 - qf'(x)$ , on déduit que

$$0 \leq f'(x) \leq M \Leftrightarrow 1 - qM \leq 1 - qf'(x) \leq 1 - q \cdot 0 \Leftrightarrow 1 - qM \leq \phi'(x) \leq 1.$$

En choisissant  $0 \leq q \leq 1/M$ , on rassure que  $0 \leq \phi'(x) \leq 1$


8. Considérer la fonction  $f(x) = xe^{-x^2/2} - c$ , où  $c = 0,2 = 1/5$ , sur l'intervalle  $[0, \infty[$ . L'objectif est de trouver toutes les racines  $x^* \in [0, 1]$ .
- (a) Sachant que la dérivée  $f'(x) = (1 - x^2)e^{-x^2/2}$  n'a qu'une seule racine sur  $[0, \infty[$ , montrer que le nombre de racines est égale à deux.
- (b) Montrer que l'itération  $x^{(i+1)} = \phi(x^{(i)})$  avec  $\phi(x) = ce^{x^2/2}$  est consistante.
- (c) En utilisant
- la continuité de  $\phi(x)$
  - la positivité de  $\phi'(x)$ , ainsi que son allure monotonement croissante

argumenter que l'itération converge autour de la racine la plus petite et diverge autour de la racine plus grande.

- (d) Trouver une fonction d'itération qui converge vers la racine la plus grande. (Plusieurs pistes étant possibles, une piste pourrait se baser sur le fait que pour  $x \geq 1$ ,  $|f'(x)| \leq |f'(\sqrt{3})|$ .)

### corrigé

- (a)  $f'(x) = 0 \Leftrightarrow x = 1$  et  $f(1) = e^{-1/2} - c > 0$ . De l'autre côté, on a  $f(0) = -c < 0$  ainsi que  $\lim_{x \rightarrow \infty} f(x) = -c < 0$ . La continuité de  $f(x)$  permet de conclure l'existence de deux racines, dont l'une se trouve dans l'intervalle  $[0, 1]$ , alors que l'autre se situe au delà de la valeur 1.
- (b)  $\phi(x) = x \Leftrightarrow ce^{x^2/2} = x \Leftrightarrow xe^{-x^2/2} = c \Leftrightarrow f(x) = 0$
- (c) L'itération converge localement si  $|\phi'(x)| < 1$  dans voisinage du point fixe de  $\phi(x)$ . La dérivée, étant positive, est une fonction croissante, donc, si  $\phi'(x)$  était inférieure à 1 dans le second point fixe, elle le serait nécessairement aussi dans le premier point. Puisqu'il est impossible qu'une courbe continue croise la droite d'identité (donc  $\phi(x) = x$ ) sous une pente inférieure à une ( $\phi'(x) < 1$ ) deux fois successives, il s'ensuit que  $|\phi'(x)| > 1$  dans le second point fixe. De l'autre côté, il est également impossible qu'une fonction montante  $\phi(x)$  a deux intersections successives avec la droite d'identité sous une pente plus forte que 1.
- (d) On est à la recherche d'une fonction  $\phi(x)$  telle que  $|\phi'(x)|$  soit inférieure à 1. Par exemple, on peut proposer une  $\phi(x)$  sous la forme  $\phi(x) = x + Af(x)$  (voir slides). Alors  $\phi'(x) = 1 + Af'(x)$ . Puisque  $f'(x) \geq f'(\sqrt{3}) = (1 - 3)e^{-3/2} = -2e^{-3/2} = -0.446$ , on peut prendre  $A = 1$ .



Considérer l'équation non-linéaire  $x = 2 \cos(x^2)$  sur l'intervalle  $[-2, 2]$ . L'objectif est de trouver la racine  $x^* \in [-2, 2]$ . Le graphique illustre la méthode de la corde sur  $[-2, 2]$ , traçant la fonction d'itération  $\phi(x)$ .

- (a) Donner les expressions de  $f(x)$  et de  $\phi(x)$ .
- (b) En se basant sur le graphique, comment peut-on conclure que la méthode de la corde ne convergera pas pour ce problème ?
- (c) Donner la formule qui exprime la phrase suivante : "la méthode de la corde ne convergera pas quand la pente locale autour de la racine est relativement raide".
- (d) Expliquer la phrase suivante : "Trouver la racine d'une fonction

à pente raide est un problème facile du point de vue numérique (l'échec de la méthode de la corde pour cette classe de problèmes est donc un point faible)".

- (e) Montrer que toute fonction d'itération  $\phi_c(x) = cx + (1 - c)\phi(x)$  (pour  $c \neq 1$ ) donne lieu à une itération consistante.
- (f) Effectuer quatre fois l'itération  $\phi_c(x)$  pour  $c = 0,8$  à partir de  $x_0 = 1$ .
- (g) Evaluer la dérivée  $\phi'_c(x)$  et en tirer la conclusion par rapport à la convergence locale : convergence ou divergence ? Spirale ou escalier ?

### corrigé

- (a) La fonction dont il faut trouver la racine est  $f(x) = x - 2 \cos(x^2)$ .  
 $\phi(x) = x - \frac{b-a}{f(b)-f(a)}f(x) = x - \frac{4}{4}(x - 2 \cos(x^2)) = 2 \cos(x^2)$
- (b) L'itération ne convergera pas parce que la dérivée de  $\phi(x)$  dans le point fixe est plus grande que 1 (La fonction  $\phi(x)$  croise la fonction identique avec une pente plus raide que 1)
- (c) L'itération de la corde convergera quand

$$0 < \frac{b-a}{f(b)-f(a)}f'(x^*) < 2$$

Ici  $f'(x^*)$  représente la pente locale, alors que  $\frac{f(b)-f(a)}{b-a}$  est la pente moyenne sur l'intervalle.

NB : Comparer avec la méthode de Newton-Raphson :

$$\phi'(x) = \frac{f(x)f''(x)}{[f'(x)]^2},$$

qui convergera quand  $[f'(x)]^2$  est grande (en proportion des valeurs de  $f(x)$  et  $f''(x)$ ).

- (d) Trouver une racine dans laquelle la pente de la fonction est forte, est un problème bien conditionné.
- (e)  $\phi_c(x) = x \Leftrightarrow cx + (1 - c)\phi(x) = x \Leftrightarrow (c - 1)[x - \phi(x)] = 0 \Leftrightarrow x = \phi(x)$
- (f) On a

$$\begin{aligned} x_0 &= 1 \\ x_1 &= 0,8 \cdot 1 + 0,2 \cdot 2 \cos(1) = 1,0161 \\ x_2 &= 0,8 \cdot 1,0161 + 0,2 \cdot 2 \cos(1,0161^2) = 1,0180 \\ x_3 &= 0,8 \cdot 1,0180 + 0,2 \cdot 2 \cos(1,0180^2) = 1,0182 \\ x_4 &= 0,8 \cdot 1,0182 + 0,2 \cdot 2 \cos(1,0182^2) = 1,0182 \end{aligned}$$

- (g)  $\phi'_c(x) = c + (1 - c)\phi'(x) = c - 4(1 - c)x \sin(x^2) = 0,0989$  La dérivée est positive mais inférieure à 1, l'itération converge sous forme d'un escalier, ce qui est confirmé par les résultats numériques de la question précédente.

10. Considérer la fonction  $h(x) = x [5 + \cos(2 \log(x)) + 2 \sin(2 \log(x))] / 5$ , pour  $x \in \mathbb{R}^+$  et sa dérivée  $h'(x) = 2 \cos^2(\log(x)) = \cos(2 \log(x)) + 1$  (ici,  $\log(u) = \ln(u)$  représente le logarithme naturel/népérien). La question est de trouver la racine  $x^*$  de la fonction  $f(x) = h(x) - c$  pour  $c \in \mathbb{R}$  quelconque.
- (a) Argumenter que  $x^*$  est unique.
  - (b) Expliquer que la méthode de Newton-Raphson ne peut pas converger globalement, suite à des points d'annulation de  $f'(x) = h'(x)$ .
  - (c) Considérer la fonction d'itération  $\phi(x) = \alpha f(x) + x$ , dans une itération de point fixe. L'itération est consistante pour toute valeur d' $\alpha$  (on ne demande pas de montrer la consistance). Montrer que  $\alpha = -1$  est la seule valeur pour laquelle l'itération converge globalement.
  - (d) Pour  $c = 1$ , on peut vérifier que la racine  $x^*$  se situe autour de  $x^* \approx 0,9$ . La convergence des itérations  $\phi(x) = x - f(x)$ , sera-t-elle lente ou rapide, sous forme d'une spirale ou d'un escalier ?
  - (e) Ecrire la valeur d' $\alpha$  qui correspond à la méthode de la corde sur l'intervalle  $[a, b]$ .
  - (f) Expliquer que la méthode de Newton-Raphson ne peut pas être écrite sous la forme  $\phi(x) = \alpha f(x) + x$ .

### corrigé

- (a) La dérivée étant positive partout, on ne peut pas avoir deux racines
- (b) La fonction d'itération étant égale à  $\phi(x) = x - f(x)/f'(x)$ , celle-ci tend vers l'infini quand  $f'(x)$  s'annule (sauf si, exceptionnellement,  $f(x)$  s'annule en même temps). Une itération qui passe par l'infini ne peut pas converger (autrement dit, la dérivée  $\phi'(x)$ , dépassera la valeur absolue de 1).
- (c) Il faut que  $|\phi'(x)| < 1$ , pour toute valeur de  $x$  (convergence globale). Cette condition revient à  $|1 + \alpha f'(x)| < 1 \Leftrightarrow |1 + \alpha h'(x)| < 1$ . Sachant que  $h'(x)$  fluctue entre 0 et 2, la seule valeur d' $\alpha$  qui fait fluctuer  $\phi'(x)$  entre  $-1$  et  $1$  est de  $\alpha = -1$ .
- (d)  $\phi'(x^*) = 1 - f'(x^*) = 1 - h'(x^*) = 1 - 2 \cos^2(\log(x^*)) \approx 1 - 2 \cos^2(\log(0,9)) = -0,9779$  Cette valeur étant négative, la convergence prendra la forme d'une spirale. La valeur étant proche de  $-1$ , la convergence sera très lente.

### (e) Remarque

La méthode de la corde est à cheval entre les méthodes linéarisées  $x^{(k+1)} = x^{(k)} - q_k^{-1} f(x^{(k)})$  et les méthodes de point fixe,  $x^{(k+1)} = \phi(x^{(k)})$ . Les méthodes à cheval entre les deux se caractérisent par une valeur constante de  $q_k$ . La forme  $\phi(x) = x + \alpha f(x)$  revient à une méthode linéarisée où  $q_k = -1/\alpha$ .

### Réponse

On a pour la méthode de la corde

$$\alpha = -1/q_k = -\frac{b-a}{f(b)-f(a)}$$

- (f) La méthode de Newton-Raphson utilise, outre la fonction  $f(x)$ , la dérivée  $f'(x)$ . Par conséquent, elle n'est pas une méthode de point fixe de la forme  $\phi(x) = \alpha f(x) + x$  (elle est bien une méthode de point fixe).

11. Considérer la fonction  $f(x) = \exp(-x^2/2) - 1/3$ , dont la dérivée est donnée par  $f'(x) = -x \exp(-x^2/2)$ . On est à la recherche d'une racine sur l'intervalle  $[1, 2]$ .

- (a) Argumenter que la racine existe et qu'elle est unique.
- (b) On peut démontrer (la démonstration ne fait pas partie de l'énoncé) que pour  $x \in [1, 2]$  la dérivée est comprise entre  $-0,61 < f'(x) < -0,27$ . En se basant sur ce résultat, qu'est-ce qu'on peut dire sur la convergence de la méthode de point fixe avec la fonction d'itération  $\phi(x) = x + f(x)$  : convergence ou divergence, globale ou locale, escalier ou spirale ?
- (c) Expliquer : quand une itération converge sous forme d'un escalier sur tout l'intervalle  $[x_1, x_2]$ , c'est une bonne idée de lancer deux itérations : l'une en  $x_1$ , l'autre en  $x_2$ .
- (d) Question bonus (un point à gagner, rien à perdre) : trouver toutes les valeurs  $\alpha$  telles que  $\phi(x) = x + \alpha f(x)$  converge globalement sur  $[1, 2]$  sous forme d'une spirale.

### corrigé

- (a) L'existence suit des observations  $f(1) > 0$  et  $f(2) < 0$ , alors que  $f(x)$  est continue. L'unicité suit du fait que  $f'(x) < 0$  sur tout l'intervalle.

**Remarque :** dans ce cas-ci, une stratégie possible consiste de chercher une expression explicite pour toutes les racines :

$$f(x) = 0 \Leftrightarrow \exp(-x^2/2) = 1/3 \Leftrightarrow x^2 = -2 \ln(1/3) = 2 \ln(3) \Leftrightarrow x = \pm \sqrt{2 \ln(3)},$$

pour constater alors qu'une seule racine se trouve dans l'intervalle  $[1, 2]$ .

- (b)  $\phi'(x) = 1 + f'(x) \Rightarrow 1 - 0,61 < \phi'(x) < 1 - 0,27 \Rightarrow 0 < \phi'(x) < 1$   
Convergence globale sous forme d'un escalier.
- (c) L'application de deux itérations en même temps permet de maintenir une borne supérieure et une borne inférieure pour la racine inconnue. L'évolution de ces deux bornes nous apporte une idée du taux de convergence.


- (d)  $-1 < \phi'(x) < 0 \Leftrightarrow -1 < \alpha f'(x) + 1 < 0 \Leftrightarrow -2 < \alpha f'(x) < -1 \Leftrightarrow 1 < \alpha(-f'(x)) < 2$

Puisque  $f'(x) < 0 \Rightarrow -f'(x) = |f'(x)|$ , la condition pour  $\alpha$  devient

$$1/|f'(x)| < \alpha < 2/|f'(x)|$$

Sachant que  $-0,61 < f'(x) < -0,27$ , une convergence globale nécessite que  $1/0,27 < \alpha$  et, en même temps,  $\alpha < 2/0,61$ , ce qui aboutit à  $3,70 < \alpha$  et  $\alpha < 3,27$ . L'ensemble de valeurs  $\alpha$  favorable est donc le vide.

12. Soit  $f(x)$  une fonction dont la dérivée est tracée dans le graphique ci-dessous :



On sait que la pente moyenne est égale à 1, c'est-à-dire,

$$\frac{\int_a^b f'(x) dx}{b-a} = \frac{f(b) - f(a)}{b-a} = 1.$$

Sachant que  $f(a) < 0$  et  $f(b) > 0$ , on voudrait connaître la racine  $\alpha \in [a, b]$

- Argumenter que dans ce cas-ci, il n'y a qu'une racine.
- Expliquer qu'avec la méthode de la corde sur  $[a, b]$  on n'est pas sûr de trouver la racine (en particulier que le succès dépendra de la position de la racine dans l'intervalle).
- Expliquer que l'évaluation de deux points avant l'application de la méthode de la corde pourrait remédier à cette incertitude.

### corrigé

- La dérivée étant positive partout, on ne peut pas avoir deux racines
- La condition de convergence locale de la méthode de la corde s'exprime ainsi

$$0 < f'(x^*) < 2 \frac{f(b) - f(a)}{b-a}$$

La pente moyenne étant de 1, il n'y aura pas de convergence si  $f'(x^*)$  est plus grande que 2, une situation qui pourrait se produire.

- En évaluant  $f(c)$  et  $f(d)$ , on pourrait identifier l'un des sous-intervalles  $[a, c]$ ,  $[c, d]$ , ou  $[d, b]$  dans lequel la racine se trouve. En plus, sur tous ces sous-intervalles, la pente maximale s'écarte de la moyenne d'une valeur inférieure à 2.


13. Considérer la fonction  $f(u) = \exp(-u) + \exp(u) - d$  sur l'intervalle  $[0, 1]$  avec  $d = 2, 5$ . Soit  $x \in [0, 1]$  défini par  $f(x) = 0$ .
- (a) Argumenter que la racine existe et qu'elle est unique.
  - (b) Argumenter que pour toute valeur de  $x \in [0, 1]$  :  $f'(0) \leq f'(x) \leq f'(1)$ .
  - (c) Déterminer les valeurs de  $\alpha$  pour lesquelles la méthode de point fixe avec la fonction d'itération  $\phi(x) = x + \alpha f(x)$  converge globalement sous forme d'un escalier.
  - (d) Déterminer les valeurs de  $\alpha$  pour lesquelles la méthode de point fixe avec la fonction d'itération  $\phi(x) = x + \alpha f(x)$  converge globalement sous forme d'une spirale.

### corrigé

- (a) L'existence suit des observations  $f(0) < 0$  et  $f(1) < 1$ , alors que  $f(x)$  est continue. L'unicité suit du fait que  $f'(x) > 0$  sur tout l'intervalle.
- (b) La dérivée de  $f'(x) = -\exp(-x) + \exp(x)$ , c'est-à-dire,  $f''(x)$  est donnée par  $f''(x) = \exp(-x) + \exp(x) = f(x)$ . Cette fonction est positive sur tout l'intervalle, d'où vient que  $f'(x)$  est monotone et non-descente.
- (c) Vu que  $\phi'(x) = 1 + \alpha f'(x)$ , on a  $0 < \phi'(x) < 1 \Leftrightarrow 0 < 1 + \alpha f'(x) < 1 \Leftrightarrow -1 < \alpha f'(x) < 0 \Leftrightarrow -1/f'(x) < \alpha < 0$ . Pour que la condition soit satisfaite pour toute valeur de  $x$ , il suffit qu'elle est satisfaite pour  $x = 1$ , car  $f'(x) \leq f'(1) \Leftrightarrow -1/f'(x) \leq -1/f'(1)$ . On a donc  $\alpha \in [-1/f'(1), 0] = [-1/(e - e^{-1}), 0]$ .
- (d) On a  $-1 < \phi'(x) < 0 \Leftrightarrow -1 < 1 + \alpha f'(x) < 0 \Leftrightarrow -2 < \alpha f'(x) < -1 \Leftrightarrow -2/f'(x) < \alpha < -1/f'(x)$ . La borne inférieure est satisfaite si  $-2/f'(1) < \alpha$ , alors que la borne supérieure est satisfaite si  $\alpha < -1/f'(1)$ . On a donc  $\alpha \in [-2/f'(1), -1/f'(0)] = [-2/(e - e^{-1}), -1/0]$ . Cet intervalle est le vide.

14. Considérer la fonction  $f(u) = \exp(-u) + \exp(u) - d$  sur l'intervalle  $[0, 1]$  avec  $d = 2, 5$ . Soit  $x \in [0, 1]$  défini par  $f(x) = 0$ .

- (a) Le graphique ci-dessous trace la fonction  $\phi(x)$  pour la méthode de Newton-Raphson, ainsi que la droite d'identité  $y(x) = x$  (en ligne grise). Expliquer que la méthode de Newton-Raphson converge globalement sur l'intervalle  $(0, \infty)$ , bien que la dérivée  $\phi'(x)$  soit beaucoup plus grande que 1 (en valeur absolue) pour  $x$  autour de l'origine et légèrement plus grande que 1 pour  $x$  tendant vers l'infini.



### corrigé

- (a) Une valeur  $x^{(k)}$  très petite est envoyée sur une valeur  $x^{(k+1)}$  très grande. Il suffit donc d'analyser la convergence pour les valeurs très grandes. La dérivée de la fonction d'itération pour  $x$  très grand, se situe autour de 1 (un peu plus grande ou un peu plus petit). Quelque soit la valeur de la dérivée, la valeur de  $\phi(x)$  est toujours plus petite que la valeur de  $x$ , ce qui explique la convergence vers la racine de  $f(x)$ . (Remarque : la valeur de la dérivée plus élevée que 1 correspond à la divergence par rapport à la racine à l'infini de l'équation  $x = \phi(x)$ ).

15. Considérer la fonction  $f(x) = \exp(-x^2) - x$  sur les réels positifs. Soit  $x^* \in \mathbb{R}^+$  défini par  $f(x^*) = 0$ .

- (a) Argumenter que la racine existe et qu'elle est unique.  
 (b) Considérer les deux fonctions d'itération  $\phi_1(x) = e^{-x^2}$  et  $\phi_2(x) = \sqrt{|\ln(x)|}$ . Argumenter la consistance des deux, en se basant sur le fait que  $\phi_2(x) = \phi_1^{-1}(x)$ .  
 (c) Utiliser l'expression

$$\frac{d}{dx} [\phi^{-1}(x)] = \frac{1}{\phi'[\phi^{-1}(x)]}$$

pour montrer (au niveau général, donc pas juste dans ce cas-ci) que, à condition que  $|\phi'_1(x^*)| \neq 1$ , on a la convergence locale pour soit  $\phi_1(x)$ , ou pour  $\phi_2(x)$  (mais pas pour les deux).

- (d) Montrer que la racine de  $f(u)$  est comprise entre 0 et  $1/\sqrt{2}$ .  
 (e) Utiliser les faits que  $\phi'_1(x) = -2x\phi_1(x)$  et  $x^* < 1/\sqrt{2}$  pour montrer que  $-1 < \phi'_1(x^*) < 0$ .  
 (f) Tirer la conclusion par rapport à la convergence de  $\phi_1(x)$  : convergence, divergence, escalier, spirale ?  
 (g) Ecrire  $\phi_{NR}(x)$ , la fonction d'itération pour la méthode de Newton-Raphson.

### corrigé

- (a) L'existence suit des observations  $f(0) > 0$  et  $\lim_{x \rightarrow \infty} f(x) = -\infty$ , alors que  $f(x)$  est continue. L'unicité suit du fait que  $f'(x) < 0$  partout.

- (b)  $\phi_1(x)$  est consistant, car  $\phi_1(x) = x \Leftrightarrow e^{-x^2} = x \Leftrightarrow e^{-x^2} - x = 0 \Leftrightarrow f(x) = 0$ . Ensuite,  $\phi_2(x) = x \Leftrightarrow \phi_1^{-1}(x) = x \Leftrightarrow x = \phi_1(x)$

(c) On a

$$|\phi_2'(x^*)| = \frac{1}{|\phi_1'[\phi_1^{-1}(x^*)]|} = \frac{1}{|\phi_1'(x^*)|}$$

Donc  $|\phi_2'(x^*)| < 1 \Leftrightarrow |\phi_1'(x^*)| > 1$ .

- (d)  $f(1/\sqrt{2}) = e^{-1/2} - 1/\sqrt{2} < 0$ , alors que  $f(0) = 1 > 0$ . La fonction  $f(x)$  est continue.

- (e) On a  $\phi_1'(x^*) = -2x^*\phi_1(x^*) = -2x^{*2}$ , ce qui est un nombre négatif, mais au-dessus de  $-1$ , car  $x^* < 1/\sqrt{2}$ .

(f) Convergence, spirale

- (g)  $\phi_{NR}(x) = x - f(x)/f'(x) = x - (e^{-x^2} - x)/(-2xe^{-x^2} - 1) = x + (e^{-x^2} - x)/(2xe^{-x^2} + 1)$

16. Considérer la fonction  $f(x) = \exp(-x) - x^2$  sur les réels positifs. Soit  $x^* \in [0, 1]$  défini par  $f(x^*) = 0$ .


- (a) Argumenter que la racine existe et qu'elle est unique.  
 (b) Considérer la fonction d'itération  $\phi(x) = e^{-x/2}$ . Discuter la consistance et la convergence globale.  
 (c) Discuter la forme de la convergence ou divergence locale : escalier ou spirale ?  
 (d) Ecrire  $\phi_{NR}(x)$ , la fonction d'itération pour la méthode de Newton-Raphson.

### corrigé


- (a) L'existence suit des observations  $f(0) > 0$  et  $f(1) < 0$ , alors que  $f(x)$  est continue. L'unicité suit du fait que  $f'(x) < 0$  partout.  
 (b)  $\phi(x)$  est consistant, car  $\phi(x) = x \Leftrightarrow e^{-x/2} = x \Leftrightarrow e^{-x} = x^2 \Leftrightarrow f(x) = 0$ .  
 (c) Convergence, spirale  
 (d)  $\phi_{NR}(x) = x - f(x)/f'(x) = x - (e^{-x} - x^2)/(-e^{-x} - 2x)$

17. Considérer la fonction  $f(x) = \exp(-x) - \ln(1+x)/5$  sur l'intervalle  $[a, b] = [0, 2]$  et les fonctions d'itération  $\phi_\gamma(x) = x + \gamma f(x)$ .

- (a) Argumenter que la fonction contient exactement une racine sur l'intervalle.  
 (b) Les graphiques ci-dessous tracent les courbes de  $\phi_\gamma(x)$  pour  $\gamma = 1$ , pour  $\gamma$  donné par la méthode de la corde ainsi que la fonction d'itération pour la méthode de Newton. Identifier les trois graphiques.



- (c) Expliquer que la fonction d'itération de Newton ne peut pas être écrite sous forme de  $\phi_\gamma(x) = x + \gamma f(x)$  (donner l'expression de  $\phi(x)$  pour la méthode de Newton).
- (d) Donner la valeur de  $\gamma$  dans la méthode de la corde.
- (e) Les graphiques ci-dessous affichent les résultats des itérations en partant de  $x^{(0)} = 2$  pour les trois méthodes. Identifier-les.



### corrigé

- (a) Les valeurs  $f(a) = f(0) = 1$  et  $f(b) = f(2) = e^{-2} - \ln(3)/5 = -0,084$  sont de signes contraires, ce qui démontre l'existence d'un nombre impair de racines. Le nombre est de un parce que la dérivée  $f'(x) = -e^{-x} - 1/[5(1+x)]$  est négative partout sur l'intervalle.

- (b) Le graphique à gauche contient la fonction  $\phi(x)$  de la méthode de Newton, car dans le point fixe elle atteint un maximum : sa dérivée y s'annule, ce qui correspond à l'ordre deux de la convergence.

Le graphique au milieu est celui de la fonction  $\phi_\gamma(x)$  pour  $\gamma = 1$ , car  $\phi_\gamma(0) = \gamma f(0) = 1$

Le graphique à droite contient la fonction  $\phi_\gamma(x)$  pour la méthode de la corde.

- (c) Pour la méthode de Newton on a  $\phi(x) = x - \frac{f(x)}{f'(x)}$ , ce qui ne peut pas être écrit sous forme de  $\phi_\gamma(x) = x + \gamma f(x)$ .  $\phi(x) = x - \frac{\exp(-x) - \ln(1+x)/5}{-\exp(-x) - 1/[5(1+x)]}$ .

- (d) Pour la méthode de la corde on a





$$\gamma = -\frac{b-a}{f(b)-f(a)} = -\frac{2}{-0,084-1} = 1,8444$$

- (e) Le graphique à gauche contient les itérations pour la fonction  $\phi_\gamma(x)$  avec  $\gamma = 1$ , car cette méthode converge le plus lentement, parce que  $\phi'(x)$  est proche de 1.

Le graphique central contient les itérations pour la méthode de Newton, car avec  $x^{(0)} = 2$  on voit que  $x^{(1)} = \phi(x^{(0)})$  est inférieur à la racine (ce qui n'est pas le cas pour les deux autres méthodes)

Le graphique à droite contient les itérations pour la méthode de la corde.

18. (a) Considérer la fonction  $f(x) = \sum_{k=1}^n \frac{1}{x-k} - \frac{2n}{x}$  sur l'intervalle  $x \in [n, 2n]$ . Argumenter que  $f(2n) < 0$  en constatant que le plus grand terme de la somme est inférieur à  $1/n$ . Ensuite, argumenter l'existence d'une racine de  $f(x)$  sur  $[n, 2n]$ .
- (b) Comment pourrait-on prouver l'unicité de la racine (pas besoin de développer le calcul).
- (c) Les graphiques ci-dessous tracent les courbes de la fonction d'itération pour la méthode de Newton, une autre fonction d'itération convergente, une fonction d'itération non convergente et une fonction qui n'est pas une fonction d'itération pour le problème concerné. Indiquer quelle fonction correspond à chaque graphique et expliquer (l'explication est indispensable pour obtenir des points).



- (d) Comment peut-on déduire du graphique des itérations  $x^{(k)}$  en fonction de  $k$  si la convergence prend la forme d'une spirale ou d'un escalier ?

corrigé

(a)

$$f(2n) = \sum_{k=1}^n \frac{1}{2n-k} - 1$$

Puisque

$$\frac{1}{2n-k} \leq \frac{1}{2n-n} = \frac{1}{n}$$

la somme est bornée par

$$f(2n) \leq n \cdot \frac{1}{n} - 1 = 0.$$



On a

$$f(n) = +\infty,$$

Par conséquent, la fonction continue doit passer par une racine dans l'intervalle.

- (b) L'unicité suit de la monotonie : la dérivée est négative sur tout l'intervalle.
- (c)
- La fonction à gauche n'est pas une fonction d'itération pour le problème, parce qu'elle n'a pas de point fixe à la position des points fixes des autres fonctions.
  - La seconde fonction est une fonction d'itération convergente, mais elle ne correspond pas à la méthode de Newton, parce que sa dérivée dans le point fixe est inférieure à un en valeur absolue, mais elle ne s'annule pas.
  - La troisième fonction doit être la fonction d'itération de la méthode de Newton, parce que c'est la seule fonction dont la dérivée s'annule dans le point d'itération. Cette situation reflète la convergence d'ordre deux de la méthode.
  - La dernière fonction est une fonction d'itération non-convergente, car sa dérivée dans le point fixe est supérieure à un.
- (d) La convergence prend la forme d'un escalier si le graphique de  $x^{(k)}$  en fonction de  $k$  converge de manière monotone. La convergence sous forme de spirale se manifeste comme une convergence oscillante de  $x^{(k)}$  en fonction de  $k$ .

19. Considérer l'équation non linéaire  $f(x) = \exp(x) - 2\sqrt{|x|} \cdot \text{sign}(x) - 1 = 0$ . La solution triviale  $x = 0$  étant sans intérêt, on est à la recherche de la solution  $x_1$  dans l'intervalle  $]0, 2[$ .



- (a) Expliquer qu'aucune fonction d'itération de la forme  $\phi(x) = \alpha f(x) + x$  ne peut converger vers la solution triviale.
- (b) Considérer la fonction  $\phi(x) = (e^x - 1)^2 / 4$  (dont le graphique se trouve ci-dessus). Montrer qu'une itération sur base de cette  $\phi(x)$  est fortement consistante.

- (c) En partant de  $\phi(x)$ , trouver une autre fonction  $f(x)$  qui a les mêmes racines que la fonction  $f(x)$  donnée.


**corrigé**

- (a) Puisque  $\lim_{x \rightarrow 0} f'(x) = -\infty$ , on a  $\lim_{x \rightarrow 0} \phi'(x) = \lim_{x \rightarrow 0} [\alpha f'(x) + 1] = -\infty$ . Donc,  $|f'(x)| > 1$  sur tout intervalle  $] -\varepsilon, \varepsilon[$ .  
 (b) Toute solution de  $f(x) = 0$  sera une solution de  $\phi(x) = x$ . Effectivement

$$\exp(x) - 2\sqrt{|x|} \cdot \text{sign}(x) - 1 = 0 \Leftrightarrow \exp(x) - 1 = 2\sqrt{|x|} \cdot \text{sign}(x) \Rightarrow (e^x - 1)^2 = 4|x|$$

- (c) Prenez  $f(x) = \phi(x) - x = (e^x - 1)^2/4 - x$

20. Considérer l'équation non linéaire  $f(x) = x^2 - \sin(x) = 0$ . La solution triviale  $x = 0$  étant sans intérêt, on est à la recherche de la solution  $x_1$  dans d'intervalle  $]0, 2[$ .




- (a) Expliquer que la fonction d'itération  $\phi(x) = x + f(x)/2$  ne peut pas converger à la solution sur base du fait que  $\phi'(0) = 1/2$ .  
 (b) Expliquer que la fonction d'itération  $\phi(x) = \sqrt{|\sin(x)|}$  convergera vers  $x_1$  sur base de la continuité et de la positivité de  $\phi'(x)$  sur  $]0, 2[$  et du fait que  $\lim_{x \rightarrow 0+} \phi'(x) = \infty$ .  
 (c) Donner la valeur numérique de  $x_1$  (5 chiffres significatifs).

**corrigé**

- (a) Comme la dérivée à l'origine est plus petite que 1, elle sera nécessairement plus grande que 1 dans le point fixe suivant. L'itération ne peut donc pas converger vers ce point suivant.  
 (b) Puisque  $\lim_{x \rightarrow 0+} \phi'(x) = \infty$ , il existe un intervalle  $]0, \varepsilon[$  sur lequel  $\phi(x) > x$ . En plus,  $\phi'(x)$  est continue. Pour rejoindre la droite d'identité, il faut que la pente de  $\phi(x)$  (donc la valeur de  $\phi'(x)$ ) descende en dessous de 1. Etant donné que  $\phi'(x)$  reste positive, la situation où  $\phi'(x) < -1$  ne peut pas se produire.  
 (c)  $x = 0.876726215395062$

21. Le graphique ci-dessous trace la courbe d'une fonction d'itération  $\phi(x)$  de la méthode de Newton pour la résolution d'un problème  $f(x) = 0$ .




- (a) Combien de racines la fonction  $f(x)$  a-t-elle ?
- (b) Expliquer l'origine des asymptotes verticales dans la courbe de  $\phi(x)$ .
- (c) Vrai ou faux (expliquer ou corriger) : la convergence vers l'une des racines est locale dans le sens que si une racine existe entre deux deux asymptotes, elle sera trouvée en partant d'un point initial arbitraire sur l'intervalle entre les deux asymptotes.

**corrigé**

- (a) Il y a deux racines. Il s'agit des intersections de la ligne d'identité avec la courbe de  $\phi(x)$ .
- (b) Les asymptotes verticales viennent de l'expression de la méthode de Newton,  $\phi(x) = x - f(x)/f'(x)$ . En effet, les asymptotes correspondent aux racines de  $f'(x)$ , c'est-à-dire, aux extrêmes locaux de la fonction  $f(x)$ .
- (c) Faux. La convergence ne s'étend pas sur tout l'intervalle entre deux asymptotes. En réalité, elle est limitée au sous-intervalle sur lequel la dérivée de  $\phi(x)$  est comprise en  $[-1, 1]$ .

22. Le graphique ci-dessous trace la courbe d'une fonction d'itération  $\phi(x)$ , définie par  $\phi(x) = x - [f(x)]^2$  pour la résolution d'un problème  $f(x) = 0$ .



- (a) Argumenter que la méthode est consistante.
- (b) Expliquer pourquoi le point fixe de  $\phi(x)$  est un point tangent à la droite d'identité.
- (c) Examiner la convergence de la méthode sur les intervalles (argumenter)
 

|              |              |              |              |              |              |              |
|--------------|--------------|--------------|--------------|--------------|--------------|--------------|
| $[x_0, x_1]$ | $[x_1, x_2]$ | $[x_2, x_3]$ | $[x_3, x_4]$ | $[x_4, x_5]$ | $[x_5, x_6]$ | $[x_6, x_7]$ |
|--------------|--------------|--------------|--------------|--------------|--------------|--------------|

### corrigé

- (a)  $\phi(x) = x \Leftrightarrow x + [f(x)]^2 = x \Leftrightarrow [f(x)]^2 = 0 \Leftrightarrow f(x) = 0$
- (b) Cette observation est expliquée par l'usage du carré de  $f(x)$ . En effet, la fonction  $[f(x)]^2$  étant positive partout, la fonction  $x - [f(x)]^2$  est toujours plus petite que  $x$ .
- (c)
- Sur l'intervalle  $[x_0, x_1]$  la méthode est divergente, car  $|\phi'(x)| > 1$ .
  - Sur l'intervalle  $[x_1, x_2]$  la méthode est convergente, car  $|\phi'(x)| < 1$ .
  - Sur l'intervalle  $[x_2, x_3]$  la méthode est convergente, car un point dans cet intervalle est renvoyé, lors de la première itération, vers un point en  $[x_1, x_2]$ , d'où la convergence est garantie.
  - Sur les intervalles  $[x_3, x_4]$  et  $[x_4, x_5]$ , la méthode est divergente. Effectivement, même si la dérivée  $\phi'(x)$  y est petite, ces points sont renvoyés vers l'intervalle  $[x_0, x_1]$ , d'où le point fixe n'est pas accessible en itérant  $\phi(x)$ .
  - Sur l'intervalle  $[x_5, x_6]$  la méthode est convergente, car un point dans cet intervalle est renvoyé, lors de la première itération, vers un point en  $[x_1, x_2]$ , d'où la convergence est garantie.
  - Sur l'intervalle  $[x_6, x_7]$  la méthode est divergente, car les valeurs de cet intervalle sont renvoyées sur l'intervalle  $[x_3, x_5]$ , sur laquelle la méthode ne conduit pas à la solution.
-