

Séance 2 — Représentation à virgule fixe et virgule flottante

Rappel théorique

Dans ce qui suit, nous devons toujours travailler dans une base b fixée (typiquement $b = 2$ dans un ordinateur ou $b = 10$ lorsque nous raisonnons sur papier).

La représentation à *virgule fixe* consiste à se fixer une base $b \geq 2$, un signe $s \in \{0, 1\}$ (où $s = 0$ désigne qu'un nombre est positif et $s = 1$ désigne qu'un nombre est négatif) et $n + m + 1$ chiffres (en base b toujours) dont les $n + 1$ premiers sont utilisés pour représenter la partie entière d'un nombre et les m suivants sont utilisés pour représenter la partie décimale, i.e. :

$$x = ([x_n, x_{n-1}, \dots, x_1, x_0, x_{-1}, \dots, x_{-m}], b, s),$$

où les x_k sont entre 0 et $b - 1$ (donc des chiffres en base b). Cette représentation représente le nombre :

$$x = (-1)^s \sum_{k=-m}^n x_k \cdot b^k.$$

Attention, nous identifions ici la représentation et la valeur du nombre représenté.

Travailler en virgule fixe correspond en réalité à travailler uniquement sur des entiers sur $m + 1 + n$ chiffres, mais de les interpréter $\times b^{-m}$.

Cependant, en fonction du contexte, on pourrait vouloir avoir plus de précision pour la partie entière ou plus de précision pour la partie décimale, ce qui n'est pas possible.

La *virgule flottante* cherche à contourner ce problème en travaillant sur une *mantisse* de taille t fixée, mais également avec un exposant e (généralisant la notation scientifique). Le nombre à virgule flottante suivant

$$x = ([x_1, \dots, x_t], e, b, s)$$

est donc à interpréter comme le nombre réel suivant

$$x = (-1)^s m b^{e-t} = (-1)^s \sum_{k=1}^t x_k b^{e-k}.$$

Attention, nous imposons à nouveau ici $s \in \{0, 1\}$, $b \geq 2$, $e \in \mathbb{Z}$ (en effet cet exposant peut très bien être négatif), mais également $1 \leq x_1 \leq b - 1$ et $0 \leq x_k \leq b - 1$ pour $k \geq 2$. En particulier x_1 ne peut pas être nul (ce qui garantit l'unicité de la représentation d'un nombre sous cette forme).

À base b fixée, pour t, L, U des entiers tels que $L \leq U$, nous définissons l'ensemble $\mathbb{F}(b, t, L, U)$ comme l'ensemble contenant tous les réels $x \in \mathbb{R}$ qui admettent une représentation à virgule flottante avec (i) une mantisse de taille t ; (ii) la base b ; et (iii) $L \leq e \leq U$.

Notons qu'il est possible de montrer que $|\mathbb{F}(b, t, L, U)| = 2(U - L + 1)(b - 1)b^{t-1}$. En effet, dans la représentation $([x_1, \dots, x_t], e, b, s)$ peut prendre :

- 2 valeurs pour s (à savoir 0, 1) ;

- $U - L + 1$ valeurs pour e (à savoir $L, L + 1, \dots, U - 1, U$);
- $b - 1$ valeurs pour x_1 (à savoir $1, 2, \dots, b - 1$);
- et b valeurs pour chacun des x_k pour $2 \leq k \leq t$ (à savoir $0, 1, \dots, b - 1$).

Le produit de ces différentes entrées vaut bien $2(U - L + 1)(b - 1)b^{t-1}$.

Notons tout de même que le fait d'imposer $x_1 \neq 0$ nous empêche de représenter 0 en virgule flottante. Nous appelons ces représentations sous *forme normalisée*. Évidemment, en pratique, la possibilité de tout de même mettre x_1 à 0 permet de représenter des *valeurs spéciales*, e.g. la valeur 0, mais également $\pm\infty$, ou encore NaN.

2.1 Virgule fixe

- **Exercice 2.1.** Si $b = 10, n = 3, m = 6$ et $s = 0$, à quel nombre correspond $[0012200000]$?
- **Exercice 2.2.** Même question si $b = 3$?
- **Exercice 2.3.** Si $b = 3, n = 3, m = 6$ et $s = 0$, à quel nombre correspond $[3012200000]$?

2.2 Virgule flottante

■ **Exercice 2.4.** A quels nombres correspondent :

- $([34], e = 2, b = 10, s = 0)$;
- $([34], e = 1, b = 16, s = 1)$;
- $([10001], e = 6, b = 2, s = 0)$?

■ **Exercice 2.5.** Représentez le nombre 234.5 en virgule flottante avec $b = 2$ et les autres paramètres suffisamment grands.

■ **Exercice 2.6.** Combien de nombres peut-on représenter en virgule flottante en base $b = 4$, et avec les paramètres $L = -2, U = 2$, et $t = 2$?

■ **Exercice 2.7.** Considérons le système linéaire suivant :

$$\begin{cases} 0.461x_1 + 0.311x_2 &= 0.150 \\ 0.209x_1 + 0.141x_2 &= 0.068 \end{cases}$$

■ Il admet pour solution $(x_1, x_2) = (1, -1)$. Montrez que la résolution de ce système en utilisant une représentation en virgule flottante ($b = 10, t = 3$) manque de précision.

■ **Exercice 2.8.** Considérez l'équation $\alpha x + \beta = 0$ pour $\alpha = 0.111$ et $\beta = -2$. $z = 18$ en est une solution approchée. Utilisez l'arithmétique décimale (donc en base $b = 10$) tronquée à 3 chiffres (donc $t = 3$) pour calculer le reste $r = -\beta - \alpha \cdot z$. Comparez avec le résultat en arithmétique exacte.