

Séance 4 — Manipulation de nombres à virgule flottante en Matlab

Dans cette séance, nous ferons l'hypothèse simplificatrice que l'arithmétique employée par MATLAB (ou OCTAVE) est exacte.

Exercice 4.1. Écrivez une fonction qui, étant donné un nombre x et son approximation $\hat{x}$, calcule (i) l'erreur absolue et (ii) l'erreur relative.

Exercice 4.2. Dessinez le graphique de de l'erreur relative obtenue pour le problème $F(d) = (d - 1)^2$ avec une perturbation fixe des données de 10^{-2} . Prenez les données dans l'intervalle $[-1, 3]$. Dessinez ensuite sur la même figure le graphique du conditionnement relatif du problème.

Exercice 4.3. Écrivez une fonction `increment(m, b)` qui prend en paramètre une mantisse m sous forme d'un vecteur de taille t et une base b , et qui renvoie la mantisse associée à $m+1$ (toujours en base b).

Ensuite, écrivez une fonction `floset(b, t, L, U)` qui prend en paramètre une base b , une taille de mantisse t , et les bornes sur un exposant L et U . Cette fonction doit renvoyer une paire $[F, \text{card}]$ où F est un vecteur trié qui contient toutes les valeurs de $\mathbb{F}(b, t, L, U)$ et où `card` est la taille de F .

Représentez ensuite ce vecteur sur une figure (c.f. la Figure 2.1 du syllabus).

Exercice 4.4. Utilisez le code de l'exercice précédent et représentez sur une figure les distances relatives entre les éléments consécutifs de $\mathbb{F}(b, t, L, U)$ (c.f. la Figure 2.2 du syllabus).

Exercice 4.5. Écrivez une fonction `fl(x, b, t, L, U)` qui prend en paramètre une valeur $x \in \mathbb{R}$, une base b , une taille de mantisse t et des bornes L et U sur un exposant ; et qui renvoie la valeur $\hat{x} = \text{fl}(x) \in \mathbb{F}(b, t, L, U)$, i.e. la valeur approchée la plus proche de x dans cette représentation.

Séance 5 — Introduction à la résolution de systèmes linéaires

Rappel théorique

Un système linéaire est un ensemble de m équations linéaires à n inconnues :

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ \vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n = b_m \end{cases}$$

Nous pouvons le réécrire sous forme matricielle :

$$Ax = b,$$

où $A \in \mathbb{R}^{m \times n}$ est la matrice de coefficients, $x \in \mathbb{R}^n$ est le vecteur d'inconnues et $b \in \mathbb{R}^m$ est le vecteur de solutions.

Théorème 1. Si A est une matrice carrée, alors les conditions suivantes sont équivalentes :

1. A est inversible (ou encore $\det A \neq 0$);
2. $Ax = 0$ admet uniquement $x = 0$ pour solution;
3. $Ax = b$ admet une unique solution pour tout b ;
4. $\text{rank } A = m = n$.

Méthode de Cramer

Nous introduisons la notation suivante pour tout $1 \leq j \leq n$:

$$B_j := \begin{bmatrix} a_{1,1} & \dots & a_{1,j-1} & b_1 & a_{1,j+1} & \dots & a_{1,n} \\ & & & \vdots & & & \\ a_{n,1} & \dots & a_{n,j-1} & b_n & a_{n,j+1} & \dots & a_{n,n} \end{bmatrix}$$

La matrice B_j est donc la matrice obtenue en remplaçant la j ème colonne de A par le vecteur b .

Théorème 2 (Cramer). Le vecteur x donné par $x_j = \frac{\det B_j}{\det A}$ est une solution à l'équation $Ax = b$.

Méthode de Gauss

Une matrice A est dite *triangulaire supérieure* si $a_{i,j} = 0$ pour tous $i > j$ et est dite *triangulaire inférieure* si $a_{i,j} = 0$ pour tous $j > i$. A est dite *triangulaire* si elle est soit triangulaire supérieure soit triangulaire inférieure.

Observons que si la matrice A est triangulaire, le système $Ax = b$ est facile à résoudre. En effet, si A est triangulaire supérieure, nous utilisons la substitution rétrograde :

$$x_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j=i+1}^n a_{i,j}x_j \right).$$

En déterminant les entrées de x dans l'ordre décroissante (de x_n jusque x_1), nous pouvons trouver la solution en temps quadratique. De manière symétrique, si A est triangulaire inférieure, nous utilisons la substitution progressive :

$$x_i = \frac{1}{a_{i,i}} \left(b_i - \sum_{j=1}^{i-1} a_{i,j} x_j \right).$$

En déterminant les entrées de x dans l'ordre croissant (de x_1 à x_n), à nouveau, nous pouvons trouver la solution en temps quadratique.

L'objectif de la méthode de Gauss est de transformer le système $Ax = b$ en un système équivalent $A'x = b'$ où la matrice A' est triangulaire. Ici, deux systèmes $A^{(1)}x = b^{(1)}$ et $A^{(2)}x = b^{(2)}$ (ou de manière équivalente deux paires $(A^{(1)}, b^{(1)})$ et $(A^{(2)}, b^{(2)})$) sont dits *équivalents* lorsqu'ils admettent les mêmes solutions.

À l'étape $j \in \{1, \dots, n\}$, on veut s'assurer que la matrice A soit triangulaire (supérieure) jusqu'à la colonne j , i.e. que pour $j' \leq j$ et $i > j'$, l'entrée $A_{i,j'}^{(j)}$ soit nulle. En procédant de la sorte, à la fin (donc après la n ème étape), nous aurons bien une matrice triangulaire supérieure.

Pour ce faire, nous notons $m_{i,j}$ le coefficient utilisé à la ligne i , lors de l'étape j , et nous définissons la matrice $A^{(j)}$ comme ceci (où $A^{(0)} := A$) :

$$a_{i,k}^{(j)} = \begin{cases} a_{i,k}^{(j-1)} - m_{i,j} a_{j,k}^{(j-1)} & \text{si } i > j \\ a_{i,k}^{(j-1)} & \text{si } i \leq j \end{cases}$$

De manière équivalente, nous définissons $A^{(j)}$ comme étant $A^{(j-1)}$ à laquelle la j ème ligne est retirée $m_{i,j}$ fois à la ligne i . Bien entendu la même opération doit être appliquée sur b et donc (pour $b^{(0)} := b$) :

$$b_i^{(j)} = \begin{cases} b_i^{(j-1)} - m_{i,j} b_j^{(j-1)} & \text{si } i > j \\ b_i^{(j-1)} & \text{si } i \leq j \end{cases}$$

Nous voulons nous assurer que $a_{i,k}^{(j)} = 0$ pour tous i, j, k tels que $i > k$ et $k \leq j$. Pour cela, nous prenons $m_{i,j} = \frac{a_{i,j}^{(j-1)}}{a_{j,j}^{(j-1)}}$. Nous pouvons aisément vérifier que c'est suffisant par induction. En effet pour $j = 0$, le résultat est trivialement vrai. Pour $j \geq 1$, soit nous regardons le cas $k = j$ où donc pour $i > k$:

$$a_{i,k}^{(j)} = a_{i,j}^{(j)} = a_{i,j}^{(j-1)} - m_{i,j} a_{j,j}^{(j-1)} = 0,$$

par définition de $m_{i,j}$, soit nous regardons le cas $k < j$ et donc par hypothèse d'induction, pour $i > k$:

$$a_{i,k}^{(j)} = \begin{cases} a_{i,k}^{(j-1)} = 0 & \text{si } i \leq j \\ a_{i,k}^{(j-1)} - m_{i,j} a_{j,k}^{(j-1)} = 0 - m_{i,j} \cdot 0 = 0 & \text{si } i > j \end{cases}$$

Attention tout de même, ici à chaque étape, nous devons diviser par $a_{j,j}^{(j-1)}$, mais donc si cette valeur est nulle, le problème est mal défini. Il nous faut alors utiliser la notion de *pivot*, i.e. nous devons interchanger les lignes j et j' où $j' > j$ est l'indice maximisant la

quantité $|a_{j',j}^{(j-1)}|$. Cette méthode de pivot s'appelle *pivot partiel*. Il existe également une notion de *pivot total* dans lequel on échange à la fois deux lignes et deux colonnes afin de placer l'entrée $a_{i',j'}^{(j-1)}$ maximale en valeur absolue à la place de $a_{j,j}^{(j-1)}$. Dans ce cas-ci, attention tout de même à bien conserver les permutations de colonnes qui ont été faites afin de pouvoir retrouver la bonne valeur de x (puisque un échange de colonnes correspond à intervertir deux entrées de x).

Exercice 5.1. Résolvez le système suivant avec la méthode de Cramer :

$$\begin{bmatrix} 4 & 8 & 12 \\ 3 & 8 & 13 \\ 2 & 9 & 18 \end{bmatrix} x = \begin{bmatrix} 4 \\ 5 \\ 11 \end{bmatrix}.$$

■ **Exercice 5.2.** Résolvez ce même système par la méthode de Gauss.

Exercice 5.3. Résolvez le système suivant avec la méthode de Gauss en arithmétique flottante pour $b = 10$ et $t = 3$:

$$\begin{bmatrix} 10^{-4} & 1 \\ 1 & 1 \end{bmatrix} x = \begin{bmatrix} 1 \\ 2 \end{bmatrix}.$$

Faites pareil en échangeant les deux lignes.

Exercice 5.4. Résolvez les systèmes suivantes avec la méthode de Gauss et pivot partiel :

1.

$$\begin{bmatrix} -1 & 2 & 1 \\ 1 & 4 & -3 \\ -2 & 0 & 1 \end{bmatrix} x = \begin{bmatrix} 5 \\ -8 \\ 5 \end{bmatrix}$$

2.

$$\begin{bmatrix} 1 & 2 & -1 \\ 2 & 4 & 1 \\ 3 & 6 & -2 \end{bmatrix} x = \begin{bmatrix} 2 \\ 7 \\ 7 \end{bmatrix}$$

3.

$$\begin{bmatrix} 1 & -1 & 1 \\ 2 & 1 & -1 \\ 1 & 2 & -2 \end{bmatrix} x = \begin{bmatrix} 0 \\ -3 \\ -2 \end{bmatrix}$$

4.

$$\begin{bmatrix} 2 & -3 & 2 & 5 \\ 1 & -1 & 1 & 2 \\ 3 & 2 & 2 & 1 \\ 1 & 1 & -3 & -1 \end{bmatrix} x = \begin{bmatrix} 3 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$